

Четыре уточнения

Ответы на вопросы к разбору модели

Четыре места, про которые задали вопросы: амортизация головы E , раскладывается ли совместное распределение так, как записано в спецификации, что именно называется калибровкой прибора, и что такое коррегионализация вместе с её регуляризатором.

Два из четырёх ответов — поправки. Формула разложения в спецификации записана неверно, и это исправляется; голова E описана как нуждающаяся в регуляризации, тогда как измерения говорят, что её вообще незачем делать поштучной.

Все числа получены прогонами на данных соревнования в день выпуска документа.

Содержание

1 Амортизация головы E	2
1.1 Что такое E и почему с ней вообще проблема	2
1.2 Что значит «амортизовать» и чем это отличается от подгонки	2
1.3 Почему это работает как регуляризатор	3
1.4 А теперь измерения, и они меняют вывод	3
1.5 Гребень видно прямо в данных	4
2 Раскладывается ли совместное распределение на эти три множителя	5
2.1 Короткий ответ	5
2.2 Что за величины и что именно утверждается	5
2.3 Как выглядит правильное разложение	6
2.4 Почему прежняя запись всё-таки не разваливает вывод	6
3 Калибровка прибора	8
3.1 Какую задачу она решает	8
3.2 Форма калибровки следует из уравнения кривой	8
3.3 Что получилось на данных	9
3.4 Риск, который был записан в главе о слабых местах	9
4 Коррегионализация и её регуляризатор	10
4.1 Задача: как связать четыре фермента	10
4.2 Как это устроено у нас	11
4.3 Что говорят данные	12
4.4 Регуляризационный член	12
4.5 Как это выглядит в коде и что проверить	13

1 Амортизация головы E

1.1 Что такое E и почему с ней вообще проблема

Кривая доза-эффект описывается тремя числами. π — потенция, та самая pIC_{50} , ради которой всё затевается. h — крутизна перехода. И E — глубина: на сколько процентов соединение подавляет фермент, если концентрацию поднять до бесконечности.

$$I(C) = \frac{E}{1 + 10^{h(pC - \pi)}}, \quad pC = -\log_{10} C \quad (1)$$

Разбор формулы

$I(C)$ доля активности фермента, подавленная при концентрации C .

E предельная глубина подавления. $E = 1$ — полный ингибитор, $E = 0.6$ — частичный: сколько нилей, сорок процентов активности останется.

h крутизна; при $h = 1$ переход от 10 до 90 процентов эффекта занимает примерно две декады концентрации.

π потенция в логарифмической шкале.

Проверим на числах при $E = 1$, $h = 1$, $\pi = 5.2$, то есть $IC_{50} = 6.3$ мкМ. При $C = 100$ мкМ показатель равен $4.0 - 5.2 = -1.2$, значит $10^{-1.2} = 0.063$ и $I = 1/1.063 = 0.94$. При $C = 6.3$ мкМ показатель ноль, $I = 1/2 = 0.50$. При $C = 1$ мкМ показатель $+0.8$, $10^{0.8} = 6.3$ и $I = 1/7.3 = 0.14$.

Проблема в том, что E и π плохо разделяются. Если измерения не доходят до плато, кривая глубиной 0.6 с высокой потенцией и кривая глубиной 1.0 с потенцией пониже проходят почти через одни и те же точки. Подгонщик кривой ползает вдоль этого гребня, и куда он остановится, решает не химия, а шум.

Термин: идентифицируемость

Свойство параметра быть однозначно определяемым по данным. Параметр неидентифицируем, если разные его значения дают одинаковое (или почти одинаковое) распределение наблюдений. Тогда никакой объём данных не сузит оценку — она будет гулять вдоль направления, в котором правдоподобие плоское.

1.2 Что значит «амортизировать» и чем это отличается от подгонки

Есть два способа получить E для каждого соединения.

Поштучная подгонка. У каждого соединения m свой свободный параметр E_m . Для N соединений и четырёх ферментов это $4N$ независимых чисел, каждое подбирается только по данным этого соединения. Никакой связи между соединениями нет: похожие молекулы могут получить совершенно разные E , потому что подгонщику для каждой из них досталась своя реализация шума.

Амортизация. Свободных E_m нет вообще. Есть одна общая функция — голова сети, — которая получает представление молекулы z_m и выдаёт E :

$$E_{m,e} = \sigma(u_e^\top z_m + c_e) \quad (2)$$

Разбор формулы

z_m вектор-представление молекулы m , который выдаёт общий ствол сети.

u_e, c_e веса и сдвиг головы для фермента e . Их всего $d + 1$ штук на фермент, и они общие для всех соединений.

$\sigma(\cdot)$ сигмоида, зажимающая ответ в интервал от нуля до единицы, потому что глубина подавления не может быть отрицательной или больше полной.

Разница в счёте параметров. Поштучно: $4N = 4 \cdot 4905 = 19\,620$ свободных чисел, из которых данными подпёрты только 6525 — у остальных вообще нет кривой, по которой можно было бы подобрать E . Амортизовано: $4(d + 1)$, то есть при $d = 256$ ровно 1028 — и эта тысяча обслуживает все соединения сразу, включая те, у которых своей кривой нет.

Отсюда и слово: дорогая процедура вывода *амортизуется* по всем объектам. Заплатили один раз обучением сети — дальше ответ для нового соединения получается одним прогоном, без всякой подгонки.

Термин: амортизованный вывод

Подход, при котором вместо решения задачи вывода заново для каждого объекта обучают одну сеть, сразу выдающую ответ по описанию объекта. Дороже на обучении, зато на новом объекте — один прогон, и все объекты делят между собой одни и те же параметры.

1.3 Почему это работает как регуляризатор

Механизм простой. Чтобы выдать соединению m нестандартное E , сети приходится сдвинуть z_m — но z_m производится общим стволом из структуры, и тот же ствол обслуживает все остальные соединения. Сдвинуть представление одной молекулы, не задев похожих на неё, нельзя.

Значит сеть может подогнать E индивидуально только там, где для этого есть *структурная* закономерность: класс молекул, который систематически ведёт себя как частичный ингибитор. Если такого класса нет, а есть только шум подгонки кривой, сети выгоднее выдать всем примерно одинаковое E и не тратить ёмкость представления.

Формально это ограничение гипотез: множество достижимых наборов $\{E_m\}$ сужается с «любой вектор длины N » до «образ структурного пространства под гладким отображением». Регуляризация здесь не слагаемое в функции потерь, а свойство параметризации. Такое иногда называют неявной регуляризацией.

1.4 А теперь измерения, и они меняют вывод

Всё вышесказанное — аргумент о том, почему амортизация *безопасна*. Но у организаторов опубликованы измеренные E : колонки `EmaxVsPosCtrl_direct_inhibition`, по одной на фермент, вместе с доверительными полосами. Их стоило посмотреть до всяких рассуждений.

Фермент	Измерено	Медиана E	5–95%	Ширина полосы	Надёжность
CYP1A2	1413	−0.99	0.16	0.296	−1.43
CYP2C9	1285	−1.02	0.24	0.473	−1.42
CYP2D6	1494	−1.03	0.09	0.179	−1.39
CYP3A4	2335	−0.98	0.06	0.195	−0.73

Таблица 1. Измеренная предельная глубина подавления. Шкала — относительно положительного контроля, поэтому полный ингибитор даёт примерно −1. Столбец 5–95% — ширина интервала, в который попадают девяносто процентов соединений. Надёжность считается как $1 - \text{Var}(\text{шум})/\text{Var}(\text{набл})$.

Два числа в этой таблице надо читать вместе. У CYP3A4 весь разброс E между соединениями укладывается в 0.06, а заявленная ширина доверительной полосы одного измерения — 0.195, то есть втрое больше. У CYP2D6 то же самое: 0.09 против 0.179. Отсюда и отрицательная надёжность.

Что означает отрицательная надёжность

Надёжность — это доля дисперсии наблюдений, которая не объясняется шумом:

$$\text{надёжность} = 1 - \frac{\text{Var}(\text{шум})}{\text{Var}(\text{наблюдаемое})} \quad (3)$$

У честной величины она лежит между нулём и единицей. Отрицательная означает, что заявленная дисперсия шума *больше* всего наблюдаемого разброса: 0.0029 против 0.0017 у CYP3A4. Соединения различаются между собой меньше, чем прибор ошибается на одном соединении.

Буквально это может означать, что полосы посчитаны консервативно. Но верхняя оценка сигнала уровня соединения от этого не меняется: он не превышает нуля.

Вывод сильнее, чем был в спецификации

В E нет сигнала уровня соединения. Не «мало» — нисколько. Значит амортизация была правильным инстинктом по неправильной причине: в спецификации написано, что сеть не сможет переобучиться, потому что ей пришлось бы найти структурную закономерность. На самом деле находить нечего.

Правильная архитектура — не голова, а одна константа на фермент (−0.99, −1.02, −1.03, −0.98), плюс, если хочется страховки, поштучная поправка с жёстким штрафом, которую данные обязаны прижать к нулю. Диагностика та же, что была: смотрим разброс выхода поправки; если он заметно отличается от нуля, значит голова используется как свалка для остатка, и это повод искать ошибку в другом месте.

1.5 Гребень видно прямо в данных

Ещё одно наблюдение, подтверждающее, что вариация E — артефакт подгонки, а не химия. Посмотрим корреляцию между измеренными E и π отдельно по зонам активности.

Связь резко усиливается ровно в средней зоне — там, где кривая обрывается, не дойдя

Фермент	$\text{pIC}_{50} < 4$	4–5	≥ 5
CYP1A2	+0.14	−0.63	+0.19
CYP2C9	+0.20	−0.57	+0.53
CYP2D6	−0.15	+0.54	−0.21
CYP3A4	+0.03	−0.46	+0.08

Таблица 2. Ранговая корреляция между измеренной глубиной E и потенцией π по зонам активности.

до плато, и подгонщику приходится выбирать точку на гребне. А знак у CYP2D6 противоположен остальным трём. Химически это бессмысленно: не бывает так, чтобы у трёх ферментов более потентные соединения давили глубже, а у четвертого — мельче. Это подпись процедуры подгонки, а не свойство молекул.

2 Раскладывается ли совместное распределение на эти три множителя

2.1 Короткий ответ

Нет. В спецификации записано

$$p(y_{\text{drc}}, y_{\text{scr}}, R \mid \theta) = p(y_{\text{drc}} \mid \theta) p(y_{\text{scr}} \mid \theta) p(R \mid y_{\text{scr}}) \quad (4)$$

и средний множитель здесь неверен. Сомнение обоснованное: два показания — полная кривая и скрининг — не независимы при фиксированном θ , потому что оба меряют одну и ту же скрытую активность соединения. Правильное разложение выписано ниже, и хорошая новость в том, что вывод, ради которого формула приводилась, от поправки не страдает.

2.2 Что за величины и что именно утверждается

Обозначения

a_m скрытая («латентная») истинная активность соединения m : то, что мерил бы идеальный прибор.

θ параметры модели, превращающие структуру молекулы в предсказание активности.

y_{scr} показание первичного скрининга при одной концентрации. Есть у всех 4376 соединений.

y_{drc} pIC_{50} из полной кривой доза-эффект. Есть только у отобранных.

R индикатор отбора: единица, если для соединения сняли полную кривую.

Утверждений на самом деле два, и их надо разделить.

Утверждение А (про отбор). Множитель $p(R \mid y_{\text{scr}})$ не зависит от θ и потому выпадает из градиента. Это и есть переход от «пропуски зависят от того, чего мы не видим» к «пропуски зависят от того, что мы видим».

Утверждение Б (про независимость каналов). $p(y_{\text{drc}}, y_{\text{scr}} \mid \theta) = p(y_{\text{drc}} \mid \theta) p(y_{\text{scr}} \mid \theta)$.

Утверждение А верно. Утверждение Б неверно всякий раз, когда у соединения есть собственный латентный остаток — то есть когда модель не предсказывает активность в

точности, а именно так и обстоит дело.

2.3 Как выглядит правильное разложение

Пишем совместную плотность через скрытую активность, честно:

$$p(y_{\text{drc}}, y_{\text{scr}}, R \mid x, \theta) = p(R \mid y_{\text{scr}}) \int p(a \mid x, \theta) p(y_{\text{scr}} \mid a) p(y_{\text{drc}} \mid a)^R da \quad (5)$$

Разбор формулы

$p(a \mid x, \theta)$ что модель думает об активности до всяких измерений: центр — предсказание сети, ширина — признание того, что структура определяет активность не полностью.

$p(y_{\text{scr}} \mid a)$ шум скрининга. Зависит только от истинной активности, не от параметров.

$p(y_{\text{drc}} \mid a)^R$ шум кривой, входит только если кривую снимали.

$\int \dots da$ суммирование по всем возможным значениям скрытой активности с их весами.

Ключевой шаг — вынос $p(R \mid y_{\text{scr}})$ за интеграл. Это законно ровно потому, что решение об отборе принималось глядя на показание скрининга, а не на скрытую активность: под интегралом величины a этот множитель просто не содержит.

Дальше применяем цепное правило и получаем то, что должно было стоять в спецификации:

$$p(y_{\text{drc}}, y_{\text{scr}}, R \mid \theta) = \underbrace{p(R \mid y_{\text{scr}})}_{\text{без } \theta} \cdot \underbrace{p(y_{\text{drc}} \mid y_{\text{scr}}, \theta)}_{\text{условно, не маргинально}} \cdot p(y_{\text{scr}} \mid \theta) \quad (6)$$

Множителей по-прежнему три. Отличие одно, и оно принципиальное: средний множитель — условный по y_{scr} . Скрининг, который мы уже видели у этого соединения, входит в условие.

Термин: цепное правило вероятностей

Совместную плотность нескольких величин всегда можно разложить в произведение условных: $p(u, v) = p(u \mid v) p(v)$. Это тождество, оно не требует никаких предположений. Предположением является замена $p(u \mid v)$ на $p(u)$ — то есть независимость.

2.4 Почему прежняя запись всё-таки не разваливает вывод

Что происходит, если оставить маргинальный множитель вместо условного? Получается не правдоподобие, а *составное правдоподобие*: произведение верно заданных маргиналов, скреплённых неверным предположением о независимости.

Термин: составное правдоподобие

Произведение маргинальных или низкоразмерных условных плотностей, взятое вместо настоящей совместной. Стандартный приём, когда совместная слишком дорога. Оценка при этом остаётся состоятельной, если каждый сомножитель задан верно, но информация переоценивается: коррелированные наблюдения считаются за независимые, и погрешность выходит заниженной.

Симуляция, где истина известна по построению, показывает, что именно ломается. Скрытая активность $a = x^\top \beta + \varepsilon$, скрининг у всех, кривая — у верхних тридцати процентов по скринингу. Меняем только один параметр: собственный латентный разброс соединения $\sigma_{\text{лат}}$.

	0.00	0.35	0.70
Латентный остаток $\sigma_{\text{лат}}$			
Смещение наивной схемы (три маргинала)	0.0005	0.0027	0.0124
Смещение честной схемы (условная)	0.0005	0.0007	0.0010
Истинное ско оценки	0.0046	0.0080	0.0132
Заявленная наивной схемой погрешность	0.0045	0.0068	0.0109
Занижение погрешности	1.03×	1.17×	1.21×

Таблица 3. 300 повторов, 4000 соединений, 5 коэффициентов. Смещение — максимальное по координатам отклонение среднего от истины.

Читается это так.

При $\sigma_{\text{лат}} = 0$ прежняя запись просто верна. Если модель предсказывает активность идеально и вся разница между двумя показаниями — независимый приборный шум, каналы действительно независимы при фиксированном θ , и три маргинальных множителя — это и есть совместная плотность.

При ненулевом латентном остатке появляется смещение, и оно растёт: при $\sigma_{\text{лат}} = 0.70$ оно уже сравнимо с собственным ско оценки. Механизм: отбор идёт по y_{scr} , а y_{drc} коррелирован с ним через общее a ; значит распределение y_{drc} среди отобранных сдвинуто относительно безусловного. Маргинальный множитель этого сдвига не знает, условный — знает.

И независимо от смещения, наивная схема занижает собственную погрешность на 17–21 процент. Она считает два коррелированных наблюдения одного соединения за два независимых свидетельства.

Что исправляем, а что остаётся

Формула в спецификации исправляется: средний множитель условный, а не маргинальный. Практически это значит, что голова, предсказывающая pIC_{50} для отобранных соединений, должна получать на вход показание скрининга этого соединения — или, что то же самое, обе величины должны выводиться из общего латентного слоя с явной ковариацией, а не из двух независимых голов.

Вывод про отбор при этом не меняется вообще. Множитель $p(R \mid y_{\text{scr}})$ выпадает в обеих записях, потому что решение об отборе принималось по наблюдаемой величине. Именно это проверялось симуляцией в главе про ревизию, и там же было показано, что если сломать наблюдаемость отбора, ломается всё — значит держится аргумент именно на ней.

Отдельно стоит держать в голове, что на инференсе скрининга нет: пересечение теста с первичной библиотекой — ровно ноль соединений. Условный множитель $p(y_{\text{drc}} \mid y_{\text{scr}}, \theta)$ нужен на обучении, чтобы оценка не была смещена отбором. На предсказании мы маргинализуем по y_{scr} , то есть считаем $\int p(y_{\text{drc}} \mid y_{\text{scr}}, \theta) p(y_{\text{scr}} \mid$

$x, \theta) dy_{scr}$, что при общем латентном слое сводится к одному прогону сети.

3 Калибровка прибора

3.1 Какую задачу она решает

У нас два разных измерения одной и той же химии, снятых по-разному.

Полная кривая даёт pIC_{50} — число в логарифмической шкале концентраций. Первичный скрининг даёт $\log_2 fc$: логарифм по основанию два от того, во сколько раз изменился сигнал, при одной единственной концентрации 49.5 мкМ.

Это не одна величина в разных единицах. Между ними стоит прибор, и связь нелинейная и насыщающаяся: очень сильный ингибитор и ингибитор вдесятеро сильнее дадут при 49.5 мкМ практически одинаковое показание, потому что оба подавили всё, что можно было подавить.

Термин: калибровка

Функция, переводящая скрытую величину в показание прибора. Не свойство соединения, а свойство измерительной установки: одна и та же молекула на другом приборе даст другое показание, а pIC_{50} у неё останется прежней.

Калибровка нужна ровно затем, чтобы обучать одну модель на обоих источниках. Модель предсказывает π ; чтобы сравнить это предсказание с показанием скрининга, показание надо привести к той же шкале.

3.2 Форма калибровки следует из уравнения кривой

Тут ничего изобретать не надо: калибровка — это та же кривая Хилла, взятая в одной точке. При концентрации скрининга $C_0 = 49.5$ мкМ подавленная доля активности равна

$$I_0(\pi) = \frac{E}{1 + 10^{h(pC_0 - \pi)}}, \quad pC_0 = -\log_{10}(4.95 \cdot 10^{-5}) = 4.305 \quad (7)$$

а прибор показывает логарифм оставшейся активности:

$$g(\pi) = \log_2(1 - I_0(\pi)) \quad (8)$$

Разбор формулы

π — потенция соединения — то, что предсказывает модель.

E, h — параметры калибровки: одна пара на фермент, общая для всех соединений.

pC_0 — концентрация скрининга в логарифмической шкале. Ровно та точка, где кривая даёт максимум информации о π .

$g(\pi)$ — предсказанное показание скрининга.

Посчитаем на СУР3А4, где подобрались $E = 0.931$ и $h = 1.968$. Для соединения с $\pi = 5.3$ показатель равен $1.968(4.305 - 5.3) = -1.958$, значит $10^{-1.958} = 0.011$ и $I_0 = 0.931/1.011 = 0.921$. Осталось $1 - 0.921 = 0.079$, и показание $\log_2 0.079 = -3.66$.

Для соединения послабее, $\pi = 4.3$: показатель ≈ 0.010 , $10^{0.010} = 1.023$, $I_0 = 0.931/2.023 = 0.460$, остаток 0.540, показание $\log_2 0.540 = -0.89$.

А для $\pi = 6.3$: $I_0 = 0.9308$, остаток 0.0692, показание -3.85 . Целая единица pIC_{50} между 5.3 и 6.3 стоит всего 0.19 в показании — вот оно, насыщение.

Обратите внимание: E здесь — не та E , что обсуждалась в первом разделе. Там была предельная глубина подавления самого соединения, измеренная относительно положительного контроля и равная примерно -1 у всех. Здесь — параметр калибровки, вбирающий в себя динамический диапазон установки: какую долю сигнала вообще способен обнулить скрининг на этом ферменте. Совпадение буквы неудачное, и в спецификации это стоит развести обозначениями.

3.3 Что получилось на данных

Подгоняем E и h по соединениям, у которых есть и pIC_{50} , и показание скрининга.

Фермент	n	E	h	Ско остатка	Предел (изотоника)	ρ
CYP1A2	1412	0.728	1.261	0.231	0.208	-0.862
CYP2C9	1285	0.621	1.112	0.185	0.167	-0.896
CYP2D6	1493	0.867	1.243	0.497	0.390	-0.828
CYP3A4	1805	0.931	1.968	0.612	0.499	-0.936

Таблица 4. Калибровка на фермент. Столбец «предел» — ско остатка от свободной монотонной кривой (изотонической регрессии); ниже него не спустится никакая монотонная калибровка. ρ — ранговая корреляция между pIC_{50} и показанием скрининга.

Три вещи отсюда.

Связь очень сильная. Ранговая корреляция от -0.83 до -0.94 . Знак минус, потому что сильнее ингибирование — ниже сигнал. Именно поэтому первичный скрининг — почти достаточная статистика: изотоника по измеренному показанию даёт макро-STRAE 0.359 против 0.767 у полной модели по структуре. Знай мы показание скрининга для тестовых соединений, задача была бы вдвое легче.

Хилловская форма теряет немного, но теряет. Разрыв между подгонкой и свободной монотонной кривой: 11 процентов на 1A2 и 2C9, 27 на 2D6, 23 на 3A4. То есть двухпараметрическая калибровка чуть жёстче, чем нужно. Это аргумент за то, чтобы дать калибровке гибкость — например, монотонную сплайн-поправку поверх хилловской формы, — но не за то, чтобы отказываться от параметрической формы совсем: она даёт правильную экстраполяцию в зонах, где данных мало.

Крутизна разная. У CYP3A4 $h = 1.97$, у остальных около 1.2. Это не химия соединений, а свойство постановки на конкретном ферменте, и ровно поэтому калибровка не может быть общей на все четыре.

3.4 Риск, который был записан в главе о слабых местах

В списке рисков стояло: «фиксированная калибровка на фермент может быть слишком грубой», потому что глубина и крутизна могут меняться между соединениями и между

планшетами. Проверяем.

Планшетов девять на фермент. Наивно посчитанный разброс медиан по планшетам выглядит тревожно: до 0.24 при размахе 0.78. Но планшеты не рандомизированы — активные соединения сидят кучно, — поэтому надо вычесть то, что объясняется составом планшета, и посмотреть на остаток.

Фермент	Ско медиан, сырое	Размах	После контроля	Размах	Ско остатка
СУР1А2	0.070	0.218	0.036	0.129	0.208
СУР2С9	0.132	0.371	0.038	0.108	0.168
СУР2D6	0.230	0.714	0.062	0.225	0.390
СУР3А4	0.239	0.782	0.034	0.091	0.499

Таблица 5. Сдвиг планшета до и после вычитания предсказанного по pIC_{50} . «Контроль» — изотоническая регрессия показания на pIC_{50} , то есть удаление того, что объясняется составом планшета.

После контроля состава планшетный сдвиг практически исчезает: 0.034–0.062 против ско остатка 0.17–0.50. Планшет объясняет от одного до трёх процентов остаточной дисперсии.

Риск закрыт измерением

Планшетного слагаемого в модели не нужно. То, что выглядело как дрейф прибора, — это состав планшетов, и оно уже учтено тем, что модель предсказывает активность. Калибровка: одна пара (E, h) на фермент плюс монотонная поправка, если абляция покажет, что 11–27 процентов разрыва с изотоникой стоят усложнения.

Оставшаяся часть риска — зависимость калибровки от соединения — в этих данных непроверяема: у каждого соединения одно показание скрининга, разделить «соединение отклоняется от калибровки» и «прибор шумит» на одном измерении нельзя. Это остаётся в списке непроверенного.

4 Коррегионализация и её регуляризатор

4.1 Задача: как связать четыре фермента

Ферментов четыре, и у каждого свои метки. Есть три очевидных способа их связать, и все три плохие.

Четыре независимые модели. Каждый фермент учится сам по себе. Тогда 2С9 не пользуется 2335 метками 3А4, хотя они меряют почти одно и то же (ранговая корреляция 0.69).

Одна общая голова. Все четыре предсказываются одним выходом со сдвигом. Тогда 2D6 тянут в сторону остальных трёх, а он с ними не коррелирует вовсе.

Общий ствол, четыре независимые головы. Уже лучше, но связь между задачами остаётся неявной: никакого механизма, который говорил бы, что ошибка на 2С9 должна быть похожа на ошибку на 3А4 и не должна быть похожа на ошибку на 2D6.

Коррегионализация — это способ записать структуру связей явно и параметром.

Термин: коррегионализация

Термин из геостатистики: совместное моделирование нескольких величин, измеренных в одних и тех же точках пространства, через общую пространственную структуру и матрицу связей между величинами. В машинном обучении — многозадачная модель, где ковариация между задачами вынесена в отдельную матрицу и оценивается вместе со всем остальным. «Внутренняя модель коррегионализации» (ICM) — простейший вариант: все задачи делят одно и то же ядро, а различаются только матрицей связей.

4.2 Как это устроено у нас

Голова линейная поверх общего представления:

$$\pi_{m,e} = w_e^\top g(z_m) + b_e, \quad W = [w_1 \ w_2 \ w_3 \ w_4] \in \mathbb{R}^{d \times 4} \quad (9)$$

Разбор формулы

z_m представление молекулы из общего ствола.
 $g(\cdot)$ последний общий слой, единый для всех четырёх ферментов.
 w_e вектор весов фермента e длины d .
 b_e сдвиг фермента e : разные ферменты ингибируются в среднем по-разному.
 W матрица всех четырёх векторов, поставленных столбцами.

Вся связь между ферментами сидит в углах между столбцами W . Если w_2 и w_4 смотрят почти в одну сторону, модель для 2C9 и 3A4 читает представление одинаково. Если w_3 ортогонален остальным, 2D6 читает своё.

Матрица этих углов и есть матрица коррегионализации:

$$B = W^\top W \in \mathbb{R}^{4 \times 4}, \quad B_{ee'} = w_e^\top w_{e'} \quad (10)$$

Дальше мы не оставляем B свободной, а навязываем ей структуру «несколько общих осей плюс своё у каждого»:

$$B \approx LL^\top + \text{diag}(\kappa), \quad L \in \mathbb{R}^{4 \times r}, \ r = 2 \quad (11)$$

Разбор формулы

L нагрузки: строка e говорит, насколько фермент e участвует в каждой из r общих осей.
 $LL^\top$ общая часть ковариации; её ранг равен r , то есть все связи между ферментами проходят через r осей.
 κ_e специфичная часть фермента e : то, что есть только у него и ни с кем не делится.
 $\text{diag}(\kappa)$ диагональная матрица из этих чисел.

Такое разложение называется факторной моделью. Смысл: «есть r общих механизмов узнавания плюс у каждого фермента что-то своё».

4.3 Что говорят данные

Считаем ранговые корреляции между rIC_{50} разных ферментов по общим соединениям.

	1A2	2C9	2D6	3A4
CYP1A2	1.000	0.423	0.059	0.383
CYP2C9	0.423	1.000	-0.120	0.688
CYP2D6	0.059	-0.120	1.000	0.056
CYP3A4	0.383	0.688	0.056	1.000

Таблица 6. Общих соединений на пару: от 230 (2C9–2D6) до 473 (2C9–3A4). Матрица положительно определена, минимальное собственное число 0.287, так что раскладывать её можно.

Факторная модель ранга 2 (с итеративной оценкой общностей, а не наивным разложением полной матрицы) даёт такие нагрузки:

Фермент	Ось 1	Ось 2	κ
CYP1A2	-0.480	-0.103	0.759
CYP2C9	-0.907	0.123	0.161
CYP2D6	0.033	-0.726	0.472
CYP3A4	-0.773	-0.112	0.390

Таблица 7. Первая ось нагружает 2C9, 3A4 и слабее 1A2, а 2D6 на ней стоит на нуле. Вторая ось — почти исключительно 2D6. Внедиагональные элементы восстанавливаются точно.

Это ровно та картина, которая была заявлена в спецификации: одна общая ось (липофильная промискуитетность — крупные жирные молекулы садятся в широкие карманы 2C9 и 3A4) плюс отдельная ось для 2D6, где узнавание идёт через солевой мостик с заряженным азотом.

Честная оговорка про ранг. При четырёх задачах внедиагональ содержит шесть чисел, а нагрузки ранга 2 дают $4 \times 2 = 8$ параметров минус одна степень свободы на вращение, то есть семь. Модель насыщена: ранг 2 воспроизводит внедиагональ точно не потому, что угадал структуру, а потому что параметров хватает. Единственный по-настоящему ограничивающий вариант — ранг 1, и он промахируется максимум на 0.10, причём весь промах приходится на 2D6.

Значит структура ранга 2 — это не сжатие, а способ задать приор и инициализацию. Польза от неё проявится, когда ферментов станет больше или когда B будет тянуть головы во время обучения, а не в самой аппроксимации матрицы четыре на четыре.

4.4 Регуляризационный член

В спецификации его не было — справедливое замечание. Вот он.

Задача регуляризатора: не дать столбцам W разъехаться в произвольные углы, когда у фермента мало меток, и притянуть матрицу связей к тому, что видно в данных. Пишем два слагаемых.

$$\mathcal{R}(W, \kappa) = \underbrace{\frac{\lambda_1}{2} \|\rho(W^\top W) - \hat{\rho}\|_F^2}_{\text{притяжение к эмпирике}} + \underbrace{\frac{\lambda_2}{2} \|W\|_F^2}_{\text{ограничение масштаба}} \quad (12)$$

Разбор формулы

$\rho(\cdot)$ перевод ковариационной матрицы в корреляционную: $\rho(B) = D^{-1/2} B D^{-1/2}$, где D — диагональ B . Нужен потому, что притягивать хотим углы, а не длины.

$\hat{\rho}$ эмпирическая матрица из таблицы выше.

$\|\cdot\|_F$ норма Фробениуса: корень из суммы квадратов всех элементов.

$\|W\|_F^2$ сумма квадратов всех весов, обычная весовая усадка.

λ_1, λ_2 силы притяжения, подбираются на валидации.

Почему именно так, а не проще. Матрица W определена не однозначно: если умножить её справа на любую ортогональную матрицу Q , произведение $W^\top W$ не изменится, а значит не изменятся и предсказания. Регуляризатор обязан обладать той же симметрией, иначе он будет штрафовать за выбор системы координат, а не за содержание. Обе записанные величины через W проходят только в виде $W^\top W$, поэтому симметрию сохраняют. Поэлементный штраф на W — не сохраняет, и ставить его нельзя.

Первое слагаемое считается так. Берём текущие столбцы, строим $B = W^\top W$, нормируем в корреляции, вычитаем эмпирическую матрицу, складываем квадраты разностей. Для четырёх ферментов это двенадцать внедиагональных слагаемых (шесть, посчитанных дважды); диагональ по построению единичная у обеих матриц и вклада не даёт.

Низкоранговая структура при этом входит не штрафом, а параметризацией: мы не штрафуем B за высокий ранг, мы просто держим L размера 4×2 и κ отдельно, и используем $LL^\top + \text{diag}(\kappa)$ как *цель* для $W^\top W$:

$$\mathcal{R}_{\text{ранг}}(W, L, \kappa) = \frac{\lambda_3}{2} \|W^\top W - LL^\top - \text{diag}(\kappa)\|_F^2 \quad (13)$$

причём L и κ обучаются вместе со всем остальным, стартуя со значений из таблицы выше.

Термин: норма Фробениуса

Мера «величины» матрицы: $\|A\|_F = \sqrt{\sum_{ij} A_{ij}^2}$. То же самое, что евклидова длина вектора, если матрицу вытянуть в строку.

4.5 Как это выглядит в коде и что проверить

Практически проще держать не W со сложным штрафом, а сразу L и κ , и *строить* головы из них. Тогда:

1. Общий ствол выдаёт $g(z_m) \in \mathbb{R}^d$.
2. $r = 2$ общие оси: $U \in \mathbb{R}^{d \times 2}$, и $u_m = U^\top g(z_m)$.
3. Специфичные части: $v_{m,e} = s_e^\top g(z_m)$, по одному вектору s_e на фермент.
4. Голова фермента: $\pi_{m,e} = L_e \cdot u_m + \sqrt{\kappa_e} v_{m,e} + b_e$.

Тогда ковариация задач равна $LL^\top + \text{diag}(\kappa)$ по построению, штраф $\mathcal{R}_{\text{ранг}}$ не нужен вообще, а от регуляризатора остаётся только притяжение $\rho(LL^\top + \text{diag} \kappa)$ к $\hat{\rho}$ плюс обычная усадка весов.

Проверять надо две вещи. Первая: положить $\lambda_1 = 0$ и посмотреть, куда уедет выученная матрица связей от эмпирической — если далеко, значит либо в представлении есть структура, которой нет в сырых корреляциях, либо голова переобучается. Вторая: сравнить с четырьмя независимыми головами на тех же разбиениях. Обе строки идут в абляционную сетку, и обе — на четырёх зёрнах разбиения, а не на одном.

Статус

Структура подтверждена данными: две оси, распределение нагрузок ровно такое, как предполагалось, эмпирическая матрица положительно определена и раскладывается. Регуляризатор выписан здесь впервые. Ни один из вариантов не запускался — это часть той самой строки абляции, которая до сих пор пуста.