

Как устроена наша модель

Полный разбор с объяснением каждой формулы

Тот же документ, что техническая спецификация модели, но написанный для человека, который не занимается машинным обучением. Каждая формула разобрана посимвольно, каждый термин определён, где возможно приведён пример, который можно пересчитать на бумаге.

Что предполагается известным: школьная математика, логарифмы, представление о производной как о скорости изменения. Всё остальное объясняется по ходу. Если термин встретился без объяснения, он есть в словаре в конце.

Числа получены прогонами на открытых данных соревнования и воспроизводимы.

Содержание

1	Что вообще делает обучаемая модель	4
1.1	Модель — это функция с ручками	4
1.2	Функция потерь: как модель узнаёт, что ошиблась	4
1.3	Градиентный спуск: как ручки крутятся	5
1.4	Переобучение: главная опасность	6
2	Наша задача	6
2.1	Вход и выход	6
2.2	Метрика регрессии, и почему она не средний квадрат	7
2.3	Метрика классификации	8
2.4	Данные: пять таблиц и одна асимметрия	8
3	Правдоподобие	9
3.1	Вероятность и правдоподобие — это разные вещи	9
3.2	Почему на практике берут логарифм и минус	9
3.3	Зачем это нам	10
4	Наша порождающая модель	10
4.1	Скрытый объект — кривая	10
4.2	Модель прибора	11
4.3	Пять правдоподобий	12
5	Почему модель сама понимает, когда прибор ослеп	14
5.1	Проблема	14
5.2	Что происходит в правдоподобии	14
5.3	Что это значит для обучения	15
5.4	Проверка на данных	16
6	Чего не видно из одной точки	16
6.1	Проблема идентифицируемости	16
6.2	Три средства, по возрастанию жёсткости	17
6.3	Как ловить, если пошло не так	18

7	Как соединения попадали в выборку, и почему это ломает CYP2D6	18
7.1	Отбор по зависимой переменной	18
7.2	Что это сделало с CYP2D6	18
7.3	Почему совместное правдоподобие это чинит	19
8	Архитектура: что именно считает нейросеть	20
8.1	Энкодер	20
8.2	Связь между ферментами	21
8.3	Механистический блок	22
8.4	Канал артефактов пробы	22
8.5	Головы	23
9	Функция потерь и обучение	23
9.1	Лосс целиком	23
9.2	Веса источников	24
9.3	Батч по молекулам, а не по строкам	24
9.4	Двухэтапная калибровка прибора	24
9.5	Что происходит на тесте	25
10	Неопределённость	25
10.1	Зачем модели говорить, насколько она не уверена	25
10.2	Два разных источника неуверенности	25
10.3	Как получить распределение вместо числа	26
10.4	Калибровка: проверка, что заявленной уверенности можно верить	26
11	Что именно отправлять	27
11.1	Постановка	27
11.2	Вывод	27
11.3	Что показал прогон, и почему это меняет план	28
11.4	А вот для классификации слой окупается	30
12	Как мы проверяем сами себя	32
12.1	Три уровня строгости разбиения	32
12.2	Парный бутстрап: почему разность без интервала не результат	32
12.3	Сетка абляций	33
12.4	Что уже проверено и не работает	33

13 Что скорее всего сломается	34
13.1 Про смещение теста, отдельно	35
13.2 Про серии, отдельно	35
Словарь	35

Как читать

Разделы 1–3 объясняют базовые понятия: что вообще делает обучаемая модель, как устроена наша задача и что такое правдоподобие. Без них дальше будет трудно. Разделы 4–7 — сама модель и её тонкие места. Разделы 8–10 — как она обучается и как оценивается её неуверенность. Раздел 11 разбирает вопрос «что именно отправлять на проверку», и там же лежит один отрицательный результат, который поменял план. Разделы 12–13 — как мы проверяем себя и словарь.

Формулы вынесены в отдельные блоки с номером. После каждой идёт разбор: что означает каждый символ и почему формула написана именно так. Пропускать разбор не надо — в нём и есть содержание.

1 Что вообще делает обучаемая модель

Начнём с самого низа, чтобы дальше не было провалов.

1.1 Модель — это функция с ручками

Представьте прибор с тысячей ручек-регуляторов. На вход прибора подаётся описание молекулы, на выходе загорается число — предсказанная активность. Как именно вход превращается в выход, определяется положением всех ручек.

Формально это записывают так:

$$\hat{y} = f_{\theta}(x) \quad (1)$$

Разбор формулы

x вход. У нас это описание молекулы: набор чисел, полученных из её структурной формулы.

$\hat{y}$ выход модели, её предсказание. Крышечка над буквой всегда означает «это оценка, а не истина».

θ набор всех настраиваемых параметров, тех самых ручек. Греческая «тета». Их может быть от десятков до миллиардов.

f_{θ} сама функция, преобразующая вход в выход. Индекс θ подчёркивает, что при разных положениях ручек это разные функции.

Ничего сверх этого в записи нет. Обучение — это подбор θ .

1.2 Функция потерь: как модель узнаёт, что ошиблась

Чтобы крутить ручки осмысленно, нужна мера того, насколько плохо модель работает сейчас. Эта мера называется *функцией потерь* или *лоссом*.

Термин: функция потерь

Число, которое тем больше, чем хуже предсказания. Считается по обучающей выборке. Задача обучения — сделать его как можно меньше. Названия «лосс», «целевая функция», «критерий» в этом контексте взаимозаменяемы.

Простейший пример — средний квадрат ошибки:

$$\mathcal{L}(\theta) = \frac{1}{N} \sum_{i=1}^N (f_{\theta}(x_i) - y_i)^2 \quad (2)$$

Разбор формулы

N сколько всего примеров в обучающей выборке.

i номер примера. Значок $\sum_{i=1}^N$ означает «сложи то, что справа, по всем примерам от первого до N -го».

y_i правильный ответ для i -го примера, известный из эксперимента.

$f_{\theta}(x_i)$ что предсказала модель для этого примера.

$\mathcal{L}$ собственно лосс. Каллиграфическая «L» от loss.

Разность возводится в квадрат по двум причинам: чтобы промахи в обе стороны штрафовались одинаково, и чтобы крупные промахи весили сильнее мелких.

Деление на N нужно только для того, чтобы величина не зависела от размера выборки.

Пересчитаем руками. Пусть примеров три, правильные ответы 5.0, 4.0, 6.0, а модель предсказала 5.2, 4.5, 5.1. Разности: 0.2, -0.5 , -0.9 . Квадраты: 0.04, 0.25, 0.81. Сумма 1.10, делим на 3, получаем $\mathcal{L} = 0.367$.

Ключевая мысль: **лосс задаёт, что именно модель считает ошибкой**. Поменяли лосс — поменялось поведение модели, даже если всё остальное осталось прежним. В нашей задаче лосс будет непохож на средний квадрат, и причина этому — в разделе 2.

1.3 Градиентный спуск: как ручки крутятся

Ручек тысячи, перебрать все положения невозможно. Работает другой приём.

Возьмём одну ручку и чуть-чуть повернём её вправо. Лосс либо вырос, либо упал. Если упал — продолжаем крутить в ту же сторону. Насколько быстро лосс меняется при повороте ручки, показывает производная.

Термин: производная и градиент

Производная функции по переменной — скорость её изменения при изменении этой переменной. Если производная лосса по ручке θ_j равна $+3$, значит увеличение θ_j на маленькую величину ε увеличит лосс примерно на 3ε . Чтобы лосс уменьшить, ручку надо крутить в обратную сторону.

Градиент — это просто все производные, собранные в один список: по одной на каждую ручку. Обозначается $\nabla_{\theta}\mathcal{L}$, значок «набла».

$$\theta \leftarrow \theta - \eta \nabla_{\theta}\mathcal{L}(\theta) \quad (3)$$

Разбор формулы

$\leftarrow$ присваивание: «новое значение θ равно тому, что справа».

$\nabla_{\theta}\mathcal{L}$ градиент лосса по параметрам. Указывает направление *роста* лосса.

η размер шага, по-английски learning rate. Греческая «эта». Слишком большой шаг — модель перепрыгивает минимум и разваливается; слишком маленький — обучение тянется вечно.

— минус перед шагом ставится потому, что градиент показывает, куда лосс растёт, а нам надо туда, где он падает.

Эту операцию повторяют десятки тысяч раз. Каждый раз на небольшой порции примеров, а не на всей выборке — так быстрее и, как ни странно, устойчивее.

Термин: батч и эпоха

Батч — порция примеров, на которой считается один шаг градиента. Типично от 32 до нескольких тысяч. *Эпоха* — один полный проход по всей обучающей выборке. Обучение обычно занимает от нескольких до сотен эпох.

1.4 Переобучение: главная опасность

Модель с тысячами ручек может просто запомнить обучающую выборку наизусть, вообще ничего не поняв. На запомненных примерах она даст идеальный ответ, на новых — случайный. Это называется *переобучением*.

Термин: переобучение

Ситуация, когда модель хорошо работает на данных, которые видела при обучении, и плохо — на новых. Единственный способ заметить: держать часть данных в стороне и проверять на ней. Эти отложенные данные называют *проверочной* или *валидационной* выборкой.

В нашей задаче есть особая форма этой опасности, и она стоит отдельного разговора. Если разбить соединения на обучающую и проверочную части случайно, в проверочную попадут ближайшие химические родственники обучающих. Модель, которая просто запоминает «вот такой каркас — активный», покажет отличный результат и провалится на настоящем тесте, где каркасы новые.

Поэтому мы группируем соединения по химическому сходству и раскидываем по частям *целые группы*. Разница огромна: собственная базовая модель организаторов даёт R^2 около 0.6 при случайном разбиении и около 0.1 при групповом. Все числа в этом документе получены при групповом.

Термин: R^2 , коэффициент детерминации

Доля разброса правильных ответов, которую модель сумела объяснить. Единица — предсказания идеальны. Ноль — модель работает не лучше, чем если бы всем подряд выдавала одно число, среднее по выборке. Отрицательное значение означает, что она хуже такого константного предсказателя.

2 Наша задача

2.1 Вход и выход

На входе — SMILES, текстовая запись структурной формулы. На выходе — предсказания для 750 закрытых соединений, по двум трекам сразу.

$$\hat{Y}_{\text{рег}} \in \mathbb{R}^{750 \times 4}, \quad \hat{Y}_{\text{класс}} \in \{0, 1\}^{750 \times 2} \quad (4)$$

Разбор формулы

$\mathbb{R}$ множество всех вещественных чисел. Запись $\mathbb{R}^{750 \times 4}$ означает таблицу из 750 строк и 4 столбцов, в каждой клетке — любое число.

$\{0, 1\}$ множество из двух элементов. $\{0, 1\}^{750 \times 2}$ — таблица 750 на 2, в каждой клетке либо ноль, либо единица.

750 число соединений в закрытом тесте.

4 четыре фермента для регрессии: CYP1A2, CYP2C9, CYP2D6, CYP3A4.

2 два фермента для классификации: CYP3A4 и CYP2D6.

Первая таблица — предсказанная сила ингибирования, вторая — ответ «да/нет» на вопрос, отравляет ли соединение фермент необратимо.

2.2 Метрика регрессии, и почему она не средний квадрат

Организаторы измеряли активность не как одно число, а байесовской подгонкой кривой, которая выдаёт *интервал правдоподобных значений*. У сильного ингибитора он узкий, у слабого расплывается на два-три порядка: прибор просто не различает, где именно там правда.

Метрика построена на этом. Она называется ST-RAE, и штраф в ней считается не до точки, а до ближайшего края интервала.

$$\text{ST-RAE} = \frac{\sum_i [(\hat{y}_i - h_i)_+ + (l_i - \hat{y}_i)_+]}{\sum_i [(\bar{y} - h_i)_+ + (l_i - \bar{y})_+]} \quad (5)$$

Разбор формулы

$\hat{y}_i$ что мы отправили для i -го соединения.

l_i , h_i нижняя и верхняя границы интервала достоверности для этого соединения, из данных.

$(z)_+$ «положительная часть»: равна z , если $z > 0$, и нулю иначе. Читается как $\max(z, 0)$.

$\bar{y}$ среднее всех правильных ответов по выборке. Это предсказание самого тупого возможного предсказателя, который всем подряд выдаёт одно число.

Числитель: за что штрафуют нас. Если предсказание выше верхней границы, первое слагаемое равно превышению, второе — нулю. Если ниже нижней — наоборот. Если внутри интервала — оба слагаемых нули, штраф отсутствует.

Знаменатель: тот же штраф, но для тупого предсказателя. Деление превращает величину в относительную: теперь 1.0 означает «мы ровно настолько же полезны, как константа», 0 — «всегда попадаем внутрь интервалов», больше 1 — «хуже, чем ничего».

Считаем на трёх соединениях. Правда: 6.20, 3.10, 5.00, значит $\bar{y} = 4.77$. Интервалы: [6.08, 6.33], [2.15, 4.60], [4.90, 5.15]. Модель предсказала 5.70, 3.60, 5.05.

наш штраф	штраф константы
A (6.08 – 5.70) = 0.38	(6.08 – 4.77) = 1.31
B внутри, 0	внутри, 0
C внутри, 0	(4.90 – 4.77) = 0.13

$$\text{ST-RAE} = 0.38/1.44 = 0.264.$$

Обратите внимание на соединение B: оно не даёт вклада ни в числитель, ни в знаменатель. Соединения с широким интервалом в этой метрике почти невесома. Метрика намеренно сосредоточена на тех, про которые эксперимент действительно что-то знает.

Итоговая оценка — среднее арифметическое ST-RAE по четырём ферментам. Отсюда

следствие для приоритетов: улучшение на худшем ферменте стоит ровно столько же, сколько на лучшем, а даётся дешевле.

Термин: макро-усреднение

Усреднение метрики по задачам с равными весами, независимо от того, сколько в каждой задаче примеров. Противоположность — микро-усреднение, где сначала складывают все примеры вместе. Макро защищает маленькие задачи от растворения в больших.

2.3 Метрика классификации

Здесь ответ бинарный, и классы неравны: положительных примерно каждое пятое. Модель, отвечающая «нет» на всё, будет права в 79 процентах случаев и при этом бесполезна. Поэтому долю правильных ответов брать нельзя.

$$MCC = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \quad (6)$$

Разбор формулы

TP true positive: модель сказала «да», и это правда.

TN true negative: сказала «нет», и это правда.

FP false positive: сказала «да» зря.

FN false negative: сказала «нет» зря.

Четыре числа полностью описывают качество бинарного предсказателя, и MCC использует все четыре сразу. Именно поэтому его не обмануть однообразным ответом.

Проверим. Модель, отвечающая всегда «нет», на 1000 объектах с 200 положительными даёт $TP = 0$, $FP = 0$, $TN = 800$, $FN = 200$. Числитель: $0 \cdot 800 - 0 \cdot 200 = 0$. Значит $MCC = 0$, ровно как у подбрасывания монетки. Доля правильных ответов при этом 80 процентов.

MCC меняется от -1 (систематически наоборот) через 0 (не лучше случайности) до $+1$ (идеально). В задачах такого рода 0.3 — уже приличный результат.

2.4 Данные: пять таблиц и одна асимметрия

Источник	Форма	Заполнено	Что в клетке
Кривые, прямое плечо	4905×4	26–48%	pIC_{50} , границы интервала, погрешность
Кривые, плечо с преинкубацией	6145×4	24–58%	то же для условия с преинкубацией
Етах, оба плеча	6146×8	частично	максимальная глубина подавления
Одноточечный скрининг	4376×4	100%	падение сигнала при 49.5 мкМ
Тест	750×4	—	закрыт

Таблица 1. Около 35 тысяч строк суммарно. Пересечения между ферментами в файле кривых маленькие: одновременно для 1A2 и 2C9 измерено 295 молекул.

Асимметрия, вокруг которой всё построено: обучающая матрица разрежена и смещена отбором, тестовая — плотная. И единственный плотный источник, покрывающий весь диапазон активностей, — одноточечный скрининг, который обычно выбрасывают как «не настоящие IC_{50} ».

3 Правдоподобие

Это центральное понятие всего документа. Без него дальше не будет ничего понятно, поэтому разберём медленно.

3.1 Вероятность и правдоподобие — это разные вещи

Возьмём монетку, у которой шанс выпадения орла равен p .

Вероятность отвечает на вопрос: « p известно, какова вероятность увидеть три орла из пяти бросков?» Параметр фиксирован, данные пока не наблюдались.

Правдоподобие отвечает на обратный вопрос: «мы увидели три орла из пяти, насколько согласуется с этим то или иное значение p ?» Данные фиксированы, параметр перебирается.

Термин: правдоподобие

Функция параметра, которая для каждого возможного значения параметра говорит, насколько вероятно было получить *именно те данные, которые мы получили*, если бы параметр был таким. Обозначается $p(\text{данные} \mid \text{параметр})$; вертикальная черта читается «при условии».

Считаем правдоподобие руками

Три орла из пяти бросков. Для каждого кандидата p вероятность такого исхода равна $\binom{5}{3}p^3(1-p)^2$, где $\binom{5}{3} = 10$ — число способов выбрать, какие именно три броска дали орла.

p	0.3	0.6	0.9
$10p^3(1-p)^2$	$10 \cdot 0.027 \cdot 0.49 = 0.132$	$10 \cdot 0.216 \cdot 0.16 = 0.346$	$10 \cdot 0.729 \cdot 0.01 = 0.073$

Значение $p = 0.6$ согласуется с наблюдением лучше остальных двух. Метод максимального правдоподобия ровно в этом и состоит: перебрать параметр и взять тот, при котором наблюдение наиболее вероятно. Для монетки ответ известен точно: $p = 3/5 = 0.6$.

3.2 Почему на практике берут логарифм и минус

Правдоподобия перемножаются: если наблюдений много и они независимы, вероятность увидеть их все — произведение вероятностей. Произведение тысячи чисел, каждое меньше единицы, мгновенно уходит в машинный ноль. Поэтому берут логарифм: произведение превращается в сумму.

$$\log \prod_{i=1}^N p(y_i | \theta) = \sum_{i=1}^N \log p(y_i | \theta) \quad (7)$$

Разбор формулы

$\prod$ знак произведения, как $\sum$ для суммы.

$\log$ натуральный логарифм. Его главное свойство: $\log(ab) = \log a + \log b$, то есть он превращает умножение в сложение.

Дальше ставят минус и получают *отрицательный логарифм правдоподобия*, по-английски *negative log-likelihood*, сокращённо *NLL*. Минус нужен, чтобы задача стала задачей *минимизации*: правдоподобие надо максимизировать, а градиентный спуск умеет только спускаться.

Итог: *NLL* — это функция потерь, и всё, что было сказано в разделе 1 про градиентный спуск, применимо к ней без изменений.

3.3 Зачем это нам

Простой лосс вида «средний квадрат ошибки» умеет сравнивать предсказание с одним числом. У нас же пять разных источников данных, которые меряют разные вещи разными приборами с разной точностью. Сложить их в один средний квадрат нельзя: непонятно, в каких единицах и с какими весами.

Правдоподобие решает эту проблему естественно. Для каждого источника мы записываем, как из параметров модели получается то, что видит прибор, и насколько прибор при этом шумит. Дальше все источники просто складываются в сумму отрицательных логарифмов, и каждый автоматически получает вес, соответствующий своей точности. Точное измерение тянет сильно, грубое — слабо, и никаких вручную подобранных коэффициентов не нужно.

Термин: порождающая модель

Описание того, как данные возникли: какие есть скрытые величины и по каким правилам из них получаются наблюдения. Противоположность — *дискриминативная* модель, которая просто учит отображение «вход в выход», не задаваясь вопросом, откуда взялся выход.

4 Наша порождающая модель

4.1 Скрытый объект — кривая

Химик меряет не число, а кривую: как падает активность фермента при росте концентрации ингибитора. Кривая S-образная и полностью описывается тремя параметрами.

$$\theta_{m,e} = (\pi_{m,e}, E_{m,e}, h_e) \quad (8)$$

Разбор формулы

m номер молекулы.

e номер фермента, от 1 до 4.

π положение перегиба кривой. Это и есть pIC_{50} , та величина, которую с нас спрашивают на лидер-борде. Греческая «пи», выбрана просто как буква, к числу 3.14 отношения не имеет.

E глубина падения, $E_{\max}$. Насколько сильно соединение вообще способно заглушить фермент. Величина от 0 до 1: единица означает полное подавление.

h крутизна кривой, наклон Хилла. Индекс e без m означает, что этот параметр общий для всех молекул внутри фермента; почему так — в разделе 6.

Термин: латентная (скрытая) переменная

Величина, которая участвует в модели, но напрямую не наблюдается. Мы видим только её следствия в измерениях. Здесь латентны все три параметра кривой: прибор показывает не их, а падение сигнала.

Плецо с преинкубацией — та же кривая, но сдвинутая:

$$\pi_{m,e}^{\text{tdi}} = \pi_{m,e} + \Delta_{m,e}, \quad \Delta \geq 0 \quad (9)$$

Разбор формулы

Δ насколько сильнее становится ингибирование после получаса преинкубации фермента с веществом и кофактором. Греческая «дельта», традиционно обозначает разность.

Ограничение $\Delta \geq 0$ отражает химию: преинкубация может только усилить ингибирование, потому что за это время часть фермента успевает необратимо испортиться. Сдвиг больше чем на $\log_{10} 2 \approx 0.301$ и есть метка TDI.

4.2 Модель прибора

Теперь связываем скрытые параметры с тем, что показывает прибор.

$$I(C; \theta) = \frac{E}{1 + 10^{h(pC - \pi)}}, \quad pC = -\log_{10} C \quad (10)$$

Разбор формулы

C концентрация ингибитора в эксперименте, моль на литр.

pC та же концентрация в логарифмической шкале, с минусом, чтобы числа были удобными. При $C = 10^{-5}$ получаем $pC = 5$.

$I(C; \theta)$ доля подавленной активности при этой концентрации. Ноль — фермент работает как обычно, единица — заглушён полностью.

Разберём знаменатель. Показатель степени равен $h(pC - \pi)$: насколько текущая концентрация в логарифмической шкале слабее потенциальности соединения, умноженное на крутизну.

Здесь легко перепутать знаки, потому что pC тем *больше*, чем *меньше* концентрация: это логарифм с минусом. Поэтому проверим на числах. Пусть $\pi = 5.2$ и $h = 1$.

концентрация	pC	показатель	$10^{\text{показатель}}$	подавление I
$10^{-4} = 100 \text{ мкМ}$	4.0	-1.2	0.063	$E/1.063 = 0.94E$
$10^{-5.2} = 6.3 \text{ мкМ}$	5.2	0	1.000	$E/2 = 0.50E$
$10^{-6} = 1 \text{ мкМ}$	6.0	+0.8	6.310	$E/7.31 = 0.14E$

Всё сходится с химией: чем больше вещества в пробирке, тем сильнее оно мешает ферменту. При $pC = \pi$ показатель обращается в ноль, $10^0 = 1$, знаменатель равен двум, и подавление составляет ровно половину максимального. Отсюда и название pIC_{50} : это та концентрация, при которой достигается половина эффекта.

Замечание о том, откуда взялась эта формула. Стандартная запись уравнения Хилла — $I = E [\text{ингибитор}] / ([\text{ингибитор}] + IC_{50})$, то есть доля занятых мест на ферменте. Разделив числитель и знаменатель на концентрацию ингибитора и перейдя к логарифмам, получаем ровно то, что написано выше. Показатель h добавляется, когда молекул связывается несколько и они влияют друг на друга.




Рис. 1. Три параметра кривой на картинке. Синяя — прямое плечо, точки на ней — двенадцать измерений полной кривой. Красная пунктирная — плечо с преинкубацией, сдвинутое на Δ . Зелёная точка — результат одноточечного скрининга: одна ордината той же кривой при известной абсциссе.

4.3 Пять правдоподобий

Теперь подключаем каждый источник данных.

Полная кривая. Организаторы дали не одно число, а несимметричный интервал. Вместо того чтобы усреднить границы и потерять асимметрию, используем распределение, у которого левая и правая половины имеют разную ширину.

$$-\log p(y^{\text{крив}} | \pi) = \text{split-N}(\pi; \hat{\pi}, \sigma^-, \sigma^+), \quad \sigma^- = \frac{\hat{\pi} - l}{1.96}, \quad \sigma^+ = \frac{h - \hat{\pi}}{1.96} \quad (11)$$

Разбор формулы

$\hat{\pi}$ опубликованная точечная оценка потентности.

l, h границы интервала достоверности из данных.

σ^-, σ^+ ширина распределения слева и справа от центра. Греческая «сигма», традиционное обозначение разброса.

- 1.96 множитель, связывающий 95-процентный интервал с шириной нормального распределения: для нормального распределения 95 процентов массы лежит в пределах $\pm 1.96\sigma$ от центра.
- split-N «разрезанное нормальное» распределение: слева от центра оно ведёт себя как нормальное с шириной σ^- , справа — с шириной σ^+ .

Смысл прост: чем шире опубликованный интервал, тем более пологим получается штраф, и тем слабее это измерение тянет модель. Для сильного ингибитора с интервалом шириной 0.2 отклонение на 0.3 будет стоить дорого, для слабого с интервалом шириной 2.5 — почти ничего.




Рис. 2. Как выглядит правдоподобие для двух соединений. Узкий пик — сильный ингибитор, измеренный точно: отклонение на десятую долю уже штрафует заметно. Широкий и асимметричный — слабый: почти вся зона от 2 до 4.5 обходится дёшево.

Одноточечный скрининг. Здесь и лежит главная идея. Скрининг — это измерение той же кривой, просто в одной точке. Значит его можно предсказать из параметров:

$$\hat{y}^{\text{скр}} = s_e \cdot \log_2(1 - I(C_0; \theta)) + b_e \quad (12)$$

Разбор формулы

- C_0 концентрация скрининга, 49.5 микромоля. Одна и та же для всех измерений.
- $1 - I$ доля *оставшейся* активности. Если подавлено 80 процентов, осталось 20.
- $\log_2$ логарифм по основанию 2, потому что прибор выдаёт результат именно в такой шкале («во сколько раз упал сигнал», в двоичных логарифмах).
- s_e, b_e два калибровочных числа на каждый фермент: масштаб и сдвиг. Они поглощают то, что у разных проб разный динамический диапазон и разная нормировка планшета.

Само правдоподобие — обычное нормальное вокруг этого предсказания:

$$-\log p(y^{\text{скр}} | \theta, \psi_e) = \frac{(y^{\text{скр}} - \hat{y}^{\text{скр}})^2}{2(\sigma_i^2 + \sigma_e^2)} + \log \sqrt{\sigma_i^2 + \sigma_e^2}$$

где σ_i — погрешность конкретного измерения, опубликованная вместе с данными, а σ_e — обучаемая добавка на фермент, покрывающая всё, чего простая модель прибора не учла. Первое слагаемое — знакомый квадрат ошибки, поделённый на дисперсию; второе нужно, чтобы модель не могла жульничать, объявляя всё измеренным крайне неточно.

Етах и плечо с преинкубацией. Файл Етах — прямое наблюдение параметра E , с тем же несимметричным распределением. Плечо с преинкубацией — наблюдение величины $\pi + \Delta$. Отдельных объяснений они не требуют.

5 Почему модель сама понимает, когда прибор ослеп

Это главный технический аргумент за всю конструкцию, и он полностью выводится из формулы прибора.

5.1 Проблема

При концентрации 49.5 микромоля сильный ингибитор глушит фермент полностью. Ингибитор вдвое сильнее заглушит его тоже полностью — сигнал одинаковый. Симметрично, совсем слабое соединение не двигает сигнал вообще, и вдвое более слабое не двигает его тоже.

Значит в этих двух зонах одноточечное измерение *не различает* соединения. Любая схема, которая пытается пересчитать сигнал в потентность напрямую, обязана выдать там какое-то число — и выдаёт его с уверенностью, которой не имеет. Мы это измерили: двухэтапная схема «предсказать сигнал, затем перевести монотонной калибровкой» даёт ST-RAE 1.006 против 0.788 у прямой регрессии, то есть работает хуже константного предсказателя.

5.2 Что происходит в правдоподобии

Посмотрим, насколько сильно меняется предсказанный сигнал при изменении потентности. Это и есть производная модели прибора.

$$\frac{\partial I}{\partial \pi} = E \cdot h \cdot \ln 10 \cdot \frac{x}{(1+x)^2}, \quad x = 10^{h(pC_0 - \pi)} \quad (13)$$

Разбор формулы

$\partial I / \partial \pi$ частная производная: насколько изменится подавление I , если чуть-чуть изменить потентность π , оставив всё остальное на месте. Значок ∂ («ди») используется вместо обычного d , когда переменных несколько.

$\ln 10$ натуральный логарифм десяти, примерно 2.303. Появляется из-за того, что в формуле стоит степень десятки, а дифференцируем мы по показателю.

x вспомогательное обозначение для той самой десятки в степени. Когда x близок к нулю — концентрация намного выше потентности, фермент задавлен. Когда x огромен — концентрация намного ниже, эффекта нет.

Всё существенное сидит в множителе $x/(1+x)^2$. Посчитаем его в трёх точках:

$x = 0.01$ (сильно задавлен)	$0.01/1.0201$	$= 0.0098$
$x = 1$ (ровно на перегибе)	$1/4$	$= 0.25$
$x = 100$ (эффекта нет)	$100/10201$	$= 0.0098$

Максимум достигается при $x = 1$, то есть ровно тогда, когда $\pi = pC_0 = 4.31$, и равен $1/4$. В обе стороны множитель падает — причём экспоненциально, потому что x сам

является степенью десяти.




Рис. 3. Насколько сигнал однократного скрининга чувствителен к настоящей потентности соединения. Колокол сосредоточен вокруг концентрации, при которой сделано измерение. Слева и справа от него измерение почти не различает соединения, и ширина колокола обратно пропорциональна крутизне кривой.

5.3 Что это значит для обучения

Вспомним раздел 1: обучение идёт по градиенту, то есть по производной лосса. А производная лосса по потентности пропорциональна как раз этому множителю.

Термин: фишеровская информация

Мера того, сколько сведений о параметре несёт одно измерение. Формально — средний квадрат производной логарифма правдоподобия по параметру. Практический смысл: чем сильнее наблюдаемая величина реагирует на изменение параметра, тем точнее по ней можно этот параметр восстановить. Если реакции нет, информации нет тоже.

Отсюда всё и получается само:

- Для соединения, чья потентность близка к 4.3, скрининг информативен, и градиент от него большой. Модель учится на нём почти как на полноценной кривой.
- Для очень сильного или очень слабого соединения множитель близок к нулю, градиент почти нулевой, и обучение просто не тянет туда потентность. Из такого измерения извлекается лишь неравенство вида «сильнее такого-то порога», и ничего сверх.

Почему это лечит именно ту поломку

Точечная инверсия обязана выдать число: у неё нет способа сказать «не знаю». Правдоподобие может — оно просто становится плоским, и плоское правдоподобие не двигает параметр.

Та же физика, подключённая на уровне правдоподобия, а не на уровне пересчё-

та, автоматически даёт то поведение, которое иначе пришлось бы прописывать вручную: цензурирование в зонах насыщения. Это и есть аргумент за конструкцию.

5.4 Проверка на данных

Всё вышесказанное — теория. Проверим, видна ли она в реальных измерениях.

Если разбить соединения по настоящей потентности на корзины и посмотреть медианный сигнал скрининга в каждой корзине, форма должна повторить кривую Хилла: плато слева, крутой участок в районе 4.3, плато справа.




Рис. 4. Медианный сигнал скрининга по корзинам настоящей потентности, по обучающей выборке. Зелёная пунктирная линия — концентрация измерения. Перегиб приходится ровно на неё у всех четырёх ферментов. Ранговая связь сигнала с потентностью доходит до 0.94.

Форма совпадает. Это не доказывает, что модель заработает, но подтверждает, что прямая модель прибора описывает реальность, а не наши фантазии о ней.

6 Чего не видно из одной точки

6.1 Проблема идентифицируемости

Из одноточечного измерения наблюдается ровно одно число — доля подавления $I(C_0)$. А параметров кривой три. Значит бесконечно много разных троек (π, E, h) дают ровно одно и то же наблюдение.

Термин: идентифицируемость

Свойство модели, при котором разные значения параметров дают разные наблюдения. Если модель неидентифицируема, никакой объём данных не позволит различить эти значения: они одинаково хорошо объясняют всё, что мы видим.

Пример неразличимости

Пусть при C_0 наблюдается подавление на 50 процентов. Это объясняется, например, так:

- $E = 1.0$, $\pi = 4.31$ — полный ингибитор средней силы, ровно на перегибе;
- $E = 0.5$, $\pi = 6.0$ — сильный, но частичный: он выключает только половину фермента, зато делает это уже при низких концентрациях;
- $E = 0.7$, $\pi \approx 4.7$ — что-то среднее.

Все три дают одинаковый сигнал скрининга. Различить их можно только по полной кривой.

Практический риск конкретный: сеть сбрасывает необъяснённый остаток в голову, отвечающую за E , чтобы точнее подогнать сигнал скрининга, и портит при этом π — единственную величину, которую с нас спрашивают.

6.2 Три средства, по возрастанию жёсткости

Крутизну выносим на уровень фермента. Вместо $h_{m,e}$ для каждой молекулы пищи h_e , один параметр на фермент. Было бы десятки тысяч свободных чисел, стало четыре. Первую версию делаем вообще с $h_e \equiv 1$.

На E ставим **приор**.

$$E = \sigma(u) = \frac{1}{1 + e^{-u}}, \quad u \sim \mathcal{N}(2, 1) \quad (14)$$

Разбор формулы

$\sigma(\cdot)$ сигмоида, она же логистическая функция. Берёт любое число и превращает его в число между нулём и единицей. Нужна потому, что E по смыслу — доля, и вылезать за эти границы не должна.

u внутренняя, ничем не ограниченная величина, которую и выдаёт сеть.

$\mathcal{N}(2, 1)$ нормальное распределение со средним 2 и дисперсией 1.

$\sim$ «распределено как».

Что это даёт численно. При $u = 2$ получаем $\sigma(2) = 1/(1 + e^{-2}) = 1/1.135 = 0.88$. При $u = 4$ — 0.982. При $u = 0$ — ровно 0.5. Центрируя приор на двойке, мы говорим модели: «по умолчанию считай соединение полным ингибитором; если данные настаивают на частичном, отклоняйся, но за это будет штраф».

Термин: приор

Априорное распределение, то есть наше представление о параметре до того, как мы посмотрели данные. В функции потерь приор появляется как дополнительное слагаемое, штрафующее за отклонение от ожидаемого. Играет ту же роль, что регуляризация: не даёт модели уходить в дикие решения ради малого выигрыша на обучающей выборке.

Амортизация как регуляризатор. Третье средство работает само собой. Параметры кривой не подбираются для каждой молекулы независимо — они предсказываются нейросетью из общего представления молекулы. Значит сеть физически не может подогнать E отдельно для каждого соединения: ей пришлось бы найти структурную закономерность, а её нет.

Термин: амортизованный вывод

Подход, при котором вместо того, чтобы для каждого объекта решать задачу подбора параметров заново, обучают одну сеть, сразу выдающую ответ по описанию объекта. Дороже на этапе обучения, зато на новом объекте ответ получается одним прогоном.

6.3 Как ловить, если пошло не так

Диагностика простая и ставится сразу. Смотрим на разброс выхода головы E отдельно на двух группах: на молекулах, у которых есть полная кривая, и на молекулах, у которых есть только скрининг. Если на вторых разброс заметно выше, значит голова используется как свалка для остатка.

7 Как соединения попадали в выборку, и почему это ломает CYP2D6

7.1 Отбор по зависимой переменной

Полные кривые снимали не для всех: сначала прогнали библиотеку в одной концентрации, потом отобрали интересные соединения на подробное измерение. Отбор шёл *по той самой величине, которую мы теперь предсказываем*.

Термин: механизм пропусков

Как именно возникли дырки в данных. Различают три случая. *Полностью случайный*: монетка решала, измерять или нет. *Случайный при условии наблюдаемого*: решение зависело от чего-то, что мы видим. *Неслучайный*: решение зависело от самой пропущенной величины. Третий случай — самый опасный: наивное обучение на том, что осталось, даёт систематически смещённые оценки.

Формально наш случай — третий. Но есть спасительная деталь, к которой вернёмся через страницу.

7.2 Что это сделало с CYP2D6

У CYP2D6 отбор оставил узкую полосу: средняя половина соединений уместилась в интервал шириной 0.83 логарифмической единицы, тогда как у CYP3A4 — 1.50. Это межквартильный размах, то есть расстояние между 25-м и 75-м перцентилем.

Ограничение диапазона, на пальцах

Связь роста с результативностью в баскетболе очевидна: среди всех людей подряд высокий играет лучше низкого, корреляция большая. Измерьте ту же корреляцию внутри состава НБА — она почти исчезнет. Не потому, что рост перестал иметь значение, а потому, что в НБА все высокие, и на первый план вышло всё остальное.

Если отобрать объекты по интересующему признаку и потом мерить связь только среди отобранных, связь выглядит слабее, чем есть. Ошибки в измерении нет: просто задан другой и более трудный вопрос.

Проверка требует второго показателя активности *того же фермента*, измеренного *без отбора*. Такой есть — одноточечный скрининг для всех 4376 соединений подряд. Те же признаки, те же фолды, тот же алгоритм; меняется только то, что модель предсказывает. Чтобы разделить «шире диапазон» и «больше примеров», прогнали ещё вариант, где у широкого показателя случайно оставлено ровно столько же соединений, сколько у узкого.

Фермент	ρ на pIC_{50}	ρ на скрининге	при равном n	прирост	размах меток
CYP2D6	0.399	0.559	0.527	+0.128	0.83
CYP2C9	0.599	0.733	0.674	+0.075	0.92
CYP1A2	0.507	0.608	0.534	+0.027	1.00
CYP3A4	0.763	0.748	0.735	−0.028	1.50

Таблица 2. Строки отсортированы по ширине диапазона меток. Прирост от перехода к широкому показателю монотонно падает по мере расширения диапазона: четыре фермента, идеальный порядок. Отрицательный знак у CYP3A4 работает внутренним контролем против объяснения «скрининг просто легче предсказуем».

Термин: ρ , коэффициент Спирмена

Мера того, насколько верно модель расставила объекты *по порядку*, независимо от абсолютных значений. Считается так: заменяем и предсказания, и правильные ответы их номерами в отсортированном списке, а потом меряем обычную корреляцию между номерами. Единица — порядок воспроизведён идеально, ноль — случаен. Устойчив к систематическому сдвигу шкалы.

На CYP2D6 при равном количестве обучающих примеров R^2 поднимается с 0.136 до 0.323. Модель прекрасно умеет учить химию этого фермента — она не может показать это на выданных метках.

7.3 Почему совместное правдоподобие это чинит

Вот та спасительная деталь. Переменная, по которой шёл отбор, — результат скрининга — *наблюдаема*. Она есть для 4375 из 4905 молекул обучающей выборки.

$$p(y^{\text{крив}}, y^{\text{скр}}, R \mid \theta) = \underbrace{p(R \mid y^{\text{скр}})}_{\text{отбор}} \cdot \underbrace{p(y^{\text{крив}} \mid y^{\text{скр}}, \theta)}_{\text{кривая, условно}} \cdot \underbrace{p(y^{\text{скр}} \mid \theta)}_{\text{скрининг}} \quad (15)$$

Разбор формулы

R индикатор: единица, если для молекулы сняли полную кривую, ноль иначе.

$p(R | y^{\text{скр}})$ вероятность попасть в подробное измерение при данном результате скрининга.

$p(y^{\text{крив}} | y^{\text{скр}}, \theta)$ распределение результата кривой при уже известном результате скрининга того же соединения.

Смысл разложения: совместная вероятность увидеть всё вместе распадается на три множителя, и первый *не зависит от θ* . А раз он не зависит от параметров, при дифференцировании логарифма он даёт ноль и полностью выпадает из градиента.

Средний множитель обязан быть *условным*. В первых версиях этого документа на его месте стоял маргинальный $p(y^{\text{крив}} | \theta)$, и это была ошибка: два показания одного соединения не независимы, они меряют одну и ту же скрытую активность. Отбор идёт по скринингу, значит среди отобранных распределение результата кривой сдвинуто, и маргинальный множитель про этот сдвиг не знает. Подробный разбор с симуляцией — в дополнении «Четыре уточнения»; вывод про отбор от поправки не меняется, потому что первый множитель выпадает при обеих записях.

Практический вывод: можно обучаться на полном правдоподобии, вообще не моделируя процедуру отбора, и оценки останутся состоятельными. Условие ровно одно — скрининг должен входить в модель как наблюдение. Если его выбросить, третий множитель перестанет быть делимым, и смещение вернётся.

Это ровно то, чего не хватало CYP2D6. Чинится не признаками, а тем, что в правдоподобие входит источник с полным диапазоном.

Оговорка: 530 молекул с кривой не имеют скрининга, и для них аргумент не работает. Доля небольшая, но в абляции их стоит проверить отдельно.

8 Архитектура: что именно считает нейросеть

8.1 Энкодер

Термин: энкодер и эмбединг

Энкодер — часть модели, превращающая объект произвольной формы (текст, картинку, молекулу) в вектор фиксированной длины. Этот вектор называется *эмбедингом* или *представлением*. Смысл: дальше с объектом можно работать как с набором чисел, а похожие объекты получают близкие векторы.

$$z_m = f_\varphi(\text{SMILES}_m), \quad z_m \in \mathbb{R}^d \quad (16)$$

Разбор формулы

z_m эмбединг m -й молекулы, вектор из d чисел. Типично d от 128 до 1024.

φ параметры энкодера. Отдельная буква нужна, чтобы отличать их от параметров кривой θ .

Энкодер мы берём предобученным.

Термин: предобучение и дообучение

Предобучение — обучение модели на большой посторонней задаче, где данных много. *Дообучение* — последующая подгонка под нашу маленькую задачу. Смысл в том, что общие закономерности строения молекул одинаковы везде, и выучить их лучше на миллионе примеров, чем на шести тысячах.

Организаторы выложили свои предобученные веса, есть и другие. Комбинировать выгодно *разные семейства*, а не разные запуски одного: они ошибаются по-разному, и их ошибки частично гасят друг друга.

Термин: LoRA

Способ дообучения, при котором исходные веса замораживают, а рядом добавляют маленькую обучаемую поправку низкого ранга. Нужен, когда обучающих примеров мало: полное дообучение шести тысячами примеров просто переписет всё, что модель знала до этого.

8.2 Связь между ферментами

Простейший вариант — четыре независимые головы, по одной на фермент. Второй простейший — одна общая. Оба плохи, и данные говорят почему: 2C9 и 3A4 коррелируют на 0.69, а 2D6 практически ортогонален всем трем (0.06, −0.12, 0.06). Общая голова будет тянуть 2D6 в сторону липофильной промискуитетности и портить его; независимые — не воспользуются тем, что 2C9 и 3A4 родственны.

Промежуточное решение:

$$\pi_{m,e} = w_e^\top g(z_m) + b_e, \quad W^\top W \approx B = LL^\top + \text{diag}(\kappa) \quad (17)$$

Разбор формулы

$g(z_m)$ несколько промежуточных слоёв поверх эмбединга, общих для всех ферментов.

w_e вектор весов головы e -го фермента. Значок $^\top$ означает транспонирование, а запись $w^\top v$ — скалярное произведение: перемножить покомпонентно и сложить.

b_e свободный член, сдвиг.

W матрица, в столбцах которой стоят все четыре вектора w_e .

B матрица 4 на 4, описывающая, насколько головы похожи друг на друга.

L узкая матрица (4 строки, 2 столбца). Произведение $LL^\top$ даёт матрицу 4 на 4 ранга 2.

$\text{diag}(\kappa)$ диагональная матрица: специфичная для каждого фермента часть, которую нельзя объяснить общими осями.

Смысл конструкции. Мы говорим модели: «четыре головы не независимы, но и не одинаковы; их сходство описывается двумя общими осями плюс индивидуальной

добавкой». Две оси — ровно то, что видно в данных: одна ось липофильности, вдоль которой идут 2C9 и 3A4, и одна ось заряда, где живёт 2D6.

Матрицу L инициализируем из измеренных корреляций, а не случайно. Это не косметика: модель начинает не с нуля, а с уже известного факта, и не тратит данные на его переоткрытие.

Термин: ранг матрицы

Число независимых направлений, которые она содержит. Матрица 4 на 4 ранга 2 означает: четыре величины, но управляются двумя независимыми факторами. Ограничение ранга — способ сказать «связей меньше, чем клеток в таблице», то есть форма регуляризации.

8.3 Механистический блок

Фингерпринт видит атомы и связи. Заряд атома азота в структурной формуле не написан: он появляется только в воде определённой кислотности. Для CYP2D6 это решающая величина, потому что в его активном центре сидят две отрицательно заряженные аминокислоты, и держится за них именно заряженный азот.

Поэтому к эмбедингу добавляются 28 чисел, каждое из которых что-то означает по-химически: оценка рКа самого основного центра, доля протонированной формы при pH 7.4, полный заряд молекулы, счётчики классов азота и кислотных групп, расстояние от заряженного азота до ароматики.

Что дал блок, честно

По метрике соревнования прирост в шуме: для 2D6 парный бутстрап даёт -0.012 с интервалом $[-0.041, +0.017]$, то есть ноль не исключён.

По ранжированию эффект есть и он избирателен ровно так, как предсказывает химия: 2D6 растёт с 0.351 до 0.403, 2C9 с 0.583 до 0.597, а 1A2 и 3A4 не двигаются вовсе (0.497 против 0.496 и 0.764 против 0.765). Совпадение с химией трудно объяснить случайностью.

И самое показательное: модель на одних этих 28 числах воспроизводит 92 процента ранжирующей способности полной модели на 2265 признаках — но только на 2D6. На остальных трёх ферментах 44–53 процента. Сигнал 2D6 низкоразмерный и химически специфичный.

8.4 Канал артефактов пробы

1A2, 2C9 и 3A4 меряют по свечению, 2D6 — масс-спектрометрией. Соединение, которое само светится или гасит свечение, притворится ингибитором в первых трёх и не притворится в четвёртом.

Добавляем скалярный признак-подсказку (сопряжённость, известные хромофорные каркасы) с обучаемым коэффициентом, входящий *только* в три флуоресцентных эндпойнта. Это структурированная поправка на мешающий фактор, а не ещё одна фица в

общую кучу.

Термин: конфаундер

Посторонняя причина, которая влияет и на то, что мы измеряем, и на то, по чему предсказываем, создавая ложную связь. Если её не учесть, модель выучит артефакт прибора вместо химии.

8.5 Головы

Голова

Что выдаёт и зачем

π	потентность, линейный выход поверх коргионализации
σ^-, σ^+	ширину собственного интервала неуверенности, отдельно влево и вправо
E	глубину подавления через сигмоиду, с приором из раздела 6
Δ	сдвиг от преинкубации, через softplus для неотрицательности

Термин: softplus

Функция $\text{softplus}(u) = \log(1 + e^u)$. Превращает любое число в положительное, но в отличие от жёсткого обрезания делает это гладко, поэтому градиент не обнуляется. Используется там, где величина по смыслу неотрицательна.

Про Δ стоит сказать отдельно. Казалось бы, проще предсказать оба плеча по отдельности и вычесть. Так хуже, и это измерено: 0.255 против 0.323 по МСС на 3A4. Причина в том, что оба плеча меряются в одном эксперименте и их шумы коррелированы; в разности этот общий шум частично сокращается, а при вычитании двух независимых предсказаний — наоборот, складывается.

9 Функция потерь и обучение

9.1 Лосс целиком

$$\mathcal{L} = \sum_{m,e} [\lambda_{\text{крив}} \ell_{\text{крив}} + \lambda_{\text{tdi}} \ell_{\text{tdi}} + \lambda_{\text{max}} \ell_{\text{max}} + \lambda_{\text{скр}} \ell_{\text{скр}}] + \lambda_{\text{гр}} \ell_{\text{гр}} + \lambda_{\text{st}} \ell_{\text{st}} + \Omega(W) \quad (18)$$

Разбор формулы

- $\sum_{m,e}$ сумма по всем молекулам и всем ферментам, для которых есть хоть какие-то измерения.
- $\ell_{\bullet}$ отрицательный логарифм правдоподобия соответствующего источника, из раздела 4.
- $\lambda_{\bullet}$ веса источников. Греческая «лямбда».
- $\ell_{\text{гр}}$ дополнительная цель: предсказывать сами границы интервала достоверности. Они лежат в данных, их никто не использует, а решающему слою из раздела 11 они нужны.
- ℓ_{st} клипованная L1-ошибка — та самая функция из метрики соревнования. Нужна, чтобы обучение шло под ту же функцию, по которой нас потом будут оценивать.
- $\Omega(W)$ регуляризатор коргионализации: штраф за отклонение матрицы сходства задач от низкоранго-

вого вида.

Слагаемых много, но структура простая: каждый источник данных даёт своё слагаемое, плюс две вспомогательные цели, плюс регуляризатор.

Термин: регуляризация

Добавка к лоссу, штрафующая модель за сложность или за отклонение от ожидаемого вида. Нужна против переобучения: без неё модель предпочтёт объяснить обучающую выборку любой ценой, включая заучивание шума.

9.2 Веса источников

Скрининга 17.5 тысяч измерений, кривых 6.5 тысяч. Если сложить всё с одинаковым весом, скрининг задавит кривые числом. Стартуем с обратно пропорционального:

$$\lambda_{\text{источник}} \propto \frac{1}{n_{\text{источник}}} \quad (19)$$

Знак $\propto$ читается «пропорционально»: важны отношения весов, а не абсолютные значения.

Дальше пробуем более умный вариант, где веса не задаются вручную, а выводятся из обучаемых оценок шумности каждого источника. Ставим это в абляцию, а не в веру.

9.3 Батч по молекулам, а не по строкам

Это тонкость, которая легко теряется при реализации, а стоит всей идеи.

Единица батча — молекула со всеми её измерениями сразу: и кривая, и E_{max}, и скрининг, и оба плеча, по всем ферментам, где что-то есть.

Почему нельзя батчить по строкам

Латентная кривая $\theta_{m,e}$ — общая для всех измерений одной пары «молекула–фермент». Смысл конструкции в том, что градиенты от разных источников сходятся на одном и том же узле и вместе его двигают.

Если набирать батч случайными строками из общей кучи, измерения одной молекулы попадут в разные шаги градиента, и совместность пропадёт. Останется обычная многозадачная сеть с общим стволом, то есть ровно то, от чего мы уходили.

9.4 Двухэтапная калибровка прибора

Если учить калибровочные числа $\psi_e = (s_e, b_e, \sigma_e)$ вместе с сетью с самого начала, есть вырожденное решение: сеть подстраивает потентности под удобную калибровку вместо обратного. Порядок должен быть такой:

1. На подмножестве, где есть и кривая, и скрининг, фиксируем π равным опубликованному и подгоняем двенадцать скаляров ψ напрямую. Задача низкоразмерная,

- решается за секунды.
2. Обучаем сеть с замороженной ψ .
 3. Размораживаем ψ с маленьким шагом на последних эпохах.

Термин: заморозка параметров

Временный запрет менять часть параметров: их градиенты просто обнуляют. Приём против того, чтобы две части модели начали компенсировать ошибки друг друга вместо того, чтобы каждая делала свою работу.

9.5 Что происходит на тесте

Важная деталь, которую легко упустить. У тестовых соединений скрининга *нет*: пересечение теста с первичной библиотекой ровно ноль молекул, это свежие закупки из каталога.

Значит скрининг — обучающий сигнал, а не признак. На инференсе модель просто прогоняет структуру через энкодер и головы; никаких дополнительных измерений не требуется и не используется.

Термин: инференс

Применение обученной модели к новым объектам, в отличие от обучения. Иногда говорят «прогон» или «предсказание».

10 Неопределённость

10.1 Зачем модели говорить, насколько она не уверена

Две причины. Первая содержательная: предсказание 5.2 с разбросом ± 0.2 и предсказание 5.2 с разбросом ± 1.5 — это разные утверждения, и химик, который будет по ним принимать решение, должен их различать.

Вторая техническая: решающий слой из раздела 11 без распределения не работает вообще. Ему нужно не число, а форма.

10.2 Два разных источника неуверенности

Термин: алеаторная и эпистемическая неопределённость

Алеаторная — шум самого измерения. Она не уменьшается от того, что мы соберём больше данных: прибор как шумел, так и шумит. У нас она видна прямо в данных, в опубликованных погрешностях.

Эпистемическая — незнание модели. Велика там, где похожих обучающих примеров мало, и уменьшается с ростом выборки. Названия от латинских «случайность» и «знание».

Различать их полезно практически. Эпистемическая часть велика ровно там, где тестовое соединение далеко от всего, что модель видела, и это прямо связано с тем, что тест состоит из аналоговых серий вокруг известных лидеров.

10.3 Как получить распределение вместо числа

Гетероскедастичная голова. Модель предсказывает не только значение, но и собственный разброс.

Термин: гетероскедастичность

Ситуация, когда разброс ошибки неодинаков для разных объектов. Противоположность — гомоскедастичность, когда шум везде один и тот же. У нас разброс заведомо неодинаков: у сильных ингибиторов измерение точное, у слабых — нет.

Ансамбль. Обучаем несколько моделей с разной инициализацией и на разных семействах энкодеров, а потом смотрим на разброс их предсказаний.

Термин: глубокий ансамбль

Несколько независимо обученных копий модели. Там, где данных много, они сходятся к одному ответу; там, где мало, расходятся — и величина расхождения служит оценкой эпистемической неуверенности. Приём грубый, но на практике работает лучше многих теоретически более изящных.

10.4 Калибровка: проверка, что заявленной уверенности можно верить

Модель может выдавать красивые интервалы, которые ничего не значат. Проверка простая: если модель заявляет 90-процентные интервалы, то на проверочной выборке правильный ответ должен попадать внутрь примерно в 90 процентах случаев. Если попадает в 60 — модель самоуверенна.

Термин: конформный предсказатель

Способ строить интервалы с гарантированным покрытием, почти не делая предположений о модели. Идея: на отложенной выборке смотрим, насколько модель обычно ошибается, берём нужный квантиль этих ошибок и расширяем интервал на эту величину. Гарантия работает при одном условии — новые объекты должны приходить из того же распределения, что и отложенная выборка.

Где здесь ловушка

Обычная конформная калибровка даёт *маргинальное* покрытие: в среднем по всей выборке 90 процентов. Но нам нужно *условное* — отдельно среди активных и отдельно среди неактивных.

У неактивных соединений интервалы широкие по построению, и они легко наберут покрытие сильно выше 90, компенсируя провал на активных. В среднем всё

сойдётся, а на той группе, которая и определяет метрику, интервалы окажутся враньём.

Лечится тем, что калибровка делается отдельно по зонам активности. Это называется мондриановским вариантом конформного предсказания: выборка режется на группы, и в каждой квантиль считается свой.

11 Что именно отправлять

Модель выдала распределение. Отправить надо одно число. Какое?

Ответ «среднее» кажется очевидным и неверен. Правильный ответ зависит от того, как считается штраф, и его надо выводить.

11.1 Постановка

$$R(\hat{y}) = \mathbb{E}[(\hat{y} - H)_+] + \mathbb{E}[(L - \hat{y})_+] \quad (20)$$

Разбор формулы

$\hat{y}$ число, которое мы собираемся отправить. Его и выбираем.

L , H нижняя и верхняя границы интервала *будущего* измерения. На момент отправки мы их не знаем, поэтому они случайные величины.

$\mathbb{E}[\cdot]$ математическое ожидание, то есть среднее по всем возможным исходам, взвешенное их вероятностями.

$R(\hat{y})$ ожидаемый штраф при выборе $\hat{y}$. Функция риска.

Мы хотим найти $\hat{y}$, при котором R минимален.

Термин: математическое ожидание

Среднее значение случайной величины, если бы опыт повторили бесконечно много раз. Для дискретного случая: сумма значений, умноженных на их вероятности. Для монетки с выигрышем 10 при орле и 0 при решке: $\mathbb{E} = 0.5 \cdot 10 + 0.5 \cdot 0 = 5$.

11.2 Вывод

Продифференцируем риск по $\hat{y}$.

$$R'(\hat{y}) = F_H(\hat{y}) - (1 - F_L(\hat{y})) \quad (21)$$

Разбор формулы

$F_H(t)$ функция распределения величины H : вероятность того, что H окажется меньше t .

$F_L(t)$ то же для L .

Откуда это берётся. Первое слагаемое риска, $\mathbb{E}[(\hat{y} - H)_+]$, растёт только тогда, когда $\hat{y}$ уже выше H : если мы сдвинем $\hat{y}$ на маленькое ε вправо, штраф вырастет на ε ровно в тех исходах, где $H < \hat{y}$. Доля таких исходов и есть $F_H(\hat{y})$.

Второе слагаемое, наоборот, *падает* при сдвиге вправо, и падает в тех исходах, где $L > \hat{y}$. Доля таких исходов равна $1 - F_L(\hat{y})$, отсюда минус.

Обе части риска выпуклы (это сумма изломанных, но не «горбчатых» функций), поэтому точка, где производная обращается в ноль, — глобальный минимум, а не какой-нибудь локальный.

Термин: выпуклая функция

Функция, у которой любая хорда лежит не ниже графика. Практическое следствие: у неё ровно один минимум, и найти его можно, просто спускаясь вниз, не боясь застрять.

Приравниваем к нулю:

$$F_L(\hat{y}^*) + F_H(\hat{y}^*) = 1 \quad (22)$$

Разбор формулы

Условие выглядит абстрактно, но у него есть простая интерпретация. Разделим обе части на два:

$$\frac{1}{2}F_L(\hat{y}^*) + \frac{1}{2}F_H(\hat{y}^*) = \frac{1}{2}.$$

Слева стоит функция распределения смеси, в которой с вероятностью одна вторая берётся L и с вероятностью одна вторая — H . А условие «функция распределения равна одной второй» — это определение медианы.

Оптимальная оценка — медиана объединённого пула нижних и верхних границ.

Практический рецепт получается элементарный. Берём S сэмплов из предсказанного распределения, для каждого считаем пару (l, h) , сваливаем все $2S$ чисел в один массив и берём медиану. Сложность — одна сортировка.

Проверим на вырожденном случае. Если интервал схлопывается в точку, $L = H = Y$, условие превращается в $2F_Y(\hat{y}^*) = 1$, то есть $\hat{y}^*$ — медиана распределения Y . Не среднее. Это общее свойство всех лоссов, устроенных как модуль ошибки: их минимизирует медиана, а средний квадрат — среднее.

11.3 Что показал прогон, и почему это меняет план

Вывод верный. А ожидания, которые я на нём построил, — нет.

Я предполагал, что у неактивных соединений интервал сильно асимметричен и тянется вниз, а значит оптимум должен смещаться вверх. Померил асимметрию — она мизерная.




Рис. 5. Как выглядит функция риска для одного соединения. Она выпукла, у неё один минимум, и он не совпадает со средним предсказанием модели.

Зона	1A2	2C9	2D6	3A4
активные, $y \geq 5$	−0.01	−0.01	−0.00	+0.00
средние, $4 \leq y < 5$	+0.03	+0.05	+0.02	+0.04
неактивные, $y < 4$	−0.11	−0.13	+0.11	−0.12

Таблица 3. Медиана асимметрии полосы: (расстояние до верхней границы) минус (расстояние до нижней). Нигде не превышает 0.13 логарифмической единицы, а у трёх ферментов из четырёх у неактивных знак отрицательный — полоса чуть длиннее вниз, а не вверх, как я предполагал.

Вариант	1A2	2C9	2D6	3A4	Макро
Сырое предсказание модели	0.879	0.691	0.980	0.519	0.767
Медиана пула, полосы предсказаны	0.889	0.710	1.002	0.540	0.785
Медиана пула, полосы истинные (оракул)	0.864	0.670	0.971	0.505	0.752

Таблица 4. Один и тот же предсказатель, разные решающие слои, те же фолды. Оракул недостижим: он знает истинные границы. Он же задаёт потолок всей затеи.

Отрицательный результат

Потолок решающего слоя под ST-RAE — 0.015 по макро-среднему, около двух процентов относительно, и это при точном знании полос. Реалистичная версия сейчас *теряет* 0.018.

Причина понятна задним числом: метрику определяют активные соединения, а у них полоса узкая (полуширины около 0.1) и симметричная — эксплуатировать нечего. Широкие полосы у неактивных, но они почти не дают вклада ни в числитель, ни в знаменатель.

Слой понижается в приоритете. Делать после того, как заработает всё остальное, и только если гетероскедастичные головы дадут заметно лучшую оценку полос, чем нынешний бустинг.

11.4 А вот для классификации слой окупается

Здесь картина другая, и числа это показывают.

Начнём с того, что метка TDI не измеряется напрямую. Она вычисляется по правилу из двух плеч, и правило воспроизводит опубликованные метки без исключений: 2334 из 2334 для 3A4 и 1493 из 1493 для 2D6. Проверено заново и покомпонентно: убрать любое из двух слагаемых — и правило начинает пропускать положительные (84 пропуска на 3A4 и 51 на 2D6 без второго слагаемого), а взять любое слагаемое по отдельности — и оно даёт сотни ложных срабатываний. Составное правило в опубликованном виде не ошибается ни разу. Значит вероятность «да» надо считать интегрированием правила по совместному распределению, а не отдельной сигмоидой.

$$p_i = \Pr(\pi > 4, \Delta > \log_{10} 2) + \Pr(\pi \leq 4, \pi + \Delta > 4.301) \quad (23)$$

Разбор формулы

$\Pr(\cdot)$ вероятность события в скобках.

$\log_{10} 2 \approx 0.301$ порог: сдвиг больше чем в два раза.

$4.301 = 4 + \log_{10} 2$: та же двукратная планка, но отсчитанная от границы активности, а не от собственного значения соединения.

Два слагаемых — это два случая опубликованного правила разметки. Если соединение вообще активно ($\pi > 4$), смотрим на сдвиг. Если неактивно, смотрим, не стало ли оно активным после преинкубации.

Считать это надо *совместно*: π и Δ коррелированы, и перемножать их вероятности по отдельности нельзя. На практике — Монте-Карло по сэмплам из ансамбля.

Термин: Монте-Карло

Способ считать сложные интегралы и вероятности перебором случайных сэмплов. Вместо того чтобы решать задачу аналитически, генерируют много случайных исходов и смотрят, в какой доле выполнилось нужное условие. Название от казино в Монако.

Дальше — выбор порога. Коэффициент Мэтьюса не раскладывается на вклад отдель-

ных объектов, поэтому привычный порог 0.5 почти всегда неоптимален.

Почему 0.5 не оптимален

Если бы метрикой была доля правильных ответов, порог 0.5 был бы правильным: отвечай «да» тогда, когда «да» вероятнее «нет».

Но МСС устроен иначе: он наказывает за дисбаланс между предсказанными и настоящими положительными. При редком классе выгодно отвечать «да» чаще, чем велит вероятность, потому что каждое пойманное положительное стоит дороже, чем каждый лишний ложный сигнал.

Оптимальный порог находится перебором: сортируем объекты по предсказанной вероятности, ведём порог сверху вниз и на каждом шаге пересчитываем ожидаемый МСС по ожидаемым счётчикам $E[TP] = \sum_{i: p_i > t} p_i$ и аналогичным. Одна сортировка плюс один проход.

Правило решения	МСС 3A4	МСС 2D6
Всегда «нет»	0.000	0.000
Классификатор, порог 0.5	0.302	0.103
Классификатор, порог подобран	0.356	0.127
Две независимые регрессии плеч, затем правило	0.255	0.094
Голова на сдвиг, затем правило	0.323	0.104
Голова на сдвиг, порог подобран	0.324	0.149

Таблица 5. Один только выбор порога стоит плюс 18 процентов относительно на 3A4 и плюс 45 на 2D6 — при полностью неизменной модели.




Рис. 6. МСС как функция порога. Полная точка — порог по умолчанию, закрашенная — оптимальный. Расстояние между ними и есть бесплатный выигрыш.

Незакрытая дыра здесь тоже есть, и её стоит назвать: вероятностная версия формулы (20) с интегрированием по ансамблю пока не проверялась вообще. Проверялся только детерминированный подстановочный вариант.

12 Как мы проверяем сами себя

12.1 Три уровня строгости разбиения

Разбиение	Что делает и когда применимо
случайное	Соединения раскидываются по фолдам как попало. В проверочную часть попадают ближайшие родственники обучающих, и результат выходит примерно вдвое оптимистичнее правды по R^2 . Годится только для отладки кода.
по кластерам сходства	Сначала группируем химически похожие соединения, потом раскидываем целые группы. Рабочий режим; все числа этого документа получены на нём.
под дизайн теста	Строим псевдотест тем же алгоритмом, каким собран настоящий: берём хит из обучающей выборки, забираем его десять ближайших соседей, держим всю серию снаружи. Ближе всего к реальности.

Про третий стоит сказать отдельно, потому что он опирается на знание о том, как устроен тест. Организаторы описали сборку публично: по 25 лучших ингибиторов каждого из 1A2, 2C9 и 3A4, по 10 ближайших соседей на каждого, итого 750. Это проверяется на данных: медиана сходства тестового соединения с ближайшим обучающим равна 0.587, а восстановленные якоря стоят на 93.0, 97.5 и 98.2 перцентиле обучающей выборки по этим трём ферментам — и только на 62.8 по 2D6, который в отборе не участвовал. Ровно 75 серий ровно по 10 при этом не воспроизводятся: кластеризация даёт 194 группы с медианным размером два, из которых 55 групп по пять и более членов покрывают 490 соединений из 750.

Почему это стоит сделать первым

Реализуется за вечер, не требует ни одной новой модели, и защищает от главного способа потерять два месяца — от расхождения между локальной оценкой и таблицей результатов.

Масштаб расхождения в этой задаче известен: собственная базовая модель организаторов даёт R^2 около 0.6 на случайном разбиении и около 0.1 на кластерном.

12.2 Парный бутстрап: почему разность без интервала не результат

Допустим, вариант А даёт 0.993, вариант В — 0.980. Лучше ли В? Неизвестно, пока не проверено, устойчива ли эта разница к случайности состава выборки.

Термин: бутстрап

Способ оценить неустойчивость результата без дополнительных данных. Из имеющейся выборки многократно набирают новые выборки того же размера, вытягивая объекты *с возвращением* (один может попасть дважды, другой ни разу). На каждой считают интересующую величину. Разброс полученных значений и есть оценка её неустойчивости.

Важно слово «парный»: обе метрики пересчитываются на *одной и той же* пересобранной выборке, и смотрим мы на распределение их разности. Так снимается общая для обоих вариантов случайность состава, и остаётся только та часть разброса, которая от-

носится к самому сравнению.

Пример, почему это не формальность

Механистический блок на CYP2D6 сдвинул ST-RAE с 0.993 до 0.980, и это выглядит как победа.

Парный бутстрап по двум тысячам пересборок даёт среднюю разность -0.012 с интервалом $[-0.041, +0.017]$. Интервал накрывает ноль: в примерно одном случае из пяти при другом составе выборки блок оказался бы хуже. Утверждать улучшение по этой метрике нельзя.

12.3 Сетка абляций

Термин: абляция

Проверка вклада отдельной части модели: её убирают (или добавляют) при прочих равных и смотрят, как изменится результат. Единственный способ узнать, что именно работает, а что просто присутствует.

Каждая строка снимается на кластерном разбиении с парным бутстрапом относительно предыдущей.

1. Фингерпринт плюс дескрипторы, градиентный бустинг. Базовая линия: макро-ST-RAE 0.774.
2. Предобученный энкодер вместо ручных признаков, по одной голове на фермент.
3. Плюс низкоранговая связь между ферментами.
4. Плюс механистический блок и канал артефактов пробы.
5. Плюс скрининг через модель прибора. **Главная проверка всей идеи.**
6. Плюс Emax и плечо с преинкубацией в общее правдоподобие.
7. Плюс ансамбль и конформная калибровка.
8. Плюс решающий слой: отдельно для регрессии, отдельно для классификации.
9. Плюс использование структуры теста.

Строка 5 — точка, на которой конструкция оправдывается или нет. Обязательный контроль к ней: сильная обычная многозадачная модель на тех же признаках и том же энкодере, обученная только на метках кривых. Если совместное правдоподобие её не обыгрывает, это отрицательный результат, и он идёт в отчёт как есть.

12.4 Что уже проверено и не работает

Список стоит держать перед глазами: он объясняет, почему решение выглядит сложным, и экономит время тем, кто захочет пойти коротким путём.

Первая строка с уткой заслуживает пояснения, потому что ошибка типичная и коварная.

Что пробовали	ST-RAE	ρ	Вывод
Прямая регрессия (база)	0.788	0.553	отправная точка
Скрининг как признак, в лоб	0.921	0.566	утечка ломает калибровку
То же с честной вложенной схемой	0.788	0.559	ровно ноль выигрыша
Два этапа: скрининг, затем пересчёт	1.006	0.561	ранг лучше, шкала мертва
Смесь двух маршрутов пополам	0.803	0.587	ранг растёт на всех четырёх
Решающий слой под ST-RAE	0.785	—	потолок 0.015, сейчас минус

Термин: утечка

Ситуация, когда модель косвенно видит ответы, которых на момент предсказания знать не могла. Даёт красивые числа на проверке и провал на реальном тесте.

Здесь утечка была такая: вспомогательный признак считался моделью, обученной в том числе на тех же объектах, на которых потом этот признак использовался. На обучающих объектах признак получался подозрительно хорошим, на проверочных — обычным. Основная модель научилась ему доверять сильнее, чем следует, и на проверке это обернулось развалом калибровки: 0.788 превратилось в 0.921.

Нашлось это не автором эксперимента — автор смотрит на свой код глазами того, кто его писал. Поэтому в команде есть отдельная роль, единственная задача которой — пытаться опровергнуть чужие числа.

13 Что скорее всего сломается

Для каждого риска — признак, по которому мы это заметим, и что делать.

Режим отказа	Признак	Реакция
Голова E работает свалкой для необъяснённого остатка	разброс её выхода на молекулах только со скринингом заметно выше, чем на молекулах с кривой	ужесточить prior, зафиксировать $h_e = 1$
Калибровка прибора зависит от молекулы, а не только от фермента	остатки модели прибора систематически изогнуты по потентности на подмножестве с полными кривыми	сделать масштаб функцией эмбединга либо ввести смесь двух режимов
Совместное правдоподобие не обыгрывает обычную многозадачную модель	строка 5 абляции внутри интервала парного бутстрапа	зафиксировать как отрицательный результат, отправлять многозадачную; решающий слой и работа со структурой теста от этого не зависят
Серийный prior переобучается на якоря	на псевдотестовых сериях модель с priorом хуже, чем без	увеличить разброс priorа или снять слой
Интервалы калиброваны в среднем, но не по зонам	покрытие по корзинам активности расходится с номинальным	мондриановский конформал с корзинами как таксономией
Локальная оценка разошлась с промежуточной таблицей 25 сентября	разрыв больше, чем между случайным и кластерным разбиениями	чинить валидацию и поправку на смещение, а не архитектуру

13.1 Про смещение теста, отдельно

Тест собран как расширение вокруг лучших ингибиторов, значит он обогащён активными по трём ферментам и близок к фону по четвёртому.

Термин: сдвиг распределения

Ситуация, когда распределение объектов на тесте отличается от обучающего. Модель, откалиброванная на обучающем распределении, будет систематически ошибаться — в нашем случае занижать активность, потому что в обучении слабых соединений было относительно больше.

Лечится перекалибровкой под ожидаемое тестовое распределение, оценённое из известной конструкции набора. Проверять эффект надо на псевдотестовых сериях: на случайном разбиении он покажет ложный выигрыш, потому что там сдвига нет.

13.2 Про серии, отдельно

У каждого тестового соединения есть известный родственник с известной активностью. Соблазн стянуть предсказание к нему велик, и его надо давить: медианная разница активности в парах с высоким сходством составляет от 0.24 до 0.55 логарифмической единицы.

Термин: обрыв активности

Пара очень похожих молекул с сильно разной активностью. Явление обычное в медицинской химии: одна метильная группа может развернуть молекулу в кармане и убить связывание. Причина, по которой предсказание по ближайшему соседу работает хуже, чем кажется.

Словарь

Абляция

Проверка вклада части модели: убрать её при прочих равных и посмотреть, что изменится.

Алеаторная неопределённость

Шум самого измерения. Не уменьшается от увеличения выборки.

Амортизованный вывод

Вместо подбора параметров для каждого объекта — одна сеть, выдающая ответ сразу.

Ансамбль

Несколько независимо обученных копий модели; разброс их ответов — оценка неуверенности.

Батч

Порция примеров, на которой считается один шаг градиента.

Бутстрап

Многократная пересборка выборки с возвращением для оценки устойчивости результата.

Выпуклая функция

Функция с единственным минимумом; любая хорда лежит не ниже графика.

Гетероскедастичность

Неодинаковый разброс ошибки у разных объектов.

Градиент

Набор производных лосса по всем параметрам; показывает направление роста лосса.

Дообучение

Подгонка предобученной модели под конкретную задачу.

Заморозка

Временный запрет менять часть параметров.

Идентифицируемость

Свойство, при котором разные параметры дают разные наблюдения.

Инференс

Применение обученной модели к новым объектам.

Конфаундер

Посторонняя причина, создающая ложную связь между входом и выходом.

Конформный предсказатель

Способ строить интервалы с гарантированным покрытием.

Латентная переменная

Величина, участвующая в модели, но напрямую не наблюдаемая.

LoRA

Дообучение маленькой поправкой низкого ранга при замороженных исходных весах.

Макро-усреднение

Усреднение метрики по задачам с равными весами.

Математическое ожидание

Среднее значение случайной величины по всем исходам.

Механизм пропусков

Как именно возникли дырки в данных; бывает случайным и неслучайным.

Монте-Карло

Счёт вероятностей и интегралов перебором случайных сэмплов.

Обрыв активности

Пара похожих молекул с сильно разной активностью.

Ограничение диапазона

Ослабление видимой связи из-за предварительного отбора объектов.

Переобучение

Хорошая работа на виденных данных и плохая на новых.

Порождающая модель

Описание того, как данные возникли, а не только отображение вход-выход.

Правдоподобие

Насколько вероятно было получить наблюдаемые данные при данном параметре.

Предобучение

Обучение на большой посторонней задаче до основной.

Приор

Представление о параметре до просмотра данных; в лоссе — штраф за отклонение.

Производная

Скорость изменения функции при изменении переменной.

Ранг матрицы

Число независимых направлений в ней.

Регуляризация

Добавка к лоссу, штрафующая за сложность или отклонение от ожидаемого вида.

Сдвиг распределения

Расхождение между распределением обучающих и тестовых объектов.

Softplus

Гладкое превращение любого числа в положительное.

Сигмоида

Гладкое превращение любого числа в число от нуля до единицы.

Фишеровская информация

Мера того, сколько сведений о параметре несёт одно измерение.

Функция потерь

Число, тем большее, чем хуже предсказания; то, что минимизируют при обучении.

Эмбеddинг

Вектор фиксированной длины, представляющий объект.

Энкодер

Часть модели, превращающая объект в эмбеddинг.

Эпистемическая неопределённость

Незнание модели; велика там, где мало похожих примеров.

Эпоха

Один полный проход по обучающей выборке.

 R^2

Доля разброса ответов, объяснённая моделью.

 ρ Спирмена

Насколько верно воспроизведён порядок объектов.

MCC

Коэффициент Мэтьюса; метрика бинарной классификации, устойчивая к перекосу классов.

ST-RAE

Метрика регрессионного трека: штраф до края интервала достоверности, делённый на штраф константы.

TDI

Зависящее от времени ингибирование; необратимая порча фермента продуктом его же работы.

Все числа получены прогонами на открытых файлах `openadmet/cyp-challenge-train-test` 25–26 августа 2026. Базовая линия: счётчиковые фингерпринты Моргана радиуса 2 (2048 бит), 217 дескрипторов RDKit, 28 механистических признаков, градиентный бустинг 300 итераций. Валидация: пятикратная кросс-валидация по кластерам Бутины с порогом 0.35, одно и то же разбиение для всех сравниваемых вариантов, парный бутстрап 2000 пересборок. Реализация ST-RAE взята из официального репозитория соревнования без изменений.

Источники: huggingface.co/spaces/openadmet/cyp-challenge;

huggingface.co/datasets/openadmet/cyp-challenge-train-test; github.com/OpenADMET/CYP-Challenge-Tutorial.