

Как мы берём CYP-челлендж

Рабочая книга команды

Документ для всех, кто заходит в проект, включая тех, кто никогда не имел дела ни с фармакологией, ни с машинным обучением. Внутри: что за задача и почему она важна, откуда взялись данные, как считаются очки, что мы уже проверили и с каким результатом, как устроено предполагаемое решение, кто чем занимается и с какой конкретной задачи можно начать сегодня, план до 3 ноября и словарь терминов в конце.

Всё, что здесь названо числом, посчитано на открытых данных соревнования и воспроизводимо. Всё, что пока остаётся гипотезой, помечено как гипотеза.

Если хочется начать прямо сегодня

1. Прочитайте главы 1–3. Это полтора часа, после которых разговор в чате перестанет быть шифром. Незнакомые слова ищите в словаре в конце.
2. Загляните в главу 7 и выберите направление. Их восемь, и три не требуют ни химии, ни машинного обучения.
3. Возьмите первую задачу выбранного направления. Она сформулирована так, чтобы закрываться за несколько вечеров и чтобы результат было видно всей команде.

Содержание

1	Что за задача и почему она важна	3
1.1	Печень как сортировочный цех	3
1.2	Что происходит, когда фермент заблокирован	3
1.3	Необратимое отравление фермента	3
1.4	Что такое слепой челлендж	4
2	Откуда данные и что в них	4
2.1	Как измеряют силу ингибитора	4
2.2	Почему зона ниже четырёх особенная	5
2.3	Двухступенчатый отбор	5
2.4	Пять файлов	6
2.5	Чем четыре фермента отличаются друг от друга	6
3	Как считают очки	8
3.1	Трек прямого ингибирования: метрика ST-RAE	8
3.2	Трек TDI: метрика MCC	9
3.3	Структурный трек	10
3.4	Как читать таблицу результатов	10
4	Что мы уже выяснили	10
4.1	Как мы проверяем, а не только что	10
4.2	Базовая линия	11
4.3	Тестовый набор устроен предсказуемо	12
4.4	Первичный скрининг несёт почти всю информацию	13

4.5	Провал на СУР2D6 разобран	14
4.6	Три способа подключить первичный скрининг, которые не работают	18
5	Главная идея решения	18
5.1	Что это даёт помимо красоты	20
6	Слои решения	20
6.1	L1. Представление молекулы	20
6.2	L2. Совместное правдоподобие	21
6.3	L3. Неопределённость	22
6.4	L4. Решающий слой	22
6.5	L5. Тест как объект	22
6.6	L6. Структурный трек	23
7	Кто чем занимается	23
8	План до 3 ноября	26
9	Правила и дисциплина	26
9.1	Правила соревнования	28
9.2	Наши собственные правила	28
10	Как поймём, что ошиблись	28
10.1	Что считать успехом	29
10.2	Чего мы не проверили	29
11	Ревизия: что пересчитано и что не сошлось	30
11.1	Семь мест, где документ расходился с данными	30
11.2	Что делает случайность разбиения	31
11.3	Что подтвердилось впервые	32
11.4	Формулы	33
11.5	Что проверено и сошлось без изменений	34
11.6	Что осталось непроверенным	34
	Словарь	35

1 Что за задача и почему она важна

1.1 Печень как сортировочный цех

Всё чужеродное, что попадает внутрь организма, надо обезвредить и вывести. Основную работу делает печень, а внутри печени — семейство ферментов под названием цитохромы P450. Это белки, в сердцевине которых сидит атом железа, зажатый в плоской органической рамке (геме, той же молекуле, что красит кровь). Железо захватывает кислород и вставляет его в молекулу-жертву. Молекула становится растворимее в воде, и почки её выводят.

Название семейства пришло от цвета. Комплекс этих белков с угарным газом поглощает свет на длине волны 450 нанометров, отсюда «пигмент 450».

Изоформ у человека несколько десятков, но подавляющее большинство лекарств разбирают четыре: CYP3A4, CYP2C9, CYP2D6 и CYP1A2. Про них и соревнование.

1.2 Что происходит, когда фермент заблокирован

Представьте цех с четырьмя линиями разборки. Каждая берёт свой тип деталей, ассортименты частично перекрываются. Бросьте на одну линию что-нибудь, что в ней застревает, и линия встанет, а всё, что было на неё рассчитано, начнёт копиться.

Так работает ингибирование: новая молекула садится в активный центр фермента и мешает ему разбирать остальное. Человек, принимающий одновременно новое лекарство и старое, получает концентрацию старого выше расчётной, иногда в разы. Если у старого лекарства узкое окно между лечебной и токсичной дозой, это прямая дорога к отравлению.

Такие эпизоды называются лекарственными взаимодействиями и остаются одной из самых частых причин, по которым препараты снимают с разработки или отзывают с рынка. Проверка на ингибирование основных цитохромов — обязательное регуляторное требование и в США, и в Европе.

1.3 Необратимое отравление фермента

Обычное ингибирование обратимо: молекула посидела в активном центре, вышла, фермент снова работает. Бывает хуже.

Иногда фермент начинает разбирать молекулу, и в процессе разбора получается нестабильный, химически агрессивный обломок. Обломок, не успев уйти, реагирует прямо с самим ферментом и выводит его из строя навсегда. Фермент, по сути, сам себя убивает, пытаясь выполнить свою работу. Такой механизм называют самоубийственным ингибированием, а на практике — зависящим от времени ингибированием, сокращённо TDI.

Последствия здесь переживают само лекарство. Обратимый ингибитор перестаёт мешать, как только выводится из крови. Убитый фермент организму приходится синтезировать заново, а это дни. Взаимодействие тянется ещё долго после того, как виновника в крови уже нет.

Меряют TDI так: снимают силу ингибирования дважды, сразу и после того, как дали

ферменту с ингибитором и кофактором поработать вместе полчаса. Если во втором случае ингибирование заметно сильнее, значит за эти полчаса что-то необратимо испортилось. Порог, принятый в соревновании, — сдвиг больше чем в два раза.

1.4 Что такое слепой челлендж

Консорциум OpenADMET вместе с компанией Octant измерил активность нескольких тысяч соединений против всех четырёх ферментов. Часть результатов выложена открыто и служит обучающей выборкой. Ещё 750 соединений измерены, но ответы спрятаны: участники присылают предсказания, организатор сверяет.

Слепой формат нужен для честности. Подсмотреть ответ нельзя ни случайно, ни намеренно, и результат каждой команды сопоставим с остальными.

Выиграть можно двумя разными способами, и это влияет на то, как мы планируем работу. Первый — лидерборд, обычная таблица результатов по точности предсказаний, отдельная для каждого трека. Второй — Innovation in ML Award, награда за самый интересный подход, которую организаторы присуждают по своему усмотрению и независимо от места в таблице. В их формулировке названы четыре вещи: архитектурная новизна, творческое использование данных, новые способы работы с неопределённостью и простые, но действенные идеи.

Вторая цель для нас важнее первой. Мы почти наверняка не переиграем по чистой точности команды из крупных фарм-компаний с их закрытыми массивами данных. Но идея, которую мы строим, у них скорее всего не появится, и вот это разыгрывается.

Условие участия, о котором легко забыть

Для награды за подход обязателен открытый код: публичная ссылка на репозиторий ставится в момент отправки предсказаний и показывается в таблице результатов. Репозиторий должен быть в приличном виде к каждой отправке, а не «когда-нибудь потом». Дисциплина на эту тему — в главе 9.

2 Откуда данные и что в них

2.1 Как измеряют силу ингибитора

Берут очищенный фермент, дают ему субстрат, который тот умеет разбирать, и смотрят на скорость реакции. Потом добавляют испытуемое вещество в какой-то концентрации, и скорость падает. Потом повторяют при другой концентрации, и ещё при другой. Получается S-образная кривая: слева, при малых концентрациях, фермент работает как обычно, справа заглушён почти полностью.

Чтобы не описывать всю кривую целиком, её сворачивают в одно число: IC_{50} , концентрацию, при которой фермент теряет ровно половину активности. Чем меньше IC_{50} , тем сильнее вещество. Числа эти тянутся на пять-шесть порядков, поэтому берут отрицательный десятичный логарифм и получают pIC_{50} .




Рис. 1. Кривая доза–ответ. Так устроены обучающие данные соревнования: для каждого соединения и каждого фермента снята кривая из двенадцати концентраций, и по ней подобрана гладкая кривая. Горизонтальная ось логарифмическая, иначе интересная часть сжалась бы в узкую полоску у левого края.

На пальцах: считаем pIC_{50} руками

Логарифм по основанию 10 отвечает на вопрос «в какую степень надо возвести 10, чтобы получить это число». Минус впереди нужен только затем, чтобы сильные ингибиторы получали большие значения, а не большие отрицательные.

$$IC_{50} = 10 \text{ мкМ} = 10^{-5} \text{ моль/л} \rightarrow pIC_{50} = 5.0$$

$$IC_{50} = 1 \text{ мкМ} = 10^{-6} \text{ моль/л} \rightarrow pIC_{50} = 6.0$$

$$IC_{50} = 100 \text{ мкМ} = 10^{-4} \text{ моль/л} \rightarrow pIC_{50} = 4.0$$

Одна единица pIC_{50} — это ровно десятикратная разница в силе. Ориентир: 6 и выше — сильный ингибитор, повод беспокоиться при разработке лекарства. Около 5 — умеренный. Ниже 4 — вещество практически не мешает.

2.2 Почему зона ниже четырёх особенная

Самая высокая концентрация, которую вообще пробовали в этих экспериментах, — около 50 микромолей на литр, а это pIC_{50} примерно 4.3. Если при максимальной пробованной концентрации фермент упал всего на четверть, точное значение IC_{50} приходится экстраполировать, и это уже не измерение, а домысливание: настоящее значение с тем же успехом могло быть 2.8 или 4.1.

Организаторы поступили честно. Они подгоняли кривые байесовским методом, который выдаёт не одно число, а интервал правдоподобных значений. У сильного ингибитора он узкий, у слабого расплывается на два-три порядка. В файлах для каждого соединения лежат три колонки: оценка, нижняя граница, верхняя.

2.3 Двухступенчатый отбор

Снимать полную кривую из двенадцати концентраций для каждого соединения дорого, поэтому сделали в два этапа.

Сначала большую библиотеку (набор разнообразных соединений от Enamine плюс набор одобренных лекарств) прогнали в одной концентрации, 49.5 микромоля. Получилось 4376 соединений на 4 фермента, то есть 17 504 измерения, и для каждого запи-




Рис. 2. Ширина интервала достоверности в зависимости от активности, по обучающей выборке. У активных соединений интервал держится в пределах четверти логарифмической единицы. У неактивных он расходится до двух с половиной, то есть настоящее значение может отличаться от опубликованного в сотни раз. На этой асимметрии построена метрика соревнования (глава 3).

сали, во сколько раз упал сигнал фермента. Затем интересные соединения подняли на подробное измерение из двенадцати точек: около полутора тысяч кривых на фермент. Тестовый набор собрали иначе. Взяли по 25 лучших ингибиторов каждого из 1A2, 2C9 и 3A4, купили у Enamine по 10 ближайших химических родственников каждого, и вот эти $3 \times 25 \times 10 = 750$ соединений измерили полностью против всех четырёх ферментов.




Рис. 3. Как собирались данные. Отсюда главная асимметрия проекта: обучающая матрица разреженная и смещённая, тестовая — плотная и построенная вокруг известных лидеров.

2.4 Пять файлов

Обучающая матрица заполнена примерно на четверть. У соединения обычно есть кривая для одного-двух ферментов из четырёх, и пересечения между ферментами маленькие: одновременно для 1A2 и 2C9 измерено всего 295 соединений. В тесте измерены все четыре у каждого из 750.

2.5 Чем четыре фермента отличаются друг от друга

Это не четыре одинаковые задачи. Активный центр каждого фермента выстлан своими аминокислотами, и держит он молекулу по-разному.

Файл	Строк	Что внутри
Прямое ингибирование, обучение	4905	pIC_{50} с интервалом и погрешностью, 4 фермента
Тест, слепой	750	только названия и структурные формулы
Зависящее от времени ингибирование	6145	метки TDI для 2D6 и 3A4 плюс оба плеча
Первичный скрининг	17 504	4376 соединений $\times$ 4 фермента, одна концентрация
Максимальный эффект (E_{max})	6146	насколько глубоко соединение глушит фермент

Таблица 1. Около 35 тысяч строк суммарно. Самый большой файл — первичный скрининг, и он же обычно остаётся неиспользованным, потому что «это же не настоящие IC_{50} ». Мы собираемся построить решение вокруг него.




Рис. 4. Сколько соединений из обучающей выборки имеют полную кривую для каждого фермента. Серым — вся выборка, синим — измеренная часть.

У СУР3A4 полость огромная и неполярная. Молекулу она держит в основном за счёт того, что жирной молекуле выгоднее сидеть в жирной полости, чем торчать в воде. Главный предиктор здесь — липофильность. У СУР2C9 похожая история плюс положительно заряженный карман, притягивающий кислотные группы. СУР1A2 — узкая плоская щель, любит плоские вытянутые ароматические молекулы вроде кофеина.

СУР2D6 устроен принципиально иначе. В его полости на видном месте две аминокислоты с отрицательным зарядом (Asp301 и Glu216). Классический ингибитор 2D6 — молекула с положительно заряженным атомом азота, притягивающимся к ним, плюс ароматическое кольцо на расстоянии пяти-семи ангстрем.

Проверяется это прямо в данных.

Свойство молекулы	1A2	2C9	2D6	3A4
Липофильность (logP)	0.23	0.49	0.03	0.60
Число основных атомов азота	−0.10	−0.19	+0.30	−0.12

Таблица 2. Ранговая корреляция с pIC_{50} по обучающей выборке. Липофильность решает для 3A4 и не значит ничего для 2D6, основной азот — ровно наоборот.




Рис. 5. Как коррелируют активности между ферментами. 2C9 и 3A4 идут в паре, а 2D6 практически ортогонален всем трим. Модель с одной общей головой на все четыре фермента будет тянуть 2D6 в сторону липофильности и портить его.

3 Как считают очки

Треков три, метрики разные.

3.1 Трек прямого ингибирования: метрика ST-RAE

Обычно точность предсказания числа меряют средней абсолютной ошибкой. Здесь так нельзя.

Допустим, у соединения опубликовано $pIC_{50} = 3.1$, но интервал тянется от 2.15 до 4.60. Модель предсказала 4.2. По средней абсолютной ошибке это промах на 1.1, то есть провал. По сути же модель попала внутрь диапазона, который сам эксперимент не различает. Штрафовать её за это значит учить воспроизводить шум прибора.

Метрика соревнования называется ST-RAE и устроена так: ошибка меряется не до точки, а до ближайшего края интервала достоверности, а попадание внутрь стоит ноль. Накопленный штраф делится на штраф самого тупого возможного предсказателя, того, который всем подряд выдаёт одно и то же число, среднее по выборке.

На пальцах: считаем ST-RAE на трёх соединениях

Среднее по трём равно $(6.20 + 3.10 + 5.00)/3 = 4.77$, это и есть предсказание тупого эталона.

	правда	интервал	модель	штраф модели	штраф эталона
соединение А	6.20	[6.08, 6.33]	5.70	0.38	$6.08 - 4.77 = 1.31$
соединение В	3.10	[2.15, 4.60]	3.60	0.00	внутри = 0.00
соединение С	5.00	[4.90, 5.15]	5.05	0.00	$4.90 - 4.77 = 0.13$

$ST-RAE = 0.38/1.44 = 0.264$.



Рис. 6. Как считается штраф. Голубая полоса — интервал достоверности, синяя точка — опубликованное значение. У сильного ингибитора интервал узкий, и промах на поединицы стоит 0.38. У слабого интервал занимает два с половиной порядка, и предсказать 3.6 или 4.5 одинаково бесплатно.

Ноль означает идеал, всегда внутри интервалов. Единица — модель ровно настолько же полезна, как предсказание одного числа для всех подряд. Больше единицы — хуже, чем ничего.

Обратите внимание на соединение В: оно не даёт вклада ни в числитель, ни в знаменатель. Соединения с широкими интервалами в этой метрике почти невесомы, и метрика намеренно сосредоточена на тех, про которые эксперимент что-то знает.

Итог по треку — среднее арифметическое ST-RAE по четырём ферментам. Отсюда прямое следствие для приоритетов. Улучшение на худшем ферменте стоит ровно столько же, сколько на лучшем, а даётся дешевле: сдвинуть 2D6 с 0.99 до 0.80 улучшает среднее на 0.048, а выжать 3A4 с 0.52 до 0.45 — всего на 0.018, и это несравнимо труднее.

3.2 Трек TDI: метрика MCC

Здесь ответ не число, а «да» или «нет»: является ли соединение необратимым отравителем фермента. Оценивают только для 3A4 и 2D6.

Классы неравны, положительных примерно каждое пятое. Модель, которая на всё отвечает «нет», будет права в 79 процентах случаев и при этом совершенно бесполезна, поэтому долю правильных ответов брать нельзя. Коэффициент Мэтьюса (MCC) на такую хитрость не покупается: он учитывает все четыре клетки таблицы ошибок сразу и обращается в ноль для любого предсказателя, который на самом деле не смотрит на объект.

На пальцах: почему «всегда нет» даёт MCC = 0

Разложим ответы модели на четыре группы: угадала «да» (TP), угадала «нет» (TN), сказала «да» зря (FP), сказала «нет» зря (FN).

$$MCC = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

Для модели, отвечающей всегда «нет», на 1000 объектах с 200 положительными: $TP = 0$, $FP = 0$, $TN = 800$, $FN = 200$. Числитель равен $0 \cdot 800 - 0 \cdot 200 = 0$, значит $MCC = 0$. Доля правильных ответов при этом 80 процентов — вот почему её не берут.

МСС меняется от -1 (систематически наоборот) через 0 (не лучше монетки) до $+1$ (идеально). В задачах такого рода 0.3 уже приличный результат, 0.5 — хороший.

Отдельная тонкость, которая пригодится в главе 5. Метка TDI не измеряется напрямую, а вычисляется по правилу из двух измеренных величин: силы ингибирования без преинкубации и с ней. Правило опубликовано, и я его проверил на обучающих данных: оно воспроизводит все опубликованные метки без единого исключения, 2334 из 2334 для 3A4 и 1493 из 1493 для 2D6.

3.3 Структурный трек

Он откроется в середине соревнования, условия ещё не опубликованы. Известно, что речь про 184 структуры и про предсказание позы, то есть надо будет сказать, как именно молекула располагается внутри активного центра. Готовиться можно уже сейчас, вкладываться всерьёз рано.

3.4 Как читать таблицу результатов

Организаторы показывают не одно число, а число с доверительным интервалом: они тысячу раз пересобирают тестовую выборку случайной выборкой с возвращением и каждый раз пересчитывают метрику. Разброс полученных значений и есть интервал. Практически это значит, что различия в третьем знаке между соседями по таблице ничего не значат, и смотреть надо, перекрываются ли интервалы.

4 Что мы уже выяснили

К моменту написания документа проведены две серии экспериментов на открытых данных. Каждое утверждение ниже сопровождается числом и способом, которым оно получено. Список того, что осталось непроверенным, — в главе 10.

4.1 Как мы проверяем, а не только что

Это стоит проговорить отдельно, потому что здесь ошибаются чаще, чем в самих моделях.

Если разбить соединения на обучающую и проверочную части случайно, в проверочную попадут ближайшие родственники обучающих. Модель покажет результат, который на новых химических классах не повторится никогда. Чтобы этого не было, мы сначала группируем соединения по химическому сходству и раскидываем по проверочным частям целые группы: модель проверяется на структурных классах, которых не видела.

Разница огромна. Собственная базовая модель организаторов при случайном разбиении даёт R^2 около 0.6 , при кластерном — около 0.1 . Все числа ниже получены при кластерном разбиении, то есть они консервативные.

4.2 Базовая линия

Молекула превращается в набор чисел двумя способами. Фингерпринт перебирает все фрагменты в радиусе двух связей от каждого атома и раскладывает их по 2048 счётчикам. Дескрипторы — это около двухсот численных свойств: масса, липофильность, число колец, площадь полярной поверхности и прочее. На них учится градиентный бустинг, ансамбль решающих деревьев, где каждое следующее исправляет ошибки предыдущих.




Рис. 7. Базовая линия регрессионного трека. Красная линия — уровень предсказания одного числа для всех соединений подряд. CYP2D6 стоит на 0.994, то есть вся конструкция из 2265 признаков и сотен деревьев отыграла у бессмысленного эталона шесть тысячных.

Фермент	Меток	ST-RAE	R ²	Спирмен ρ
CYP1A2	1412	0.881	0.216	0.497
CYP2C9	1285	0.702	0.350	0.583
CYP2D6	1493	0.994	0.122	0.351
CYP3A4	2335	0.518	0.589	0.763
Среднее по треку	6525	0.774	0.319	0.549

Таблица 3. Стартовая точка. Всё, что мы строим дальше, должно её обыгрывать, и обыгрывать при той же процедуре проверки.

По треку TDI есть деталь, которую стоит знать до всякой модели. В файле TDI размечены 3584 соединения по CYP3A4, и положительных среди них 21.3 процента. Но 1238 из этих 3584 отсутствуют в файле с кривыми доза-эффект, и среди этих 1238 положительных ровно ноль. Не мало — ноль. Соединение можно объявить time-dependent ингибитором только если оно вообще ингибирует, так что отсутствие кривой автоматически означает отрицательную метку. Среди оставшихся 2346 доля положительных уже 32.6 процента. По CYP2D6 такого эффекта нет: там вне файла кривых всего два соединения.

Отсюда два следствия. Первое: 21.3 процента — это доля по файлу, а не по той популяции, на которой мы учимся и считаем MCC; правильное число для наших таблиц — 32.6. Второе, и более важное: в тестовом файле только имя и SMILES, никакой информации о том, снимали ли для соединения кривую, там нет и быть не может. Признак «есть ли запись в файле кривых» идеально работает на обучении и недоступен на тесте.

Это ровно та ловушка, на которой в подобных соревнованиях горят решения, и её надо обойти сознательно, а не случайно.

С этой оговоркой картина по треку такая:

Способ	MCC 3A4	MCC 2D6
Отвечать «нет» всегда	0.000	0.000
Прямая классификация, порог 0.5	0.302	0.103
Прямая классификация, порог подобран	0.356	0.127
Две независимые регрессии плеч, затем правило	0.255	0.094
Отдельная голова на сдвиг, затем правило	0.323	0.104
То же с подобранным порогом сдвига	0.324	0.149

Таблица 4. Два наблюдения отсюда влияют на архитектуру. Выбор порога стоит очень много: на 3A4 плюс 18 процентов относительно, на 2D6 плюс 45. И предсказывать сдвиг отдельной головой существенно лучше, чем вычитать два независимых предсказания. Все числа таблицы получены на 2346 соединениях для 3A4 и 1495 для 2D6 — это те, у кого есть и признаки, и метка TDI.




Рис. 8. MCC как функция порога принятия решения. Полная точка — порог по умолчанию, закрашенная — оптимальный. Одно только смещение порога даёт заметный прирост при полностью неизменной модели.

4.3 Тестовый набор устроен предсказуемо

Организаторы описали, как его собирали, и это проверяется. Я кластеризовал 750 тестовых соединений по химическому сходству и нашёл для каждой группы ближайшего родственника в обучающей выборке. Картина сходится с описанием частично. Серийная структура видна: 194 группы на 750 соединений, из них 55 групп по пять и более членов, и в этих 55 группах лежат 490 из 750 соединений. Но ровно 75 серий ровно по 10 кластеризация не даёт: 72 группы одиночные, медианный размер группы — два, серий ровно по десять членов шестнадцать. Число 75 получается делением 750 на 10 и является пересказом описания организаторов, а не результатом измерения.

Что действительно измеряется и держится — положение якорей. Восстановленные яко-

ря стоят на 93.0, 97.5 и 98.2 перцентиле обучающей выборки по 1A2, 2C9 и 3A4 и только на 62.8 по 2D6 (медианы по всем 194 группам; по 55 крупным группам — 92.9, 98.4, 96.8 и 76.6). Разрыв между тремя ферментами отбора и CYP2D6 воспроизводится при любом способе счёта, и это единственное, на что мы опираемся дальше.




Рис. 9. Сходство каждого тестового соединения с ближайшим обучающим. Распределение узкое и сосредоточено около 0.59, что характерно для покупки химических аналогов по каталогу, а не для случайной выборки.

Следствий два. Тест смещён в сторону активных для трёх ферментов и близок к фону для четвёртого, поэтому модель, откалиброванная на обучающем распределении, будет систематически занижать. И у каждого тестового соединения есть известный родственник с известной активностью, что является законным источником информации. Пользоваться им, впрочем, надо осторожно.




Рис. 10. Насколько сильно различаются активности у похожих соединений, по обучающей выборке. Даже у пар с высоким сходством медианная разница держится около половины логарифмической единицы. Обрывы активности реальны, и копировать активность родственника нельзя.

4.4 Первичный скрининг несёт почти всю информацию

Величина, которую меряет первичный скрининг, — во сколько раз упал сигнал фермента при 49.5 микромоля. Её ранговая связь с полноценным pIC_{50} доходит до 0.94. Более того, форма зависимости в точности такая, какую предсказывает теория.

Это ровно та точка, вокруг которой строится наше решение, и об этом следующая глава.




Рис. 11. Медианное падение сигнала в одной концентрации в зависимости от настоящей активности. Зелёная пунктирная линия — концентрация, при которой сделано измерение. Перегиб приходится ровно на неё, как и должно быть для кривой доза–ответ: слева от неё вещество слишком слабое, чтобы что-то показать, справа сигнал уже упёрся в потолок.

4.5 Провал на CYP2D6 разобран

Отдельно расследовали, почему на CYP2D6 модель практически не работает. Проверили три версии.

Версия первая: учить нечего, метки шумные

Опубликованные значения разбросаны, и разброс складывается из настоящих химических различий и погрешности измерения. Если почти весь разброс — погрешность, учить нечего. Обычно разделить эти две части трудно, но здесь организаторы вместе с каждым значением опубликовали его собственную погрешность.

На пальцах: разложение дисперсии

Дисперсия — средний квадрат отклонения от среднего, мера разброса. Дисперсии независимых источников разброса складываются:

$$\text{Var}(\text{наблюдаемое}) = \text{Var}(\text{настоящее}) + \text{Var}(\text{шум}),$$

$$\text{надёжность} = 1 - \frac{\text{Var}(\text{шум})}{\text{Var}(\text{наблюдаемое})}.$$

Для CYP2D6 стандартное отклонение меток равно 0.916, среднеквадратичная погрешность одного измерения — 0.236. Слово «среднеквадратичная» здесь существенно: медианная погрешность всего 0.069, распределение сильно скошено, и верхние пять процентов соединений дают почти шестьдесят процентов всей шумовой дисперсии. В разложении дисперсии нужна именно средняя квадратичная, поэтому в формулу идёт 0.236, но «типичным» это число называть нельзя. Значит $\text{Var}(\text{наблюдаемое}) = 0.839$, $\text{Var}(\text{шум}) = 0.056$, $\text{надёжность} = 1 - 0.056/0.839 = 0.934$.

Читается так: 93 процента разброса опубликованных активностей CYP2D6 — настоящие химические различия между соединениями, и лишь 7 процентов — погрешность. Поскольку предсказать шум невозможно, эта же величина задаёт потолок для R^2 любой модели на этих метках.




Рис. 12. Потолок против достигнутого. Подписи показывают, какую долю доступного сигнала модель освоила. У СУР3A4 — две трети, у СУР2D6 — восьмую часть. Оценка потолка сделана по погрешности подгонки кривой и не включает разброс между планшетами и партиями вещества, то есть это верхняя граница.

Версия отвергнута

Учить есть что, и много. Потолок для СУР2D6 — R^2 около 0.93, модель добралась до 0.122. Заодно проверено, что и метрика не мешает: ST-RAE гипотетического предсказателя, знающего правду с точностью одного повторного измерения, у всех четырёх ферментов лежит между 0.010 и 0.017, то есть практически ноль.

Версия вторая: признаки не кодируют механизм

Фингерпринт видит атомы и связи. Заряд атома азота в структурной формуле не написан: он появляется только тогда, когда молекула оказывается в воде определённой кислотности и азот присоединяет протон. Разные азоты делают это по-разному, а внешне все выглядят как «атом N с тремя связями».

На пальцах: рКа и заряд

Основание — молекула, способная присоединить протон и стать положительно заряженной. Насколько охотно она это делает, описывается числом рКа: это та кислотность среды, при которой ровно половина молекул несёт протон. В крови и внутри клеток кислотность постоянна, $pH = 7.4$, и доля протонированных молекул считается так:

$$\text{доля протонированных} = \frac{1}{1 + 10^{pH - pK_a}}.$$

Для третичного амина с $pK_a = 9.5$ получается $1/(1 + 10^{-2.1}) = 0.992$, то есть 99 процентов молекул заряжены. Для пиридинового азота с $pK_a = 5.2$ получается $1/(1 + 158) = 0.006$, шесть молекул из тысячи. У амидного азота pK_a около нуля, он не заряжен никогда.

Разница между первым и вторым случаем — больше чем в сто раз по доле заряженных молекул. Для фингерпринта это два похожих азота.

Мы собрали блок из 28 химически осмысленных чисел: оценка pK_a самого основного центра, доля протонированной формы, полный заряд молекулы при $pH 7.4$, счётчики классов азота и кислотных групп, расстояние от заряженного азота до ближайшего ароматического кольца. Оценщик pK_a проверен на 20 соединениях с литературными зна-

чениями: средняя ошибка 0.60 единицы, а на бинарный вопрос «заряжено ли при 7.4» правило ответило правильно во всех двадцати случаях.




Рис. 13. Абляция признаков. Одни и те же соединения, те же кластерные фолды, тот же алгоритм, меняется только матрица признаков. По ST-RAE прирост от механистического блока крошечный. По ранжированию он заметен, и заметен избирательно: 2D6 и 2C9 растут, 1A2 и 3A4 не двигаются.

Парный бутстрап по соединениям даёт для 2D6 разность -0.012 с интервалом от -0.041 до $+0.017$. Интервал накрывает ноль, значит по метрике соревнования эффект статистически не доказан. На макро-уровне — а именно макро сортирует лидерборд — картина та же: разность -0.0056 с интервалом от -0.0155 до $+0.0041$, вероятность того, что блок на самом деле вредит, равна 0.14. Ни на одном отдельном ферменте, ни в среднем по треку выигрыш в ST-RAE от механистического блока статистически не отличим от нуля. При этом Спирмен на 2D6 вырос с 0.351 до 0.403, что является самым большим приростом во всей таблице, а на 1A2 и 3A4 не изменился вовсе (0.497 против 0.496 и 0.764 против 0.765). Блок помог ровно тем двум ферментам, узнавание у которых завязано на заряд.

Этот прирост, в отличие от прироста по ST-RAE, бутстрап подтверждает. Тот же парный бутстрап по соединениям даёт на 2D6 $+0.052$ с интервалом от $+0.022$ до $+0.082$: вероятность того, что прироста нет, равна 0.001. На 2C9 $+0.014$ от -0.002 до $+0.029$ — на грани. На 1A2 и 3A4 нули с интервалами шириной в две сотых. Механистический блок улучшает порядок и не улучшает шкалу, и оба этих утверждения теперь измерены, а не заявлены.

Ещё показательнее вот что. Модель, построенная только на двадцати восьми механистических числах, без фингерпринта и дескрипторов, воспроизводит на CYP2D6 92 процента ранжирующей способности модели на фингерпринте с дескрипторами (0.324 против 0.351) и 80 процентов от полной модели со всеми тремя блоками (0.324 против 0.403) — против 43–53 процентов на трёх остальных ферментах при любом из двух знаменателей. Сигнал CYP2D6 низкоразмерный и химически специфичный.

Версия подтверждена частично

Механизм назван верно: оценка pK_a — важнейший признак блока для 2D6, с двукратным отрывом от следующего. Но по метрике соревнования выигрыш неотличим от нуля. Признаки — часть ответа, не главная его часть.

Версия третья: дело в том, какие соединения попали в выборку

Полные кривые снимали не для всех подряд. Для СУР2D6 отбор оставил узкую полосу: средняя половина соединений уместилась в интервал шириной 0.83 логарифмической единицы (это межквартильный размах).




Рис. 14. Распределения измеренных активностей. Розовым выделены средние 50 процентов соединений. У СУР3A4 задача во многом сводится к тому, чтобы отделить левую часть от правой. У СУР2D6 такой левой части почти нет, и модели приходится различать соединения внутри узкой полосы.

На пальцах: ограничение диапазона

Связь между ростом и результативностью в баскетболе очевидна: среди всех людей подряд высокий играет лучше низкого. Измерьте ту же корреляцию внутри состава НБА, и она почти исчезнет. Не потому, что рост перестал иметь значение, а потому, что в НБА все высокие, и на первый план вышло всё остальное.

Если отобрать объекты по интересующему признаку и потом мерить связь только среди отобранных, связь выглядит слабее, чем есть. Ошибки в измерении при этом нет, просто вопрос задан другой и более трудный.

Проверка требует второго показателя активности того же фермента, измеренного без отбора. Такой есть — первичный скрининг, прогнанный для 4376 соединений подряд. Те же признаки, те же фолды, тот же алгоритм, меняется только то, что модель предсказывает. Чтобы разделить «шире диапазон» и «больше примеров», я прогнал ещё один вариант, где у широкого показателя случайно оставлено ровно столько же соединений, сколько у узкого.

Фермент	ρ на pIC_{50}	ρ на скрининге	при равном n	прирост	размах меток
СУР2D6	0.399	0.559	0.527	+0.128	0.83
СУР2C9	0.599	0.733	0.674	+0.075	0.92
СУР1A2	0.507	0.608	0.534	+0.027	1.00
СУР3A4	0.763	0.748	0.735	−0.028	1.50

Таблица 5. Строки отсортированы по ширине диапазона меток. Прирост от перехода к широкому показателю монотонно падает по мере расширения диапазона: четыре фермента, идеальный порядок.

На СУР2D6 при равном количестве обучающих примеров R^2 поднимается с 0.136 до




Рис. 15. То же самое картинкой. Отрицательный знак у CYP3A4 работает внутренним контролем: если бы показатель скрининга был просто по своей природе легче предсказуем, выигрыш был бы у всех четырёх.

0.323, а Спирмен — с 0.399 до 0.527. Модель прекрасно умеет учить химию CYP2D6, она не может показать это на выданных метках.

Версия подтверждена, и это главное

Основная причина провала на CYP2D6 — геометрия меток. Отбор соединений в подробное измерение оставил узкую полосу активностей, и задача превратилась из «отличить активное от неактивного» в «упорядочить активные», которая на порядок тоньше.

4.6 Три способа подключить первичный скрининг, которые не работают

Это тоже результат, и важный: он объясняет, почему решение выглядит именно так, а не проще.

Подход	ST-RAE	Δ к своей базе	ρ	$\Delta\rho$
Скрининг как признак, в лоб	0.921	+0.138	0.566	+0.009
То же с честной вложенной схемой	0.788	0.000	0.559	+0.006
Два этапа: скрининг, затем пересчёт	1.006	+0.212	0.561	+0.010
Смесь двух маршрутов пополам	0.803	+0.009	0.587	+0.036

Таблица 6. Информация в первичном скрининге есть, ранг улучшается всегда. Проблема исключительно в том, как перевести её в абсолютную шкалу pIC₅₀. Разности считаются от базовой линии *того же прогона*: 0.783 для первой строки, 0.788 для второй, 0.794 для двух последних. Базовые линии разных прогонов гуляют на 0.011 — ровно того же порядка, что разброс от смены разбиения (глава 11), поэтому сравнивать строки между собой по абсолютной величине нельзя, только по разностям.

5 Главная идея решения

Обычный подход к такой задаче выглядит так: взять файл с pIC₅₀, обучить модель предсказывать pIC₅₀, отправить. Остальные четыре файла при этом либо не используются вовсе, либо приделываются сбоку как вспомогательные задачи.

Наша ставка в другом. Пять файлов — это не пять задач, а пять разных наблюдений одного и того же физического объекта.

Объект — кривая зависимости активности фермента от концентрации ингибитора, та самая S-образная, с которой начиналась глава 2. У неё три параметра: положение перегиба (это и есть pIC_{50}), глубина падения (E_{max} , насколько сильно вещество вообще способно заглушить фермент) и крутизна.




Рис. 16. Одна кривая и наблюдения над ней. Синяя кривая — обычное ингибирование, точки на ней — двенадцать измерений полной кривой. Красная пунктирная — то же вещество после получаса преинкубации с ферментом: если она заметно левее, фермент повреждён необратимо, и это метка TDI. Зелёная точка — результат первичного скрининга, буквально одна ордината той же кривой при известной абсциссе.

Всё встаёт на места. Двенадцатиточечная кривая говорит про положение перегиба. Файл E_{max} — про глубину падения. Первичный скрининг — это одна точка на этой же кривой при известной концентрации. Плечо с преинкубацией — та же кривая для условия «фермент уже поработал с веществом полчаса».

Значит модель должна предсказывать не число, а параметры кривой. А каждое измерение подключается к обучению через своё правдоподобие, то есть через ответ на вопрос «насколько вероятно было увидеть именно такое измерение, если кривая на самом деле вот такая».

Как это выглядит формально

Модель прибора связывает параметры кривой с тем, что видно в эксперименте. Доля подавленной активности при концентрации C :

$$I(C) = \frac{E_{\max}}{1 + 10^{h(pC - pIC_{50})}}, \quad pC = -\log_{10} C.$$

Отсюда предсказание для однократного скрининга: $\log_2 f_c = \log_2(1 - I(C_0)) + b_e$, где b_e — калибровочная поправка на фермент. Кривая из двенадцати точек даёт наблюдение самого pIC_{50} с несимметричным интервалом, файл E_{max} — наблюдение $E_{\max}$, а плечо с преинкубацией — наблюдение сдвинутого $pIC_{50} + \Delta$.

Функция потерь — сумма отрицательных логарифмов правдоподобия по всем пяти источникам, с весами по числу наблюдений.

5.1 Что это даёт помимо красоты

В обучение входят все 35 тысяч строк. Сейчас типичное решение использует 6.5 тысячи. Первичный скрининг втрое плотнее и покрывает весь диапазон активностей, включая неактивные соединения, которых в файле кривых почти нет. Для СУР2D6, как выяснилось в главе 4, именно этого не хватает.

Проблема насыщения решается сама. Вспомните таблицу трёх неработающих подходов. При 49.5 микромоля сильный ингибитор глушит фермент полностью, и дальнейший рост силы на сигнале никак не отражается: все сильные выглядят одинаково. Точечный пересчёт обязан выдать число и выдаёт его с уверенностью, которой не имеет, отсюда $ST-RAE = 1.006$. Правдоподобие в этой зоне просто становится плоским, и модель извлекает оттуда «этот ингибитор сильнее такого-то порога» и ничего сверх того. Та же физика, подключённая на правильном уровне, лечит поломку, которую создаёт наивная версия.

Метрика становится родной. $ST-RAE$ по сути и есть ошибка с допуском в виде интервала, и обучаться надо на той же функции, а не на среднеквадратичной ошибке.

TDI перестаёт быть отдельной задачей. Метка вычисляется по правилу из двух плеч, и правило воспроизводит опубликованные метки идеально, значит вероятность «да» считается интегрированием этого правила по совместному распределению двух плеч, а не отдельным классификатором.

Почему это разыгрывается на награду

Организаторы назвали четыре критерия. Архитектурная новизна — модель прибора вместо модели метки. Творческое использование данных — 17.5 тысячи «второсортных» измерений превращаются в полноценную супервизию, а границы интервалов достоверности становятся отдельной обучающей целью. Новая работа с неопределённостью — распределение по параметрам кривой плюс теоретическо-решающий слой поверх. Простая, но действенная идея — реконструкция того, как собирали тестовый набор, и валидация под неё. Каждый пункт закрыт своим слоем.

6 Слои решения

Шесть слоёв, каждый работает поверх предыдущего. Нумерация отражает зависимость, а не важность: без первого не заработает второй, но самый большой выигрыш может дать четвёртый.

6.1 L1. Представление молекулы

Основа — предобученный химический энкодер, нейросеть, которую заранее прогнали по миллионам молекул, чтобы она выучила общие закономерности строения. Организаторы выложили свои, есть и другие. Их выгодно комбинировать: две-три разные модели ошибаются по-разному, и ансамбль из разных семейств полезнее десяти запусков одного.

Поверх идёт то, чего энкодер не видит. Блок для 2D6 содержит оценку кислотно-




Рис. 17. Стек решения. Слои L4 и L5 не зависят от L2 и работают поверх любого предсказателя, поэтому их можно строить параллельно и они уцелеют, даже если основная идея не сойдётся.

основных свойств, долю заряженной формы при физиологической кислотности и расстояние от заряженного азота до ароматического кольца; проверено, что оценка кислотности — важнейший признак блока для этого фермента. Блок для 3A4 и 2C9 — липофильность, размер, ароматические кольца, кислотные группы. Блок для 1A2 — плоскостность и вытянутость молекулы, поскольку щель узкая. Блок для TDI — структурные фрагменты, известные способностью превращаться в агрессивные обломки: концевые тройные связи, фураны, тиофены, метилendioксифенил и прочие; собирается по литературе, это направление С в главе 7.

Отдельно стоит канал артефактов прибора. Три фермента меряют по свечению, а 2D6 — масс-спектрометрией. Соединение, которое само светится или гасит свечение, притворится ингибитором в первых трёх и не притворится в четвёртом. Признак-подсказка на этот случай подаётся только в те три.

Связь между ферментами задаётся не общей головой, а обучаемой матрицей сходства задач, инициализированной измеренными корреляциями. Данные говорят, что 2C9 и 3A4 идут в паре, а 2D6 сам по себе; пусть модель это унаследует, а не переоткрывает.

6.2 L2. Совместное правдоподобие

Головы модели выдают параметры кривой для каждого фермента и каждого плеча. Функция потерь — сумма вкладов от всех пяти файлов, каждый со своим весом по числу наблюдений и своей формой.

Кривая из двенадцати точек даёт несимметричное распределение вокруг pIC_{50} : границы интервала сверху и снизу разные, и это надо уважать, а не усреднять. Первичный

скрининг входит через прямую модель прибора: зная параметры кривой и концентрацию, можно вычислить, какое падение сигнала должно было получиться, и сравнить с измеренным. Emax — прямое наблюдение второго параметра кривой.

Отдельная голова предсказывает сдвиг между плечами, а не второе плечо целиком. Обоснование измерено: 0.255 против 0.323 по MCC на 3A4. Шум двух плеч коррелирован и частично сокращается в разности.

Границы интервалов достоверности используются как дополнительная обучающая цель. Они лежат в данных, никто их не использует, а слою L4 они нужны.

6.3 L3. Неопределённость

Модель должна выдавать не число, а распределение: «скорее всего 5.2, но диапазон от 4.6 до 5.9». Практически это ансамбль из нескольких запусков и семейств плюс голова, которая сама предсказывает разброс.

Дальше идёт калибровка — проверка, что заявленные 90 процентов уверенности означают именно 90 процентов попаданий. Проверять надо не в среднем, а по зонам: у неактивных соединений интервалы широкие по построению, и средняя калибровка это замаскирует.

Полезно разделять два источника неуверенности. Шум прибора виден в данных напрямую. Незнание модели велико там, где мало похожих обучающих примеров, и оно прямо связано с тем, что тест состоит из аналоговых серий.

6.4 L4. Решающий слой

Самый недооценённый слой, и по нему уже есть измеренное доказательство ценности.

Для регрессии метрика штрафует только выход за границы интервала, и оптимальную точку можно вычислить из предсказанного распределения: риск выпуклый, а условие оптимума приводит к медиане объединённого пула сэмплов нижней и верхней границ. Я это прогнал, и результат отрицательный. Даже при точном знании полос выигрыш составляет 0.015 по среднему, а реалистичная версия с предсказанными полосами теряет 0.018. Причина в том, что полосы почти симметричны во всех зонах активности (медиана асимметрии не превышает 0.13 логарифмической единицы), а метрику определяют активные соединения, у которых полоса и без того узкая. Для регрессии слой понижается в приоритете.

Для TDI коэффициент Мэтьюса не раскладывается по объектам, поэтому порог 0.5 неоптимален. Числа уже есть: подбор порога поднимает MCC на 3A4 с 0.302 до 0.356, а на 2D6 лучший вариант даёт 0.149 против 0.103 у наивного, и это прирост при полностью неизменной модели.

Обязательная демонстрация для отчёта — тот же предсказатель, разные решающие слои. Чистое число, которое хорошо смотрится и в заявке на награду.

6.5 L5. Тест как объект

Мы знаем, что тест — это 75 серий по 10 аналогов вокруг известных лидеров. Это публичная информация, подтверждённая на данных.

Поправка на смещение нужна потому, что тест обогащён активными для трёх ферментов; модель, обученная на другом распределении, будет занижать, и это лечится перекалибровкой. Серийный эффект означает, что активность соединения складывается из предсказания модели и поправки на серию, где поправка тянется к активности якоря; сила притяжения оценивается по обучающим парам с тем же уровнем сходства и, по измерениям, должна быть слабой.

Проверка под дизайн теста устроена так: строим псевдотестовые наборы тем же способом, каким собран настоящий. Берём лидера из обучающей выборки, забираем его десять ближайших соседей, держим всю серию снаружи. Это единственный способ добиться, чтобы локальные измерения коррелировали с таблицей результатов.

6.6 L6. Структурный трек

Условия трека ещё не опубликованы, стартует он в середине соревнования. Заранее имеет смысл собрать стенд с кристаллическими структурами всех четырёх ферментов, корректно параметризованным гемом и воспроизводимой подготовкой лиганда. Дальше — докинг с ограничением на координацию к железу гема плюс независимый маршрут через нейросетевое предсказание комплекса.

Признаки из полученных поз возвращаются в L1: расстояние заряженного азота до отрицательных остатков 2D6, расстояние ближайшего окисляемого атома до железа (это прямо связано со склонностью к необратимому отравлению), плотность упаковки.

Дисциплина здесь простая: не вкладываться всерьёз раньше, чем появятся условия. Активные треки приоритетнее.

7 Кто чем занимается

Восемь направлений. Три из них (A, G, H) не требуют ни химического образования, ни опыта в машинном обучении. У каждого написана первая задача, сформулированная так, чтобы закрываться за несколько вечеров и чтобы результат было видно всей команде.

Направление не равно человеку: одно может тянуть двое, один может вести два. Но у каждого должен быть кто-то, кто отвечает за то, что оно вообще движется.

А Инфраструктура и метрики

Нужно: уверенный Python, pandas, git. Химия и машинное обучение не нужны вообще, это лучшая точка входа для программиста из другой области.

ПЕРВАЯ ЗАДАЧА

Собрать пакет, который скачивает пять файлов, проверяет их целостность и одной командой воспроизводит базовое число 0.774. Плюс валидатор отправляемого файла: ровно 750 строк, точные имена колонок, никаких пропусков и бесконечностей.

ГОТОВО, КОГДА

Коллега на своей машине с нуля получает те же 0.774 ± 0.005 , не задавая вопросов.

ДАЛЬШЕ

Учёт экспериментов, чтобы через месяц можно было понять, откуда взялось любое число. Автоматическая проверка отправляемых файлов до отправки, а не после отказа.

В Валидация под дизайн теста

Нужно: Python и умение прочитать структурную формулу библиотекой. Химическое образование не требуется, нужна аккуратность в работе с мерами сходства.

ПЕРВАЯ ЗАДАЧА

Воспроизвести сборку тестового набора на обучающих данных: взять по 25 лучших ингибиторов 1A2, 2C9 и 3A4, найти каждому по 10 ближайших родственников, сложить псевдотест. Сделать генератор проверочных наборов, который держит серию целиком снаружи.

ГОТОВО, КОГДА

Есть генератор фолдов, и на нём базовая модель показывает число, которое мы сравним с промежуточной таблицей 25 сентября. Успех — если разрыв меньше, чем при обычном кластерном разбиении.

ПОЧЕМУ ЭТО ВАЖНО

Половина странных результатов в таких задачах — артефакт слишком мягкой проверки. Это направление защищает всю команду от самообмана.

С Химический блок

Нужно: органическая химия и кислотно-основные свойства. Язык записи фрагментов SMARTS учится за день, программировать почти не надо.

ПЕРВАЯ ЗАДАЧА

Расширить проверочный набор для оценщика кислотно-основных свойств с 20 соединений до 60 с литературными значениями и починить известные систематические промахи: насыщенные гетероциклы (морфолин, пиперазин) и жёсткие бициклы оцениваются неверно на 1.2–1.8 единицы.

ВТОРАЯ ЗАДАЧА

Собрать по литературе список структурных фрагментов, связанных с необратимым отравлением фермента, и записать каждый как SMARTS со ссылкой на источник. Без ссылки фрагмент в код не идёт.

ГОТОВО, КОГДА

Средняя ошибка оценщика ниже 0.5 единицы на 60 эталонах, и каждый структурный фрагмент имеет обоснование.

D Модель кривой

Нужно: обучение нейросетей, метод максимального правдоподобия, немного ферментативной кинетики. Самое трудное направление и главный научный вклад проекта.

ПЕРВАЯ ЗАДАЧА

Откалибровать прямую модель прибора по каждому ферменту: на соединениях, у которых есть и кривая, и результат первичного скрининга, подобрать связь между падением сигнала и параметрами кривой. Показать остатки.

ГОТОВО, КОГДА

Подобранная связь воспроизводит наблюдаемую зависимость (рис. 11) без систематического изгиба в остатках.

ДАЛЬШЕ

Совместное обучение на всех пяти источниках. Обязательная проверка — против сильной обычной многозадачной модели на тех же признаках. Если не выигрывает, это тоже результат и идёт в отчёт.

E Неопределённость и решающий слой

Нужно: статистика и умение думать про калибровку. Химия не нужна совсем: слой работает уже с выходами модели.

ПЕРВАЯ ЗАДАЧА

При фиксированном предсказателе подобрать точечную оценку, минимизирующую ожидаемый штраф метрики, и измерить, сколько это даёт из ничего. Для TDI — подбор порога под ожидаемый MCC.

ГОТОВО, КОГДА

Показан прирост при полностью неизменной модели. Ориентир уже есть: на TDI один только выбор порога даёт 3A4 с 0.302 до 0.356, 2D6 с 0.103 до 0.127.

ДАЛЬШЕ

Ансамблирование, конформная калибровка интервалов, проверка покрытия отдельно по зонам активности.

F Структурный трек

Нужно: работа с белковыми структурами, докинг, подготовка лигандов. Гем требует отдельного внимания, стандартные силовые поля его нередко калечат.

ПЕРВАЯ ЗАДАЧА

Собрать воспроизводимый стенд: структуры четырёх ферментов, протокол подготовки лиганда, докинг с ограничением на координацию к железу. Проверить на известных комплексах, воспроизводится ли кристаллическая поза.

ГОТОВО, КОГДА

Среднеквадратичное отклонение при передокинге известных комплексов ниже 2 ангстрем.

ДИСЦИПЛИНА

Не вкладываться всерьёз до публикации условий трека. До этого — только стенд и признаки для активностных треков.

G Литература и внешние данные

Нужно: умение читать научные статьи и работать с базами. Программировать не требуется. Хорошая точка входа для человека с биологическим или фармацевтическим образованием.

ПЕРВАЯ ЗАДАЧА

Свести в таблицу внешние открытые источники данных по ингибированию цитохромов с обязательной пометкой, каким пробным субстратом мерили. Это решающая деталь: значения, полученные с разными пробами, между собой не сопоставимы напрямую, и смешивать их без поправки — прямой путь испортить обучение.

ВТОРАЯ ЗАДАЧА

Обзор опубликованных моделей предсказания ингибирования цитохромов: что уже пробовали, с каким результатом, на каких данных и где авторы сами признают слабое место.

ГОТОВО, КОГДА

Есть таблица источников с числом соединений, типом пробы и оценкой совместимости с нашими данными, по которой можно принимать решения.

H Красная команда

Нужно: умение читать чужой код и не верить результатам на слово. Ни химии, ни опыта в машинном обучении не требуется, требуется занудство в лучшем смысле.

ПЕРВАЯ ЗАДАЧА

Пройти по всем числам этого документа и попытаться их опровергнуть. Особое внимание — утечкам: не попал ли один и тот же структурный класс одновременно в обучение и проверку, не использована ли где-нибудь информация, которой на момент предсказания быть не могло.

ГОТОВО, КОГДА

Найдена хотя бы одна настоящая ошибка. Если за неделю не найдена, значит искали плохо, а не значит, что ошибок нет.

ПОЧЕМУ ЭТО ОТДЕЛЬНАЯ РОЛЬ

Автор эксперимента почти никогда не находит собственную утечку: он смотрит на код глазами того, кто его писал. Одна из уже найденных таким способом ошибок в этом проекте — вспомогательный признак, посчитанный на тех же данных, на которых обучался, что раздуло метрику с 0.788 до 0.921 и чуть не привело к неверному выводу.

8 План до 3 ноября

Главный принцип: в любой момент времени у нас должно быть что отправить. Сначала работающее и честно проверенное, потом умное. Выделенные строки — контрольные точки, которые нельзя сдвигать.

9 Правила и дисциплина




Рис. 18. План работ. Синие полосы — то, что нужно, чтобы вообще участвовать. Зелёные — то, что даёт основной прирост. Красные — непереносимые даты и оформление.

Когда	Что	Кто
25--31 августа	Загрузки данных, точная реализация обеих метрик, харнесс проверки, первая отправка в обоих треках. Цель недели --- воспроизвести базовые числа и занять строчку в таблице, чтобы дальше было с чем сравнивать.	А, В
1--7 сентября	Предобученные энкодеры плюс механистические блоки. Первая проверка: даёт ли явная химия узнавания сдвиг на 2D6 и 1A2. Абляция по блокам --- что именно сколько стоит.	С, D, Н
8--14 сентября	Калибровка прямой модели прибора, подключение первичного скрининга и Emax через правдоподобие. Основной научный вклад проекта. Обязательное сравнение с сильной обычной многозадачной моделью.	D, E
15--21 сентября	Ансамбль, калибровка, решающий слой под обе метрики. Голова на сдвиг для TDI. Здесь ожидается самый дешёвый прирост.	E, D
22--24 сентября	Промежуточная отправка. Заморозка кода, валидация файлов, галочки об открытом коде и отсутствии закрытых данных, публичная ссылка на репозиторий. Дедлайн 24 сентября, 23:59 UTC.	все
25 сентября	Разбор промежуточной таблицы. Единственный за всё соревнование показ относительных результатов на полном тесте. Смотрим на разрыв между нашей локальной оценкой и реальной. Если разрыв большой, чиним валидацию и калибровку, а не архитектуру. Подгонять под этот показ нельзя: он одноразовый, и переобучиться на нём легко.	В, Н
26 сентября --- 12 октября	Поправка на смещение распределения, серийные эффекты. Параллельно структурный стенд, как только опубликуют условия.	В, F
13--26 октября	Полная таблица вкладов каждого слоя, диагностика по ферментам, финальный ансамбль. Всё, что не дало выигрыша, идёт в раздел отрицательных результатов, а не в мусор.	D, E, Н
27 октября --- 3 ноября	Заморозка и оформление. Финальные отправки, README с воспроизводимым конвейером, описание метода. Награда присуждается по усмотрению организаторов, и судить будут в том числе по тому, насколько понятно изложено.	все

9.1 Правила соревнования

Одна отправка на команду или лабораторию. Несколько заявок от людей, которые плотно работают вместе, не допускаются. Это надо выяснить до первой отправки, а не после: если кто-то из коллег по институту тоже собирается участвовать, договариваться нужно заранее.

Не чаще раза в 12 часов, и в зачёт идёт последняя валидная отправка, а не лучшая. Значит перед отправкой файл прогоняется через валидатор, всегда.

Открытый код обязателен для награды за подход: ссылка ставится в момент отправки и должна работать сразу. Закрытые данные разрешены, но с пометкой, которая публично отображается в таблице; мы закрытых данных не используем. Внешние открытые данные и предобученные модели разрешены полностью.

Свой препринт организаторы не пишут и прямо предлагают участникам публиковаться самостоятельно.

9.2 Наши собственные правила

Ни одно число не попадает в общий чат без указания, как оно посчитано: на каком разбиении, на каких признаках, каким скриптом. Число без происхождения — это не результат, а слух.

Отрицательный результат оформляется так же тщательно, как положительный. У нас их уже три, и они несут больше пользы, чем половина положительных: именно они объясняют, почему решение выглядит сложно.

Сравнения только при одинаковом разбиении. Сравнить модель на кластерном сплите с моделью на случайном — самая частая и самая дорогая ошибка в этой области.

Репозиторий всегда в приличном виде. Не из любви к аккуратности, а потому что ссылка на него публичная с первой же отправки.

Любой эксперимент воспроизводится одной командой. Если для воспроизведения нужно спросить того, кто делал, эксперимента нет.

10 Как поймём, что ошиблись

Для каждого риска — признак, по которому мы это заметим, и что делать.

Модель кривой не сойдётся или не даст выигрыша. Самый вероятный сценарий провала: конструкция сложная, а данных немного. Признак — совместное обучение не обыгрывает обычную многозадачную модель на тех же признаках при одинаковом разбиении. Тогда фиксируем это как отрицательный результат, отправляем многозадачную модель, а слои L4 и L5 оставляем: они от L2 не зависят.

Калибровка прибора окажется зависящей от соединения. Глубина падения и крутизна кривой меняются не только между ферментами, но и между соединениями, и фиксированная калибровка на фермент может быть слишком грубой. Проверяется рано и дешево, на подмножестве с полными кривыми.

Серийный приор переобучится на якоря. Измеренные обрывы активности говорят,

что притяжение к якорю должно быть слабым. Признак — на псевдотестовых сериях модель с приором хуже, чем без. Проверять именно там, а не на случайном разбиении.

Промежуточная таблица покажет большой разрыв с нашей оценкой. Это не катастрофа, а диагноз: значит валидация мягче реальности либо распределение теста учтено неверно. Реакция — чинить направление В и слой L5, а не менять архитектуру в панике за месяц до конца.

Условия структурного трека окажутся неподъёмными. Они ещё не опубликованы. Правило простое: активностные треки приоритетнее, структурный подключается по остаточному принципу.

Кто-то из коллег отправит заявку параллельно. Дисквалифицирует обе. Выясняется один раз, в самом начале, и это единственный пункт списка, который надо закрыть на этой неделе.

10.1 Что считать успехом

Три цели, каждая достижима независимо от строчки в таблице

Место в первой десятке было бы отличным результатом, но мы не рассчитываем переиграть по чистой точности команды с закрытыми массивами данных. Реальные цели другие: заявка на награду за подход, воспроизводимый открытый репозиторий, которым кто-то воспользуется после соревнования, и собственная публикация метода с отрицательными результатами включительно.

10.2 Чего мы не проверили

Честный отчёт заканчивается списком дыр.

Надёжность меток оценена сверху: число 0.934 посчитано из погрешности подгонки кривой и не включает разброс между планшетами, партиями вещества и днями измерения. Настоящая воспроизводимость ниже, насколько — по этим данным сказать нельзя.

Оценщик рКа грубый: средняя ошибка 0.60 единицы на двадцати эталонах, с известными систематическими промахами. Правильнее было бы взять обученный предсказатель, но тогда каждое число блока нельзя было бы пересчитать руками.

Геометрия только топологическая. Расстояние от азота до кольца считалось в связях, а не в ангстремах, трёхмерные конформации не строились. Для гибких молекул это может быть существенно.

Сравнение двух показателей активности не идеально чистое. Это разные физические величины, и часть разрыва может объясняться тем, что скрининг — более прямое измерение. Обратный знак у СУР3А4 говорит против этого объяснения, но не исключает его полностью. Совсем чистый эксперимент требует подобрать подвыборку так, чтобы совпадали и количество примеров, и форма распределения меток; выровнено было только количество.

Модель одна и простая: везде градиентный бустинг поверх фингерпринтов. Современная нейросеть на графах может повести себя иначе и, например, сама выучить прото-

нирование из структуры. Проверять это надо отдельно.

Разбиение одно, с фиксированным зерном. Бутстрап учитывает случайность выборки соединений, но не случайность самого разбиения.

11 Ревизия: что пересчитано и что не сошлось

Всё, что описано выше, прошло сплошную проверку: формулы пересчитаны независимой реализацией и проверены на числах, каждое число восстановлено из исходных таблиц, скрипты прочитаны построчно на утечки, ключевые выводы прогнаны на других разбиениях. Эта глава — отчёт о ревизии. Она нужна не для порядка: в прошлый проход такая же проверка поймала перепутанный знак в показателе уравнения Хилла, и ловить ошибки дешевле до отправки, чем после.

11.1 Семь мест, где документ расходился с данными

Первое. «Семьдесят пять серий по десять» — пересказ, а не измерение. Кластеризация 750 тестовых соединений даёт 194 группы с медианным размером два. Одиночек 72, серий ровно по десять членов шестнадцать, групп по пять и более членов 55, и в них лежат 490 соединений из 750. Серийная структура в наборе есть, но числа 75 и 10 получаются делением 750 на 10, а не из данных. Исправлено.

Второе. Перцентили якорей не воспроизводятся. Стояло 92.5, 98.1, 97.2 и 68.9; ни один из перебранных способов счёта их не даёт. Правильные — 93.0, 97.5, 98.2 и 62.8 (медианы по всем 194 группам). Вывод, ради которого числа приводились, устоял: якоря трёх ферментов отбора сидят в верхних процентах распределения, якорь 2D6 — в середине, и разрыв в тридцать пунктов не зависит от способа счёта. Но сами числа были не те. Исправлено.

Третье. 0.236 — не типичная погрешность. Арифметика надёжности верна, и в разложение дисперсии идёт именно среднеквадратичная погрешность. Но медианная погрешность СУР2D6 равна 0.069, то есть в 3.4 раза меньше, и почти шестьдесят процентов всей шумовой дисперсии делают верхние пять процентов соединений с развалившейся подгонкой кривой. Слово «типичная» тут вводит в заблуждение, а сам факт — резкая гетероскедастичность шума — прямо подсказывает, что взвешивание по σ важнее, чем кажется по среднему. Исправлено.

Четвёртое. Девяносто два процента — от другого знаменателя. Модель на одних механистических числах даёт на 2D6 $\rho = 0.324$. Это 92 процента от модели на фингерпринте с дескрипторами (0.351) и 80 процентов от полной модели со всеми тремя блоками (0.403). В документе стояло «92 процента от полной модели». Контраст с остальными ферментами (43–53 процента) держится при обоих знаменателях. Исправлено.

Пятое. Доля положительных TDI относилась не к той популяции. Разобрано в главе 4: 21.3 процента — по файлу, 32.6 — по той выборке, на которой считался МСС, и разница целиком объясняется 1238 соединениями без кривой доза-эффект, среди которых положительных ровно ноль. Исправлено, и туда же добавлено предупреждение о признаке, который на обучении работает идеально, а на тесте недоступен.

Шестое. Порог по ожидаемому МСС требует калибровки, о которой не было ска-

зано. Правило верное: на симуляции с честными вероятностями оно попадает в оптимум. На наших сохранённых вероятностях промахивается, потому что вероятности смещены — на 3A4 средняя предсказанная 0.256 против настоящей доли 0.326, на 2D6 0.079 против 0.217. Цена промаха на 3A4 — 0.033 МСС, то есть больше половины всего выигрыша от подбора порога. Вложенная калибровка Платта возвращает почти весь: потеря падает до 0.003, чистый выигрыш +0.028 МСС. На 2D6 не окупается: при МСС порядка 0.12 и 260 положительных калибратор добавляет больше шума, чем убирает. В архитектуру идёт связка «вложенная калибровка, затем plug-in», с абляцией на каждом эндпоинте отдельно.

Седьмое. Разбиение двигает результат сильнее измеряемого эффекта. Об этом — следующий раздел.

11.2 Что делает случайность разбиения

Все числа регрессионного трека до сих пор стояли на одном разбиении: кластеры Бутины при пороге 0.35 раскидывались по пяти фолдам генератором с зерном ноль. Парный бутстрап покрывал случайность выборки соединений, но не случайность самого разбиения — это было честно записано в главе о слабых местах и теперь закрыто прямым прогоном. Меняется только зерно; кластеризация, признаки, гиперпараметры и код те же.

Разбиение	1A2	2C9	2D6	3A4	Макро	△ от блока
Зерно 0, без блока	0.8797	0.7015	0.9927	0.5178	0.7729	
с механистическим блоком	0.8786	0.6908	0.9803	0.5194	0.7673	−0.0056
Зерно 1, без блока	0.8712	0.7194	1.0097	0.5319	0.7830	
с механистическим блоком	0.8625	0.7050	0.9813	0.5273	0.7690	−0.0140
Зерно 2, без блока	0.8479	0.7210	0.9778	0.5220	0.7672	
с механистическим блоком	0.8526	0.7065	0.9780	0.5270	0.7660	−0.0012
Зерно 3, без блока	0.8619	0.7226	0.9897	0.5284	0.7757	
с механистическим блоком	0.8605	0.6943	0.9698	0.5332	0.7645	−0.0112
Среднее, без блока					0.7747	
Среднее, с блоком					0.7667	−0.0080
Ско по зёрнам, без блока					0.0066	
Ско по зёрнам, с блоком					0.0019	

Таблица 7. ST-RAE по кластерным фолдам при четырёх зёрнах разбиения. Последний столбец — разность макро между полным набором признаков и набором без механистического блока на этом же разбиении.

Читать это надо в двух измерениях сразу.

Абсолютный уровень плавает. Макро-ST-RAE набора без механистического блока по четырём зёрнам: 0.7729, 0.7830, 0.7672, 0.7757. Среднее 0.7747, стандартное отклонение 0.0066, размах 0.0158. Это больше, чем весь эффект, ради измерения которого строилась абляционная сетка. Любое число вида «макро 0.767» без указания разбиения — число с точностью до первого знака после запятой, не до третьего. Сравнить наши результаты с чужими по абсолютной величине бессмысленно; сравнивать свои между собой можно только на одном и том же разбиении.

Направление держится. Разность между наборами отрицательна на всех четырёх зёр-

нах: -0.0056 , -0.0140 , -0.0012 , -0.0112 . Спирмен по треку растёт тоже на всех четырёх, в среднем на $+0.015$, а на 2D6 — от $+0.033$ до $+0.052$. Парный бутстрап на одном разбиении накрывал ноль; четыре разбиения показывают, что знак устойчив, хотя величина гуляет в десять раз.

И самое интересное в этой таблице — не средние, а стандартные отклонения. Набор без механистического блока имеет по зёрнам разброс 0.0066 , с блоком — 0.0019 , то есть в 3.4 раза меньше. По ферментам эффект сосредоточен ровно там, где и должен: на 2D6 разброс падает с 0.0132 до 0.0052 , размах — с 0.032 до 0.012 , тогда как на 3A4 не меняется почти совсем (0.0063 против 0.0057).

Читается это так. Двадцать восемь механистических чисел дают модели устойчивую опору, не зависящую от того, какие именно аналоги попали в обучающие фолды. Фингерпринт такой опоры не даёт: он узнаёт соединение по соседям, и когда соседи уезжают в отложенный фолд, узнавание рассыпается. Это, по-видимому, и есть главная польза блока — не столько прирост среднего, сколько снижение зависимости от разбиения. Прежняя формулировка «выигрыш неотличим от нуля» была верна по букве и упускала суть.

Практический вывод простой и он меняет протокол. Любое сравнение вариантов архитектуры дальше идёт на фиксированном наборе из нескольких разбиений, а не на одном, и отчитывается разностью на каждом разбиении отдельно плюс разбросом. Одно разбиение годится для отладки и не годится для решения, какую модель отправлять.

11.3 Что подтвердилось впервые

Переход от MNAR к MAR — центральный аргумент всей конструкции — проверен симуляцией. До сих пор он существовал как выкладка: отбор в подробное измерение смотрит на наблюдаемый скрининг, поэтому множитель отбора не зависит от параметров и выпадает из градиента. Симуляция, где истинные коэффициенты известны по построению, даёт следующее.

Способ подгонки	Смещение, норма	Наклон калибровки
Только отобранные метки кривых (как сейчас)	0.433	0.731
Совместное правдоподобие, отбор по скринингу	0.019	1.012
Только скрининг, все строки (контроль сверху)	0.002	1.000
Отбор по скрытой истине, скрининг у неотобранных не виден	0.512	0.681

Таблица 8. Сорок повторов, шесть тысяч соединений, в подробное измерение попадает 28 процентов.

Подгонка по одним отобранным меткам сжимает коэффициенты до 0.73 от истины — ровно то ограничение диапазона, которое мы видим на CYP2D6. Совместное правдоподобие возвращает 1.01. Четвёртая строка важнее первых трёх: если сломать условие, сделав отбор зависящим от скрытой величины и убрав скрининг у неотобранных, совместная схема ломается так же, как наивная. Значит аргумент держится не на общей идее «использовать больше данных», а конкретно на наблюдаемости первой ступени отбора. В наших данных она наблюдаема: скрининг при 49.5 мкМ снят для 4376 соединений, включая те, для которых кривую снимать не стали.

Прирост ранжирования от механистического блока подтверждён бутстрапом.

Раньше он был заявлен по точечным оценкам. Парный бутстрап по соединениям на 3000 ресэмплов даёт на 2D6 $+0.052$ с интервалом от $+0.022$ до $+0.082$ и вероятностью отсутствия прироста 0.001; на 2C9 $+0.014$ от -0.002 до $+0.029$; на 1A2 и 3A4 нули с интервалами шириной в две сотых. Заодно закрыт пробел с обратной стороны: макро-бутстрап по ST-RAE (ресэмплим соединения, для каждого фермента берём те из них, у кого есть метка, — так сохраняется корреляция между ферментами) даёт разность -0.0056 с интервалом от -0.0155 до $+0.0041$. Итоговая формулировка теперь подкреплена целиком: блок улучшает порядок на том единственном ферменте, где узнавание завязано на заряд, и не улучшает шкалу ни на одном — ни поштучно, ни в среднем по треку.

Наша проверка труднее настоящего теста. Мера — сходство соединения с ближайшим к нему обучающим. У отложенного фолда медиана 0.435, доля соединений со сходством выше 0.7 равна половине процента. У настоящего тестового набора медиана 0.587, и таких соединений каждое десятое. Разрыв медиан 0.153, и он идёт в неожиданную сторону.

Хорошая новость: 0.767 — оценка снизу, на лидерборде должно быть лучше. Плохая: мы отбираем модели по способности экстраполировать на чужую химию, а тест награждает за интерполяцию внутри серии аналогов. Это разные умения. Валидация, воспроизводящая конструкцию теста, была в плане пунктом «хорошо бы»; теперь у неё есть цена, выраженная числом.

11.4 Формулы

Каждая формула из документов пересчитана независимой реализацией: 44 проверки, из них 43 сошлись сразу, одна вскрыла неточность формулировки. ST-RAE сверена построчно с кодом оргкомитета — совпадение до 10^{-12} на пяти случайных наборах, вырожденный случай сводится к обычному RAE, предсказание среднего даёт ровно единицу. Уравнение Хилла держит исправленный знак: 0.941, 0.500 и 0.137 при $IC_{50} = 6.3$ мкМ. Аналитическая производная совпадает с конечной разностью до 10^{-6} ; множитель $x/(1+x)^2$ максимален ровно при $x = 1$ со значением одна четвёртая и на декаду от IC_{50} падает в 3.02 раза. Байесовский оптимум под ST-RAE: численная минимизация риска на 400 тысячах сэмплов с заведомо асимметричной полосой даёт 4.8800 против медианы пула 4.8769, риск выпуклый, при нулевой полосе оптимум сходится к обычной медиане. Матрица коррегионализации положительно определена, разложение Холецкого воспроизводит её с невязкой 10^{-16} .

Неточность — в расщеплённой нормали. Правило $\sigma^- = (\mu - l)/1.96$, $\sigma^+ = (h - \mu)/1.96$ точно только при симметричной полосе: у расщеплённой нормали слева лежит масса $\sigma^-/(\sigma^- + \sigma^+)$, а не половина, поэтому квантиль стоит не в 1.96 сигмы. При $\sigma^- = 0.30$ и $\sigma^+ = 0.55$ правило даёт интервал [4.120, 5.323] вместо заявленного [4.10, 5.30]. На наших данных это не играет: полосы почти симметричны, границы расходятся на 0.0004 единицы pIC_{50} . Правило годится — но по причине, которую надо назвать, а не по общей верности.

11.5 Что проверено и сошлось без изменений

Утечек не найдено. Прочитаны построчно шесть скриптов, дающих все числа регрессионного трека. Фолды назначаются по кластерам, обучение строго на обучающих фолдах, предсказание на отложенном, признаки считаются помолекулярно и метку не видят, полуширины полосы и предиктивная сигма в решающем слое обучены только на обучающих фолдах. Кластеризация идёт по всей выборке, но только по структурам.

Загрязнения между обучением и тестом нет: пересечение по имени — ноль во всех трёх обучающих файлах, по каноническому SMILES — ноль, со снятой стереохимией — тоже ноль. Дубликатов внутри выборок нет.

Разница гиперпараметров, которая могла испортить заголовочное сравнение, оказалась несущественной: базовая линия считалась при 400 итерациях, абляция при 300, но прямое сравнение внутри одной абляции даёт 0.7729 против 0.7673, то есть настройки стоят около одной тысячной.

Сошлись с исходными таблицами: размеры всех пяти файлов; числа меток по ферментам и их сумма; межквартильные размахи; разметка TDI; максимум асимметрии полосы; средняя ошибка оценщика рКа и его результат по бинарному вопросу; все шесть строк таблицы TDI-базовых линий; решающий слой и оракульные значения; изотоника по измеренному скринингу; конфигурация оценки целиком.

11.6 Что осталось непроверенным

Сама совместная модель не запускалась ни разу. Проверен её теоретический фундамент и все компоненты по отдельности; строка абляции, где стоит она сама, пуста. Это главный незакрытый риск: всё остальное — про то, почему конструкция должна работать, а не про то, что она работает.

Вероятностное правило TDI — интегрирование правила разметки по совместному предсказательному распределению плеч — не запускалось; все шесть измеренных вариантов детерминированные. Оценщик рКа проверен на двадцати соединениях, которые я сам и выбрал: средняя ошибка 0.60 при медианной 0.2, то есть среднее делают четыре промаха, худший — кофеин, 4.5 единицы; мотив «ароматический азот через атом от карбонила», на котором правило и спотыкается, встречается у трёх процентов обучающей выборки. Учит ли графовая сеть протонирование сама — не проверялось, и если учит, часть выводов про механистический блок придётся переписать. Таблица способов подключить скрининг досверена целиком и переделана: выяснилось, что её четыре строки пришли из трёх разных прогонов с базовыми линиями 0.783, 0.788 и 0.794, а подавались как сравнение с одной. Разброс базовых линий 0.011 — ровно того же порядка, что разброс от смены разбиения. Числа самих строк подтвердились до третьего знака (1.006 и 0.803 по ST-RAE, 0.561 и 0.587 по Спирмену), но теперь таблица показывает разности от своей базы, а не абсолютные значения. Одна оценка при этом улучшилась: смесь двух маршрутов стоит +0.009 ST-RAE, а не +0.015, и покупает за это +0.036 Спирмена.

И последнее, о чём не сказано ни в одном документе. Знаменатель ST-RAE считается по среднему того набора, на котором метрика вычисляется. У нас это среднее по обучающей подвыборке фермента, на лидерборде — по 750 тестовым соединениям. Наши

числа и числа лидерборда напрямую несопоставимы, даже если модель одна и та же.

Словарь

Цитохром P450 (CYP)

Семейство ферментов печени с атомом железа в геме, разбирающих чужеродные вещества. Название --- от пика поглощения света на 450 нм.

Изоформа

Конкретный представитель семейства: CYP3A4, CYP2C9, CYP2D6, CYP1A2. У каждого свой активный центр и своя химия узнавания.

Ингибирование

Блокировка работы фермента посторонней молекулой.

IC_{50} и pIC_{50}

Концентрация, при которой активность фермента падает вдвое, и её отрицательный десятичный логарифм. Одна единица pIC_{50} --- десятикратная разница в силе.

TDI

Зависящее от времени ингибирование. Фермент разбирает молекулу, получает агрессивный обломок и выходит из строя необратимо. Последствия переживают само лекарство.

E_{max}

Насколько глубоко соединение вообще способно заглушить фермент. Вторая характеристика кривой помимо потентности.

Интервал достоверности

Диапазон значений, совместимых с измерением. У сильных ингибиторов узкий, у слабых расплывается на порядки.

ST-RAE

Метрика регрессионного трека. Штраф считается до края интервала достоверности, попадание внутрь бесплатно. Единица --- уровень предсказания одного числа для всех.

MCC

Коэффициент Мэтьюса, метрика TDI-трека. Устойчив к перекосу классов: предсказатель, отвечающий всегда одинаково, получает ровно ноль.

R^2

Доля разброса настоящих значений, объяснённая моделью. Единица --- идеал, ноль --- не лучше среднего.

Спирмен ρ

Насколько верно модель расставила соединения по порядку, независимо от абсолютных значений.

Фингерпринт

Преобразование молекулы в вектор счётчиков структурных фрагментов. Видит атомы и связи, не видит заряд и геометрию.

Дескриптор

Численное свойство молекулы: масса, липофильность, число колец, площадь полярной поверхности.

logP

Липофильность, насколько молекуле выгоднее находиться в жире, чем в воде. Главный предиктор для CYP3A4.

pKa

Кислотность среды, при которой половина молекул несёт лишний протон. Определяет, заряжена ли молекула в организме.

SMILES и SMARTS

Текстовая запись структуры молекулы и текстовая запись шаблона для её поиска.

Кластерное разбиение

Разделение на обучающую и проверочную части по химическим классам целиком. Даёт честную, консервативную оценку.

Утечка

Ситуация, когда модель косвенно видит проверочные ответы. Даёт красивые числа и провал на реальном тесте.

Бутстрап

Многократная пересборка выборки с возвращением, чтобы понять, насколько результат устойчив к случайности состава.

Правдоподобие

Насколько вероятно было увидеть наблюдаемые данные при заданных параметрах модели. Основа для объединения разнородных измерений.

Обрыв активности

Пара очень похожих молекул с сильно разной активностью. Причина, по которой нельзя предсказывать по ближайшему соседу.

Ограничение диапазона

Ослабление видимой связи, когда объекты предварительно отобраны по интересующему признаку. Главная причина провала на CYP2D6.

Числа в главах 3, 4 и 6 получены прогонами на открытых файлах `openadmet/cyp-challenge-train-test` 25 августа 2026. Признаки: счётчиковые отпечатки Моргана радиуса 2 (2048 бит), 217 дескрипторов RDKit, 28 механистических признаков. Модель: градиентный бустинг, 300 итераций. Проверка: пятикратная кросс-валидация по кластерам Бутины с порогом 0.35, одно и то же разбиение для всех сравниваемых вариантов. Реализация ST-RAE взята из официального репозитория соревнования без изменений.

Источники: страница челленджа huggingface.co/spaces/openadmet/cyp-challenge; данные huggingface.co/datasets/openadmet/cyp-challenge-train-test; официальная реализация метрик github.com/OpenADMET/CYP-Challenge-Tutorial; анонс соревнования openadmet.ghost.io.