

Как мы предсказываем ингибирование цитохромов P450

Устройство решения и математика за ним, без предварительных знаний

9 сентября 2026

Аннотация

Мы участвуем в слепом соревновании OpenADMET: по структуре молекулы предсказать, насколько сильно она подавляет четыре изофермента цитохрома P450. Этот текст объясняет, что мы построили и почему, для читателя, который знает, что такое IC_{50} и зачем нужны цитохромы, но не занимается машинным обучением. Чисел здесь почти нет: интересны идеи. Формулы есть, но все они собраны во врезках, каждый символ назван словами, и текст читается связно, если врезки пропустить. Отдельный раздел посвящён тому, чего наше решение *не* умеет — это не оговорка для приличия, а самая полезная часть.

Как читать формулы. Их пять, и все про одно и то же: как устроен счёт в соревновании и что из этого следует. Обозначения сквозные — p всегда предсказание модели, y измеренное значение, $[\ell, h]$ полоса погрешности вокруг него. Формулы стоят в рамках и дублируются словами рядом; если они мешают, их можно пропустить без потери смысла.

Содержание

1	Задача	1
2	Что нам дали	1
3	Одна вещь, без которой дальше ничего не понятно	2
4	Полоса вокруг измерения, и главная идея решения	3
5	Пять читателей одной молекулы	5
6	Ферменты учат друг друга	6
7	Вклад, измеренный однажды, — не вклад сегодня	6
8	Как мы себя проверяем	7
9	Что мы про себя знаем плохого	8
10	Второй трек: обратимое против необратимого	8
11	Итог	9

1. Задача

Цитохромы P450 метаболизируют большую часть лекарств, попадающих в организм. Если новое соединение подавляет один из них, любой другой препарат, который этим

ферментом обезвреживается, начинает накапливаться. Так возникает лекарственное взаимодействие — одна из самых частых причин, по которым молекула вылетает из разработки на поздней стадии или получает ограничения в инструкции.

Проверять это в эксперименте дорого, а кандидатов много. Поэтому есть смысл научиться отвечать на вопрос *до* эксперимента, по одной лишь структуре.

Организаторы дали обучающую выборку с измеренными значениями и спрятали набор соединений, для которых надо прислать предсказания. Правильные ответы не покажут до конца соревнования, попытка одна. Предсказать нужно две вещи: **силу обратимого ингибирования** для четырёх изоферментов и **наличие ингибирования, зависящего от времени** — того случая, когда соединение не просто садится в активный центр, а выводит фермент из строя необратимо.

2. Что нам дали

Данные дырявые. Подавляющее большинство молекул измерено только на одном ферменте, на всех четырёх — считанные десятки. Это не дефект выборки, а обычное следствие того, как накапливаются экспериментальные данные: разные соединения приходили из разных кампаний с разными целями.

Кроме самих значений дали три вещи, и каждая оказалась важной.

Границы доверия. У каждого измерения есть не только точка, но и полоса, внутри которой лежит истинное значение с учётом погрешности анализа. Для экспериментатора это обычная вещь; как выяснится, это самая полезная часть данных.

Одноточечный скрининг. Отдельная таблица: для многих молекул есть не кривая, а одно измерение при одной концентрации. Строк там заметно больше, чем полных кривых, но это другая величина — прямо в IC₅₀ она не переводится.

Плечо преинкубации. Те же молекулы, померенные после предварительной инкубации с ферментом. Разница между этим значением и обычным — и есть след необратимого ингибирования.

3. Одна вещь, без которой дальше ничего не понятно

Здесь надо сразу оговорить, кто что делает, потому что из этого следует всё остальное.

Соревнование не делает с нашими числами ничего. Оно берёт присланный файл и считает штраф по нему как есть. А вот мы сами, последним шагом перед отправкой, прогоняем предсказания через **перемасштабирование**: все предсказания одного фермента сдвигаем и стягиваем к общему центру на одну и ту же величину. Это наше решение, а не правило соревнования. Но раз оно принято, дальше всё следует из него.

Формула 1: перемасштабирование. Каждое предсказание p заменяется на

$$q = c + \lambda(p - c), \quad \lambda > 0,$$

где c — общий центр, а λ — общий коэффициент сжатия; оба подбираются один раз на фермент. Словами: сдвинуть все предсказания и стянуть их к центру.

Ключевое в том, что λ строго положительна. Если $p_1 > p_2$, то $q_1 - q_2 = \lambda(p_1 - p_2) > 0$: **порядок сохраняется в точности**, какими бы ни были c и λ . Это преобразование физически не способно переставить два соединения местами.

Что из этого следует

Любая систематическая ошибка у нас бесплатна. Не потому, что метрика её прощает — она не прощает, и без этого шага модель была бы за неё наказана, — а потому, что наш собственный последний шаг её и так снимает. Считает модель все соединения активнее, чем они есть, — сдвиг уберёт разницу. Преувеличивает разброс — сжатие уберёт и это.

Практический вывод неочевиден и стоил нам нескольких недель: *улучшать калибровку модели бессмысленно*. Всё, что можно поправить одним сдвигом и одним сжатием, поправит сдвиг и сжатие.

А вот порядок этот шаг починить не может — вообще никогда. Если модель считает соединение А сильнее соединения Б, а на самом деле наоборот, никакой сдвиг и никакое сжатие этого не исправят: они монотонны.

Поэтому настоящая задача — не «угадать IC_{50} », а **правильно расставить соединения по силе**. Мы меряем себя ранговой корреляцией и относимся к ней как к главному числу.

Это звучит технической деталью, но это самый частый способ обмануться. Несколько раз мы получали улучшение основной метрики, которое *исчезало или меняло знак* после перемасштабирования. Идея выглядела рабочей ровно до того момента, когда её мерили после того шага, который всё равно будет применён.

Как и почему это работает у нас на самом деле

Всё сказанное выше — про то, что этот шаг *способен* сделать. Полезно посмотреть, что он делает *фактически*, и ответ оказался не тем, которого мы ждали.

Сжатия у нас практически нет. Подобранный коэффициент λ выходит равным единице на трёх ферментах из четырёх и лишь немного меньше на четвёртом. Причина видна сразу, стоит посмотреть на разброс: предсказания модели разбросаны в два-три раза *уже*, чем истинные значения. Модель и так осторожна, сжимать нечего — подгонка упирается в верхний край допустимого диапазона и просит скорее растянуть, чем сжать.

И на наших собственных данных этот шаг почти ничего не улучшает. Если подобрать его так, чтобы нашему же счёту было хорошо, выигрыш составляет тысячные доли — внутри шума. Историю он себе заработал раньше, на более грубых версиях модели, которым было что исправлять; по мере того как модель становилась лучше, работы у этого шага оставалось всё меньше.

Зачем он тогда стоит в подаче? Потому что он там делает не то, что можно было подумать. Мы настраиваем его *не* под наши данные, а под предположение о спрятанных: что они в среднем активнее нашей обучающей выборки. Поэтому предсказания сдвигаются вверх заметно сильнее, чем выбрали бы наши собственные метки.

подобрано под наши данные		подаётся
сдвиг предсказаний вверх	едва заметный	заметно больший
счёт на нашей выборке	лучший возможный	хуже

То есть это **ставка, а не оптимизация**. Мы сознательно ухудшаем свой результат на известных нам данных ради того, чтобы оказаться правыми на неизвестных. Ставка

окупится, если спрятанные соединения действительно активнее; если они устроены как наши — мы просто отдали часть счёта задаром. Насколько это рискованно, обсуждается в разделе 9: это самое крупное непроверяемое допущение во всём решении.

Что важно: **на порядок соединений эта ставка не влияет никак** — она монотонна. Проиграть на ней можно только в той части счёта, которая и так почти целиком определяется не нами.

4. Полоса вокруг измерения, и главная идея решения

Теперь про то, что дало самый большой выигрыш.

Представьте, что вы просите оценить массу навески. Истинное значение известно, но весы дают погрешность. Ответ, попавший внутрь этой погрешности, — не ошибка: требовать большего бессмысленно, прибор всё равно не различит.

Метрика соревнования устроена ровно так же. Если предсказание попадает **внутрь полосы доверия** измерения, ошибка засчитывается нулевой. Штраф начинается только за выход за край, и считается как расстояние до ближайшей границы, а не до точки.

Формула 2: во что нам обходится одно предсказание. Пусть p — предсказание, а $[\ell, h]$ — нижняя и верхняя границы полосы измерения. Штраф за это соединение равен

$$L(p) = \max(0, \ell - p, p - h).$$

Словами: если p ниже нижней границы — платим, насколько ниже; если выше верхней — платим, насколько выше; если внутри — не платим ничего. Полный счёт по ферменту — сумма таких штрафов, делённая на такую же сумму для «глупого» предсказателя, который всем соединениям выдаёт одно и то же среднее значение. Деление нужно, чтобы разные ферменты можно было усреднить между собой; итог по четырём ферментам — среднее четырёх таких дробей.

Слева на рис. 1 нарисована эта самая функция L . Обратите внимание на её форму: плоское дно шириной в полосу погрешности и два прямых склона по краям.

Обычная модель этого не знает: её учат целиться в точку. Мы сделали иначе. Модель сначала обучается как обычно, а потом **переобучается на исправленную цель**: если её предсказание и так внутри полосы — цель совпадает с предсказанием, менять нечего; если снаружи — целью становится ближайший край полосы, а не далёкая точка. Это правая панель рис. 1.

Смысл в том, что модель перестаёт тратить силы на то, за что её всё равно не штрафуют, и занимается только теми соединениями, где действительно промахнулась.




Рис. 1. Слева: штраф за одно соединение как функция предсказания p ; числа над отрезками — наклон. Дно плоское: внутри полосы погрешности метрика безразлична к тому, где именно оказалось предсказание, и наклон там равен нулю. Снаружи наклон равен ± 1 независимо от того, насколько далеко ушло предсказание, — это и есть формула 4. **Справа:** куда мы переносим цель обучения. Предсказание p_0 , оказавшееся снаружи, притягивается к ближайшему краю полосы, а не к точке измерения. Предсказание p'_0 , уже попавшее внутрь полосы, остаётся на месте: цель для него совпадает с ним самим, и переучивать модель на нём нечему.

Формула 3: почему это законно, а не просто правдоподобно. Обозначим через $\text{clip}(p, \ell, h)$ операцию «загнать p в полосу»: вернуть ℓ , если p ниже неё, вернуть h , если выше, и вернуть само p , если внутри. Новая цель для соединения — это $t = \text{clip}(p_0, \ell, h)$, где p_0 — честное предсказание модели, полученное на данных, которых она не видела при обучении.

Тогда для любого нового предсказания p верно

$$|p - t| \geq L(p),$$

причём в точке $p = p_0$ здесь стоит равенство. Словами: расстояние до новой цели никогда не меньше настоящего штрафа и совпадает с ним там, где модель сейчас находится. Значит, уменьшая расстояние до цели, мы гарантированно уменьшаем и сам штраф — мы давим на потолок, который лежит поверх настоящей функции потерь и касается её в текущей точке. Приём известен как мажорирование; он же стоит за многими алгоритмами вида «сделай шаг по удобной задаче, повтори».

У той же картинке есть второе, более короткое прочтение — через наклон.

Формула 4: наклон штрафа. Производная функции штрафа по предсказанию равна

$$\frac{dL}{dp} = \text{sign}(p - \text{clip}(p, \ell, h)).$$

Проверяется перебором трёх случаев и видна прямо на левой панели рис. 1: слева от полосы наклон равен -1 , внутри полосы 0 , справа $+1$. Иначе говоря, **направление, в котором надо двигать предсказание, полностью определяется тем, с какой стороны от полосы оно оказалось** — и ничем больше. Ни расстояние до точки измерения, ни ширина полосы на это направление не влияют.

Отсюда и берётся вся конструкция: величина шага задаётся мажорированием из формулы 3, а направление — этим наклоном. Обе формулы проверены численно.


Это самый крупный вклад во всё решение — примерно треть накопленного улучшения приносит одна эта идея. И она не про алгоритм, а про то, чтобы внимательно прочитать условие задачи.

5. Пять читателей одной молекулы

Молекулу сначала переводят в числа: какие структурные фрагменты в ней встречаются, обычные физико-химические дескрипторы (масса, липофильность, доноры водородной связи) и небольшой набор признаков, написанных специально под цитохромы — про основные атомы азота, способные координировать гем, про размер, форму и заряд.

Затем пять разных моделей независимо читают эти числа, и каждая выдаёт своё предсказание. Они устроены по-разному нарочно: одна учится на каждом ферменте отдельно; вторая — на всех сразу, с пометкой, о каком ферменте речь; третья опирается на сходство структур по принципу «похожие молекулы ведут себя похоже»; четвёртая — простая линейная, только на физико-химических дескрипторах; пятая — небольшая нейросеть с общим стволом и четырьмя выходами.

Их предсказания усредняются. Идея та же, что за консилиумом: пять специалистов, ошибающихся *по-разному*, вместе надёжнее любого одного, даже если каждый по отдельности слабее лучшего. Работает это только пока они ошибаются по-разному — если все смотрят на одно и то же, усреднение не даёт ничего. Ниже будет пример, где именно так и вышло.



Правка на «мёртвую зону» применяется к каждому участнику отдельно, до усреднения.

6. Ферменты учат друг друга

Одно наблюдение стоит отдельного раздела, потому что оно про биологию, а не про технику.

Модель, которая учится на всех четырёх ферментах сразу, предсказывает лучше, чем четыре отдельные модели. Естественное объяснение — «просто больше данных» — оказалось неверным: мы добавили заметно больше строк, максимально похожих на имеющиеся, и это не дало ничего.

Верное объяснение другое. Дело не в количестве, а в **контрасте**. Когда модель видит, что одно и то же соединение сильно подавляет один фермент и не трогает другой, она узнаёт не про соединение, а про то, *чем эти ферменты отличаются*. Мы проверили это прямо: если спрятать от модели, о каком ферменте идёт речь, она становится заметно хуже четырёх отдельных моделей. А если сообщить ей средний уровень активности каждого фермента, но по-прежнему не давать различать их в остальном, — не помогает совсем.

Значит выигрыш даёт именно способность выучить *разные* закономерности для разных ферментов, а не знание про их общий уровень. Это, по сути, утверждение о том, что различия между изоформами информативнее их сходства.




Рис. 2. Две гипотезы о том, что общая модель извлекает из четырёх ферментов сразу. Слева — ферменты отличаются только уровнем; справа — они по-разному отзываются на одни и те же черты структуры, вплоть до противоположного знака. Измерение выбрало правую картину: выдать модели уровень каждого фермента даром не помогает вовсе, а вот запретить ей различать ферменты — хуже, чем вообще не объединять данные.

Формула 5: две гипотезы, которые легко перепутать. Пусть x — описание молекулы, e — номер фермента. Есть два способа устроить общую модель:

$$\text{уровень: } p = f(x) + \mu_e \quad \text{против} \quad \text{контраст: } p = f_e(x).$$

Слева одна и та же зависимость от структуры, сдвинутая на свою константу μ_e для каждого фермента. Справа — своя зависимость на каждый фермент.

Эксперимент различает их напрямую. Если убрать e совсем, оставив $p = f(x)$, модель становится заметно хуже четырёх отдельных. Если вернуть только μ_e , то есть выдать уровень каждого фермента даром, — не помогает совсем. Работает лишь третий вариант.

Платит не сдвиг μ_e , а зависимость f_e .

7. Вклад, измеренный однажды, — не вклад сегодня

У предыдущего раздела есть продолжение, и оно оказалось важнее самого раздела.

Все элементы решения добавлялись по одному, и вклад каждого мерился в момент добавления: насколько лучше стало от того, что мы его внесли. Так накопился список: вот эта идея стоит столько-то, вот эта — столько-то. Список сходился с общим результатом, и это выглядело подтверждением.

Недавно мы проверили тот же список *наоборот*: не «сколько добавляет элемент к тому, что было», а «сколько теряется, если убрать его из готовой модели». Разница оказалась большой.

Кое-что подтвердилось почти точь-в-точь — правка на «мёртвую зону» и нейросеть стоят ровно столько, сколько записано. Зато та самая модель, которая учится на всех ферментах сразу, в готовом ансамбле **не добавляет уже ничего**: без неё получается даже чуть-чуть лучше. Механизм с контрастом реален, но к моменту, когда усреднены четыре остальных, всё, что этот участник приносил, там уже есть.

Это общее свойство, а не курьёз. Пока система растёт, элементы начинают дублировать друг друга, и вклад, измеренный на пустом месте, перестаёт что-либо говорить о вкладе здесь и сейчас. Единственный способ узнать правду — выбивать элемент из готовой системы, а не добавлять его к пустой.

8. Как мы себя проверяем

Эта часть ближе всего к тому, как устроена работа в лаборатории, и мы относимся к ней серьёзнее, чем к самим моделям.

Проверка на неродственников. Легко получить красивое число, если проверять модель на молекулах, у которых в обучении лежат близкие аналоги: тогда достаточно узнать знакомое. Мы разбиваем данные так, чтобы структурно похожие соединения попадали в одну группу целиком, и группа целиком уходит либо в обучение, либо в проверку.

Шумовой порог. Прежде чем радоваться улучшению, надо знать, какого размера бывает случайная разница. Мы это померили: одна только перетасовка разбиения двигает результат сильнее, чем типичный эффект, который хочется объявить улучшением. Всё, что меньше порога, у нас не считается результатом — даже если очень хочется.

Условия — до прогона. Прежде чем запускать проверку идеи, мы записываем, какой результат будем считать успехом. Это ровно то же, что регистрация протокола до эксперимента, и по той же причине: иначе критерий незаметно подстраивается под то, что получилось.

Журнал. Всё измеренное лежит в одном файле, устроенном как журнал *неудач*: верная идея занимает один пункт, неверная — три (выдвижение, опровержение, поправка к опровержению). Соотношение при чтении выходит примерно три к одному в пользу провалов, и это честная картина того, как идёт работа.

9. Что мы про себя знаем плохого

На той метрике, которую показывает турнирная таблица, весь наш выигрыш меньше шума одного замера. Разброс результата от одного прогона к другому больше, чем всё, что мы набрали за месяцы. По рангу мы уверенно вне шума, но ранг в таблице не показывают. Это надо знать заранее, чтобы не делать выводов из одной цифры на промежуточном этапе.

Наша проверка строже настоящего экзамена, и не в ту сторону. Мы намеренно проверяем себя на молекулах без близких родственников. А спрятанные соединения устроены иначе: они ближе к обучающей выборке, чем обучающая выборка сама к себе. Грубо говоря, у каждого пятого тестового соединения есть близкий аналог среди наших — а в нашей проверке такое встречается примерно в одном случае из ста. Мы измеряем себя в режиме, в котором экзамена почти не будет.

Один из четырёх ферментов ведёт себя иначе, и мы не до конца понимаем почему. На CYP3A4 почти всё, что помогает остальным, помогает слабее или не помогает вовсе. В итоге для него подаётся не коллегия, а один-единственный её участник. Отдельно выяснилось, что обучающая выборка по этому ферменту — это на самом деле два разных набора, склеенных вместе: широкий скрининг и аналоговая серия.

Мы не знаем, насколько тестовый набор смещён по активности относительно обучающего. Финальное перемасштабирование настраивается под предположение об этом смещении, и это предположение — самое крупное допущение во всём решении.

10. Второй трек: обратимое против необратимого

Здесь получился результат в двух частях. Первая — про то, как правильно поставить задачу; вторая — про то, что в самих данных нашлась поломка.

Задачу поставили неверно, и это видно из условия

Надо предсказывать метку «зависит от времени» — да или нет. Мы долго строили под неё классификаторы и упирались в потолок. Оказалось, зря: **организаторы задали эту метку формулой, и формула напечатана в условии**. Соединение помечается положительным, если после преинкубации оно подавляет фермент как минимум вдвое сильнее, чем без неё, — плюс оговорка про слабые соединения, у которых сдвиг нельзя измерить напрямую. Никакой скрытой закономерности тут нет; это определение, а не наша находка.

Находка в другом — в том, что из этого следует. Раз метка *вычисляется* из двух измеренных величин (потентности в обычном плече и в плече с преинкубацией), учить «что такое TDI» не нужно вовсе. Достаточно предсказать эти две физические величины — ровно те же, что и на первом треке, — и подставить их в готовую формулу. Мы так и делаем. На соединениях, где оба плеча измерены, формула воспроизводит опубликованную метку без единого исключения (2334 из 2334 для CYP3A4, 1493 из 1493 для CYP2D6) — это не заслуга модели, а подтверждение, что мы правильно прочли условие.

Из той же формулы читается, почему два фермента даются по-разному. Потентность — необходимое условие: слабое соединение не может быть положительным, как бы ни сдвигалось. На CYP3A4 это условие отсекает около 40 % соединений, и распознать их — отдельная задача про силу, которую модель решает хорошо. На CYP2D6 оно отсекает лишь около 6 %, поэтому там метка — это почти целиком вопрос сдвига. Вся разница в качестве между двумя ферментами объясняется этим одним числом, и никакого другого объяснения не требует.

Тысяча меток оказалась заглушками

Проверяя формулу, мы наткнулись на то, что стоит рассказать отдельно, потому что это про целостность данных, а не про модель.

У части соединений измерено только плечо с преинкубацией, а обычного плеча нет. По CYP3A4 таких **1249**, и *все до одного* помечены отрицательными — при том, что в среднем по этому ферменту положителен каждый третий. Более того: у 1055 из этих 1249 (около 85 %) потентность после преинкубации выше порога, за которым только и возможен положительный ответ, и по потентности эти соединения *сильнее* размеченной популяции, а не слабее (медиана 5.4 против 4.6).

Иными словами, это ровно те соединения, среди которых положительных должно быть особенно много, а стоит ноль. Если бы метки были настоящими измерениями, хоть сколько-то из 1249 оказались бы положительными; их ноль. Единственное разумное прочтение — **это не измерения, а заполнитель**: пустые клетки, залитые словом «нет». Практический вывод прямой: эти строки нельзя давать классификатору, иначе он учится на тысяче перевёрнутых меток. Мы их исключаем.

11. Итог

Наше решение — это не одна большая модель, а пять средних, усреднённых, с двумя правками до и после: одна учит модель целиться в полосу измерения, а не в точку, вторая приводит итоговую шкалу в порядок.

Больше всего выигрыша принесли не алгоритмы, а внимательное чтение условия: то, что метрика прощает попадание в полосу погрешности. Второе по важности — собственное наблюдение, а не правило: общий сдвиг можно снять одним дешёвым шагом в самом конце, а значит бороться с ним внутри модели незачем, и всё внимание надо отдать порядку.

И, пожалуй, главное, что мы вынесли. Из идей, которые кажутся разумными, работает примерно одна из четырёх. А из тех, что уже сработали когда-то, часть перестает работать, когда вокруг них вырастает всё остальное, — и заметить это можно, только если время от времени разбирать собственную конструкцию обратно.