

Модель предсказания ингибирования цитохромов P450

Устройство решения для OpenADMET CYP Blind Challenge: что в данных,
что мы измерили, как устроена модель и почему именно так

27 августа 2026

Аннотация

Документ описывает решение задачи предсказания ингибирования четырёх изоформ цитохрома P450 по структуре молекулы. Содержит разбор того, что лежит в данных и что мы из них измерили, устройство модели и обоснование каждого её элемента, протокол проверки и список того, что уже проверено и не работает. Все числа получены прогонами на открытых данных соревнования и воспроизводимы; графики построены по тем же прогонам. Рассчитан на две аудитории сразу: на химика, знакомого с основами машинного обучения, и на специалиста по машинному обучению, знакомого с основами биохимии.

Содержание

1	Задача	3
1.1	Метрика регрессии и что из неё следует	3
1.2	Метрика классификации	3
2	Биохимия задачи	4
2.1	Что такое цитохромы P450 и почему именно эти четыре	4
2.2	Почему ингибирование — проблема	4
2.3	Что такое IC_{50} и pIC_{50}	5
2.4	Как читают результат и откуда берутся артефакты	5
2.5	Что такое time-dependent ингибирование	5
2.6	Что такое E_{max} и положительный контроль	6
2.7	Чем четыре фермента различаются	6
3	Данные	7
3.1	Что меряют эти таблицы	7
3.2	Как собран тестовый набор	8
4	Что мы измерили до того, как что-то строить	9
4.1	Версия первая: метки шумные, учить нечего	10
4.2	Версия вторая: не хватает нужных признаков	10
4.3	Версия третья: дело в том, какие соединения попали в выборку	11
5	Порождающая модель	13
5.1	Правдоподобия по источникам	14
5.2	Калибровка прибора	14
5.3	Почему цензурирование получается само	16
6	Идентифицируемость	17
6.1	Крутизна — на уровень фермента	17
6.2	Глубина: амортизация вместо поштучной подгонки	17
6.3	А теперь измерения, и они меняют вывод	18

7	Механизм пропусков	19
7.1	Как раскладывается совместное распределение	19
7.2	Что даёт симуляция	20
8	Архитектура	20
8.1	Ствол	20
8.2	Связь между ферментами: коррегионализация	21
8.3	Механистический блок	23
8.4	Канал артефактов пробы	23
8.5	Головы	23
9	Функция потерь и обучение	23
9.1	Батчинг по молекулам, а не по строкам	24
9.2	Двухэтапная калибровка	24
9.3	Веса источников	24
10	Неопределённость	24
11	Решающий слой	25
11.1	Регрессия: вывод	25
11.2	Регрессия: то, что работает	27
11.3	TDI: здесь слой окупается	29
12	Трансдуктивный слой	30
12.1	Сдвиг распределения	31
12.2	Серийный случайный эффект	31
13	Протокол оценки	31
13.1	Уровней строгости меньше, чем задумывалось	31
13.2	Насколько наша проверка похожа на тест	32
13.3	Устойчивость к разбиению	34
13.4	Устойчивость к версии библиотеки	35
13.5	Парный бутстрап	35
13.6	Сетка абляций	35
14	Что уже измерено	36
14.1	Совместное правдоподобие: первый запуск	37
15	Что сломается и по какому признаку это видно	41
16	Что не проверено	42
17	Сводка чисел	43

1. Задача

Вход — SMILES молекулы. Оцениваемых треков два: регрессия и классификация. Третий, предсказание позы лиганда в кармане фермента, откроется в середине соревнования и здесь не разбирается.

В регрессионном треке нужно выдать матрицу $\hat{Y} \in \mathbb{R}^{750 \times 4}$: pIC_{50} прямого ингибирования для CYP1A2, CYP2C9, CYP2D6 и CYP3A4. В классификационном — $\hat{Y} \in \{0, 1\}^{750 \times 2}$: метку time-dependent ингибирования для 3A4 и 2D6. Тестовые 750 соединений выданы без меток, отправка закрывается 3 ноября.

1.1. Метрика регрессии и что из неё следует

Метрика — не средняя абсолютная ошибка. Организаторы публикуют вместе с каждым pIC_{50} границы доверительного интервала байесовской подгонки кривой, и ошибка считается до ближайшей границы, а не до точечной оценки:

$$\text{ST-RAE} = \frac{\sum_i [(\hat{y}_i - h_i)_+ + (l_i - \hat{y}_i)_+]}{\sum_i [(\bar{y} - h_i)_+ + (l_i - \bar{y})_+]}, \quad \bar{y} = \frac{1}{n} \sum_i y_i. \quad (1)$$

Здесь l_i и h_i — нижняя и верхняя границы интервала i -го соединения, а $(\cdot)_+ = \max(\cdot, 0)$. Числитель: предсказание, попавшее внутрь полосы, не штрафуетсся вовсе, а вышедшее наружу штрафуетсся только на расстояние до ближайшего края. Знаменатель: та же величина для константного предсказателя, выдающего среднее по оценочному набору. Отношение единица означает, что модель не лучше предсказания одного числа для всех соединений подряд; меньше единицы — лучше.

Из этого следует три вещи, и каждая влияет на архитектуру.

Первое. Задача интервально-цензурированная, и обучаться надо на той же клипованной L1, а не на квадратичной ошибке. Квадратичная будет тянуть предсказание к центру полосы там, где метрике всё равно, где именно внутри полосы оно стоит.

Второе. Это отношение сумм, а не среднее отношений. Соединения с широкой полосой почти невесомы в обеих частях: они дают мало и в числитель, и в знаменатель. Метрику определяют соединения с узкой полосой, то есть активные, у которых кривая хорошо определена.

Третье. Оптимальная точечная оценка под (1) не обязана совпадать с условным средним предсказательного распределения. Это разбирается в разделе 11.

Знаменатель считается по среднему *того набора*, на котором метрика вычисляется. У нас это среднее по обучающей подвыборке фермента, на лидерборде — по 750 тестовым соединениям. Значит наши числа и числа лидерборда напрямую несопоставимы, даже если модель одна и та же; сопоставимы только разности между вариантами, посчитанные на одном наборе.

1.2. Метрика классификации

Для TDI считается коэффициент корреляции Мэтьюса:

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}. \quad (2)$$

Это коэффициент корреляции Пирсона между двумя бинарными векторами, предсказанным и истинным. При несбалансированных классах он ведёт себя куда

честнее точности: предсказать всем «нет» даёт точность 78 процентов и МСС ровно ноль.

МСС не раскладывается по объектам. Вклад одного соединения зависит от того, что предсказано остальным, потому что все четыре счётчика стоят под общим корнем. Отсюда следует, что порог 0.5 почти никогда не оптимален и его надо выбирать явно — см. раздел 11.

Обе метрики агрегируются макро-усреднением по эндпойнтам, и лидерборд сортируется по этому среднему. Организаторы пересчитывают его на 1000 бутстрап-выборках.


2. Биохимия задачи

Раздел для тех, кто пришёл со стороны машинного обучения: что физически стоит за каждой колонкой в данных. Без этого половина решений в модели выглядит произволом.

2.1. Что такое цитохромы P450 и почему именно эти четыре

Цитохромы P450 — надсемейство гем-тиолатных монооксигеназ. Гем — порфириновое кольцо с железом в центре, то же самое, что в гемоглобине; «тиолатные» означает, что пятое координационное место железа занимает атом серы остатка цистеина. Название историческое: восстановленный комплекс фермента с угарным газом даёт полосу поглощения при 450 нм.

Каталитический цикл в общем виде: фермент связывает субстрат, железо восстанавливается, присоединяет кислород, кислород расщепляется с образованием высокореакционного оксоферрильного интермедиата (Compound I), который вырывает водород у субстрата и вставляет туда гидроксил. Суммарно



Электроны поставляет НАДФН через флавопротеин цитохром-P450-редуктазу. Для эксперимента отсюда следует вот что: без НАДФН фермент не работает, так что катализ можно включать и выключать в пробирке. На этом приёме построено измерение TDI.

Смысл реакции — сделать липофильную чужеродную молекулу более полярной, чтобы её можно было конъюгировать (вторая фаза метаболизма) и вывести. Печёночные P450 — главный барьер между проглоченным веществом и системным кровотоком.

Изоформ у человека около 57, но лекарственный метаболизм сосредоточен в немногих. CYP3A4 отвечает примерно за половину всех оборотов, CYP2D6, CYP2C9, CYP2C19 и CYP1A2 — за большую часть остального. Четвёрка в соревновании покрывает подавляющее большинство клинически значимых взаимодействий.

2.2. Почему ингибирование — проблема

Если препарат А ингибирует фермент, который выводит препарат В, концентрация В в крови растёт — иногда в разы. Для препарата с узким терапевтическим окном это прямая дорога к токсичности, вплоть до снятия с рынка уже зарегистрированного средства, безопасного само по себе.

Поэтому ингибирование P450 проверяют рано, ещё на стадии выбора соединения-кандидата. Предсказание по структуре экономит эти пробы, и цена ошибки здесь измеряется в снятых с разработки молекулах.

2.3. Что такое IC_{50} и pIC_{50}

В пробу вносят фермент, зонд-субстрат с известной скоростью превращения и испытуемое соединение в нескольких концентрациях. Измеряют, насколько упала скорость превращения зонда. IC_{50} — концентрация испытуемого соединения, при которой скорость падает вдвое. $pIC_{50} = -\log_{10} IC_{50}$ в молях на литр: $pIC_{50} = 6$ соответствует одному микромолю, $pIC_{50} = 4$ — ста микромолям. Больше pIC_{50} — сильнее ингибитор.

Важная оговорка: IC_{50} — не константа связывания. Она зависит от концентрации зонд-субстрата и от механизма (конкурентный ингибитор вытесняется субстратом, неконкурентный — нет); связь с константой ингибирования K_i даёт соотношение Ченга–Прусоффа. Сравнивать IC_{50} между лабораториями и пробами напрямую нельзя, внутри одного набора — можно, и именно это мы и делаем.

2.4. Как читают результат и откуда берутся артефакты

Зонд-субстрат подбирают так, чтобы его превращение было легко измерить. Способов два.

Флуоресцентный: зонд после окисления даёт флуоресцирующий продукт, и прибор просто меряет свечение. Дёшево и быстро, поэтому так сделаны 1A2, 2C9 и 3A4 в этом наборе.

Масс-спектрометрический: продукт детектируют по массе. Дороже, но специфичнее; так сделан 2D6.

Отсюда конкретный артефакт. Если испытуемое соединение само флуоресцирует в том же диапазоне или, наоборот, тушит флуоресценцию продукта, прибор покажет изменение сигнала, которого химически не было. Ложное «ингибирование» появится в трёх флуоресцентных эндпойнтах и не появится в масс-спектрометрическом. Поэтому в модели заведён отдельный канал артефактов пробы (раздел 8.4): это конфаундер с известной структурой, а не шум.

2.5. Что такое time-dependent ингибирование

Обычное ингибирование обратимо: молекула садится в карман, мешает субстрату, отпускает. Уберите ингибитор — активность вернётся.

Time-dependent ингибирование, оно же механизм-зависимая инактивация, устроено иначе. Фермент сам превращает соединение в реакционноспособный продукт, и этот продукт остаётся — ковалентно модифицирует гем или белок, либо образует прочный комплекс с железом (metabolite-intermediate complex). Фермент выведен из строя необратимо. Отличительные признаки: процесс требует катализа (без НАДФН не идёт), развивается во времени, насыщается по концентрации, и активность не восстанавливается отмывкой.

Клинически это гораздо хуже обратимого ингибирования. Обратимый ингибитор перестаёт мешать, как только выводится из организма. Инактивированный фермент восстанавливается только синтезом нового белка, а на это уходят сутки-двое. Поэтому эффект накапливается при повторных приёмах и держится долго после отмены.

Как это измеряют. Ставят два плеча одной пробы.

Прямое плечо: соединение и зонд-субстрат вносят одновременно, сразу меряют IC_{50} . Видно обратимое ингибирование.

Плечо с преинкубацией: соединение сначала выдерживают с ферментом и НАДФН, дав катализу поработать, и только потом вносят зонд и меряют IC_{50} . Если соединение — механизм-зависимый инактиватор, за время преинкубации часть фермента выведена из строя, и измеренная IC_{50} окажется ниже: соединение выглядит потентнее, чем было.

Разница между плечами и есть сигнал. В логарифмической шкале это сдвиг

$$\Delta = \pi_{\text{после преинкубации}} - \pi_{\text{прямое}} \geq 0,$$

и неотрицательность здесь не соглашение, а физика: преинкубация может только добавить инактивации, но не отменить обратимое связывание. Двукратный сдвиг IC_{50} — то есть $\Delta > \log_{10} 2 \approx 0.301$ — общепринятый порог, за которым соединение помечают как TDI.

Отсюда становится понятной вторая ветвь правила разметки из раздела 11. Соединение может быть настолько слабым обратимым ингибитором, что в прямом плече его IC_{50} вообще не определяется как значимая ($\pi \leq 4$, то есть слабее ста микромолей). Но если после преинкубации оно перешло порог активности с тем же двукратным запасом ($\pi + \Delta > 4 + \log_{10} 2$), это тоже TDI — просто инактивация оказалась единственным его механизмом. Правило и состоит из этих двух случаев.

2.6. Что такое $E_{\max}$ и положительный контроль

Кривая доза-эффект выходит на плато. Высота плато — $E_{\max}$, предельная доля подавленной активности. Полный ингибитор обнуляет активность, частичный оставляет какую-то долю сколь угодно высокой концентрации. Причины частичности бывают разные: соединение садится не в каталитический карман, а в аллостерический; или у фермента несколько сайтов связывания субстрата, как у CYP3A4.

Измеряют $E_{\max}$ не в абсолютных единицах, а относительно положительного контроля — известного полного ингибитора этого фермента, который ставят в ту же пробу. Отсюда шкала в данных: полный ингибитор даёт примерно -1 , потому что подавил столько же, сколько контроль. Такая нормировка снимает разброс между планшетами и партиями фермента.

2.7. Чем четыре фермента различаются

Отсюда понятно, почему модель устроена как многозадачная с явной матрицей связей, а не как одна голова.

CYP3A4 — самый крупный и самый неразборчивый. Активный карман большой и податливый, вмещает молекулы вплоть до циклических пептидов; в нём помещается больше одного лиганда одновременно, откуда кооперативность и не всегда сигмоидные кривые. Узнавание в основном гидрофобное, поэтому предсказатель «крупная жирная молекула — вероятный ингибитор» работает удивительно хорошо. Отсюда и лучшая предсказуемость 3A4 в наших измерениях.

CYP2C9 — карман поменьше, на входе положительно заряженный остаток аргинина, притягивающий анионы. Субстраты преимущественно кислые, с карбоксильной или другой ионизуемой группой. С 3A4 частично перекрывается по липофильности, отсюда ранговая корреляция 0.69.

CYP1A2 — узкая плоская щель. Субстраты — плоские ароматические системы, полициклика и азотистые гетероциклы. Они же его и индуцируют, из-за чего у курильщиков клиренс некоторых препаратов заметно выше.

CYP2D6 объясняет половину этого документа. В активном центре сидят остатки аспартата и глутамата, дающие солевой мостик с протонированным атомом азота лиганда. Практически все известные субстраты и ингибиторы 2D6 — основания, заряженные при физиологическом pH. Узнавание идёт не по общей липофильности, а по конкретному электростатическому взаимодействию на конкретном расстоянии от ароматического ядра.

Долю протонированной формы даёт уравнение Гендерсона–Хассельбальха:

$$f_{\text{прот}} = \frac{1}{1 + 10^{\text{pH} - \text{p}K_a}}. \quad (3)$$

При pH 7.4 третичный амин с $\text{p}K_a$ около 9.8 заряжен на 99.6 процента, пиридиновый азот с $\text{p}K_a$ 5.2 — на 0.6 процента, а амид не заряжен вовсе. Разница в сто с лишним раз по доле заряженных молекул. Фингерпринт, считающий фрагменты в радиусе двух связей, видит во всех трёх случаях просто «атом азота в таком-то окружении» и различить их не может — отсюда механистический блок признаков.

И ещё: 2D6 сильно полиморфен. Часть популяции несёт неработающие аллели, часть — дубликации гена; это делает предсказание ингибирования 2D6 клинически особенно ценным, но на наши данные не влияет, поскольку измерения делаются на рекомбинантном ферменте одного варианта.

3. Данные

Пять таблиц, около 35 тысяч строк. Устройство этих данных важнее их объёма: вся конструкция модели вырастает из одной асимметрии. Обучающая матрица разрежена и смещена отбором, тестовая плотная.

Источник	Форма	Заполнено	Что это
Кривые доза-эффект, прямое плечо	4905 × 4	26–48 %	pIC_{50} плюс границы интервала и стандартная ошибка
Кривые, плечо преинкубацией	с 6145 × 4	21–58 %	то же для условия TDI
E_{max} , оба плеча	6146 × 8	частично	предельная глубина подавления и её интервал
Одноточечный скрининг	4376 × 4	100 %	$\log_2 f_c$ при 49.5 мкМ и стандартная ошибка
Тест	750 × 4	—	слепой, плотный

Таблица 1. Пять источников. Пересечения между ферментами внутри таблицы кривых маленькие: одновременно для 1A2 и 2C9 измерено 295 соединений, для 2C9 и 2D6 — 230. Скрининг — единственный плотный источник, и он покрывает весь диапазон активностей, включая неактивные соединения, которых в кривых почти нет.

3.1. Что меряют эти таблицы

Кривая доза-эффект: соединение разводят по концентрациям, для каждой измеряют, насколько подавлена активность фермента, и через полученные точки проводят

сигмоиду. Из подгонки получают pIC_{50} — отрицательный десятичный логарифм концентрации, при которой активность падает вдвое. Байесовская подгонка даёт не только точку, но и интервал, отражающий, насколько уверенно эта точка определена. У соединений, чья кривая не дошла до плато, интервал широкий.

Одноточечный скрининг: то же измерение, но при одной концентрации 49.5 мкМ. На выходе $\log_2 fc$ — логарифм отношения сигнала с соединением к сигналу без него. Ноль означает, что ничего не произошло, отрицательные значения — что активность подавлена.

Полные кривые снимали не для всех подряд. Соединение поднимали на подробное измерение, если оно показало эффект на скрининге. Это отбор по зависимой переменной, и он деформирует обучающую выборку способом, который разобран в разделе 4.3.

Правило это не универсальное. Скрининг есть у 4375 из 4905 соединений с кривыми; у оставшихся 530 его нет, и все 530 несут метку *только* по 3A4 — на 1A2, 2C9 и 2D6 у них меток ноль. То есть для трёх ферментов отбор по скринингу описывает выборку целиком, а на 3A4 почти четверть кривых (530 из 2335) пришла каким-то другим путём, и для них аргумент про отбор просто не про них.

3.2. Как собран тестовый набор

Организаторы описали процедуру: взяли по 25 лучших ингибиторов каждого из 1A2, 2C9 и 3A4, к каждому добавили по 10 ближайших соседей по фингерпринту, итого $3 \times 25 \times 10 = 750$.

Это проверяется, и проверка сходится частично. Здесь важно, что порог кластеризации выбирается, а не выводится, и картина от него зависит сильно. При рабочем пороге 0.35 из 750 тестовых соединений выходит 477 групп с медианным размером один, групп по пять и более членов 21, и в них лежат 155 соединений. При 0.48 — 203 группы с медианным размером два, 56 групп по пять и более, в них 496 соединений. То есть серийная структура в наборе есть, но её видимый охват меняется от пятой части до двух третей в зависимости от того, что считать серийей. Ровно 75 серий ровно по 10 не восстанавливается ни при каком пороге — число 75 получается делением 750 на 10.

Что восстанавливается уверенно, так это положение якорей: оно от порога почти не зависит. Для каждой группы найдено ближайшее обучающее соединение, и его активность стоит на 92–94 перцентиле обучающего распределения по 1A2 и на 97.5–99 по 2C9 при любом пороге от 0.35 до 0.50, тогда как по 2D6, который в отборе не участвовал, — на 58–66. По 3A4 оценка гуляет заметно шире, от 82 до 95, и опираться на неё точное число нельзя. Оговорка, без которой эти проценты читаются неверно: якорей с меткой всего от девяти до тридцати семи на фермент, так что медиана здесь имеет широкий интервал. Медианное сходство Танимото тестового соединения с ближайшим обучающим равно 0.587.

Значит распределение меток на тесте не совпадает с обучающим: тест обогащён активными по трём ферментам и близок к фону по четвёртому. И устроен он как набор серий аналогов вокруг известных хитов, а не как случайная выборка из химического пространства. Проверять модель надо соответственно.

4. Что мы измерили до того, как что-то строить

Первое, что было сделано — простая базовая линия и разбор, почему она ведёт себя так, как ведёт. Без этого нет способа отличить работающую конструкцию от красивой.

Базовая линия: счётчики фрагментов Моргана радиуса 2 (2048 бит), 217 дескрипторов RDKit, градиентный бустинг, пятикратная кросс-валидация по кластерам Бутины при пороге сходства 0.35.

Три вещи из этого перечисления стоит расшифровать сразу, потому что дальше они встречаются на каждой странице.

Счётчики фрагментов Моргана — способ описать молекулу числами: перебираются все её фрагменты до заданного радиуса вокруг каждого атома, и каждый попадает в свою ячейку из двух тысяч. Получается длинный вектор, по которому похожие молекулы похожи. *Дескрипторы* — две сотни обычных вычислимых характеристик: молекулярная масса, липофильность, число доноров водородной связи и так далее.

Кросс-валидация — способ честно измерить качество, не имея тестовых меток. Выборка режется на пять частей; модель учат на четырёх и предсказывают пятую, потом меняют, какая часть отложена, и так пять раз. В итоге у каждого соединения есть предсказание от модели, которая его *не видела*. Такие предсказания называют предсказаниями вне фолда, и только они годятся для оценки: числа, посчитанные на тех же молекулах, на которых учились, показывают способность запоминать, а не предсказывать.

По кластерам Бутины — уточнение, зачем нужно отдельное объяснение. Если резать выборку случайно, близкий структурный аналог соединения легко останется в обучении, и модель «угадает» его по родственнику. Поэтому соединения сначала группируют по сходству, и в отложенную часть уходит целая группа целиком. Насколько это на самом деле меняет дело — отдельный вопрос, к нему мы вернёмся в разделе 13, и ответ там неожиданный.




Рис. 1. Базовая линия регрессионного трека. Красная линия — уровень предсказания одного числа для всех соединений. CYP3A4 предсказывается вдвое лучше этого уровня, CYP2D6 — на семь тысячных.

Прежде чем читать числа, стоит договориться о шкале. Метрика конкурса, ST-RAE, устроена так, что **меньше — лучше**, а единица — это уровень бессмысленного предсказания: столько получится, если всем соединениям подряд выдать одно и то же число. Всё, что заметно ниже единицы, — работа модели; всё, что около единицы,

— её отсутствие.

По этой шкале CYP3A4 предсказывается примерно вдвое лучше бессмысленного уровня, а CYP2D6 — на семь тысячных лучше него, то есть не предсказывается вовсе. Три остальных фермента располагаются между этими крайностями. Ранговое согласие (насколько верно модель расставляет соединения по порядку активности, безотносительно самих чисел) даёт ту же картину: на 3A4 оно высокое, на 2D6 — вдвое ниже.

CYP2D6 и стал главным предметом разбирательства, потому что от объяснения зависит, что вообще строить дальше. Ниже три версии, по очереди.

4.1. Версия первая: метки шумные, учить нечего

Если почти весь разброс опубликованных активностей — погрешность измерения, то потолок для любой модели низкий и делать нечего. Обычно разделить настоящий разброс и шум трудно, но здесь вместе с каждым значением опубликована его собственная стандартная ошибка.

Дисперсии независимых источников разброса складываются, поэтому

$$\text{Var(наблюдаемое)} = \text{Var(настоящее)} + \text{Var(шум)}, \quad \text{надёжность} = 1 - \frac{\text{Var(шум)}}{\text{Var(набл.)}}. \quad (4)$$

Надёжность — доля разброса меток, которая приходится на настоящие химические различия. Она же задаёт потолок R^2 для любой модели на этих метках: предсказать шум нельзя.

Для CYP2D6 надёжность выходит **0.93**: девяносто три процента разброса опубликованных активностей — это настоящие химические различия, и только семь процентов — погрешность прибора. У остальных трёх ферментов примерно столько же. Версия не подтвердилась: учить есть чему.

Более того, сравнение с этим потолком показывает, насколько велик недобор. На CYP2D6 модель осваивает лишь восьмую часть того, что метки в принципе позволяют освоить, а на CYP3A4 — две трети. Дело, стало быть, не в том, что данные плохи, а в том, что модель их не берёт.

Оговорка, которую надо держать в голове. Надёжность посчитана через *средний квадрат* погрешности, и это существенно, потому что погрешность распределена крайне неравномерно: у типичного соединения она в несколько раз меньше средней, а почти шестьдесят процентов всего шума дают верхние пять процентов соединений, у которых подгонка кривой развалилась. Число в (4) от этого не портится — туда и должен идти средний квадрат, — но следствие важное: взвешивать соединения по их индивидуальной погрешности имеет гораздо больше смысла, чем кажется, если смотреть только на среднее.

4.2. Версия вторая: не хватает нужных признаков

Как разобрано в разделе 2.7, CYP2D6 узнаёт субстраты через солевой мостик с протонированным азотом, а не через общую липофильность. Фингерпринт про заряд не знает: третичный амин и амид для него — два похожих азота в похожем окружении, хотя доля заряженной формы у них различается в сотни раз.

Собрали блок из 30 химически осмысленных чисел: оценка pK_a самого основного центра, доля протонированной формы при pH 7.4, полный заряд молекулы, счётчики

классов азота и кислотных групп, топологическое расстояние от заряженного азота до ближайшего ароматического кольца. Оценщик pK_a — правило: базовое значение класса минус индуктивный штраф от электроноакцепторных заместителей с затуханием по числу связей. На двадцати соединениях с литературными значениями средняя ошибка 0.60 единицы, медианная 0.2, и на бинарный вопрос «заряжено ли при 7.4» правило ответило верно во всех двадцати случаях.

Результат двойственный, и это тот случай, когда полезно смотреть на две метрики сразу.

Чтобы понять, что было дальше, нужна одна процедура. Сравнивая две модели, мало посмотреть, у какой число лучше: разница может целиком объясняться тем, какие соединения случайно попали в выборку. Поэтому выборку многократно пересобирают с возвращением и всякий раз считают разность — это называют парным бутстрапом. Получается интервал, в котором разность лежит правдоподобно. Если интервал накрывает ноль, различить две модели этими данными нельзя.

По метрике конкурса выигрыша нет. Интервал накрывает ноль и на CYP2D6, и на макро. Механистический блок, придуманный ровно под механизм CYP2D6, по ST-RAE не даёт ничего.

По ранжированию выигрыш есть, и он избирателен именно так, как предсказывает химия. На CYP2D6 ранговое согласие растёт с 0.35 до 0.40, и здесь интервал ноль уже не накрывает. На CYP2C9 прирост на грани различимости, а на CYP1A2 и CYP3A4 — нули. То есть блок помогает там и только там, где по химическим соображениям и должен.

Ещё показательнее вот что. Модель, построенная на одних только тридцати механистических числах — без фингерпринта и без дескрипторов вообще, — воспроизводит на CYP2D6 почти всю ранжирующую способность полной модели. На трёх остальных ферментах те же тридцать чисел дают примерно половину. Сигнал CYP2D6, стало быть, низкоразмерный и химически специфичный: его несут несколько осмысленных величин, а не две тысячи структурных битов.

Итог: механизм назван верно, но выигрыш по метрике соревнования неотличим от нуля. Признаки — часть ответа, не главная его часть.

4.3. Версия третья: дело в том, какие соединения попали в выборку

У CYP2D6 отбор оставил узкую полосу: средняя половина соединений уместилась в интервал шириной 0.83 логарифмической единицы против 1.50 у CYP3A4. Это ограничение диапазона, оно же *selection on the dependent variable*: если отобрать объекты по интересующему признаку и потом мерить связь только среди отобранных, связь ослабевают, хотя в полной популяции она никуда не делась.

Проверка требует второго показателя активности того же фермента, измеренного без отбора. Он есть: $\log_2 fc$ скрининга, снятый для 4375 соединений подряд, включая неактивные. Учим ту же модель на тех же признаках и тех же фолдах предсказывать его вместо pIC_{50} .

Чтобы это не превратилось в сравнение «больше примеров против меньше», сделан контроль: из соединений со скринингом случайно выбирается ровно столько же, сколько у этого фермента меток кривых.

Результат ложится ровно так, как предсказывает объяснение через ограничение диапазона: чем уже полоса меток у фермента, тем больше выигрыш от перехода на показатель с полным диапазоном. Порядок ферментов по величине выигрыша в точности обратен порядку по ширине полосы, а на CYP3A4 — у которого полоса самая




Рис. 2. Распределения измеренных активностей. Цветом выделены средние 50 процентов соединений. У CYP3A4 задача во многом сводится к тому, чтобы отделить левую часть от правой. У CYP2D6 левой части почти нет, и модели приходится различать соединения внутри узкой полосы.




Рис. 3. Выигрыш от перехода на показатель с полным диапазоном против ширины полосы меток. Пустой кружок — качество на метках кривых, закрашенный — на скрининге при равном числе обучающих примеров. Стрелка тем длиннее, чем уже полоса меток, и на CYP3A4 разворачивается.

широкая — выигрыш вообще меняет знак.

Этот отрицательный знак важнее самой монотонности: он работает внутренним контролем. Если бы дело было просто в том, что скрининг легче предсказуем сам по себе, выигрыш был бы положительным везде. Он не положительный везде. На CYP2D6 же доля объяснённой дисперсии при равном числе обучающих примеров вырастает более чем вдвое.

Модель прекрасно умеет учить химию CYP2D6, но не может показать это на выданных метках. Основная причина провала — геометрия меток, и чинится она не признаками, а тем, что в правдоподобие входит источник с полным диапазоном. На этом и построено всё остальное.

Честная оговорка про контроль: выровнено количество примеров, но не форма распределения меток. Совсем чистый эксперимент требует подобрать подвыборку так, чтобы совпадало и то и другое.

5. Порождающая модель

Все пять таблиц — наблюдения над одним объектом: кривой доза-эффект для тройки «молекула m , фермент e , плечо a » (плечо — прямое измерение или измерение после преинкубации). Модель описывает эту кривую, а не отдельные таблицы, и каждая таблица подключается своим правдоподобием.

Слово «правдоподобие» здесь ключевое и дальше встречается постоянно, поэтому стоит сказать, что за ним стоит. Настоящей кривой мы не видим никогда — видим только результаты измерений, каждое со своим шумом. Правдоподобие отвечает на вопрос: если предположить, что настоящая кривая вот такая, насколько ожидаемым было бы то, что мы на самом деле намерили? Обучение состоит в переборе возможных кривых в пользу тех, при которых наблюдения выглядят наименее удивительно. Записывают это обычно через $-\log p$ — логарифм берут, чтобы вероятности разных измерений складывались, а не перемножались, а минус — чтобы задача стала задачей минимизации. Ценность такой записи в том, что каждый источник данных добавляет в общую сумму своё слагаемое, и разные по природе измерения оказываются на одном языке.

Латентные параметры тройки:

$$\theta_{m,e,a} = (\pi_{m,e,a}, E_{m,e,a}, h_e), \quad \pi_{m,e,\text{tdi}} = \pi_{m,e,\text{dir}} + \Delta_{m,e}, \quad \Delta \geq 0. \quad (5)$$

Здесь π — потенция, та самая pIC_{50} ; E — предельная глубина подавления, то есть какая доля активности фермента подавляется при бесконечной концентрации; h — крутизна перехода, вынесенная на уровень фермента (почему — в разделе 6). Сдвиг Δ неотрицателен, потому что преинкубация может только усилить ингибирование, а не ослабить.

Прямая модель прибора — доля подавленной активности при концентрации C :

$$I(C; \theta) = \frac{E}{1 + 10^{h(\text{pC} - \pi)}}, \quad \text{pC} = -\log_{10} C. \quad (6)$$

Уравнение Хилла. При $\text{pC} = \pi$, то есть когда концентрация равна IC_{50} , показатель обнуляется и подавлена ровно половина от предельной глубины. Выше концентрация — меньше pC — отрицательнее показатель — ближе I к E . Ниже — наоборот. Крутизна h задаёт, за сколько декад концентрации происходит переход: при $h = 1$ путь от десяти до девяноста процентов эффекта занимает примерно две декады.

5.1. Правдоподобия по источникам

Кривая из двенадцати точек даёт несимметричную оценку: интервал вокруг pIC_{50} обычно длиннее с одной стороны. Усреднять границы — терять эту информацию, поэтому берём расщеплённую нормаль с двумя масштабами:

$$-\log p(y_{\text{крив}} | \pi) = \text{split-}\mathcal{N}(\pi; \hat{\pi}, \sigma^-, \sigma^+), \quad \sigma^- = \frac{\hat{\pi} - l}{1.96}, \quad \sigma^+ = \frac{h - \hat{\pi}}{1.96}. \quad (7)$$

Две половинки нормального распределения с разными ширинами, сшитые в моде и отнормированные общим множителем $2/[\sqrt{2\pi}(\sigma^- + \sigma^+)]$. Правило деления на 1.96 точно только при симметричной полосе: у расщеплённой нормали слева лежит масса $\sigma^-/(\sigma^- + \sigma^+)$, а не половина, поэтому квантиль стоит не в 1.96 сигмы. На наших данных полосы почти симметричны — максимум медианной асимметрии 0.13 логарифмической единицы — и расхождение составляет 0.0004 единицы pIC_{50} . Правило годится, но по этой причине, а не по общей верности.

Скрининг входит через (6) с аффинной калибровкой на фермент:

$$\hat{y}_{\text{скр}} = s_e \cdot \log_2(1 - I(C_0; \theta_{\text{dir}})) + b_e, \quad -\log p(y_{\text{скр}} | \theta, \psi_e) = \frac{(y_{\text{скр}} - \hat{y}_{\text{скр}})^2}{2(\sigma_i^2 + \sigma_e^2)} + \log \sqrt{\sigma_i^2 + \sigma_e^2}. \quad (8)$$

Прибор показывает логарифм оставшейся активности, отсюда $\log_2(1 - I)$. Пара (s_e, b_e) поглощает динамический диапазон пробы и нормировку; σ_i — опубликованная стандартная ошибка конкретного измерения, σ_e — обучаемая добавка, отвечающая за неучтённый разброс. Набор $\psi_e = (s_e, b_e, \sigma_e)$ и есть калибровка прибора.

E_{max} — прямое наблюдение второго параметра тройки; плечо с преинкубацией — наблюдение $\pi + \Delta$ с тем же расщеплённым нормальным правдоподобием.

5.2. Калибровка прибора

Калибровка — это функция, переводящая скрытую кривую в показание прибора. Не свойство соединения, а свойство установки: та же молекула на другом приборе даст другое показание, а pIC_{50} у неё останется прежней. Связь нелинейная и насыщающаяся: очень сильный ингибитор и ингибитор вдесятеро сильнее дадут при 49.5 мкМ практически одинаковое показание, потому что оба подавили всё, что можно.

Подгоняем E и h на фермент по соединениям, у которых есть и то и другое измерение.

Из этой картинки следует три вещи.

Связь очень сильная: ранговая корреляция от -0.83 до -0.94 . Поэтому скрининг — почти достаточная статистика. Свободная монотонная калибровка по *измеренному* показанию даёт макро-ST-RAE 0.359 против 0.767 у полной модели по структуре. Знай мы показание скрининга для тестовых соединений, задача была бы вдвое легче; но на тесте его нет, пересечение теста с первичной библиотекой ровно нулевое.

Хилловская форма теряет немного, но теряет. Стандартное отклонение остатка против свободной монотонной кривой: 0.231 против 0.208 на 1A2, 0.185 против 0.167 на 2C9, 0.497 против 0.390 на 2D6, 0.612 против 0.499 на 3A4. То есть двухпараметрическая форма жёстче, чем нужно, особенно на 2D6, где свободная кривая выходит на плато у неактивных, а хилловская тянется к нулю. Это аргумент за монотонную сплайн-поправку поверх параметрической формы, но не за отказ от неё: форма даёт правильную экстраполяцию там, где данных мало.




Рис. 4. Калибровка. Точки — соединения, у которых есть и pIC_{50} , и показание скрининга. Сплошная линия — подгонка формой (6) с двумя параметрами на фермент, пунктир — свободная монотонная кривая, задающая предел для любой монотонной калибровки.

Крутизна разная: на 3A4 подобралось $h = 1.97$, на остальных около 1.2. Это свойство постановки на конкретном ферменте, поэтому калибровка не может быть общей на все четыре.

Отдельно проверен планшетный дрейф. Планшетов девять на фермент, и сырой разброс медиан по планшетам выглядит тревожно: до 0.293 при размахе 0.922. Но планшеты не рандомизированы, активные соединения сидят кучно, поэтому надо вычесть то, что объясняется составом планшета. После вычитания предсказанного по pIC_{50} разброс падает до 0.039–0.087 при стандартном отклонении остатка 0.19–0.61.

Планшет объясняет от 0.9 до 8 процентов остаточной дисперсии, и разброс по ферментам здесь важнее диапазона: 3A4 0.9 %, 2D6 2.3 %, 1A2 3.2 %, а 2C9 8.1 % — почти в девять раз больше, чем 3A4. Вычитание свободной монотонной калибровкой вместо хилловской даёт 0.9, 2.7, 3.8 и 6.7 процента, то есть та же картина: число — свойство данных, а не выбора калибровки. Отдельного слагаемого в модели всё же не требуется, но по другой причине, чем малость доли: даже на 2C9 планшетная компонента даёт стандартное отклонение около 0.05 в единицах $\log_2 fc$, что заметно меньше собственной погрешности одного показания.

Про обозначение: E в калибровке — не тот E , что в (5). Там предельная глубина подавления самого соединения, здесь — параметр установки, вбирающий её динамический диапазон. Совпадение буквы неудачное и в коде их надо развести.

5.3. Почему цензурирование получается само

Это главный технический аргумент за такую конструкцию. Продифференцируем (6) по потенции, обозначив $x = 10^{h(pC_0 - \pi)}$:

$$\frac{\partial I}{\partial \pi} = +E h \ln 10 \cdot \frac{x}{(1+x)^2}. \quad (9)$$

Множитель $x/(1+x)^2$ максимален при $x = 1$, то есть ровно когда $\pi = pC_0$, и равен там одной четвёртой; при $x \rightarrow 0$ и $x \rightarrow \infty$ он затухает экспоненциально. Фишеровская информация о π , которую несёт одна точка скрининга, пропорциональна квадрату этого множителя.




Рис. 5. Сколько информации о потенции несёт одно измерение при концентрации C_0 . Колокол сосредоточен вокруг pC_0 с шириной порядка $1/h$ декад и обнуляется в обеих зонах насыщения.

На практике это значит, что в зонах насыщения градиент по π исчезает сам. Для соединения, которое при 49.5 мкМ не подавило ничего, модель извлекает из

скрининга мягкое неравенство «активность ниже примерно такой-то», а не число. Для соединения, подавившего всё, — неравенство с другой стороны. Никакого специального кода цензурирования писать не надо, оно следует из формы кривой.

Форма (9) видна в данных напрямую: перегиб зависимости показания от pIC_{50} на CYP3A4 приходится на 4.3 (рис. 4), то есть на $pC_0 = 4.305$ для 49.5 мкМ.

6. Идентифицируемость

Первое, что спросит любой, кто это читает: из однотоочечного измерения наблюдается ровно скаляр $I(C_0)$, а параметров в (5) три. Тройка (π, E, h) точно не идентифицируется — любая кривая, проходящая через ту же ординату при C_0 , объясняет данные одинаково хорошо.

Риск конкретный: сеть сбросит остаток в E , чтобы подогнать показание скрининга, и испортит π — единственную величину, которую с неё спрашивают на лидерборде.

Что с этим делаем, по возрастанию силы ограничения.

6.1. Крутизна — на уровень фермента

h_e , один скаляр на фермент вместо десятков тысяч. Первую версию делаем вообще с $h_e \equiv 1$. Оправдание не только техническое: крутизна кривой в такой пробе определяется в основном механизмом и стехиометрией связывания, а не индивидуальными особенностями лиганда, и подгонка калибровки (раздел 5.2) даёт по ферментам устойчивые 1.11–1.97.

6.2. Глубина: амортизация вместо поштучной подгонки

Есть два способа получить E для каждого соединения.

Поштучная подгонка: у каждого соединения свой свободный параметр E_m . Для 4905 соединений и четырёх ферментов это 19 620 свободных чисел, каждое подбирается только по данным своего соединения, и никакой связи между похожими молекулами нет.

Амортизация: свободных E_m нет вовсе, есть одна общая функция — голова сети, получающая представление молекулы и выдающая ответ:

$$E_{m,e} = \sigma(u_e^\top z_m + c_e). \quad (10)$$

Здесь z_m — вектор-представление молекулы из общего ствола, u_e и c_e — веса и сдвиг головы фермента, сигмоида зажимает ответ в интервал от нуля до единицы. Параметров $4(d+1)$, то есть при $d = 256$ чуть больше тысячи, и они обслуживают все соединения сразу, включая те, у которых своей кривой нет. Отсюда слово: дорогая процедура вывода амортизуется по всем объектам.

Как это работает регуляризатором. Чтобы выдать одному соединению нестандартное E , сети надо сдвинуть его представление, а представление производится общим стволом из структуры, и тот же ствол обслуживает все похожие молекулы. Подогнать E индивидуально можно только там, где есть структурная закономерность — класс молекул, систематически ведущий себя как частичный ингибитор. Если такого класса нет, а есть только шум подгонки кривой, сети выгоднее выдать всем примерно одинаковое E . Формально это сужение множества гипотез: достижимые наборы $\{E_m\}$ — уже не произвольный вектор длины N , а образ структурного пространства

под гладким отображением. Регуляризация здесь не слагаемое в функции потерь, а свойство параметризации.

6.3. А теперь измерения, и они меняют вывод

Всё сказанное объясняет, почему амортизация безопасна. Но у организаторов опубликованы измеренные E : колонки EmaxVsPosCtrl_direct_inhibition с доверительными полосами. Смотреть на них надо было до всяких рассуждений.




Рис. 6. Слева: цветной отрезок — где лежат 90 процентов соединений, серый — средняя ширина доверительной полосы одного измерения. Серый шире цветного на всех четырёх ферментах. Справа: надёжность по (4), отрицательная везде.

Шкала здесь относительно положительного контроля, поэтому полный ингибитор даёт примерно -1 . И вот что оказалось. Весь разброс E между соединениями уже, чем заявленная погрешность одного измерения, — на CYP3A4 втрое, на CYP2D6 вдвое. Иначе говоря, если взять два случайных соединения, разница их измеренных E в среднем меньше, чем неопределённость каждого из этих двух чисел по отдельности. Различать соединения по E в такой ситуации нельзя.

Отсюда отрицательная надёжность: от -0.73 до -1.43 . У честной величины она лежит между нулём и единицей; отрицательная означает, что заявленная дисперсия шума больше всего наблюдаемого разброса. Буквально это может означать, что полосы посчитаны консервативно, но верхняя оценка сигнала уровня соединения от этого не меняется — он не превышает нуля.

Значит амортизация была правильным решением по неправильной причине. Дело не в том, что сеть не сможет переобучиться на индивидуальные E , а в том, что переобучаться там не на чем: сигнала уровня соединения в этих колонках нет. Вместо головы достаточно одной константы на фермент, примерно -1 у всех четырёх, — и, если хочется страховки, поштучной поправки с жёстким штрафом, которую данные обязаны прижать к нулю.

Что наблюдаемая вариация E — артефакт подгонки кривой, а не химия, видно ещё и по такому признаку. Связь между измеренным E и активностью почти отсутствует у неактивных и у активных соединений, но резко усиливается в средней зоне — ровно там, где кривая доза-эффект обрывается, не дойдя до плато, и подгонщику приходится выбирать глубину наугад, по гребню. Само по себе это подозрительно. Но решает дело знак: у трёх ферментов в средней зоне более потентные соединения выглядят

давящими глубже, а у CYP2D6 — наоборот, *мельче*. Химического механизма, который переворачивал бы этот знак от фермента к ферменту, не существует. Это подпись процедуры подгонки, а не свойство молекул.

Диагностика на будущее остаётся прежней: смотреть разброс выхода головы E отдельно на соединениях с полной кривой и на соединениях только со скринингом. Если на вторых разброс заметно выше, голова используется как свалка для остатка.

7. Механизм пропусков

Полные кривые снимали не для всех: отбор шёл по результату первичного скрининга. Это отбор по зависимой переменной, то есть *missing not at random* по построению, и он же — причина провала на CYP2D6, измеренная в разделе 4.3.

Спасает вот что: *переменная отбора наблюдаема*. Скрининг есть для 4375 из 4905 соединений обучающей выборки, и именно он определял, кого поднимут на подробное измерение.

7.1. Как раскладывается совместное распределение

Пишем совместную плотность через скрытую активность a , честно:

$$p(y_{\text{крив}}, y_{\text{скр}}, R \mid x, \theta) = p(R \mid y_{\text{скр}}) \int p(a \mid x, \theta) p(y_{\text{скр}} \mid a) p(y_{\text{крив}} \mid a)^R da. \quad (11)$$

Здесь R — индикатор попадания в подробное измерение, $p(a \mid x, \theta)$ — что модель думает об активности до измерений (центр — предсказание сети, ширина — признание того, что структура определяет активность не полностью), два следующих множителя — шум каждого прибора, зависящий только от истинной активности. Множитель $p(y_{\text{крив}} \mid a)$ входит в степени R , то есть только для отобранных.

Главный шаг — вынос $p(R \mid y_{\text{скр}})$ за интеграл. Он законен потому, что решение об отборе принималось глядя на показание скрининга, а не на скрытую активность: под интегралом по a этот множитель величины a не содержит.

Применяя цепное правило, получаем рабочую форму:

$$p(y_{\text{крив}}, y_{\text{скр}}, R \mid \theta) = \underbrace{p(R \mid y_{\text{скр}})}_{\text{без } \theta} \cdot \underbrace{p(y_{\text{крив}} \mid y_{\text{скр}}, \theta)}_{\text{условно}} \cdot p(y_{\text{скр}} \mid \theta). \quad (12)$$

Первый множитель не зависит от θ , при дифференцировании логарифма даёт ноль и полностью выпадает из градиента. Значит можно обучаться на полном правдоподобии, вообще не моделируя процедуру отбора, и оценки останутся состоятельными. Условие ровно одно: скрининг должен входить в модель как наблюдение. Если его выбросить, первый множитель перестанет быть отделимым и смещение вернётся. По сути это поправка хекмановского типа, у которой первая ступень не моделируется, а наблюдается.

Средний множитель обязан быть *условным* по $y_{\text{скр}}$, и это место, где легко ошибиться. Заменить его на маргинальный $p(y_{\text{крив}} \mid \theta)$ можно только при нулевом собственном латентном разбросе соединения: два показания меряют одну скрытую активность, они коррелированы, а отбор идёт по одному из них — значит среди отобранных распределение второго сдвинуто. Маргинальный множитель про этот сдвиг не знает.

7.2. Что даёт симуляция

Проверено на данных, где истина известна по построению: $a = x^T \beta + \varepsilon$, скрининг у всех, кривая — у верхних двадцати восьми процентов по скринингу (порог квантиля 0.72).

Способ подгонки	Смещение, норма	Наклон калибровки
Только отобранные метки кривых	0.433	0.731
Совместное правдоподобие, отбор по скринингу	0.019	1.012
Только скрининг, все строки (контроль сверху)	0.002	1.000
Отбор по скрытой истине, скрининг у неотобранных не виден	0.512	0.681

Таблица 2. Сорок повторов, шесть тысяч соединений, в подробное измерение попадает 28 процентов. Наклон единица означает, что коэффициенты восстановлены без систематического сжатия.

Подгонка по одним отобранным меткам сжимает коэффициенты до 0.73 от истины — ровно то ограничение диапазона, которое видно на CYP2D6. Совместное правдоподобие возвращает 1.01.

Четвёртая строка важнее первых трёх. Сломайте условие, то есть сделайте отбор зависящим от скрытой величины и уберите скрининг у неотобранных, и совместная схема поломаётся так же, как наивная. Значит аргумент держится не на общей идее «использовать больше данных», а на наблюдаемости первой ступени отбора. В наших данных она наблюдаема.

Отдельно измерена цена замены условного множителя на маргинальный. Смещения нет при нулевом латентном остатке, при $\sigma_{\text{лат}} = 0.35$ оно примерно втрое меньше стандартной ошибки оценки, при $\sigma_{\text{лат}} = 0.70$ уже сравнимо с ней. И независимо от смещения такая схема занижает собственную погрешность в 1.18–1.21 раза, потому что считает два коррелированных наблюдения одного соединения за два независимых свидетельства. Значит голова, предсказывающая pIC_{50} , должна получать на вход показание скрининга того же соединения. Или, что то же самое, обе величины должны выводиться из общего латентного слоя с явной ковариацией, а не из двух независимых голов.

На инференсе скрининга нет, но это не мешает. Условный множитель нужен на обучении, чтобы оценка не была смещена отбором; на предсказании мы маргинализуем по $y_{\text{скр}}$, что при общем латентном слое сводится к одному прогону сети.

Оговорка: 530 соединений с кривыми не имеют скрининга, и для них аргумент не работает. По выборке целиком доля небольшая, но лежит она не равномерно: все 530 — это метки 3A4, почти четверть всех кривых этого фермента. Так что на трёх ферментах оговорка пустая, а на 3A4 её надо закрывать — взвесить или выкинуть в абляции.

8. Архитектура

8.1. Ствол

Предобученный химический энкодер $f_{\varphi} : \text{SMILES} \rightarrow z \in \mathbb{R}^d$. Организаторы выложили свои веса (CheMeleon, предобученный D-MPNN, и chemprop-foundation), плюс доступны MinimoI и графовые трансформеры. Ансамблируем по семействам

претрейна, а не по зёрнам одного семейства: ошибки разных семейств коррелируют слабее, и ансамбль из четырёх разных архитектур даёт больше, чем из восьми запусков одной. Дообучение через LoRA-адаптеры, чтобы 6.5 тысяч меток кривых не переписали претрейн, обученный на миллионах молекул.

8.2. Связь между ферментами: коррелионизация

Ферментов четыре, и надо решить, как их связать. Очевидные способы не годятся. Четыре независимые модели: 2C9 не пользуется 2335 метками 3A4, хотя они меряют почти одно и то же. Одна общая голова: 2D6 тянет в сторону остальных трёх, а он с ними не коррелирует. Общий ствол и четыре независимые головы уже лучше, но связь между задачами остаётся неявной.

Коррелионизация — термин из геостатистики: совместное моделирование нескольких величин, измеренных в одних точках, через общую структуру плюс отдельную матрицу связей между величинами. Простейший вариант, *intrinsic coregionalization model*, выносит эту матрицу в явный параметр.

Голова линейная поверх общего представления:

$$\pi_{m,e} = w_e^\top g(z_m) + b_e, \quad W = [w_1 \ w_2 \ w_3 \ w_4] \in \mathbb{R}^{d \times 4}. \quad (13)$$

Вся связь между ферментами сидит в углах между столбцами W : если w_2 и w_4 смотрят почти в одну сторону, модели 2C9 и 3A4 читают представление одинаково. Матрица этих углов

$$B = W^\top W \in \mathbb{R}^{4 \times 4}, \quad B_{ee'} = w_e^\top w_{e'}, \quad (14)$$

и на неё навязывается структура «несколько общих осей плюс своё у каждого»:

$$B \approx LL^\top + \text{diag}(\kappa), \quad L \in \mathbb{R}^{4 \times r}, \quad r = 2. \quad (15)$$

Строка e матрицы L говорит, насколько фермент участвует в каждой из r общих осей; $LL^\top$ — общая часть ковариации ранга r ; κ_e — специфичная часть фермента, то, что есть только у него. Это обычная факторная модель: r общих механизмов узнавания плюс идиосинкразия.

Данные говорят то же, что раздел 2.7: 2C9 и 3A4 идут в паре ($\rho = 0.688$), а 2D6 ортогонален всем троим (0.059, -0.120, 0.056). Матрица положительно определена, минимальное собственное число 0.287, так что раскладывать её можно. Нагрузки: ось 1 — 2C9 -0.907, 3A4 -0.773, 1A2 -0.480, 2D6 +0.033; ось 2 — 2D6 -0.726, остальные около нуля. Специфичные части κ : 0.759, 0.161, 0.472, 0.390.

Первая ось — липофильная промискуитетность: крупные жирные молекулы садятся в широкие карманы 2C9 и 3A4. Вторая — 2D6 с его солевым мостиком. Общая голова тянула бы 2D6 по первой оси и портила бы его.

Про ранг надо помнить вот что. При четырёх задачах внедиагональ содержит шесть чисел, а нагрузки ранга 2 дают $4 \times 2 = 8$ параметров минус одна степень свободы на вращение, то есть семь. Модель насыщена: ранг 2 воспроизводит внедиагональ точно не потому, что угадал структуру, а потому что параметров хватает. По-настоящему ограничивает только ранг 1, и он промахивается максимум на 0.10, причём весь промах приходится на 2D6. Так что структура ранга 2 — не сжатие, а способ задать приор и инициализацию. Польза проявится, когда B будет тянуть головы во время обучения, а не в самой аппроксимации матрицы четыре на четыре.




Рис. 7. Слева — ранговая корреляция rC_{50} между ферментами, посчитанная по общим соединениям (от 230 пар у 2C9–2D6 до 473 у 2C9–3A4). Справа — нагрузки факторной модели ранга 2 на те же данные: каждая стрелка показывает, насколько фермент участвует в каждой из двух общих осей. Первая ось нагружает 2C9, 3A4 и слабее 1A2, на 2D6 стоит на нуле; вторая ось — почти исключительно 2D6.

Регуляризационный член. Задача — не дать столбцам W разъехаться в произвольные углы, когда у фермента мало меток, и притянуть матрицу связей к тому, что видно в данных:

$$\Omega(W) = \frac{\lambda_1}{2} \|\rho(W^\top W) - \hat{\rho}\|_F^2 + \frac{\lambda_2}{2} \|W\|_F^2, \quad \rho(B) = D^{-1/2} B D^{-1/2}, \quad D = \text{diag}(B). \quad (16)$$

Первое слагаемое: строим B , нормируем в корреляционную матрицу, вычитаем эмпирическую $\hat{\rho}$, складываем квадраты разностей. Нормировка нужна потому, что притягивать надо углы, а не длины столбцов — длина отвечает за масштаб предсказания и настраивается данными. Второе — обычная усадка весов. Норма Фробениуса $\|A\|_F = \sqrt{\sum_{ij} A_{ij}^2}$ — евклидова длина матрицы, вытянутой в строку.

Почему именно так, а не поэлементный штраф на W . Матрица W определена не однозначно: умножение справа на любую ортогональную Q не меняет ни $W^\top W$, ни предсказания. Регуляризатор обязан обладать той же симметрией, иначе он штрафует за выбор системы координат, а не за содержание. Обе величины в (16) проходят через W только в виде $W^\top W$, поэтому симметрию сохраняют; поэлементный штраф — нет.

Низкий ранг входит не штрафом, а параметризацией. Практически проще держать не W со сложным штрафом, а сразу L и κ и строить головы из них:

$$\pi_{m,e} = L_e \cdot U^\top g(z_m) + \sqrt{\kappa_e} s_e^\top g(z_m) + b_e, \quad (17)$$

где $U \in \mathbb{R}^{d \times 2}$ — проекция на общие оси, общая для всех ферментов, а s_e — вектор специфичного направления фермента. Тогда $B = LL^\top + \text{diag}(\kappa)$ выполняется по построению, штраф за ранг не нужен, а от (16) остаётся притяжение к $\hat{\rho}$ плюс усадка. Инициализация L и κ — из факторного разложения эмпирической матрицы, причём именно факторным анализом с итеративной оценкой общностей: наивное собственное разложение полной матрицы с единицами на диагонали искажает внедиагональные элементы до 0.23, потому что факторы начинают гнаться за диагональю.

Проверять надо две вещи. Положить $\lambda_1 = 0$ и посмотреть, куда уедет выученная матрица связей от эмпирической: если далеко, значит либо в представлении есть структура, которой нет в сырых корреляциях, либо голова переобучается. И сравнить с четырьмя независимыми головами на тех же разбиениях.

8.3. Механистический блок

30 признаков, описанных в разделе 4.3, конкатенируются с z_m либо подаются через FiLM — то есть модулируют активации ствола, а не просто дописываются в конец вектора.

Зачем блок нужен, если по метрике он почти ничего не даёт. По ранжированию он избирателен так, как предсказывает химия, и это подтверждено бутстрапом; модель на одних этих 30 числах воспроизводит большую часть ранжирующей способности на 2D6 и меньше половины на остальных. Вдобавок он заметно стабилизирует модель (раздел 13). Считается блок за секунду.

8.4. Канал артефактов пробы

Как описано в разделе 2, 1A2, 2C9 и 3A4 читаются по флуоресценции, а 2D6 — масс-спектрометрией, и собственная флуоресценция соединения или тушение сигнала дают ложное «ингибирование» только в первых трёх. Это конфаундер, общий для трёх эндпойнтов и отсутствующий у четвёртого, и он частично объясняет, почему 1A2, 2C9 и 3A4 коррелируют между собой.

Добавляем скалярный признак-помеху (протяжённость сопряжения, известные хромофорные каркасы) с обучаемым коэффициентом, входящий только в три флуоресцентных эндпойнта. Это поправка на конфаундер с известной структурой, а не ещё один признак в общую кучу: модель получает возможность объяснить часть общей вариации артефактом, а не химией.

8.5. Головы

- π -голова — линейная поверх (17), выход в $\mathbb{R}$.
- (σ^-, σ^+) -голова — гетероскедастичные, через softplus; обучаются через (7). Границы интервалов лежат в данных и обычно никем не используются, а решающему слою они нужны.
- E — константа на фермент, по итогам раздела 6, плюс опциональная штрафующая поправка.
- Δ -голова — softplus, отдельная. Не разность двух независимых регрессий: шум двух плеч коррелирован и частично сокращается в разности, поэтому предсказывать сдвиг напрямую точнее. Измерено: 0.255 против 0.323 по МСС на 3A4 в пользу отдельной головы.

9. Функция потерь и обучение

$$\mathcal{L} = \sum_{m,e} \left[\lambda_{\text{крив}} \ell_{\text{крив}} + \lambda_{\text{tdi}} \ell_{\text{tdi}} + \lambda_{\text{max}} \ell_{\text{max}} + \lambda_{\text{скр}} \ell_{\text{скр}} \right] + \lambda_{\text{полоса}} \ell_{\text{полоса}} + \lambda_{\text{st}} \ell_{\text{st}} + \Omega(W). \quad (18)$$

Первые четыре слагаемых — правдоподобия четырёх источников из раздела 5. Пятое обучает головы полос (σ^- , σ^+). Шестое — клипованная L1 из (1), посчитанная на обучающих полосах; она выравнивает функцию потерь с метрикой соревнования, потому что правдоподобие оптимизирует не совсем то, по чему считается лидерборд. Последнее — регуляризатор (16).

9.1. Батчинг по молекулам, а не по строкам

Единица батча — молекула со всеми её наблюдениями по всем источникам и ферментам. Иначе теряется смысл конструкции: латентная $\theta_{m,e}$ общая для кривой, Emax и скрининга, и градиенты от них должны сходиться на одном узле в пределах одного шага. Батч по строкам превращает конструкцию обратно в обычную многозадачную модель с общим стволом.

9.2. Двухэтапная калибровка

Если учесть $\psi_e = (s_e, b_e, \sigma_e)$ совместно с сетью с самого начала, есть вырожденное решение: сеть подстраивает π под удобную калибровку вместо обратного. Порядок такой.

1. На подмножестве, где есть и кривая, и скрининг, фиксируем π равным опубликованному и подгоняем 12 скаляров ψ напрямую. Задача низкоразмерная, решается за секунды; результат — в разделе 5.2.
2. Обучаем сеть с замороженной ψ .
3. Размораживаем ψ с маленьким шагом обучения на последних эпохах.

9.3. Веса источников

Стартуем с $\lambda \propto 1/n_{\text{источника}}$, чтобы 17.5 тысяч точек скрининга не задавили 6.5 тысяч меток кривых. Потом пробуем гомоскедастичное взвешивание по неопределённости: каждому источнику свой обучаемый $\log \sigma^2$, веса выводятся из него, и модель сама решает, какому источнику доверять. Проверяем это абляцией, а не берём на веру: приём известен, но на маленьких выборках его собственный шум иногда съедает пользу.

10. Неопределённость

На выходе нужно распределение, а не число, и не ради красоты: решающий слой без него не работает вообще. Собирается оно из трёх частей.

Ансамбль по зёрнам и семействам энкодеров даёт эпистемическую часть — ту неопределённость, которая происходит от незнания правильной модели и падает с ростом данных. Дешёвые альтернативы, если бюджет не позволяет держать ансамбль: SWAG или лапласовское приближение на последнем слое.

Гетероскедастичные головы (σ^- , σ^+) дают алеаторную часть — шум прибора, который не уменьшить никаким количеством данных.

Конформная калибровка на разбиении, воспроизводящем дизайн теста. Обычная конформная калибровка даёт маргинальное покрытие: в среднем по всей выборке 90 процентов заявленных интервалов накрывают истину. Нам нужно условное: у

неактивных соединений полосы широкие по построению, и если модель систематически промахивается на активных, среднее покрытие это замаскирует. Проверяем покрытие по зонам активности отдельно, при необходимости берём мондриановский вариант с зонами в качестве таксономии.

Разделять алеаторную и эпистемическую части нужно не для отчёта, а для трансдуктивного слоя: эпистемическая компонента велика там, где мало похожих обучающих примеров, а тест как раз состоит из серий аналогов вокруг известных хитов.

11. Решающий слой

Предсказательное распределение получено. Осталось превратить его в то, что просят отправить: одно число для регрессии и один бит для классификации. Это отдельный шаг, и правильный ответ зависит от метрики.

11.1. Регрессия: вывод

Модель выдаёт не одно число, а распределение возможных значений активности. Отправить же надо ровно одно число. Какое?

Ответ зависит от метрики, и здесь он нетривиален. Если бы штраф был квадратичным, надо было бы брать среднее; если бы линейным — медиану. Но ST-RAE не штрафует за ошибку, попавшую внутрь доверительной полосы измерения, и это меняет ответ.

Важная тонкость, без которой дальнейшее повисает: для новой молекулы никто не сообщает ни активности, ни ширины полосы. И то и другое приходится предсказывать, поэтому границы полосы L и H — тоже случайные величины, а не известные числа. Риск точечной оценки $\hat{y}$ — это средний штраф по всему, что может оказаться правдой:

$$R(\hat{y}) = \mathbb{E}[(\hat{y} - H)_+] + \mathbb{E}[(L - \hat{y})_+], \quad R'(\hat{y}) = F_H(\hat{y}) - (1 - F_L(\hat{y})). \quad (19)$$

Здесь $\mathbb{E}$ — среднее по распределению, запись $(x)_+$ означает « x , если положительно, иначе ноль» (то есть штраф только за выход за границу), а F_L и F_H — вероятности того, что соответствующая граница окажется левее $\hat{y}$. Производная считается без выкладок, на пальцах: сдвигая ответ чуть вправо, мы добавляем штраф там, где верхняя граница уже осталась позади, и снимаем штраф там, где нижняя граница ещё впереди.

Оба слагаемых выпуклы, значит найденная точка — глобальный минимум, а условие оптимума получается на удивление простым:

$$F_L(\hat{y}^*) + F_H(\hat{y}^*) = 1. \quad (20)$$

В переводе на процедуру это означает следующее. Возьмём несколько сотен выборок из предсказательного распределения, для каждой посчитаем пару границ, сложим все получившиеся числа — и нижние, и верхние — в один общий массив и возьмём медиану. Всё. В вырожденном случае, когда полоса схлопывается в точку, рецепт даёт обычную медиану, чего и следовало ожидать от метрики на основе абсолютной ошибки.

Вывод верный и проверен численно. А вот следствие, которое из него раньше выводилось — что для неактивных соединений оптимум смещается вверх, — оказалось неверным. Оно опиралось на предположение, что полосы у неактивных соединений сильно асимметричны: длинный хвост вниз, короткий вверх. Измерение показало,

что полосы почти симметричны везде, и у трёх ферментов из четырёх у неактивных асимметрия вообще смотрит в другую сторону.

Вариант решающего слоя	1A2	2C9	2D6	3A4	Макро
Сырое предсказание модели	0.879	0.691	0.980	0.519	0.767
Пул границ, полосы предсказаны моделью	0.889	0.710	1.002	0.540	0.785
Пул границ с истинными полосами (оракул)	0.864	0.670	0.971	0.505	0.752

Таблица 3. Один и тот же предиктор, разные решающие слои, те же фолды. Оракул недостижим — он знает истинные границы, — и задаёт потолок всей затеи.

И теперь неприятное. Красивый вывод не окупается. Даже оракульная версия — та, которой кто-то заранее сообщил истинные границы полос, чего на тесте не будет никогда, — выигрывает около двух процентов. А наша реальная версия, где полосы предсказывает та же модель, не выигрывает вовсе: она *проигрывает* сырому предсказанию, и проигрывает больше, чем оракул выигрывает.

Число «два процента» стоит читать как порядок, а не как измерение. Оно получено вычитанием двух строк таблицы, посчитанных с разными настройками сэмплирования, и одна только разница настроек двигает результат на величину порядка самого эффекта. Поэтому «около двух процентов» — честная формулировка, а три знака после запятой — нет.

Кто на самом деле двигает метрику. Раньше здесь стояло объяснение: метрику целиком определяют активные соединения с узкими симметричными полосами, а у неактивных полосы широкие, поэтому вклада они не дают. Первая половина верна, вторая нет.

Доля числителя / знаменателя, %	1A2	2C9	2D6	3A4
Неактивные, $y < 4$	22 / 34	16 / 30	12 / 20	19 / 25
Средние, $4 \leq y < 5$	14 / 5	30 / 5	35 / 17	43 / 25
Активные, $y \geq 5$	64 / 62	54 / 65	53 / 63	38 / 50

Таблица 4. Числитель — это ошибка модели, знаменатель — ошибка бессмысленного предсказателя, и метрика есть их отношение. Строка показывает, какую долю каждого из них даёт зона активности. На CYP3A4 средняя зона даёт числителя больше, чем активные соединения.

Неактивные соединения несут от восьмой до пятой части всей ошибки, и полосы у них действительно широкие и заметно несимметричные. А активные доминируют только на CYP1A2; на CYP3A4 больше всего ошибки приходится на среднюю зону — ту самую, где кривая доза-эффект обрывается, не дойдя до плато. Так что прежнее объяснение было не просто неточным, а указывало не на тех.

Почему при этом слой не работает — вопрос к измерению, а не к рассуждению, и измерение уже есть: и оракульный потолок, и реальная потеря стоят в таблице выше. Объяснения, которое связывало бы одно с другим, у нас пока нет. Прежнее было неверным, и лучше это признать, чем оставить красивое.

Слой понижается в приоритете: делать после того, как заработает всё остальное, и только если головы, предсказывающие ширину полосы, дадут заметно лучшую её оценку, чем нынешний бустинг.

11.2. Регрессия: то, что работает

Пул границ оказался тупиком. Второй рычаг постобработки, найденный позже, оказался самым сильным из всего, что мы пробовали, — и одновременно самым коварным. Начать стоит с явления, которое за ним стоит, потому что понять его можно без всякого машинного обучения.

Предсказания разложены по шкале слишком широко. Возьмём молекулы, которым модель дала самые высокие оценки активности, и посмотрим на их истинные значения. В среднем они окажутся *ниже* предсказанных. Возьмём те, которым модель дала самые низкие, — их истинные значения окажутся выше. При этом модель не смещена: по выборке целиком её среднее совпадает с истинным. Преувеличены именно края.

Причина не в нашей модели, а в устройстве любого предсказания. Оценка — это сумма сигнала и ошибки. Отбирая молекулы по высокой оценке, мы отбираем и те, у которых сигнал действительно велик, и те, у которых он умеренный, а вверх их вынесла ошибка. Вторых всегда какая-то доля есть, и при проверке они возвращаются к своей настоящей, более скромной величине. Химику это знакомо как регрессия к среднему: чемпионы первичного скрининга на повторе почти всегда выглядят скромнее, и не потому, что что-то испортилось в постановке.

Отсюда лечение. Если края преувеличены, их надо поджать к середине:

$$\hat{y} \rightarrow \mu + \lambda(\hat{y} - \mu), \quad (21)$$

где μ — центр, к которому жмём, а λ — насколько сильно: при $\lambda = 1$ не жмём вовсе, при $\lambda = 0$ схлопываем все предсказания в одну точку. Коэффициент подбирается только на обучающих фолдах и применяется к отложенным. Иными словами, процедура, выбирающая λ , никогда не видит тех молекул, на которых её потом проверяют; без этой предосторожности любое улучшение было бы подгонкой под ответ, а не результатом.

Выигрыш крупный: макро ST-RAE идёт с **0.767** до **0.733** (напомним, метрика такая, что меньше — лучше). Для сравнения, весь механистический блок — тридцать признаков, придуманных специально под химию цитохромов, — стоит примерно в шесть раз меньше. Знак держится на всех четырёх разбиениях и на всех шести наборах признаков, а доверительный интервал не подходит к нулю. Порядок молекул по активности при этом не меняется вовсе: преобразование монотонное, мы не переставляем молекулы местами, а только сжимаем шкалу.

Что это не подгонка, видно и с другой стороны. Если вместо (21) просто перекалибровать предсказания методом наименьших квадратов — провести прямую через облако «предсказание против истины», — наклон выходит меньше единицы на всех четырёх ферментах, а свободный член совпадает с тем, что даёт формула сжатия, до третьего знака. Два независимых способа находят одну и ту же поправку, и у неё есть классическое имя: регрессионное затухание.

Но качество предсказаний при этом не улучшается. Средняя абсолютная ошибка почти не двигается, а на CYP3A4 сжатие её даже ухудшает; доля объяснённой дисперсии не двигается вовсе. То есть мы не стали лучше угадывать активность — мы стали лучше попадать в то, что считает метрика.

Здесь легко себя обмануть, и мы обманули. ST-RAE не штрафует за ошибку, которая укладывается в полосу погрешности самого измерения. Естественнo предположить, что сжатие загоняет предсказания внутрь этих полос, — и такое объяснение в этом

разделе стояло, пока его не проверили. Оно неверно: доля предсказаний, попадающих внутрь полосы, после сжатия не растёт, а падает.

Что происходит на самом деле, видно из разложения выигрыша по зонам активности. Неактивные соединения от сжатия всегда *проигрывают* — их предсказания уезжают вверх, дальше от истины. Выигрыш приходит из средней зоны шкалы, и он больше проигрыша. Значит сжатие — это поправка к систематическому смещению предсказаний в середине, а не эксплуатация ширины полос. Формулировка скучнее прежней, зато выдерживает проверку.

Где стоит центр, важнее, чем кажется. В самой записи (21) спрятана ловушка. Формула выглядит как два независимых рычага: куда жать и насколько сильно. На деле это одна прямая. Сжатие к центру c с коэффициентом λ — это в точности прямая $a + b\hat{y}$ с наклоном $b = \lambda$ и свободным членом $a = c(1 - \lambda)$. Закрепить центр и подбирать только λ — всё равно что искать наилучшую прямую, заранее запретив ей часть направлений.

Отсюда два следствия, оба неочевидные. Первое: сдвиг центра двигает сами предсказания не на эту величину, а на неё же, умноженную на $(1 - \lambda)$, — при типичном λ около 0.8 это впятеро меньше. Раньше здесь стояло «оптимальный сдвиг центра +0.40», и читалось это как сдвиг всех предсказаний на 0.4 логарифмической единицы; на самом деле предсказания двигались примерно на 0.1. Второе: чем ближе λ к единице, тем хуже определён центр, а при $\lambda = 1$ он не определён вовсе — жать не на что, и любой центр даёт один и тот же ответ.

Поэтому подбирать надо оба параметра сразу. Это даёт **0.715** вместо 0.733, то есть ещё примерно столько же, сколько стоил весь механистический блок, — просто за счёт того, что семейству разрешили полную свободу.

И сразу ограничение, из-за которого мы этим не пользуемся в полную силу. Всё посчитанное выше молча предполагает, что тестовый набор устроен как обучающий. Он устроен иначе. Организаторы собрали его вокруг «якорей» — соединений из верхних процентов нашего же распределения активности, — и добавили к каждому по десятку структурных соседей (раздел 3). Значит активных соединений на тесте в среднем больше, чем у нас, и середина шкалы там сдвинута вверх.

Для сжатия это существенно, потому что мы жмём к *среднему*. Если настоящее среднее теста выше нашего, мы тянем активные предсказания вниз, то есть в неправильную сторону. Первая проверка это и показала: на верхней четверти нашей собственной выборки по активности — грубой имитации обогащённого набора — сжатие к обучающему среднему ухудшает результат на всех четырёх ферментах.

Вывод, однако, оказался слишком сильным, и поправило его прямое измерение, а не рассуждение о том, как набор собран. Вместо того чтобы гадать, можно прогнать одну и ту же модель по обоим выборкам и сравнить распределения её собственных выходов. Отображение «признаки → предсказание» при этом одно и то же, поэтому разница на выходе — это разница на входе, а не разница качества. Измеренный сдвиг оказался мягким. И, что важнее любого числа, на CYP2D6 он *отрицателен* — а именно этот фермент в отборе якорей не участвовал. Метод, стало быть, отличает обогащённый набор от небогащённого, то есть меряет то, что должен.

Стресс-тест на верхней четверти двигал среднюю активность втрое сильнее, чем сдвиг, который на тесте есть на самом деле. Он опровергал не ту гипотезу.

А при мягком сдвиге оптимум почти не двигается. Если перевесить обучающую выборку так, чтобы распределение её предсказаний стало похоже на тестовое, наилучшая пара параметров остаётся практически той же, и сжатие под таким

распределением не меняет знак, а по-прежнему выигрывает — заметно.

Чего это не доказывает, и это важнее всего остального в подразделе. Перевешивание правит распределение предсказаний и молча предполагает, что связь «предсказание — истина» на тесте та же, что у нас. Проверить это можно только на тесте, а перекалибровка ровно для того и существует, так что бесплатного обеда здесь нет. Есть и вторая ось, которой перевешивание не касается вовсе: тестовые молекулы структурно ближе друг к другу и к якорям, чем что-либо, что можно выкроить из нашей выборки. Насколько сдвинут тест, мы знаем лишь с точностью до вилки, и обе её границы получены косвенно — снизу из измеренного сдвига предсказаний, сверху из перцентилей якорей.

Практический итог. В `src/submit.py` сжатие по умолчанию *выключено*, а когда его включают, оба параметра подбираются в предположении нулевого сдвига. Это не лучший выбор — лучший требовал бы знать сдвиг, — а единственный, который не требует его угадывать. Цена ошибки здесь несимметрична: тестовый набор открывается один раз.

11.3. TDI: здесь слой окупается

Метка TDI не измеряется напрямую. Она вычисляется из двух измеренных pIC_{50} — прямого плеча и плеча с преинкубацией (раздел 2.5) — по составному правилу, и правило воспроизводит опубликованные метки без единого исключения: 2334 из 2334 для 3A4 и 1493 из 1493 для 2D6. Оговорка: это те строки, где измерены оба плеча. Меток TDI по 3A4 в файле 3584, и у 1250 из них прямого плеча нет, так что правило проверено на двух третях. Проверять на остальных нечем и незачем: все 1250 размечены отрицательно.

Проверено и покомпонентно, но точнее, чем здесь стояло раньше. Убрать любое из двух слагаемых — и правило начинает пропускать положительные: 84 пропуска на 3A4 и 51 на 2D6 без второго, 680 и 273 без первого. Ложных срабатываний при этом ноль: каждое слагаемое со своим условием даёт только подмножество истинных. Сотни ложных появляются, если снять условие и взять неравенство само по себе, — 420 и 642 на 3A4, 1083 на 2D6 для второго. Единственное исключение: $\Delta > \log_{10} 2$ без условия даёт на 2D6 всего 56 ложных, десятки, а не сотни.

Значит вероятность «да» надо считать интегрированием правила по совместному предсказательному распределению, а не отдельной сигмоидой:

$$p_i = \Pr(\pi > 4, \Delta > \log_{10} 2) + \Pr(\pi \leq 4, \pi + \Delta > 4 + \log_{10} 2). \quad (22)$$

Два слагаемых — два случая правила разметки, разобранных в разделе 2.5. Считать это надо совместно: π и Δ коррелированы, перемножать вероятности по отдельности нельзя. На практике — Монте-Карло по сэмплам из ансамбля.

Дальше порог. Как отмечено в разделе 1, МСС не раскладывается по объектам, поэтому 0.5 почти всегда неоптимален. При калиброванных p_i берём порог, максимизирующий ожидаемый МСС на всём наборе из 750. Два способа, оба дешёвые: подстановка ожидаемых счётчиков $\mathbb{E}[TP] = \sum_{i: p_i > t} p_i$ со свипом по t , либо Монте-Карло по пуассон-биномиальному распределению меток.

На сохранённых вероятностях бустинга средняя предсказанная вероятность равна 0.256 против настоящей доли положительных 0.326 на 3A4 и 0.079 против 0.217 на 2D6. Подстановочный метод берёт на 3A4 порог 0.375 и даёт МСС 0.325, тогда как оптимум при 0.258 даёт 0.358 — потеря 0.033. Вложенная калибровка Платта возвращает почти




Рис. 8. MCC как функция порога. Слова «при калиброванных p_i » оказались не формальностью: на сырых вероятностях подстановочный порог промахивается мимо максимума. На CYP3A4 он даёт 0.325 при достижимых 0.358, на CYP2D6 — 0.115 при 0.127. На 3A4 промах стоит больше половины всего выигрыша от подбора порога. (Раньше в подписи стояло 0.356 против 0.358 в тексте — одна и та же величина, разошедшаяся из-за шага сетки порогов: рисунок перебирает 180 значений, `f9_mccthr` — 200. Точный максимум по всем различным вероятностям 0.3574.)

всё: потеря падает до 0.003, показатель Брайера с 0.2075 до 0.1853, чистый выигрыш +0.028 MCC.

Два уточнения к этому числу. Оно получено при зашитом зерне разбиения калибратора; по десяти зёрнам выигрыш идёт от +0.018 до +0.029 при среднем +0.025, так что 0.028 — верх диапазона, а не типичное значение. И сравнивать его с перестановками признаков в абляциях, как здесь стояло раньше, нельзя: те меряются в ST-RAE на регрессионном треке, а этот — в MCC на классификационном, и никакой абляции признаков для классификатора мы не гоняли.

На 2D6 не окупается. Калибровка чинит калибровку (средняя предсказанная с 0.079 до 0.217, Брайер с 0.199 до 0.169), а MCC не растёт: изотоническая сжимает достижимый максимум с 0.127 до 0.108, Платт уводит порог не туда. При MCC порядка 0.12 и 260 положительных на обучение калибратора его собственный шум съедает пользу.

В архитектуру идёт связка «вложенная калибровка, затем подстановочный порог», с абляцией на каждом эндпойнте отдельно.

Незакрытая дыра: вероятностная версия (22) с интегрированием по ансамблю не запускалась ни разу. Все измеренные варианты правила — детерминированные подстановочные.

12. Трансдуктивный слой

Про тест известно больше, чем обычно, и этим можно пользоваться. Аккуратно.

12.1. Сдвиг распределения

Тест обогащён активными по трём ферментам и близок к фону по четвёртому (раздел 3). Это ковариатный сдвиг с индуцированным сдвигом меток: $p_{\text{тест}}(y) \neq p_{\text{обуч}}(y)$. Модель, откалиброванная на обучающей маргинали, будет систематически занижать активность тестовых соединений. Лечится перекалибровкой под ожидаемую тестовую маргиналь, оценённую из известной конструкции набора, и проверяется на разбиении, воспроизводящем дизайн теста.

12.2. Серийный случайный эффект

Тест — серии аналогов вокруг якорей, но охват этой структуры зависит от того, что считать серией: при рабочем пороге 0.35 в группы по пять и более членов попадает 155 соединений из 750, при 0.48 — 496 (раздел 13). Естественно предположить, что соединения одной серии имеют общий сдвиг:

$$\hat{y}_i = f(x_i) + b_{s(i)}, \quad b_s \sim \mathcal{N}(\mu(\text{якорь}_s), \tau^2). \quad (23)$$

Здесь $s(i)$ — серия, к которой относится соединение i , b_s — её общий сдвиг, $\mu(\text{якорь}_s)$ — центр приора, привязанный к активности якоря, τ — насколько сильно мы разрешаем серии отклоняться от него.

Соблазн стянуть предсказание к активности якоря надо давить. Медианная разница pIC_{50} в обучающих парах со сходством Танимото 0.6–0.85 составляет от 0.33 до 0.68 логарифмической единицы. Обрывы активности реальны: похожие молекулы регулярно различаются в разы. Значит τ должно быть порядка 0.5, а не 0.1, и оценивать его надо по обучающим парам при том же уровне сходства, а не подбирать.

Оговорка, которая тут важнее самого числа: пар в этой полосе всего 601 на всю обучающую выборку, и обе метки есть лишь у 30 из них на 1A2, 15 на 2C9, 23 на 2D6 и 510 на 3A4. То есть три из четырёх медиан стоят на полутора-трёх десятках пар, и приводить их с двумя знаками — преувеличение точности. Вывод про порядок τ от этого не страдает: он одинаков при любом прочтении этих чисел. А вот оценивать τ по обучающим парам пофермент, как здесь предлагается, на 2C9 не выйдет — пятнадцати пар для этого мало, и придётся либо пулить ферменты, либо расширять полосу сходства.

Проверять эффект от (23) можно только на псевдотестовых сериях: на случайном разбиении он покажет ложный выигрыш, потому что там соседи по серии лежат в обучении.

13. Протокол оценки

Что считать выигрышем, решается до эксперимента. Иначе за два месяца можно уехать сколь угодно далеко.

13.1. Уровней строгости меньше, чем задумывалось

Задумывалось три уровня. Измерение оставило один и небольшую страту.

Случайное пятикратное — задумывалось верхней границей, годной только для отладки. Здесь стояло, что оно вдвое оптимистичнее кластерного, и это неверно. Если поменять только вектор фолдов, оставив те же признаки и те же настройки, разница

оказывается в третьем знаке, а на трёх ферментах из четырёх случайное разбиение даже *строже* кластерного. Два режима, которые задумывались как разные уровни строгости, по факту меряют одно и то же.

Кластерное по Бутине при пороге 0.35 — рабочий режим, все числа этого документа получены на нём. Соединения группируются по сходству, и целый кластер целиком уходит в отложенный фолд, так что модель не может узнать соединение по его близкому родственнику в обучении. Причина, по которой это почти не отличается от случайного, видна сразу: при пороге 0.35 из 4905 соединений получается 4703 кластера, то есть подавляющее большинство — синглтоны, и группировать почти нечего.

Отсюда не следует, что кластеризация бесполезна. Следует, что её действие не в медиане, а в хвосте: доля соединений, у которых в обучении остаётся близкий родственник со сходством выше 0.7, падает с 0.033 при случайном разбиении до 0.005 при кластерном, в семь раз. Кластерное разбиение защищает ровно те три процента выборки, у которых есть аналоги, — и на медианном соединении, у которого аналогов нет, оно неотличимо от случайного.

Разбиение под дизайн теста — задумывалось третьим уровнем: псевдотестовый фолд строится тем же алгоритмом, что и настоящий тест — берём хит из обучающей выборки, забираем его ближайших соседей, держим всю серию снаружи. Уровнем протокола оно быть не может: как *разбиение*, то есть нарезка всей выборки, тестовой геометрии оно не достигает ни при каком пороге. Как *страпа* — достигает, но маленькая. Оба утверждения измерены, подробности в следующем подразделе.

13.2. Насколько наша проверка похожа на тест

Прежде чем отбирать модели, надо спросить: наша кросс-валидация вообще такой же трудности, как тест? Мера простая — сходство соединения с ближайшим к нему обучающим.




Рис. 9. Насколько далеко проверяемое соединение от того, что модель видела. Разрыв медиан 0.153, и он идёт в неожиданную сторону: наша проверка труднее теста.

У отложенного кластерного фолда медиана 0.435 и доля соединений со сходством выше 0.7 равна половине процента. У настоящего теста медиана 0.587, и таких соединений каждое десятое.

Режим	Медиана	Доля > 0.7
Потолок: соединение против всей остальной выборки	0.450	0.038
Случайное пятикратное	0.437	0.033
Кластерное 0.35	0.435	0.005
Тест против всего обучения	0.587	0.101

Таблица 5. Сходство проверяемого соединения с ближайшим обучающим. Первая строка — leave-one-out: соединение сравнивается со всей остальной выборкой сразу. Более щедрого разбиения не существует, поэтому это потолок.

Первая строка — потолок для любой перенарезки обучающей выборки, и тест стоит *выше* него. Разрыв 0.137 неустраим: дело не в неудачно подобранном пороге кластеризации, а в том, что в обучающей выборке в среднем нет соединений, настолько похожих друг на друга. Тест устроен как серии аналогов вокруг якорей, и близость к обучению заложена в него конструкцией.

Из этого не следует, что псевдотестовую проверку построить нельзя — следует, что она не может быть *разбиением*. Разбиение делит всю выборку и потому упирается в среднее. Страта не делит: соединение уходит наружу только вместе с обязательством, что его аналог остаётся внутри. Так геометрия теста воспроизводится точно — медиана сходства отложенных с обучением 0.643 при тестовых 0.587, — но набирается таких соединений 328, то есть 6.7 процента выборки, и распределены они крайне неравно: 267 размеченных на 3A4 против 38, 36 и 32 на 1A2, 2C9 и 2D6.

Практический вывод жёсткий. Псевдотестовая проверка существует и осмысленна на CYP3A4. На остальных трёх ферментах при трёх десятках соединений доверительный интервал шире любого эффекта, который мы собираемся измерять, и называть это проверкой нельзя. Всё, что в разделах 10 и 12 обещано «на разбиении, воспроизводящем дизайн теста», проверяемо в этом объёме и не более.

Из той же таблицы видно менее очевидное. По медиане кластерное и случайное разбиения неразличимы, 0.435 против 0.437: при пороге 0.35 из 4905 соединений выходит 4703 кластера, почти все синглтоны, и кластеризация почти ничего не группирует. Расходятся они только в хвосте — доля соединений со сходством выше 0.7 отличается в семь раз, 0.005 против 0.033. Кластерное разбиение работает ровно на тех трёх процентах, у которых есть близкие аналоги, и весь его смысл там. Тест этим хвостом переобогатён втрое против случайного и в двадцать раз против кластерного.

Значит нужный инструмент — не новое разбиение, а расслоение уже имеющейся оценки по сходству: смотреть отдельно на ту четверть выборки, где проверяемое соединение ближе всего к обучающему, потому что она ближе всего к условиям теста. На этой четверти результат заметно лучше, чем на всей выборке, и особенно заметно на CYP2D6.

Читать это надо как вторую, диагностическую полосу, а не как способ отбора моделей. Она смотрит ровно на тот хвост, где кластерное и случайное разбиения вообще расходятся; а если поднять отсечку до настоящей тестовой медианы, соединений останется семь процентов — выше собственного потолка выборки отбирать уже нечего.

Приятная половина прежнего вывода остаётся: 0.767 — оценка снизу, на лидерборде должно быть лучше. Неприятная тоже: мы отбираем модели по способности экстраполировать на чужую химию, а тест награждает за интерполяцию внутри серии аналогов. Это

разные умения, и лучшая по нашей сетке модель не обязана быть лучшей там. Разбиением эту дыру не закрыть — её закрывает только промежуточный лидерборд.

13.3. Устойчивость к разбиению

Все числа регрессионного трека изначально стояли на одном разбиении — кластеры Бутины, раскиданные по фолдам генератором с зерном ноль. Парный бутстрап покрывал случайность выборки соединений, но не случайность самого разбиения. Прогон на других зёрнах меняет только то, как кластеры распределяются по пяти фолдам; кластеризация, признаки, гиперпараметры и код те же.




Рис. 10. Слева — макро-ST-RAE на четырёх зёрнах разбиения. Справа — стандартное отклонение по этим четырём зёрнам, по ферментам. Механистический блок снижает зависимость от разбиения в 3.4 раза по макро, и падение сосредоточено на 2D6.

Первое, что отсюда следует, — предостережение о точности. Абсолютный уровень гуляет от зерна к зерну на величину *большую*, чем весь эффект, ради измерения которого строилась абляционная сетка. Практический вывод: число вида «макро 0.767», названное без указания разбиения, имеет точность до первого знака после запятой, а не до третьего, и сравнивать два таких числа из разных прогонов бессмысленно.

Второе: направление при этом держится. Разность в пользу механистического блока отрицательна на всех четырёх зёрнах, ранговое согласие растёт тоже на всех четырёх. Бутстрап на одном разбиении накрывал ноль и потому не позволял ничего утверждать; четыре разбиения показывают, что знак устойчив, — хотя величина эффекта гуляет примерно в десять раз, и это тоже надо сказать вслух.

Третье, и самое интересное, — в разбросах, а не в средних. С механистическим блоком результат становится втрое менее чувствителен к тому, как именно нарезана выборка, и падение разброса сосредоточено ровно на CYP2D6, тогда как на CYP3A4 не меняется почти ничего. То есть блок делает не столько лучше, сколько *устойчивее*, и именно там, где по химическим соображениям и должен. Устойчивость — не то, ради чего его строили, но для отбора моделей она стоит не меньше среднего уровня: модель, чей результат зависит от нарезки сильнее, чем от собственного устройства, ничего не говорит о том, что будет на тесте.

Похоже, тридцать механистических чисел дают модели опору, не зависящую от того, какие аналоги попали в обучающие фолды. Фингерпринт такой опоры не даёт: он узнаёт соединение по соседям, и когда соседи уезжают в отложенный фолд, узнавание

рассыпается. Главная польза блока, видимо, в этом, а не в приросте среднего.

Протокол из-за этого меняется. Любое сравнение вариантов идёт на фиксированном наборе из нескольких разбиений и отчитывается разностью на каждом плюс разбросом. Одно разбиение годится для отладки и не годится для решения, что отправлять.

13.4. Устойчивость к версии библиотеки

Две оси случайности уже учтены: бутстрап покрывает выбор соединений, четыре зерна — выбор разбиения. Есть третья, и она не случайная: версия библиотеки, которой посчитаны числа.

Версии `scikit-learn` с 1.3.2 по 1.8.0 воспроизводят сохранённые предсказания *побитово* — максимум модуля разности ноль. Версия 1.9.0 не воспроизводит: каждое предсказание сдвигается в среднем на 0.135 pIC_{50} , максимум 0.59. На макро это выглядит безобидно — набор без блока 0.7729 против 0.7759, с блоком 0.7673 против 0.7646, — но измеряемый эффект блока при этом меняется с -0.0056 на -0.0113 , то есть удваивается.

Вывод не меняется: и 0.0113 тонет в размахе 0.0158 по зёрнам. Но величина, ради измерения которой строилась абляционная сетка, зависит от версии библиотеки вдвое — значит потолок версии в окружении не осторожность, а часть протокола, и снимать его можно только вместе с пересчётом всей таблицы.

`numpy` к этому отношения не имеет: 1.26.4 и 2.5.2 воспроизводят одинаково точно. Первое подозрение на `numpy` 2 не подтвердилось.

13.5. Парный бутстрап

Любое сравнение двух вариантов — только на одном и том же разбиении и с парным бутстрапом по соединениям: 2000–3000 пересборок, для каждой обе метрики пересчитываются на одной и той же пересобранной выборке, докладывается распределение разности и доля пересборок, где стало хуже. Разность без интервала не является результатом.

Для макро надо ресэмплировать соединения общей таблицы, а потом для каждого фермента брать те из них, у кого есть метка — так сохраняется корреляция между ферментами. Считать четыре независимых бутстрапа и усреднять нельзя.

13.6. Сетка абляций

Каждая строка снимается с парным бутстрапом относительно предыдущей, на нескольких зёрнах.

1. Фингерпринт и дескрипторы, бустинг. Базовая линия.
2. Предобученный энкодер вместо ручных признаков, одна голова на эндпойнт.
3. Плюс коррегионализация (15).
4. Плюс механистический блок и канал артефактов пробы.
5. Плюс скрининг через (8): главная проверка всей идеи.
6. Плюс Emax и плечо с преинкубацией в общее правдоподобие.
7. Плюс ансамбль и конформная калибровка.
8. Плюс решающий слой: отдельно для регрессии, отдельно для МСС.
9. Плюс трансдуктивный слой.

Строка 5 — точка, на которой конструкция оправдывается или не оправдывается. Обязательный контроль к ней: сильная многозадачная базовая линия на тех же признаках и том же энкодере, обученная на одних метках кривых. Если совместное правдоподобие её не обыгрывает, это отрицательный результат, и он идёт в отчёт как есть.

14. Что уже измерено

Это тоже результат, и он объясняет, почему решение выглядит так, а не проще. Раздел начинался как перечень того, что не работает; последний подраздел добавлен позже и описывает единственную попытку, которая частично удалась, поэтому заголовок пришлось поправить.

Если скрининг настолько информативен, зачем городить совместное правдоподобие? Нельзя ли подключить его в лоб? Проверены три способа.

Подход	ST-RAE	Δ к своей базе	ρ	$\Delta\rho$
Скрининг как признак, в лоб	0.921	+0.138	0.566	+0.009
То же с честной вложенной схемой	0.788	0.000	0.559	+0.006
Два этапа: скрининг, затем пересчёт	1.006	+0.212	0.561	+0.010
Смесь двух маршрутов пополам	0.803	+0.009	0.587	+0.036

Таблица 6. Разности считаются от базовой линии *того же прогона*: 0.783, 0.788, 0.794, 0.794. Расходятся они не случайно — это три разных скрипта с тремя разными конфигурациями, см. ниже, — поэтому сравнивать строки между собой по абсолютной величине нельзя, только по разностям.

Почему базовые линии не совпадают. Три скрипта, давшие эту таблицу, строят разбиение по фингерпринту в 1024 бита, тогда как абляционная сетка и все остальные числа документа — по 2048. При 1024 битах кластеризация даёт 4694 кластера против 4703, и вектор фолдов другой: дайджест d7b7ca15 против 2d93c198. Поэтому ни одно число этой таблицы не сопоставимо с 0.767 из раздела 13: различаются не только модели, но и выборки, на которых они отложены.

Между собой фолды у трёх скриптов совпадают, и расхождение базовых линий объясняется целиком конфигурацией: шесть физико-химических признаков против восьми даёт 0.783 против 0.788, а 250 итераций бустинга против 200 — 0.788 против 0.794. Оба различия детерминированы и воспроизводятся при повторном запуске точно. Разброс в 0.011 — это не шум прогона, а три разные модели на общих фолдах.

Скрининг как признак, в лоб. Обучаем вспомогательную модель предсказывать $\log_2 fc$, её выход подаём как признак в основную. Ошибка — вспомогательный признак посчитан моделью, для которой обучающие строки основной модели были внутренними. На них он точнее, чем окажется на отложенных, основная модель учится на него опираться, и опора рассыпается там, где её проверяют: 0.783 против 0.921. На честной вложенной схеме выигрыш ровно нулевой. Разница между 0.783 и 0.921 целиком артефакт процедуры.

Двухэтапная инверсия. Предсказать $\log_2 fc$, потом перевести в pIC_{50} монотонной калибровкой. Обязана выдать число там, где правдоподобие плоское: в зонах насыщения из раздела 5.3 калибровка не определена, и любое значение оттуда одинаково согласуется с показанием. Результат: абсолютная шкала разваливается, а ранговая информация в среднем сохраняется — но только в среднем, см. ниже.

Смесь. Полусумма двух маршрутов. Стоит +0.009 ST-RAE и покупает +0.036 Спирмена, причём ранг растёт на всех четырёх ферментах. Это уже почти приемлемый обмен, но он не решает задачу, а балансирует между двумя плохими решениями.

Общий вывод: информация в скрининге есть, но «ранг улучшается всегда» — верно только для макро. Поферментно двухэтапная инверсия ранг роняет, причём на том ферменте, вокруг которого построен весь документ: на 2D6 Спирмен идёт с 0.398 до 0.362, на 3A4 с 0.749 до 0.747, и держится макро только за счёт 1A2 (+0.048) и 2C9 (+0.028). Смесь двух маршрутов — единственный из трёх вариантов, который поднимает ранг на всех четырёх. Информация в скрининге, таким образом, есть, и вся проблема в том, как перевести её в абсолютную шкалу pIC_{50} , не потеряв ранг там, где он нужнее всего. Этим, по замыслу, занимается совместное правдоподобие через общую латентную кривую.

14.1. Совместное правдоподобие: первый запуск

Написанное выше — это то, что можно было сказать до того, как строка 5 абляционной сетки была запущена. Теперь она запущена, и предыдущий вывод требует существенного уточнения. Подраздел длинный, поэтому сначала о том, что в нём вообще происходит.

Задача. У нас есть два сорта измерений. Полная кривая доза–эффект дорога, её сняли не для всех соединений, и именно она даёт pIC_{50} — то, что просят предсказать. Скрининг в одной концентрации дешёв, его сняли гораздо шире, и он даёт одно число $\log_2 fc$, косвенно связанное с активностью. Вопрос: можно ли дешёвыми измерениями помочь предсказанию дорогой величины?

Почему не подать скрининг просто как признак. В тестовом наборе его нет вовсе — только имя и SMILES. Модель, которой на входе нужно показание скрининга, неотправляема в принципе. Значит скрининг может влиять только на *обучение*, а к моменту предсказания исчезать.

Конструкция. Общий ствол — слой, который строит внутреннее представление молекулы, — и две головы поверх него: одна предсказывает pIC_{50} , другая $\log_2 fc$. Обучаются они вместе, поэтому градиент от скрининговой головы формирует общее представление, а на выводе эта голова просто не вызывается. Ручка λ_{scr} задаёт, насколько сильно слагаемое скрининга участвует в обучении: при нуле оно не участвует вовсе.

Контрольная рука — та же самая сеть при $\lambda_{scr} = 0$. Обе головы есть и там, и там, число параметров одинаково, а начальные веса засеяны по паре (зерно разбиения, номер фолда) и *не* по λ . То есть две руки стартуют из буквально одинаковых весов, и единственное, чем они отличаются, — присутствие скрининга в функции потерь. Это и делает сравнение сравнением канала, а не двух разных сетей.

Что канал даёт, тоже стоит назвать точно. Он даёт не лишние *строки* — все 4905 молекул и так имеют хотя бы одну метку pIC_{50} , — а лишние *колонки*: для конкретного фермента появляется сигнал с тех соединений, где его кривую не мерили, а скрин снимали. По ферментам объём supervision вырастает в два-три раза.

По макро знак не держится. «Зерно» здесь — это способ нарезать выборку на пять частей для перекрёстной проверки; зёрен четыре, то есть четыре независимые нарезки. Так вот, при $\lambda_{scr} = 3$ канал на одном зерне заметно ухудшает результат, на двух улучшает, на одном не меняет. Ответ на вопрос «помогает ли канал» зависит от того, какую нарезку взять, и одно разбиение дало бы уверенный ответ — любой из

двух. Это ровно тот случай, ради которого в этом репозитории и заведено правило четырёх зёрен.

(В предыдущей версии этого абзаца стояли три числа, взятые из двух разных строк дозовой кривой — часть при $\lambda = 3$, часть при $\lambda = 1$. Каждая строка сама по себе была верна, фраза, составленная из обеих, — нет.)

Но поферментно эффект упорядочен, и это оказалось главным. Усреднив по четырём зёрнам, получаем: на CYP3A4 и CYP2C9 канал помогает, на CYP1A2 вредит, на CYP2D6 вредит сильнее всего. Этот порядок в точности повторяет то, насколько скрининг вообще связан с pIC_{50} у данного фермента: сильнее всего у 3A4, слабее всего у 2D6. Читается это так — канал помогает ровно настолько, насколько дешёвое измерение вообще что-то говорит о дорогом, и вредит там, где не говорит почти ничего. Худшим оказывается CYP2D6, тот самый фермент, вокруг трудности которого построен весь документ.

Насколько этому верить. Ферментов четыре, и совпадение порядка из четырёх элементов случайно происходит примерно в одном случае из двадцати. Это один бит свидетельства, а не закон: между ферментами меняется одновременно всё — число меток, разброс активности, ширина полос погрешности, — и связь скрининга с активностью коррелирует с любой из этих осей не хуже, чем с эффектом канала. Проверка, которая превращает четыре точки в четыре независимые кривые, описана ниже; на момент выпуска она считается.

Развилка «ранг вверх, шкала вниз» оказалась не настоящей. Здесь нужно различать две вещи, которые дальше встречаются постоянно. Модель может правильно расставить молекулы *по порядку* активности и при этом систематически ошибаться в самих числах — например, сжимать или растягивать шкалу. Первое называют ранговой информацией, второе — шкалой. Метрика конкурса смотрит на числа, поэтому испорченная шкала бьёт по результату, даже если порядок безупречен.

Измерение показало, что канал портит именно шкалу, и портит *монотонно*: порядок молекул при включении канала почти не меняется. А монотонная порча снимается монотонным же преобразованием. Изотоническая калибровка — это как раз оно: по обучающим фолдам строится неубывающая ступенчатая кривая, переводящая предсказание в лучшую оценку истины, и применяется к отложенному фолду. Она не может переставить молекулы местами, она только перерисовывает шкалу.

Макро ST-RAE, среднее по четырём зёрнам	$\lambda = 0$	$\lambda = 3$	$\lambda = 3 + \text{изо}$	$\lambda = 0 + \text{изо}$
	0.781	0.810	0.747	0.773

Таблица 7. Четвёртый столбец — контроль, без которого третий ничего не значил бы: перекалибровка помогает обеим рукам, но рука с каналом после неё лучше руки без него, и знак держится на всех четырёх зёрнах.

Читать таблицу так. Сам по себе канал ($\lambda = 3$) хуже базовой линии. Сама по себе перекалибровка ($\lambda = 0 + \text{изо}$) помогает, но умеренно. А вместе они дают лучший результат из четырёх. Значит совместное правдоподобие переносит *ранг*, а шкалу переносит перекалибровка *после* него; порознь не работает ни то, ни другое.

Возражение, которое пришлось проверить. Две свободные головы над общим стволом ничем друг с другом не связаны: голова скрининга вольна представлять $\log_2 \text{fc}$ как угодно, и ничто не заставляет её выражать его через активность. Строго говоря, выше измерена многозадачность, а не совместное правдоподобие в том виде,

в каком его задаёт раздел 5, — там скрининг связан с активностью *фиксированной* кривой прибора $g(\pi)$, подогнанной заранее (раздел 5.2).

Одноголовый вариант это исправляет буквально: один латент, предсказание канала считается как g от предсказанной активности, ноль новых параметров, та же ручка. Результат обратен ожиданию — он хуже свободной головы, и на этот раз знак держится на всех четырёх зёрнах: до перекалибровки макро 1.000 против 0.810.

Первое объяснение, которое напрашивалось и не подтвердилось. Кривая прибора g насыщается: у очень активных соединений сигнал упирается в потолок, у совсем неактивных — в пол, и в обеих зонах её производная почти нулевая. Там, где производная нулевая, показание скрининга не может сказать про активность ничего: любое значение активности одинаково с ним согласуется. Естественнo предположить, что жёсткая рука страдает тем сильнее, чем больше у фермента таких «слепых» соединений. У CYP3A4 их больше всех — около сорока процентов выборки.

Потеря при $\lambda = 3$ против $\lambda = 0$, среднее по четырём зёрнам	1A2	2C9	2D6	3A4
Доля «слепых» соединений (что предсказывает насыщение)	0.22	0.07	0.14	0.40
Двухголовая рука	+0.05	−0.03	+0.12	−0.03
Калиброванная рука	+0.24	+0.01	+0.63	+0.01
Крутизна отклика по λ , калиброванная	+0.06	+0.00	+0.18	+0.01

Таблица 8. Самый слепой фермент оказался наименее пострадавшим, а самый пострадавший — почти самым зрячим. Насыщение предсказывает обратное.

Таблица говорит обратное предположению. CYP3A4 несёт сорок процентов слепых соединений и теряет меньше всех; CYP2D6 несёт четырнадцать и теряет на порядок больше всех. Корреляция между слепотой и порчей не просто слабая — она обратного знака. Последняя строка проверяет то же самое независимо: если бы виновато было насыщение, отклик на увеличение λ был бы круче всего у 3A4, а он круче всего у 2D6. Двух проверок из двух гипотез не проходит.

Не проходит и второе объяснение. Оно состояло в том, что у одного латента некуда деть промах фиксированной кривой прибора: если для конкретного соединения кривая не годится, свободная голова спрячет расхождение в себе, а жёсткая переложит его на активность. Тогда порча должна следовать за тем, насколько плохо кривая описывает данный фермент. Величина, которая это меряет, — разброс остатков хилловской подгонки; корреляция с порчей опять получается обратного знака.

Попутно выяснилось, что величина, предлагавшаяся в качестве прокси для этого промаха, — разброс измеренного $E_{\max}$ — вообще не то, за что её принимали: это размах поклоночных измерений из другого файла и с другим знаковым соглашением, а не разброс подогнанного параметра кривой, который в десятки раз меньше. Две величины упорядочивают ферменты ровно наоборот, так что выбор между ними — не деталь. Но порчу не объясняет ни одна.

Что порчу объясняет. Ровно один порядок ложится точно, и это тот же самый, что управлял двухголовой рукой: насколько скрининг связан с активностью у данного фермента. Вывод отсюда скромнее, чем «у жёсткой калибровки своя болезнь»: *отдельной болезни у неё нет.* Она примерно впятеро умножает уже имеющуюся — там, где скрининг об активности говорит хуже всего, — и съедает выигрыш там, где он говорит хорошо: на 2C9 и 3A4 свободная голова при $\lambda = 3$ улучшала результат, а жёсткая выходит в ноль.

Оговорка про четыре точки остаётся, но здесь она работает иначе. Измерение не

подтверждает гипотезу, а исключает две, и на исключение четырёх точек хватает: обратный знак — это не слабое свидетельство «за», это свидетельство «против».

Насколько чист сам измерительный прибор. Изотоника монотонна, поэтому внутри одного фолда порядок она сохраняет точно — проверено, ни одной перестановки на двадцати применениях. Но у неё есть свойство, которое легко проглядеть: она склеивает соседние предсказания в одно значение. Сотни соединений фолда отображаются в несколько десятков различных чисел, и в склеенном значении оказывается больше девяноста пяти процентов соединений. А поскольку каждый фолд получает свою карту, на склеенном из пяти фолдов векторе порядок уже не сохраняется строго: несколько процентов пар меняются местами, и худшее соединение уезжает на сотню с лишним позиций списка. Хуже того, ранговое согласие с самими метками — то, что прибор обязан не трогать, — слегка падает на всех четырёх ферментах.

Сравнение двух рук это всё же не отменяет, и по конкретной причине: искажение почти синфазно. Оно примерно одинаково бьёт по обеим рукам, поэтому *разность* между ними смещается на порядок меньше, чем каждая из них по отдельности. Пользоваться прибором можно; говорить, что он сохраняет ранг, нельзя.

Разрыв между руками после перекалибровки: шум или нет. После изотоники руки почти сходятся — 0.747 у свободной головы против 0.752 у жёсткой. Разница 0.006 сначала была названа «вдвое меньшей, чем разброс по зёрнам», и это была ошибка выбора линейки: разброс по зёрнам брался до перекалибровки. Но обе руки к этому моменту уже перекалиброваны, а перекалибровка разброс схлопывает почти в десять раз. Против правильной линейки разрыв — это два стандартных отклонения, и знак его держится на всех четырёх зёрнах.

Формулировка поэтому такая: форма связи между каналами стоит 0.006 ранговой информации — мало, но измеримо. Не «в пределах шума». Разница принципиальна: второе закрывает вопрос, первое — это то же самое утверждение, что и до перекалибровки, только ослабленное в десятки раз.

Цена интерпретируемости, а не ничья. Прежний вывод — «спорить о форме связи между каналами было бы спором не о том» — верен про количество информации, но неверен как итог, потому что читается как оправдание раздела 5. Наоборот: рука, которая буквально реализует его порождающую конструкцию, — это та самая рука, которой нужна самая сильная починка. Честная рамка другая. Фиксированная связь есть моделирующее допущение, которое *стоит* производительности и *покупает* интерпретируемость, и у этого есть ценник: до перекалибровки 1.000 против 0.810, после — 0.752 против 0.747.

Происхождение этих чисел. Первая версия обеих рук в репозитории не сохранилась: скрипт писал оба режима в один файл под ключом, в котором режима не было, и второй прогон затирает первый. Ключ исправлен, обе руки пересчитаны заново на четырёх зёрнах, и всё, на что опирается подраздел, воспроизвелось. Тожество при $\lambda = 0$ проверено буквально: максимум модуля разности предсказаний двух рук равен нулю на всех четырёх зёрнах, как и должно быть по построению.

И последнее, про сравнение ствола с бустингом. Все числа ствола посчитаны в предположении, что тестовая выборка распределена как обучающая, а раздел 11 показывает, что это не так. Если пересчитать сравнение под сдвинутое распределение и дать обеим сторонам одинаковую постобработку, порядок не переворачивается — бустинг остаётся впереди, — но разрыв сужается примерно вдвое. Направление то самое, которого и следует ждать, если преимущество бустинга масштабное, а

преимущество ствола ранговое: масштабные преимущества первыми и теряются при сдвиге среднего. До перемены знака в правдоподобном диапазоне сдвига дело, однако, не доходит. Оговорка: этот блок посчитан на одном зерне разбиения, и притом на том, где жёсткая рука ведёт себя хуже всего.

Сюда же результаты из предыдущих разделов. Отрицательные: решающий слой на пуле границ имеет потолок 0.015 макро и в реалистичной версии теряет 0.018; выигрыш механистического блока по ST-RAE неотличим от нуля и поштучно, и на макро. Положительный, найденный позже и описанный в разделе 11: усадка предсказаний к подогнанной аффинной паре даёт -0.052 макро (0.7673 до 0.7150), на порядок больше механистического блока. Выигрыш живёт в геометрии метрики, а не в качестве предсказания, и это ограничение остаётся. А вот опасение, что на тестовой маргинали он сменит знак, измерением снято: сдвиг там вдвое слабее того, на котором знак менялся.

15. Что сломается и по какому признаку это видно

Режим отказа	Признак	Реакция
Совместное правдоподобие не обыгрывает многозадачную базовую линию	строка 5 абляции внутри интервала парного бутстрапа на нескольких зёрнах	зафиксировать как отрицательный результат, отправлять многозадачную модель; решающий и трансдуктивный слои от неё не зависят
Голова E как свалка для остатка	разброс выхода E на соединениях только со скринингом заметно выше, чем на соединениях с кривой	заменить на константу на фермент, зафиксировать $h_e = 1$
Калибровка зависит от соединения, а не только от фермента	остатки (8) систематически изогнуты по π на подмножестве с полными кривыми	монотонная сплайн-поправка поверх хилловской формы либо смесь двух режимов
Серийный приор переобучается на якоря	на псевдотестовой <i>страте</i> (328 соединений, из них 267 с меткой 3A4; раздел 13) модель с (23) хуже, чем без. На остальных трёх ферментах страта слишком мала, и триггер там не срабатывает вовсе	увеличить τ или снять слой
Конформные интервалы калиброваны маргинально, но не условно	покрытие по зонам активности расходится с номинальным	мондриановский конформал с зонами как таксономией
Расхождение локальной оценки с промежуточной таблицей	макро отличается больше чем на 0.03 — столько даёт переход к тестовой геометрии на нашей же выборке (0.767 против 0.739 на верхней четверти по сходству)	чинить разделы 13 и трансдуктивный слой, а не архитектуру

Таблица 9. Каждому риску — наблюдаемый признак и заранее решённая реакция.

Планшетный дрейф был в этом списке и снят измерением (раздел 5.2).

16. Что не проверено

Список на момент выпуска документа.

Совместная модель запущена в минимальной форме, полная — нет. Строка 5 абляции больше не пуста: общий ствол с двумя головами и переключателем при слабом скрининге измерен на четырёх зёрнах, результат в разделе 14. Коротко: канал несёт извлекаемую информацию, но получить её в единицах метрики удаётся только вместе с перекалибровкой после модели, а поферментно эффект меняет знак и на 2D6 отрицателен.

Незакрытым остаётся следующее. Измерены две свободные головы над общим стволом, то есть многозадачность; конструкция раздела 5, где скрининг ограничивает π через фиксированную калибровку, — отдельный объект, и он тоже измерен: результат в разделе 14, и он хуже, а не лучше.

Механизм порчи одноголовой руки не установлен, а две гипотезы исключены. И насыщение фиксированного отображения, и поглощение промаха (E, h) дают со измеренной поферментной потерей корреляцию *обратного* знака (раздел 14). Единственный порядок, который ложится точно, — ранговая связь скрининга с rIC_{50} , то есть тот же фактор, что управляет двухголовой рукой. Это согласуется с тем, что своей отдельной болезни у фиксированной калибровки нет, но не доказывает этого: четыре точки, и между ферментами меняется всё сразу. Проверка, которая превратила бы $n = 4$ в четыре независимые кривые, — ступенчатое подмешивание шума в скрининговый канал с наблюдением, монотонно ли ползёт эффект внутри каждого фермента, — не запускалась.

Сравнение ствола с бустингом посчитано на одном зерне. Шестой блок `src/trunkdose.py` — единственное место, где ствол и бустинг сопоставлены под наклоном маргинали, — работает на зерне разбиения 0, и это то зерно, на котором калиброванная рука ведёт себя хуже всего. Вывод «порядок не переворачивается, но разрыв сужается» надо перепроверить на четырёх зёрнах, прежде чем на него опираться при выборе того, что отправлять. Не запускались коррегионализация, предобученный энкодер и совместное правдоподобие поверх них, то есть строки 2, 3 и полная версия 5. Всё это по-прежнему объясняет, почему конструкция должна работать, а не показывает, что она работает в полном виде.

Вероятностное правило TDI — интегрирование (22) по совместному предсказательному распределению — не запускалось; все измеренные варианты детерминированные.

Оценщик rK_a проверен на двадцати соединениях, выбранных вручную. Средняя ошибка 0.60 при медианной 0.2, то есть среднее делают четыре промаха, худший — кофеин, 4.5 единицы: правило относит его азот к имидазолам с базовым 7.0 и недоштрафовывает соседние карбонилы. На бинарный вопрос про заряд при 7.4 это не влияет, но мотив «ароматический азот через атом от карбонила» встречается у трёх процентов обучающей выборки — зона, где правило может систематически завышать.

Проверка, которая это меряет, до сих пор не запускалась: у неё было сломано две подстановки путей и не хватало каталога в `sys.path`, а внутри она читала не то поле возврата — индекс атома вместо имени класса, из-за чего два её числа печатались нулями. После починки картина шире заявленной. Самый основной центр относится к имидазолу или пиридину у 55.8 процента обучающей выборки, то есть больше чем у половины молекул ответ правила опирается на ароматический азот. Пересечение

с карбонилом по соседству — ровно конфигурация кофеина — даёт 109 молекул, 2.2 процента. Три процента из предыдущего абзаца остаются верными, но относятся к мотиву, а не к тем молекулам, у которых на этом мотиве стоит итоговый ответ.

Учит ли графовая сеть протонирование сама — не проверялось. Если учит, часть выводов про механистический блок придётся переписать.

Зависимость калибровки от соединения в этих данных непроверяема: у каждого соединения одно показание скрининга, разделить «соединение отклоняется от калибровки» и «прибор шумит» на одном измерении нельзя.

Контроль в проверке ограничения диапазона выравнивает количество примеров, но не форму распределения меток.

17. Сводка чисел

	1A2	2C9	2D6	3A4	Макро
Меток pIC_{50}	1412	1285	1493	2335	6525
Межквартильный размах меток	1.00	0.92	0.83	1.50	—
Надёжность меток (потолок R^2)	0.948	0.905	0.934	0.898	—
ST-RAE, фингерпринт и дескрипторы	0.880	0.702	0.993	0.518	0.773
ST-RAE, плюс механистический блок	0.879	0.691	0.980	0.519	0.767
Спирмен, фингерпринт и дескрипторы	0.497	0.583	0.351	0.764	0.549
Спирмен, плюс механистический блок	0.496	0.597	0.403	0.765	0.565
Калибровка: E	0.728	0.621	0.867	0.931	—
Калибровка: h	1.261	1.112	1.243	1.968	—
Ранговая связь скрининга с pIC_{50}	−0.86	−0.90	−0.83	−0.94	—
Ско ST-RAE по четырём зёрнам, без блока	0.0136	0.0098	0.0132	0.0063	0.0066
Ско ST-RAE по четырём зёрнам, с блоком	0.0109	0.0078	0.0052	0.0057	0.0019

Таблица 10. Кросс-валидированы шесть строк из двенадцати. Четыре строки ST-RAE и Спирмена — пятикратная кросс-валидация по кластерам Бутины при пороге 0.35, макро на зерне 0; две строки со стандартным отклонением — по четырём зёрнам того же разбиения. Остальные шесть кросс-валидацией не являются и сравнивать их с первыми по строгости нельзя: число меток и межквартильный размах — статистики колонки, надёжность — разложение дисперсии по заявленной погрешности измерения, а калибровка E , h и ранговая связь скрининга — подгонки на всей выборке сразу, без отложенной части.

Правило решения для TDI	MCC 3A4	MCC 2D6
Всегда «нет»	0.000	0.000
Классификатор, порог 0.5	0.302	0.103
Классификатор, порог подобран	0.356	0.127
Две независимые регрессии плеч, затем правило	0.255	0.094
Отдельная голова на сдвиг, затем правило	0.323	0.104
То же с подобранным порогом сдвига	0.324	0.149
Подстановочный порог по сырым вероятностям	0.325	0.115
Подстановочный порог после калибровки Платта	0.352	0.092

Таблица 11. Все числа получены на 2346 соединениях для 3A4 и 1495 для 2D6 — тех, у кого есть и признаки, и метка. Доля положительных в этих выборках 32.6 и 21.7 процента; по файлу TDI целиком — 21.3 и 21.6, и разница целиком объясняется тем, что 1238 соединений без кривой доза-эффект автоматически размечены как отрицательные.