

Модель предсказания ингибирования цитохромов P450

Устройство решения для OpenADMET CYP Blind Challenge: что в данных,
что мы измерили, как устроена модель и почему именно так

27 августа 2026

Аннотация

Документ описывает решение задачи предсказания ингибирования четырёх изоформ цитохрома P450 по структуре молекулы. Содержит разбор того, что лежит в данных и что мы из них измерили, устройство модели и обоснование каждого её элемента, протокол проверки и список того, что уже проверено и не работает. Все числа получены прогонами на открытых данных соревнования и воспроизводимы; графики построены по тем же прогонам. Рассчитан на две аудитории сразу: на химика, знакомого с основами машинного обучения, и на специалиста по машинному обучению, знакомого с основами биохимии.

Содержание

1	Задача	3
1.1	Метрика регрессии и что из неё следует	3
1.2	Метрика классификации	3
2	Биохимия задачи	4
2.1	Что такое цитохромы P450 и почему именно эти четыре	4
2.2	Почему ингибирование — проблема	4
2.3	Что такое IC_{50} и pIC_{50}	5
2.4	Как читают результат и откуда берутся артефакты	5
2.5	Что такое time-dependent ингибирование	5
2.6	Что такое E_{max} и положительный контроль	6
2.7	Чем четыре фермента различаются	6
3	Данные	7
3.1	Что меряют эти таблицы	7
3.2	Как собран тестовый набор	8
4	Что мы измерили до того, как что-то строить	8
4.1	Версия первая: метки шумные, учить нечего	9
4.2	Версия вторая: не хватает нужных признаков	9
4.3	Версия третья: дело в том, какие соединения попали в выборку	10
5	Порождающая модель	12
5.1	Правдоподобия по источникам	12
5.2	Калибровка прибора	13
5.3	Почему цензурирование получается само	14
6	Идентифицируемость	15
6.1	Крутизна — на уровень фермента	15
6.2	Глубина: амортизация вместо поштучной подгонки	15
6.3	А теперь измерения, и они меняют вывод	16

7	Механизм пропусков	17
7.1	Как раскладывается совместное распределение	17
7.2	Что даёт симуляция	17
8	Архитектура	18
8.1	Ствол	18
8.2	Связь между ферментами: коррегионализация	19
8.3	Механистический блок	21
8.4	Канал артефактов пробы	21
8.5	Головы	21
9	Функция потерь и обучение	21
9.1	Батчинг по молекулам, а не по строкам	22
9.2	Двухэтапная калибровка	22
9.3	Веса источников	22
10	Неопределённость	22
11	Решающий слой	23
11.1	Регрессия: вывод	23
11.2	TDI: здесь слой окупается	24
12	Трансдуктивный слой	25
12.1	Сдвиг распределения	25
12.2	Серийный случайный эффект	25
13	Протокол оценки	25
13.1	Три уровня строгости разбиения	26
13.2	Насколько наша проверка похожа на тест	26
13.3	Устойчивость к разбиению	27
13.4	Устойчивость к версии библиотеки	28
13.5	Парный бутстрап	29
13.6	Сетка абляций	29
14	Что уже измерено и не работает	29
15	Что ломается и по какому признаку это видно	30
16	Что не проверено	30
17	Сводка чисел	32

1. Задача

Вход — SMILES молекулы. Оцениваемых треков два: регрессия и классификация. Третий, предсказание позы лиганда в кармане фермента, откроется в середине соревнования и здесь не разбирается.

В регрессионном треке нужно выдать матрицу $\hat{Y} \in \mathbb{R}^{750 \times 4}$: pIC_{50} прямого ингибирования для CYP1A2, CYP2C9, CYP2D6 и CYP3A4. В классификационном — $\hat{Y} \in \{0, 1\}^{750 \times 2}$: метку time-dependent ингибирования для 3A4 и 2D6. Тестовые 750 соединений выданы без меток, отправка закрывается 3 ноября.

1.1. Метрика регрессии и что из неё следует

Метрика — не средняя абсолютная ошибка. Организаторы публикуют вместе с каждым pIC_{50} границы доверительного интервала байесовской подгонки кривой, и ошибка считается до ближайшей границы, а не до точечной оценки:

$$\text{ST-RAE} = \frac{\sum_i [(\hat{y}_i - h_i)_+ + (l_i - \hat{y}_i)_+]}{\sum_i [(\bar{y} - h_i)_+ + (l_i - \bar{y})_+]}, \quad \bar{y} = \frac{1}{n} \sum_i y_i. \quad (1)$$

Здесь l_i и h_i — нижняя и верхняя границы интервала i -го соединения, а $(\cdot)_+ = \max(\cdot, 0)$. Числитель: предсказание, попавшее внутрь полосы, не штрафуетсся вовсе, а вышедшее наружу штрафуетсся только на расстояние до ближайшего края. Знаменатель: та же величина для константного предсказателя, выдающего среднее по оценочному набору. Отношение единица означает, что модель не лучше предсказания одного числа для всех соединений подряд; меньше единицы — лучше.

Из этого следует три вещи, и каждая влияет на архитектуру.

Первое. Задача интервально-цензурированная, и обучаться надо на той же клипованной L1, а не на квадратичной ошибке. Квадратичная будет тянуть предсказание к центру полосы там, где метрике всё равно, где именно внутри полосы оно стоит.

Второе. Это отношение сумм, а не среднее отношений. Соединения с широкой полосой почти невесомы в обеих частях: они дают мало и в числитель, и в знаменатель. Метрику определяют соединения с узкой полосой, то есть активные, у которых кривая хорошо определена.

Третье. Оптимальная точечная оценка под (1) не обязана совпадать с условным средним предсказательного распределения. Это разбирается в разделе 11.

Знаменатель считается по среднему *того набора*, на котором метрика вычисляется. У нас это среднее по обучающей подвыборке фермента, на лидерборде — по 750 тестовым соединениям. Значит наши числа и числа лидерборда напрямую несопоставимы, даже если модель одна и та же; сопоставимы только разности между вариантами, посчитанные на одном наборе.

1.2. Метрика классификации

Для TDI считается коэффициент корреляции Мэтьюса:

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}. \quad (2)$$

Это коэффициент корреляции Пирсона между двумя бинарными векторами, предсказанным и истинным. При несбалансированных классах он ведёт себя куда

честнее точности: предсказать всем «нет» даёт точность 78 процентов и МСС ровно ноль.

МСС не раскладывается по объектам. Вклад одного соединения зависит от того, что предсказано остальным, потому что все четыре счётчика стоят под общим корнем. Отсюда следует, что порог 0.5 почти никогда не оптимален и его надо выбирать явно — см. раздел 11.

Обе метрики агрегируются макро-усреднением по эндпойнтам, и лидерборд сортируется по этому среднему. Организаторы пересчитывают его на 1000 бутстрап-выборках.


2. Биохимия задачи

Раздел для тех, кто пришёл со стороны машинного обучения: что физически стоит за каждой колонкой в данных. Без этого половина решений в модели выглядит произволом.

2.1. Что такое цитохромы P450 и почему именно эти четыре

Цитохромы P450 — надсемейство гем-тиолатных монооксигеназ. Гем — порфириновое кольцо с железом в центре, то же самое, что в гемоглобине; «тиолатные» означает, что пятое координационное место железа занимает атом серы остатка цистеина. Название историческое: восстановленный комплекс фермента с угарным газом даёт полосу поглощения при 450 нм.

Каталитический цикл в общем виде: фермент связывает субстрат, железо восстанавливается, присоединяет кислород, кислород расщепляется с образованием высокореакционного оксоферрильного интермедиата (Compound I), который вырывает водород у субстрата и вставляет туда гидроксил. Суммарно



Электроны поставляет НАДФН через флавопротеин цитохром-P450-редуктазу. Для эксперимента отсюда следует вот что: без НАДФН фермент не работает, так что катализ можно включать и выключать в пробирке. На этом приёме построено измерение TDI.

Смысл реакции — сделать липофильную чужеродную молекулу более полярной, чтобы её можно было конъюгировать (вторая фаза метаболизма) и вывести. Печёночные P450 — главный барьер между проглоченным веществом и системным кровотоком.

Изоформ у человека около 57, но лекарственный метаболизм сосредоточен в немногих. CYP3A4 отвечает примерно за половину всех оборотов, CYP2D6, CYP2C9, CYP2C19 и CYP1A2 — за большую часть остального. Четвёрка в соревновании покрывает подавляющее большинство клинически значимых взаимодействий.

2.2. Почему ингибирование — проблема

Если препарат А ингибирует фермент, который выводит препарат В, концентрация В в крови растёт — иногда в разы. Для препарата с узким терапевтическим окном это прямая дорога к токсичности, вплоть до снятия с рынка уже зарегистрированного средства, безопасного само по себе.

Поэтому ингибирование P450 проверяют рано, ещё на стадии выбора соединения-кандидата. Предсказание по структуре экономит эти пробы, и цена ошибки здесь измеряется в снятых с разработки молекулах.

2.3. Что такое IC_{50} и pIC_{50}

В пробу вносят фермент, зонд-субстрат с известной скоростью превращения и испытуемое соединение в нескольких концентрациях. Измеряют, насколько упала скорость превращения зонда. IC_{50} — концентрация испытуемого соединения, при которой скорость падает вдвое. $pIC_{50} = -\log_{10} IC_{50}$ в молях на литр: $pIC_{50} = 6$ соответствует одному микромолю, $pIC_{50} = 4$ — ста микромолям. Больше pIC_{50} — сильнее ингибитор.

Важная оговорка: IC_{50} — не константа связывания. Она зависит от концентрации зонд-субстрата и от механизма (конкурентный ингибитор вытесняется субстратом, неконкурентный — нет); связь с константой ингибирования K_i даёт соотношение Ченга–Прусоффа. Сравнить IC_{50} между лабораториями и пробами напрямую нельзя, внутри одного набора — можно, и именно это мы и делаем.

2.4. Как читают результат и откуда берутся артефакты

Зонд-субстрат подбирают так, чтобы его превращение было легко измерить. Способов два.

Флуоресцентный: зонд после окисления даёт флуоресцирующий продукт, и прибор просто меряет свечение. Дёшево и быстро, поэтому так сделаны 1A2, 2C9 и 3A4 в этом наборе.

Масс-спектрометрический: продукт детектируют по массе. Дороже, но специфичнее; так сделан 2D6.

Отсюда конкретный артефакт. Если испытуемое соединение само флуоресцирует в том же диапазоне или, наоборот, тушит флуоресценцию продукта, прибор покажет изменение сигнала, которого химически не было. Ложное «ингибирование» появится в трёх флуоресцентных эндпойнтах и не появится в масс-спектрометрическом. Поэтому в модели заведён отдельный канал артефактов пробы (раздел 8.4): это конфаундер с известной структурой, а не шум.

2.5. Что такое time-dependent ингибирование

Обычное ингибирование обратимо: молекула садится в карман, мешает субстрату, отпускает. Уберите ингибитор — активность вернётся.

Time-dependent ингибирование, оно же механизм-зависимая инактивация, устроено иначе. Фермент сам превращает соединение в реакционноспособный продукт, и этот продукт остаётся — ковалентно модифицирует гем или белок, либо образует прочный комплекс с железом (metabolite-intermediate complex). Фермент выведен из строя необратимо. Отличительные признаки: процесс требует катализа (без НАДФН не идёт), развивается во времени, насыщается по концентрации, и активность не восстанавливается отмывкой.

Клинически это гораздо хуже обратимого ингибирования. Обратимый ингибитор перестаёт мешать, как только выводится из организма. Инактивированный фермент восстанавливается только синтезом нового белка, а на это уходят сутки-двое. Поэтому эффект накапливается при повторных приёмах и держится долго после отмены.

Как это измеряют. Ставят два плеча одной пробы.

Прямое плечо: соединение и зонд-субстрат вносят одновременно, сразу меряют IC_{50} . Видно обратимое ингибирование.

Плечо с преинкубацией: соединение сначала выдерживают с ферментом и НАДФН, дав катализу поработать, и только потом вносят зонд и меряют IC_{50} . Если соединение — механизм-зависимый инактиватор, за время преинкубации часть фермента выведена из строя, и измеренная IC_{50} окажется ниже: соединение выглядит потентнее, чем было.

Разница между плечами и есть сигнал. В логарифмической шкале это сдвиг

$$\Delta = \pi_{\text{после преинкубации}} - \pi_{\text{прямое}} \geq 0,$$

и неотрицательность здесь не соглашение, а физика: преинкубация может только добавить инактивации, но не отменить обратимое связывание. Двукратный сдвиг IC_{50} — то есть $\Delta > \log_{10} 2 \approx 0.301$ — общепринятый порог, за которым соединение помечают как TDI.

Отсюда становится понятной вторая ветвь правила разметки из раздела 11. Соединение может быть настолько слабым обратимым ингибитором, что в прямом плече его IC_{50} вообще не определяется как значимая ($\pi \leq 4$, то есть слабее ста микромолей). Но если после преинкубации оно перешло порог активности с тем же двукратным запасом ($\pi + \Delta > 4 + \log_{10} 2$), это тоже TDI — просто инактивация оказалась единственным его механизмом. Правило и состоит из этих двух случаев.

2.6. Что такое $E_{\max}$ и положительный контроль

Кривая доза-эффект выходит на плато. Высота плато — $E_{\max}$, предельная доля подавленной активности. Полный ингибитор обнуляет активность, частичный оставляет какую-то долю сколь угодно высокой концентрации. Причины частичности бывают разные: соединение садится не в каталитический карман, а в аллостерический; или у фермента несколько сайтов связывания субстрата, как у CYP3A4.

Измеряют $E_{\max}$ не в абсолютных единицах, а относительно положительного контроля — известного полного ингибитора этого фермента, который ставят в ту же пробу. Отсюда шкала в данных: полный ингибитор даёт примерно -1 , потому что подавил столько же, сколько контроль. Такая нормировка снимает разброс между планшетами и партиями фермента.

2.7. Чем четыре фермента различаются

Отсюда понятно, почему модель устроена как многозадачная с явной матрицей связей, а не как одна голова.

CYP3A4 — самый крупный и самый неразборчивый. Активный карман большой и податливый, вмещает молекулы вплоть до циклических пептидов; в нём помещается больше одного лиганда одновременно, откуда кооперативность и не всегда сигмоидные кривые. Узнавание в основном гидрофобное, поэтому предсказатель «крупная жирная молекула — вероятный ингибитор» работает удивительно хорошо. Отсюда и лучшая предсказуемость 3A4 в наших измерениях.

CYP2C9 — карман поменьше, на входе положительно заряженный остаток аргинина, притягивающий анионы. Субстраты преимущественно кислые, с карбоксильной или другой ионизуемой группой. С 3A4 частично перекрывается по липофильности, отсюда ранговая корреляция 0.69.

CYP1A2 — узкая плоская щель. Субстраты — плоские ароматические системы, полициклика и азотистые гетероциклы. Они же его и индуцируют, из-за чего у курильщиков клиренс некоторых препаратов заметно выше.

CYP2D6 объясняет половину этого документа. В активном центре сидят остатки аспартата и глутамата, дающие солевой мостик с протонированным атомом азота лиганда. Практически все известные субстраты и ингибиторы 2D6 — основания, заряженные при физиологическом pH. Узнавание идёт не по общей липофильности, а по конкретному электростатическому взаимодействию на конкретном расстоянии от ароматического ядра.

Долю протонированной формы даёт уравнение Гендерсона–Хассельбальха:

$$f_{\text{прот}} = \frac{1}{1 + 10^{\text{pH} - \text{p}K_a}}. \quad (3)$$

При pH 7.4 третичный амин с $\text{p}K_a$ около 9.8 заряжен на 99.6 процента, пиридиновый азот с $\text{p}K_a$ 5.2 — на 0.6 процента, а амид не заряжен вовсе. Разница в сто с лишним раз по доле заряженных молекул. Фингерпринт, считающий фрагменты в радиусе двух связей, видит во всех трёх случаях просто «атом азота в таком-то окружении» и различить их не может — отсюда механистический блок признаков.

И ещё: 2D6 сильно полиморфен. Часть популяции несёт неработающие аллели, часть — дубликации гена; это делает предсказание ингибирования 2D6 клинически особенно ценным, но на наши данные не влияет, поскольку измерения делаются на рекомбинантном ферменте одного варианта.

3. Данные

Пять таблиц, около 35 тысяч строк. Устройство этих данных важнее их объёма: вся конструкция модели вырастает из одной асимметрии. Обучающая матрица разрежена и смещена отбором, тестовая плотная.

Источник	Форма	Заполнено	Что это
Кривые доза-эффект, прямое плечо	4905 × 4	26–48 %	pIC_{50} плюс границы интервала и стандартная ошибка
Кривые, плечо преинкубацией	с 6145 × 4	24–58 %	то же для условия TDI
E_{max} , оба плеча	6146 × 8	частично	предельная глубина подавления и её интервал
Одноточечный скрининг	4376 × 4	100 %	$\log_2 f_c$ при 49.5 мкМ и стандартная ошибка
Тест	750 × 4	—	слепой, плотный

Таблица 1. Пять источников. Пересечения между ферментами внутри таблицы кривых маленькие: одновременно для 1A2 и 2C9 измерено 295 соединений, для 2C9 и 2D6 — 230. Скрининг — единственный плотный источник, и он покрывает весь диапазон активностей, включая неактивные соединения, которых в кривых почти нет.

3.1. Что меряют эти таблицы

Кривая доза-эффект: соединение разводят по концентрациям, для каждой измеряют, насколько подавлена активность фермента, и через полученные точки проводят

сигмоиду. Из подгонки получают pIC_{50} — отрицательный десятичный логарифм концентрации, при которой активность падает вдвое. Байесовская подгонка даёт не только точку, но и интервал, отражающий, насколько уверенно эта точка определена. У соединений, чья кривая не дошла до плато, интервал широкий.

Одноточечный скрининг: то же измерение, но при одной концентрации 49.5 мкМ. На выходе $\log_2 fc$ — логарифм отношения сигнала с соединением к сигналу без него. Ноль означает, что ничего не произошло, отрицательные значения — что активность подавлена.

Полные кривые снимали не для всех подряд. Соединение поднимали на подробное измерение, если оно показало эффект на скрининге. Это отбор по зависимой переменной, и он деформирует обучающую выборку способом, который разобран в разделе 4.3.

3.2. Как собран тестовый набор

Организаторы описали процедуру: взяли по 25 лучших ингибиторов каждого из 1A2, 2C9 и 3A4, к каждому добавили по 10 ближайших соседей по фингерпринту, итого $3 \times 25 \times 10 = 750$.

Это проверяется, и проверка сходится частично. Кластеризация 750 тестовых соединений даёт 194 группы с медианным размером два; групп по пять и более членов 55, и в них лежат 490 соединений из 750. То есть серийная структура в наборе есть и покрывает больше половины, но ровно 75 серий ровно по 10 из данных не восстанавливается — число 75 получается делением 750 на 10.

Что восстанавливается уверенно, так это положение якорей. Для каждой группы найдено ближайшее обучающее соединение, и его активность стоит на 93.0, 97.5 и 98.2 перцентиле обучающего распределения по 1A2, 2C9 и 3A4 — и только на 62.8 по 2D6, который в отборе не участвовал. Медианное сходство Танимото тестового соединения с ближайшим обучающим равно 0.587.

Значит распределение меток на тесте не совпадает с обучающим: тест обогащён активными по трём ферментам и близок к фону по четвёртому. И устроен он как набор серий аналогов вокруг известных хитов, а не как случайная выборка из химического пространства. Проверять модель надо соответственно.

4. Что мы измерили до того, как что-то строить

Первое, что было сделано — простая базовая линия и разбор, почему она ведёт себя так, как ведёт. Без этого нет способа отличить работающую конструкцию от красивой.

Базовая линия: счётчики фрагментов Моргана радиуса 2 (2048 бит), 217 дескрипторов RDKit, градиентный бустинг, пятикратная кросс-валидация по кластерам Бутины при пороге сходства 0.35.

Числа по ферментам: 1A2 — ST-RAE 0.880 при Спирмене 0.497; 2C9 — 0.702 и 0.583; 2D6 — 0.993 и 0.351; 3A4 — 0.518 и 0.764. Макро 0.773. Коэффициент детерминации на тех же фолдах: 0.216, 0.350, 0.122, 0.589.

CYP2D6 практически не предсказывается. Это и стало главным предметом разбирательства, потому что от объяснения зависит, что вообще строить дальше.




Рис. 1. Базовая линия регрессионного трека. Красная линия — уровень предсказания одного числа для всех соединений. CYP3A4 предсказывается вдвое лучше этого уровня, CYP2D6 — на две сотых.

4.1. Версия первая: метки шумные, учить нечего

Если почти весь разброс опубликованных активностей — погрешность измерения, то потолок для любой модели низкий и делать нечего. Обычно разделить настоящий разброс и шум трудно, но здесь вместе с каждым значением опубликована его собственная стандартная ошибка.

Дисперсии независимых источников разброса складываются, поэтому

$$\text{Var}(\text{наблюдаемое}) = \text{Var}(\text{настоящее}) + \text{Var}(\text{шум}), \quad \text{надёжность} = 1 - \frac{\text{Var}(\text{шум})}{\text{Var}(\text{набл.})}. \quad (4)$$

Надёжность — доля разброса меток, которая приходится на настоящие химические различия. Она же задаёт потолок R^2 для любой модели на этих метках: предсказать шум нельзя.

Для CYP2D6 стандартное отклонение меток 0.916, среднеквадратичная погрешность одного измерения 0.236, надёжность 0.934. По остальным ферментам от 0.898 до 0.948. Версия не подтвердилась: сигнала в метках достаточно. Сравнивая достигнутый R^2 с этим потолком, модель осваивает на 2D6 лишь восьмую часть доступного (0.122 из 0.934) и две трети на 3A4 (0.589 из 0.898).

Оговорка, которую надо держать в голове. Слово «среднеквадратичная» здесь существенно: медианная погрешность на 2D6 равна 0.069, то есть в три с половиной раза меньше, а почти шестьдесят процентов всей шумовой дисперсии дают верхние пять процентов соединений с развалившейся подгонкой. В разложение (4) идёт именно средний квадрат, так что число верное, но шум резко гетероскедастичен, и взвешивание по индивидуальной погрешности важнее, чем кажется по среднему.

4.2. Версия вторая: не хватает нужных признаков

Как разобрано в разделе 2.7, CYP2D6 узнаёт субстраты через солевой мостик с протонированным азотом, а не через общую липофильность. Фингерпринт про заряд не знает: третичный амин и амид для него — два похожих азота в похожем окружении, хотя доля заряженной формы у них различается в сотни раз.

Собрали блок из 28 химически осмысленных чисел: оценка pK_a самого основного центра, доля протонированной формы при pH 7.4, полный заряд молекулы, счётчики классов азота и кислотных групп, топологическое расстояние от заряженного азота до ближайшего ароматического кольца. Оценщик pK_a — правило: базовое значение класса минус индуктивный штраф от электроноакцепторных заместителей с затуханием по числу связей. На двадцати соединениях с литературными значениями средняя ошибка 0.60 единицы, медианная 0.2, и на бинарный вопрос «заряжено ли при 7.4» правило ответило верно во всех двадцати случаях.

Результат двойственный, и это тот случай, когда полезно смотреть на две метрики сразу.

По ST-RAE выигрыша нет. Парный бутстрап по соединениям даёт для 2D6 разность -0.012 с интервалом от -0.041 до $+0.017$; на макро-уровне -0.0056 с интервалом от -0.0155 до $+0.0041$. Интервалы накрывают ноль.

По ранжированию выигрыш есть, и он избирателен именно так, как предсказывает химия. Спирмен на 2D6 растёт с 0.351 до 0.403, разность $+0.052$ с интервалом от $+0.022$ до $+0.082$ и вероятностью отсутствия прироста 0.001. На 2C9 $+0.014$ на грани значимости, на 1A2 и 3A4 нули с интервалами шириной в две сотых.

Ещё показательнее вот что: модель, построенная только на тридцати механистических числах, без фингерпринта и дескрипторов, воспроизводит на 2D6 92 процента ранжирующей способности модели на фингерпринте с дескрипторами и 80 процентов от полной модели со всеми блоками — против 43–53 процентов на трёх остальных при любом из двух знаменателей. Сигнал CYP2D6 низкоразмерный и химически специфичный.

Итог: механизм назван верно, но выигрыш по метрике соревнования неотличим от нуля. Признаки — часть ответа, не главная его часть.

4.3. Версия третья: дело в том, какие соединения попали в выборку

У CYP2D6 отбор оставил узкую полосу: средняя половина соединений уместилась в интервал шириной 0.83 логарифмической единицы против 1.50 у CYP3A4. Это ограничение диапазона, оно же selection on the dependent variable: если отобрать объекты по интересующему признаку и потом мерить связь только среди отобранных, связь ослабевает, хотя в полной популяции она никуда не делась.

Проверка требует второго показателя активности того же фермента, измеренного без отбора. Он есть: $\log_2$ fc скрининга, снятый для 4375 соединений подряд, включая неактивные. Учим ту же модель на тех же признаках и тех же фолдах предсказывать его вместо pIC_{50} .

Чтобы это не превратилось в сравнение «больше примеров против меньше», сделан контроль: из соединений со скринингом случайно выбирается ровно столько же, сколько у этого фермента меток кривых.

Прирост монотонно падает с ростом размаха меток: 2D6 $+0.128$, 2C9 $+0.075$, 1A2 $+0.027$, 3A4 -0.028 . Четыре точки, монотонно, и отрицательный знак на CYP3A4 работает внутренним контролем против объяснения «скрининг просто легче предсказуем сам по себе». На 2D6 при равном числе примеров R^2 поднимается с 0.136 до 0.323.

Модель прекрасно умеет учить химию CYP2D6, но не может показать это на выданных метках. Основная причина провала — геометрия меток, и чинится она не признаками, а тем, что в правдоподобие входит источник с полным диапазоном. На этом и построено всё остальное.




Рис. 2. Распределения измеренных активностей. Цветом выделены средние 50 процентов соединений. У CYP3A4 задача во многом сводится к тому, чтобы отделить левую часть от правой. У CYP2D6 левой части почти нет, и модели приходится различать соединения внутри узкой полосы.




Рис. 3. Выигрыш от перехода на показатель с полным диапазоном против ширины полосы меток. Пустой кружок — качество на метках кривых, закрашенный — на скрининге при равном числе обучающих примеров. Стрелка тем длиннее, чем уже полоса меток, и на CYP3A4 разворачивается.

Честная оговорка про контроль: выровнено количество примеров, но не форма распределения меток. Совсем чистый эксперимент требует подобрать подвыборку так, чтобы совпадало и то и другое.

5. Порождающая модель

Все пять таблиц — наблюдения над одним объектом: кривой доза-эффект для тройки «молекула m , фермент e , плечо a » (плечо — прямое измерение или измерение после преинкубации). Модель описывает эту кривую, а не отдельные таблицы, и каждая таблица подключается своим правдоподобием.

Латентные параметры тройки:

$$\theta_{m,e,a} = (\pi_{m,e,a}, E_{m,e,a}, h_e), \quad \pi_{m,e,tdi} = \pi_{m,e,dir} + \Delta_{m,e}, \quad \Delta \geq 0. \quad (5)$$

Здесь π — потенция, та самая pIC_{50} ; E — предельная глубина подавления, то есть какая доля активности фермента подавляется при бесконечной концентрации; h — крутизна перехода, вынесенная на уровень фермента (почему — в разделе 6). Сдвиг Δ неотрицателен, потому что преинкубация может только усилить ингибирование, а не ослабить.

Прямая модель прибора — доля подавленной активности при концентрации C :

$$I(C; \theta) = \frac{E}{1 + 10^{h(pC - \pi)}}, \quad pC = -\log_{10} C. \quad (6)$$

Уравнение Хилла. При $pC = \pi$, то есть когда концентрация равна IC_{50} , показатель обнуляется и подавлена ровно половина от предельной глубины. Выше концентрация — меньше pC — отрицательное значение — ближе I к E . Ниже — наоборот. Крутизна h задаёт, за сколько декад концентрации происходит переход: при $h = 1$ путь от десяти до девяноста процентов эффекта занимает примерно две декады.

5.1. Правдоподобия по источникам

Кривая из двенадцати точек даёт несимметричную оценку: интервал вокруг pIC_{50} обычно длиннее с одной стороны. Усреднять границы — терять эту информацию, поэтому берём расщеплённую нормаль с двумя масштабами:

$$-\log p(y_{\text{крив}} | \pi) = \text{split-}\mathcal{N}(\pi; \hat{\pi}, \sigma^-, \sigma^+), \quad \sigma^- = \frac{\hat{\pi} - l}{1.96}, \quad \sigma^+ = \frac{h - \hat{\pi}}{1.96}. \quad (7)$$

Две половинки нормального распределения с разными ширинами, сшитые в моде и отнормированные общим множителем $2/[\sqrt{2\pi}(\sigma^- + \sigma^+)]$. Правило деления на 1.96 точно только при симметричной полосе: у расщеплённой нормали слева лежит масса $\sigma^-/(\sigma^- + \sigma^+)$, а не половина, поэтому квантиль стоит не в 1.96 сигмы. На наших данных полосы почти симметричны — максимум медианной асимметрии 0.13 логарифмической единицы — и расхождение составляет 0.0004 единицы pIC_{50} . Правило годится, но по этой причине, а не по общей верности.

Скрининг входит через (6) с аффинной калибровкой на фермент:

$$\hat{y}_{\text{скр}} = s_e \cdot \log_2(1 - I(C_0; \theta_{\text{dir}})) + b_e, \quad -\log p(y_{\text{скр}} | \theta, \psi_e) = \frac{(y_{\text{скр}} - \hat{y}_{\text{скр}})^2}{2(\sigma_i^2 + \sigma_e^2)} + \log \sqrt{\sigma_i^2 + \sigma_e^2}. \quad (8)$$

Прибор показывает логарифм оставшейся активности, отсюда $\log_2(1 - I)$. Пара (s_e, b_e) поглощает динамический диапазон пробы и нормировку; σ_i — опубликованная стандартная ошибка конкретного измерения, σ_e — обучаемая добавка, отвечающая за неучтённый разброс. Набор $\psi_e = (s_e, b_e, \sigma_e)$ и есть калибровка прибора.

Етах — прямое наблюдение второго параметра тройки; плечо с преинкубацией — наблюдение $\pi + \Delta$ с тем же расщеплённым нормальным правдоподобием.

5.2. Калибровка прибора

Калибровка — это функция, переводящая скрытую кривую в показание прибора. Не свойство соединения, а свойство установки: та же молекула на другом приборе даст другое показание, а pIC_{50} у неё останется прежней. Связь нелинейная и насыщающаяся: очень сильный ингибитор и ингибитор вдесятеро сильнее дадут при 49.5 мкМ практически одинаковое показание, потому что оба подавили всё, что можно.

Подгоняем E и h на фермент по соединениям, у которых есть и то и другое измерение.




Рис. 4. Калибровка. Точки — соединения, у которых есть и pIC_{50} , и показание скрининга. Сплошная линия — подгонка формой (6) с двумя параметрами на фермент, пунктир — свободная монотонная кривая, задающая предел для любой монотонной калибровки.

Из этой картинки следует три вещи.

Связь очень сильная: ранговая корреляция от -0.83 до -0.94 . Поэтому скрининг — почти достаточная статистика. Свободная монотонная калибровка по измеренному показанию даёт макро-ST-RAE 0.359 против 0.767 у полной модели по структуре. Знай мы показание скрининга для тестовых соединений, задача была бы вдвое легче; но на

тесте его нет, пересечение теста с первичной библиотекой ровно нулевое.

Хилловская форма теряет немного, но теряет. Стандартное отклонение остатка против свободной монотонной кривой: 0.231 против 0.208 на 1A2, 0.185 против 0.167 на 2C9, 0.497 против 0.390 на 2D6, 0.612 против 0.499 на 3A4. То есть двухпараметрическая форма жёстче, чем нужно, особенно на 2D6, где свободная кривая выходит на плато у неактивных, а хилловская тянется к нулю. Это аргумент за монотонную сплайн-поправку поверх параметрической формы, но не за отказ от неё: форма даёт правильную экстраполяцию там, где данных мало.

Крутизна разная: на 3A4 подобралось $h = 1.97$, на остальных около 1.2. Это свойство постановки на конкретном ферменте, поэтому калибровка не может быть общей на все четыре.

Отдельно проверен планшетный дрейф. Планшетов девять на фермент, и сырой разброс медиан по планшетам выглядит тревожно: до 0.24 при размахе 0.78. Но планшеты не рандомизированы, активные соединения сидят кучно, поэтому надо вычесть то, что объясняется составом планшета. После вычитания предсказанного по pIC_{50} разброс падает до 0.034–0.062 при стандартном отклонении остатка 0.17–0.50. Планшет объясняет от одного до трёх процентов остаточной дисперсии, отдельного слагаемого в модели не требуется.

Про обозначение: E в калибровке — не тот E , что в (5). Там предельная глубина подавления самого соединения, здесь — параметр установки, вбирающий её динамический диапазон. Совпадение буквы неудачное и в коде их надо развести.

5.3. Почему цензурирование получается само

Это главный технический аргумент за такую конструкцию. Продифференцируем (6) по потенции, обозначив $x = 10^{h(pC_0 - \pi)}$:

$$\frac{\partial I}{\partial \pi} = +E h \ln 10 \cdot \frac{x}{(1+x)^2}. \quad (9)$$

Множитель $x/(1+x)^2$ максимален при $x = 1$, то есть ровно когда $\pi = pC_0$, и равен там одной четвёртой; при $x \rightarrow 0$ и $x \rightarrow \infty$ он затухает экспоненциально. Фишеровская информация о π , которую несёт одна точка скрининга, пропорциональна квадрату этого множителя.




Рис. 5. Сколько информации о потенции несёт одно измерение при концентрации C_0 . Колокол сосредоточен вокруг pC_0 с шириной порядка $1/h$ декад и обнуляется в обеих зонах насыщения.

На практике это значит, что в зонах насыщения градиент по π исчезает сам. Для соединения, которое при 49.5 мкМ не подавило ничего, модель извлекает из скрининга мягкое неравенство «активность ниже примерно такой-то», а не число. Для соединения, подавившего всё, — неравенство с другой стороны. Никакого специального кода цензурирования писать не надо, оно следует из формы кривой.

Форма (9) видна в данных напрямую: перегиб зависимости показания от pIC_{50} на СУР3А4 приходится на 4.3 (рис. 4), то есть на $\text{pC}_0 = 4.305$ для 49.5 мкМ.

6. Идентифицируемость

Первое, что спросит любой, кто это читает: из однотоочечного измерения наблюдается ровно скаляр $I(C_0)$, а параметров в (5) три. Тройка (π, E, h) точно не идентифицируется — любая кривая, проходящая через ту же ординату при C_0 , объясняет данные одинаково хорошо.

Риск конкретный: сеть сбросит остаток в E , чтобы подогнать показание скрининга, и испортит π — единственную величину, которую с неё спрашивают на лидерборде.

Что с этим делаем, по возрастанию силы ограничения.

6.1. Крутизна — на уровень фермента

h_e , один скаляр на фермент вместо десятков тысяч. Первую версию делаем вообще с $h_e \equiv 1$. Оправдание не только техническое: крутизна кривой в такой пробе определяется в основном механизмом и стехиометрией связывания, а не индивидуальными особенностями лиганда, и подгонка калибровки (раздел 5.2) даёт по ферментам устойчивые 1.11–1.97.

6.2. Глубина: амортизация вместо поштучной подгонки

Есть два способа получить E для каждого соединения.

Поштучная подгонка: у каждого соединения свой свободный параметр E_m . Для 4905 соединений и четырёх ферментов это 19 620 свободных чисел, каждое подбирается только по данным своего соединения, и никакой связи между похожими молекулами нет.

Амортизация: свободных E_m нет вовсе, есть одна общая функция — голова сети, получающая представление молекулы и выдающая ответ:

$$E_{m,e} = \sigma(u_e^\top z_m + c_e). \quad (10)$$

Здесь z_m — вектор-представление молекулы из общего ствола, u_e и c_e — веса и сдвиг головы фермента, сигмоида зажимает ответ в интервал от нуля до единицы. Параметров $4(d+1)$, то есть при $d = 256$ чуть больше тысячи, и они обслуживают все соединения сразу, включая те, у которых своей кривой нет. Отсюда слово: дорогая процедура вывода амортизуется по всем объектам.

Как это работает регуляризатором. Чтобы выдать одному соединению нестандартное E , сети надо сдвинуть его представление, а представление производится общим стволом из структуры, и тот же ствол обслуживает все похожие молекулы. Подогнать E индивидуально можно только там, где есть структурная закономерность — класс молекул, систематически ведущий себя как частичный ингибитор. Если такого класса нет, а есть только шум подгонки кривой, сети выгоднее выдать всем примерно

одинаковое E . Формально это сужение множества гипотез: достижимые наборы $\{E_m\}$ — уже не произвольный вектор длины N , а образ структурного пространства под гладким отображением. Регуляризация здесь не слагаемое в функции потерь, а свойство параметризации.

6.3. А теперь измерения, и они меняют вывод

Всё сказанное объясняет, почему амортизация безопасна. Но у организаторов опубликованы измеренные E : колонки `EmaxVsPosCtrl_direct_inhibition` с доверительными полосами. Смотреть на них надо было до всяких рассуждений.




Рис. 6. Слева: цветной отрезок — где лежат 90 процентов соединений, серый — средняя ширина доверительной полосы одного измерения. Серый шире цветного на всех четырёх ферментах. Справа: надёжность по (4), отрицательная везде.

Шкала — относительно положительного контроля, поэтому полный ингибитор даёт примерно -1 . У CYP3A4 весь разброс E между соединениями укладывается в 0.06, а заявленная ширина полосы одного измерения 0.195, то есть втрое больше. У CYP2D6 0.09 против 0.179.

Отсюда отрицательная надёжность: от -0.73 до -1.43 . У честной величины она лежит между нулём и единицей; отрицательная означает, что заявленная дисперсия шума больше всего наблюдаемого разброса. Буквально это может означать, что полосы посчитаны консервативно, но верхняя оценка сигнала уровня соединения от этого не меняется — он не превышает нуля.

Значит амортизация была правильным решением по неправильной причине. Дело не в том, что сеть не сможет переобучиться, а в том, что переобучаться не на чем. Вместо головы нужна одна константа на фермент (-0.99 , -1.02 , -1.03 , -0.98), и, если хочется страховки, поштучная поправка с жёстким штрафом, которую данные обязаны прижать к нулю.

Что вариация E — артефакт подгонки, а не химия, видно ещё и так. Ранговая корреляция между измеренными E и π резко усиливается в средней зоне активности, там, где кривая обрывается, не дойдя до плато, и подгонщику приходится выбирать точку на гребне. По зонам $\text{pIC}_{50} < 4$, $4-5$ и ≥ 5 : на 1A2 $+0.14$, -0.63 , $+0.19$; на 2C9 $+0.20$, -0.57 , $+0.53$; на 3A4 $+0.03$, -0.46 , $+0.08$. А на 2D6 знак в средней зоне противоположный: -0.15 , $+0.54$, -0.21 . Химически бессмысленно, чтобы у трёх ферментов более потентные соединения давили глубже, а у четвёртого мельче. Это

подпись процедуры подгонки.

Диагностика на будущее остаётся прежней: смотреть разброс выхода головы E отдельно на соединениях с полной кривой и на соединениях только со скринингом. Если на вторых разброс заметно выше, голова используется как свалка для остатка.

7. Механизм пропусков

Полные кривые снимали не для всех: отбор шёл по результату первичного скрининга. Это отбор по зависимой переменной, то есть missing not at random по построению, и он же — причина провала на CYP2D6, измеренная в разделе 4.3.

Спасает вот что: *переменная отбора наблюдаема*. Скрининг есть для 4375 из 4905 соединений обучающей выборки, и именно он определял, кого поднимут на подробное измерение.

7.1. Как раскладывается совместное распределение

Пишем совместную плотность через скрытую активность a , честно:

$$p(y_{\text{крив}}, y_{\text{скр}}, R \mid x, \theta) = p(R \mid y_{\text{скр}}) \int p(a \mid x, \theta) p(y_{\text{скр}} \mid a) p(y_{\text{крив}} \mid a)^R da. \quad (11)$$

Здесь R — индикатор попадания в подробное измерение, $p(a \mid x, \theta)$ — что модель думает об активности до измерений (центр — предсказание сети, ширина — признание того, что структура определяет активность не полностью), два следующих множителя — шум каждого прибора, зависящий только от истинной активности. Множитель $p(y_{\text{крив}} \mid a)$ входит в степени R , то есть только для отобранных.

Главный шаг — вынос $p(R \mid y_{\text{скр}})$ за интеграл. Он законен потому, что решение об отборе принималось глядя на показание скрининга, а не на скрытую активность: под интегралом по a этот множитель величины a не содержит.

Применяя цепное правило, получаем рабочую форму:

$$p(y_{\text{крив}}, y_{\text{скр}}, R \mid \theta) = \underbrace{p(R \mid y_{\text{скр}})}_{\text{без } \theta} \cdot \underbrace{p(y_{\text{крив}} \mid y_{\text{скр}}, \theta)}_{\text{условно}} \cdot p(y_{\text{скр}} \mid \theta). \quad (12)$$

Первый множитель не зависит от θ , при дифференцировании логарифма даёт ноль и полностью выпадает из градиента. Значит можно обучаться на полном правдоподобии, вообще не моделируя процедуру отбора, и оценки останутся состоятельными. Условие ровно одно: скрининг должен входить в модель как наблюдение. Если его выбросить, первый множитель перестанет быть отделимым и смещение вернётся. По сути это поправка хекмановского типа, у которой первая ступень не моделируется, а наблюдается.

Средний множитель обязан быть *условным* по $y_{\text{скр}}$, и это место, где легко ошибиться. Заменить его на маргинальный $p(y_{\text{крив}} \mid \theta)$ можно только при нулевом собственном латентном разбросе соединения: два показания меряют одну скрытую активность, они коррелированы, а отбор идёт по одному из них — значит среди отобранных распределение второго сдвинуто. Маргинальный множитель про этот сдвиг не знает.

7.2. Что даёт симуляция

Проверено на данных, где истина известна по построению: $a = x^T \beta + \varepsilon$, скрининг у всех, кривая — у верхних тридцати процентов по скринингу.

Способ подгонки	Смещение, норма	Наклон калибровки
Только отобранные метки кривых	0.433	0.731
Совместное правдоподобие, отбор по скринингу	0.019	1.012
Только скрининг, все строки (контроль сверху)	0.002	1.000
Отбор по скрытой истине, скрининг у неотобранных не виден	0.512	0.681

Таблица 2. Сорок повторов, шесть тысяч соединений, в подробное измерение попадает 28 процентов. Наклон единица означает, что коэффициенты восстановлены без систематического сжатия.

Подгонка по одним отобранным меткам сжимает коэффициенты до 0.73 от истины — ровно то ограничение диапазона, которое видно на CYP2D6. Совместное правдоподобие возвращает 1.01.

Четвёртая строка важнее первых трёх. Сломайте условие, то есть сделайте отбор зависящим от скрытой величины и уберите скрининг у неотобранных, и совместная схема поломаётся так же, как наивная. Значит аргумент держится не на общей идее «использовать больше данных», а на наблюдаемости первой ступени отбора. В наших данных она наблюдается.

Отдельно измерена цена замены условного множителя на маргинальный. Смещения нет при нулевом латентном остатке, при $\sigma_{\text{лат}} = 0.35$ оно вдвое меньше стандартной ошибки оценки, при $\sigma_{\text{лат}} = 0.70$ уже сравнимо с ней. И независимо от смещения такая схема занижает собственную погрешность на 17–21 процент, потому что считает два коррелированных наблюдения одного соединения за два независимых свидетельства. Значит голова, предсказывающая pIC_{50} , должна получать на вход показание скрининга того же соединения. Или, что то же самое, обе величины должны выводиться из общего латентного слоя с явной ковариацией, а не из двух независимых голов.

На инференсе скрининга нет, но это не мешает. Условный множитель нужен на обучении, чтобы оценка не была смещена отбором; на предсказании мы маргинализуем по $y_{\text{скр}}$, что при общем латентном слое сводится к одному прогону сети.

Оговорка: 530 соединений с кривыми не имеют скрининга, и для них аргумент не работает. Доля небольшая, но при желании их можно взвесить или выкинуть в абляции.

8. Архитектура

8.1. Ствол

Предобученный химический энкодер $f_{\varphi} : \text{SMILES} \rightarrow z \in \mathbb{R}^d$. Организаторы выложили свои веса (CheMeleon, предобученный D-MPNN, и chemprop-foundation), плюс доступны Minimol и графовые трансформеры. Ансамблируем по семействам претрейна, а не по зёрнам одного семейства: ошибки разных семейств коррелируют слабее, и ансамбль из четырёх разных архитектур даёт больше, чем из восьми запусков одной. Дообучение через LoRA-адаптеры, чтобы 6.5 тысяч меток кривых не переписали претрейн, обученный на миллионах молекул.

8.2. Связь между ферментами: коррелизация

Ферментов четыре, и надо решить, как их связать. Очевидные способы не годятся. Четыре независимые модели: 2C9 не пользуется 2335 метками 3A4, хотя они меряют почти одно и то же. Одна общая голова: 2D6 тянет в сторону остальных трёх, а он с ними не коррелирует. Общий ствол и четыре независимые головы уже лучше, но связь между задачами остаётся неявной.

Коррегионализация — термин из геостатистики: совместное моделирование нескольких величин, измеренных в одних точках, через общую структуру плюс отдельную матрицу связей между величинами. Простейший вариант, *intrinsic coregionalization model*, выносит эту матрицу в явный параметр.

Голова линейная поверх общего представления:

$$\pi_{m,e} = w_e^\top g(z_m) + b_e, \quad W = [w_1 \ w_2 \ w_3 \ w_4] \in \mathbb{R}^{d \times 4}. \quad (13)$$

Вся связь между ферментами сидит в углах между столбцами W : если w_2 и w_4 смотрят почти в одну сторону, модели 2C9 и 3A4 читают представление одинаково. Матрица этих углов

$$B = W^\top W \in \mathbb{R}^{4 \times 4}, \quad B_{ee'} = w_e^\top w_{e'}, \quad (14)$$

и на неё навязывается структура «несколько общих осей плюс своё у каждого»:

$$B \approx LL^\top + \text{diag}(\kappa), \quad L \in \mathbb{R}^{4 \times r}, \quad r = 2. \quad (15)$$

Строка e матрицы L говорит, насколько фермент участвует в каждой из r общих осей; $LL^\top$ — общая часть ковариации ранга r ; κ_e — специфичная часть фермента, то, что есть только у него. Это обычная факторная модель: r общих механизмов узнавания плюс идиосинкразия.




Рис. 7. Слева — ранговая корреляция pIC_{50} между ферментами, посчитанная по общим соединениям (от 230 пар у 2C9–2D6 до 473 у 2C9–3A4). Справа — нагрузки факторной модели ранга 2 на те же данные: каждая стрелка показывает, насколько фермент участвует в каждой из двух общих осей. Первая ось нагружает 2C9, 3A4 и слабее 1A2, на 2D6 стоит на нуле; вторая ось — почти исключительно 2D6.

Данные говорят то же, что раздел 2.7: 2C9 и 3A4 идут в паре ($\rho = 0.688$), а 2D6 ортогонален всем троим (0.059, -0.120 , 0.056). Матрица положительно определена,

минимальное собственное число 0.287, так что раскладывать её можно. Нагрузки: ось 1 — 2C9 −0.907, 3A4 −0.773, 1A2 −0.480, 2D6 +0.033; ось 2 — 2D6 −0.726, остальные около нуля. Специфичные части κ : 0.759, 0.161, 0.472, 0.390.

Первая ось — липофильная промискуитетность: крупные жирные молекулы садятся в широкие карманы 2C9 и 3A4. Вторая — 2D6 с его солевым мостиком. Общая голова тянула бы 2D6 по первой оси и портила бы его.

Про ранг надо помнить вот что. При четырёх задачах внедиагональ содержит шесть чисел, а нагрузки ранга 2 дают $4 \times 2 = 8$ параметров минус одна степень свободы на вращение, то есть семь. Модель насыщена: ранг 2 воспроизводит внедиагональ точно не потому, что угадал структуру, а потому что параметров хватает. По-настоящему ограничивает только ранг 1, и он промахивается максимум на 0.10, причём весь промах приходится на 2D6. Так что структура ранга 2 — не сжатие, а способ задать приор и инициализацию. Польза проявится, когда B будет тянуть головы во время обучения, а не в самой аппроксимации матрицы четыре на четыре.

Регуляризационный член. Задача — не дать столбцам W разъехаться в произвольные углы, когда у фермента мало меток, и притянуть матрицу связей к тому, что видно в данных:

$$\Omega(W) = \frac{\lambda_1}{2} \|\rho(W^\top W) - \hat{\rho}\|_F^2 + \frac{\lambda_2}{2} \|W\|_F^2, \quad \rho(B) = D^{-1/2} B D^{-1/2}, \quad D = \text{diag}(B). \quad (16)$$

Первое слагаемое: строим B , нормируем в корреляционную матрицу, вычитаем эмпирическую $\hat{\rho}$, складываем квадраты разностей. Нормировка нужна потому, что притягивать надо углы, а не длины столбцов — длина отвечает за масштаб предсказания и настраивается данными. Второе — обычная усадка весов. Норма Фробениуса $\|A\|_F = \sqrt{\sum_{ij} A_{ij}^2}$ — евклидова длина матрицы, вытянутой в строку.

Почему именно так, а не поэлементный штраф на W . Матрица W определена не однозначно: умножение справа на любую ортогональную Q не меняет ни $W^\top W$, ни предсказания. Регуляризатор обязан обладать той же симметрией, иначе он штрафует за выбор системы координат, а не за содержание. Обе величины в (16) проходят через W только в виде $W^\top W$, поэтому симметрию сохраняют; поэлементный штраф — нет.

Низкий ранг входит не штрафом, а параметризацией. Практически проще держать не W со сложным штрафом, а сразу L и κ и строить головы из них:

$$\pi_{m,e} = L_e \cdot U^\top g(z_m) + \sqrt{\kappa_e} s_e^\top g(z_m) + b_e, \quad (17)$$

где $U \in \mathbb{R}^{d \times 2}$ — проекция на общие оси, общая для всех ферментов, а s_e — вектор специфичного направления фермента. Тогда $B = L L^\top + \text{diag}(\kappa)$ выполняется по построению, штраф за ранг не нужен, а от (16) остаётся притяжение к $\hat{\rho}$ плюс усадка. Инициализация L и κ — из факторного разложения эмпирической матрицы, причём именно факторным анализом с итеративной оценкой общностей: наивное собственное разложение полной матрицы с единицами на диагонали искажает внедиагональные элементы до 0.23, потому что факторы начинают гнаться за диагональю.

Проверять надо две вещи. Положить $\lambda_1 = 0$ и посмотреть, куда уедет выученная матрица связей от эмпирической: если далеко, значит либо в представлении есть структура, которой нет в сырых корреляциях, либо голова переобучается. И сравнить с четырьмя независимыми головами на тех же разбиениях.

8.3. Механистический блок

28 признаков, описанных в разделе 4.3, конкатенируются с z_m либо подаются через FiLM — то есть модулируют активации ствола, а не просто дописываются в конец вектора.

Зачем блок нужен, если по метрике он почти ничего не даёт. По ранжированию он избирателен так, как предсказывает химия, и это подтверждено бутстрапом; модель на одних этих 28 числах воспроизводит большую часть ранжирующей способности на 2D6 и меньше половины на остальных. Вдобавок он заметно стабилизирует модель (раздел 13). Считается блок за секунду.

8.4. Канал артефактов пробы

Как описано в разделе 2, 1A2, 2C9 и 3A4 читаются по флуоресценции, а 2D6 — масс-спектрометрией, и собственная флуоресценция соединения или тушение сигнала дают ложное «ингибирование» только в первых трёх. Это конфаундер, общий для трёх эндпойнтов и отсутствующий у четвёртого, и он частично объясняет, почему 1A2, 2C9 и 3A4 коррелируют между собой.

Добавляем скалярный признак-помеху (протяжённость сопряжения, известные хромофорные каркасы) с обучаемым коэффициентом, входящий только в три флуоресцентных эндпойнта. Это поправка на конфаундер с известной структурой, а не ещё один признак в общую кучу: модель получает возможность объяснить часть общей вариации артефактом, а не химией.

8.5. Головы

- π -голова — линейная поверх (17), выход в $\mathbb{R}$.
- (σ^-, σ^+) -голова — гетероскедастичные, через softplus; обучаются через (7). Границы интервалов лежат в данных и обычно никем не используются, а решающему слою они нужны.
- E — константа на фермент, по итогам раздела 6, плюс опциональная штрафующая поправка.
- Δ -голова — softplus, отдельная. Не разность двух независимых регрессий: шум двух плеч коррелирован и частично сокращается в разности, поэтому предсказывать сдвиг напрямую точнее. Измерено: 0.255 против 0.323 по MCC на 3A4 в пользу отдельной головы.

9. Функция потерь и обучение

$$\mathcal{L} = \sum_{m,e} \left[\lambda_{\text{крив}} \ell_{\text{крив}} + \lambda_{\text{tdi}} \ell_{\text{tdi}} + \lambda_{\text{max}} \ell_{\text{max}} + \lambda_{\text{скр}} \ell_{\text{скр}} \right] + \lambda_{\text{полоса}} \ell_{\text{полоса}} + \lambda_{\text{st}} \ell_{\text{st}} + \Omega(W). \quad (18)$$

Первые четыре слагаемых — правдоподобия четырёх источников из раздела 5. Пятое обучает головы полос (σ^-, σ^+) . Шестое — клипованная L1 из (1), посчитанная на обучающих полосах; она выравнивает функцию потерь с метрикой соревнования, потому что правдоподобие оптимизирует не совсем то, по чему считается лидерборд. Последнее — регуляризатор (16).

9.1. Батчинг по молекулам, а не по строкам

Единица батча — молекула со всеми её наблюдениями по всем источникам и ферментам. Иначе теряется смысл конструкции: латентная $\theta_{m,e}$ общая для кривой, Етах и скрининга, и градиенты от них должны сходиться на одном узле в пределах одного шага. Батч по строкам превращает конструкцию обратно в обычную многозадачную модель с общим стволом.

9.2. Двухэтапная калибровка

Если учить $\psi_e = (s_e, b_e, \sigma_e)$ совместно с сетью с самого начала, есть вырожденное решение: сеть подстраивает π под удобную калибровку вместо обратного. Порядок такой.

1. На подмножестве, где есть и кривая, и скрининг, фиксируем π равным опубликованному и подгоняем 12 скаляров ψ напрямую. Задача низкоразмерная, решается за секунды; результат — в разделе 5.2.
2. Обучаем сеть с замороженной ψ .
3. Размораживаем ψ с маленьким шагом обучения на последних эпохах.

9.3. Веса источников

Стартуем с $\lambda \propto 1/n_{\text{источника}}$, чтобы 17.5 тысяч точек скрининга не задавили 6.5 тысяч меток кривых. Потом пробуем гомоскедастичное взвешивание по неопределённости: каждому источнику свой обучаемый $\log \sigma^2$, веса выводятся из него, и модель сама решает, какому источнику доверять. Проверяем это абляцией, а не берём на веру: приём известен, но на маленьких выборках его собственный шум иногда съедает пользу.

10. Неопределённость

На выходе нужно распределение, а не число, и не ради красоты: решающий слой без него не работает вообще. Собирается оно из трёх частей.

Ансамбль по зёрнам и семействам энкодеров даёт эпистемическую часть — ту неопределённость, которая происходит от незнания правильной модели и падает с ростом данных. Дешёвые альтернативы, если бюджет не позволяет держать ансамбль: SWAG или лапласовское приближение на последнем слое.

Гетероскедастичные головы (σ^- , σ^+) дают алеаторную часть — шум прибора, который не уменьшить никаким количеством данных.

Конформная калибровка на разбиении, воспроизводящем дизайн теста. Обычная конформная калибровка даёт маргинальное покрытие: в среднем по всей выборке 90 процентов заявленных интервалов накрывают истину. Нам нужно условное: у неактивных соединений полосы широкие по построению, и если модель систематически промахивается на активных, среднее покрытие это замаскирует. Проверяем покрытие по зонам активности отдельно, при необходимости берём мондриановский вариант с зонами в качестве таксономии.

Разделять алеаторную и эпистемическую части нужно не для отчёта, а для трансдуктивного слоя: эпистемическая компонента велика там, где мало похожих

обучающих примеров, а тест как раз состоит из серий аналогов вокруг известных хитов.

11. Решающий слой

Предсказательное распределение получено. Осталось превратить его в то, что просят отправить: одно число для регрессии и один бит для классификации. Это отдельный шаг, и правильный ответ зависит от метрики.

11.1. Регрессия: вывод

Пусть (L, H) — случайные границы доверительного интервала будущего измерения. Риск точечной оценки по (1):

$$R(\hat{y}) = \mathbb{E}[(\hat{y} - H)_+] + \mathbb{E}[(L - \hat{y})_+], \quad R'(\hat{y}) = F_H(\hat{y}) - (1 - F_L(\hat{y})). \quad (19)$$

Здесь F_L и F_H — функции распределения нижней и верхней границ. Производная считается просто: сдвигая $\hat{y}$ вправо на $d\hat{y}$, мы добавляем штраф там, где H уже левее (вероятность $F_H(\hat{y})$), и снимаем штраф там, где L ещё правее (вероятность $1 - F_L(\hat{y})$).

Оба слагаемых в (19) выпуклы, значит стационарная точка глобальна, и условие оптимума

$$F_L(\hat{y}^*) + F_H(\hat{y}^*) = 1. \quad (20)$$

Это условие $F_M(\hat{y}^*) = 1/2$ для равновесной смеси $M = \frac{1}{2}L + \frac{1}{2}H$. Рецепт получается такой: взять S сэмплов из предсказательного распределения, для каждого посчитать пару (l, h) , свалить все $2S$ чисел в один массив и взять медиану. В вырожденном случае $L = H = Y$ условие даёт апостериорную медиану, а не среднее — что и следовало ожидать от метрики на основе L1.

Вывод верный, проверен численно. А вот прежнее утверждение о том, что для неактивных соединений оптимум смещается вверх, оказалось неверным. Оно опиралось на предположение, что полосы у неактивных сильно асимметричны вниз. Измерение показало, что полосы почти симметричны везде: медиана асимметрии $b - a$ (где $a = y - l$, $b = h - y$) не превышает 0.13 логарифмической единицы ни в одной ячейке, причём у трёх ферментов из четырёх у неактивных знак отрицательный.

Вариант решающего слоя	1A2	2C9	2D6	3A4	Макро
Сырое предсказание модели	0.879	0.691	0.980	0.519	0.767
Пул границ, полосы предсказаны моделью	0.889	0.710	1.002	0.540	0.785
Пул границ с истинными полосами (оракул)	0.864	0.670	0.971	0.505	0.752

Таблица 3. Один и тот же предиктор, разные решающие слои, те же фолды. Оракул недостижим — он знает истинные границы, — и задаёт потолок всей затеи.

Потолок решающего слоя под ST-RAE — 0.015 макро, около двух процентов относительно, и это при оракульном знании полос. Реалистичная версия с предсказанными полосами сейчас теряет 0.018. Причина видна из второго следствия раздела 1: метрику определяют активные соединения, а у них полосы узкие ($a \approx b \approx 0.1$) и симметричные, эксплуатировать нечего. Широкие полосы у неактивных, но они почти не дают вклада.

Слой понижается в приоритете: делать после того, как заработает всё остальное, и только если гетероскедастичные головы дадут заметно лучшую оценку полос, чем нынешний бустинг.

11.2. TDI: здесь слой окупается

Метка TDI не измеряется напрямую. Она вычисляется из двух измеренных $p_{C_{50}}$ — прямого плеча и плеча с преинкубацией (раздел 2.5) — по составному правилу, и правило воспроизводит опубликованные метки без единого исключения: 2334 из 2334 для 3A4 и 1493 из 1493 для 2D6. Проверено и покомпонентно: убрать любое из двух слагаемых, и правило начинает пропускать положительные (84 пропуска на 3A4 и 51 на 2D6 без второго), а взять любое слагаемое по отдельности — сотни ложных срабатываний.

Значит вероятность «да» надо считать интегрированием правила по совместному предсказательному распределению, а не отдельной сигмной:

$$p_i = \Pr(\pi > 4, \Delta > \log_{10} 2) + \Pr(\pi \leq 4, \pi + \Delta > 4 + \log_{10} 2). \quad (21)$$

Два слагаемых — два случая правила разметки, разобранных в разделе 2.5. Считать это надо совместно: π и Δ коррелированы, перемножать вероятности по отдельности нельзя. На практике — Монте-Карло по сэмплам из ансамбля.

Дальше порог. Как отмечено в разделе 1, MCC не раскладывается по объектам, поэтому 0.5 почти всегда неоптимален. При калиброванных p_i берём порог, максимизирующий ожидаемый MCC на всём наборе из 750. Два способа, оба дешёвые: подстановка ожидаемых счётчиков $\mathbb{E}[TP] = \sum_{i: p_i > t} p_i$ со свипом по t , либо Монте-Карло по пуассон-биномиальному распределению меток.




Рис. 8. MCC как функция порога. Слова «при калиброванных p_i » оказались не формальностью: на сырых вероятностях подстановочный порог промахивается мимо максимума. На CYP3A4 он даёт 0.325 при достижимых 0.356, на CYP2D6 — 0.115 при 0.127. На 3A4 промах стоит больше половины всего выигрыша от подбора порога.

На сохранённых вероятностях бустинга средняя предсказанная вероятность равна 0.256 против настоящей доли положительных 0.326 на 3A4 и 0.079 против 0.217 на 2D6. Подстановочный метод берёт на 3A4 порог 0.375 и даёт MCC 0.325, тогда как оптимум при 0.258 даёт 0.358 — потеря 0.033. Вложенная калибровка Платта возвращает почти

всё: потеря падает до 0.003, показатель Брайера с 0.2075 до 0.1853, чистый выигрыш +0.028 МСС. Больше, чем даёт любая перестановка признаков в наших абляциях.

На 2D6 не окупается. Калибровка чинит калибровку (средняя предсказанная с 0.079 до 0.217, Брайер с 0.199 до 0.169), а МСС не растёт: изотоническая сжимает достижимый максимум с 0.127 до 0.108, Платт уводит порог не туда. При МСС порядка 0.12 и 260 положительных на обучение калибратора его собственный шум съедает пользу.

В архитектуру идёт связка «вложенная калибровка, затем подстановочный порог», с абляцией на каждом эндпойнте отдельно.

Незакрытая дыра: вероятностная версия (21) с интегрированием по ансамблю не запускалась ни разу. Все измеренные варианты правила — детерминированные подстановочные.

12. Трансдуктивный слой

Про тест известно больше, чем обычно, и этим можно пользоваться. Аккуратно.

12.1. Сдвиг распределения

Тест обогащён активными по трём ферментам и близок к фону по четвёртому (раздел 3). Это ковариатный сдвиг с индуцированным сдвигом меток: $p_{\text{тест}}(y) \neq p_{\text{обуч}}(y)$. Модель, откалиброванная на обучающей маргинали, будет систематически занижать активность тестовых соединений. Лечится перекалибровкой под ожидаемую тестовую маргиналь, оценённую из известной конструкции набора, и проверяется на разбиении, воспроизводящем дизайн теста.

12.2. Серийный случайный эффект

Тест — серии аналогов вокруг якорей. Естественно предположить, что соединения одной серии имеют общий сдвиг:

$$\hat{y}_i = f(x_i) + b_{s(i)}, \quad b_s \sim \mathcal{N}(\mu(\text{якорь}_s), \tau^2). \quad (22)$$

Здесь $s(i)$ — серия, к которой относится соединение i , b_s — её общий сдвиг, $\mu(\text{якорь}_s)$ — центр приора, привязанный к активности якоря, τ — насколько сильно мы разрешаем серии отклоняться от него.

Соблазн стянуть предсказание к активности якоря надо давить. Медианная разница pIC_{50} в обучающих парах со сходством Танимото 0.6–0.85 составляет от 0.24 до 0.55 логарифмической единицы. Обрывы активности реальны: похожие молекулы регулярно различаются в разы. Значит τ должно быть порядка 0.5, а не 0.1, и оценивать его надо по обучающим парам при том же уровне сходства, а не подбирать.

Проверять эффект от (22) можно только на псевдотестовых сериях: на случайном разбиении он покажет ложный выигрыш, потому что там соседи по серии лежат в обучении.

13. Протокол оценки

Что считать выигрышем, решается до эксперимента. Иначе за два месяца можно уехать сколь угодно далеко.

13.1. Три уровня строгости разбиения

Случайное пятикратное — верхняя граница, полезна только для отладки. Оптимистичнее кластерного примерно вдвое по R^2 .

Кластерное по Бутине при пороге 0.35 — рабочий режим, все числа этого документа получены на нём. Соединения группируются по сходству, и целый кластер целиком уходит в отложенный фолд, так что модель не может узнать соединение по его близкому родственнику в обучении.

Разбиение под дизайн теста — задумывалось третьим уровнем: псевдотестовый фолд строится тем же алгоритмом, что и настоящий тест — берём хит из обучающей выборки, забираем его ближайших соседей, держим всю серию снаружи. Уровнем протокола оно быть не может: как *разбиение*, то есть нарезка всей выборки, тестовой геометрии оно не достигает ни при каком пороге. Как *страта* — достигает, но маленькая. Оба утверждения измерены, подробности в следующем подразделе.

13.2. Насколько наша проверка похожа на тест

Прежде чем отбирать модели, надо спросить: наша кросс-валидация вообще такой же трудности, как тест? Мера простая — сходство соединения с ближайшим к нему обучающим.




Рис. 9. Насколько далеко проверяемое соединение от того, что модель видела. Разрыв медиан 0.153, и он идёт в неожиданную сторону: наша проверка труднее теста.

У отложенного кластерного фолда медиана 0.435 и доля соединений со сходством выше 0.7 равна половине процента. У настоящего теста медиана 0.587, и таких соединений каждое десятое.

Первая строка — потолок для любой перенарезки обучающей выборки, и тест стоит *выше* него. Разрыв 0.137 неустраним: дело не в неудачно подобранном пороге кластеризации, а в том, что в обучающей выборке в среднем нет соединений, настолько похожих друг на друга. Тест устроен как серии аналогов вокруг якорей, и близость к обучению заложена в него конструкцией.

Из этого не следует, что псевдотестовую проверку построить нельзя — следует, что она не может быть *разбиением*. Разбиение делит всю выборку и потому упирается в среднее. Страта не делит: соединение уходит наружу только вместе с обязательством, что его аналог остаётся внутри. Так геометрия теста воспроизводится точно — медиана

Режим	Медиана	Доля > 0.7
Потолок: соединение против всей остальной выборки	0.450	0.038
Случайное пятикратное	0.437	0.033
Кластерное 0.35	0.435	0.005
Тест против всего обучения	0.587	0.101

Таблица 4. Сходство проверяемого соединения с ближайшим обучающим. Первая строка — leave-one-out: соединение сравнивается со всей остальной выборкой сразу. Более щедрого разбиения не существует, поэтому это потолок.

сходства отложенных с обучением 0.643 при тестовых 0.587, — но набирается таких соединений 328, то есть 6.7 процента выборки, и распределены они крайне неравно: 267 размеченных на 3A4 против 38, 36 и 32 на 1A2, 2C9 и 2D6.

Практический вывод жёсткий. Псевдотестовая проверка существует и осмысленна на СУР3A4. На остальных трёх ферментах при трёх десятках соединений доверительный интервал шире любого эффекта, который мы собираемся измерять, и называть это проверкой нельзя. Всё, что в разделах 10 и 12 обещано «на разбиении, воспроизводящем дизайн теста», проверяемо в этом объёме и не более.

Из той же таблицы видно менее очевидное. По медиане кластерное и случайное разбиения неразличимы, 0.435 против 0.437: при пороге 0.35 из 4905 соединений выходит 4703 кластера, почти все синглтоны, и кластеризация почти ничего не группирует. Расходятся они только в хвосте — доля соединений со сходством выше 0.7 отличается в семь раз, 0.005 против 0.033. Кластерное разбиение работает ровно на тех трёх процентах, у которых есть близкие аналоги, и весь его смысл там. Тест этим хвостом переобогащён втрое против случайного и в двадцать раз против кластерного.

Значит инструмент — не новое разбиение, а стратификация уже имеющейся оценки по сходству. Отсечка 0.50, то есть верхняя четверть выборки, даёт макро 0.739 против 0.767 на всей и 0.916 против 0.980 на 2D6. Читать это надо как вторую, диагностическую полосу, а не как отбор: она смотрит ровно на тот хвост, где кластерное и случайное разбиения расходятся, а по настоящей тестовой медиане 0.587 квалифицируется семь процентов выборки — выше потолка отбирать нечего.

Приятная половина прежнего вывода остаётся: 0.767 — оценка снизу, на лидерборде должно быть лучше. Неприятная тоже: мы отбираем модели по способности экстраполировать на чужую химию, а тест награждает за интерполяцию внутри серии аналогов. Это разные умения, и лучшая по нашей сетке модель не обязана быть лучшей там. Разбиением эту дыру не закрыть — её закрывает только промежуточный лидерборд.

13.3. Устойчивость к разбиению

Все числа регрессионного трека изначально стояли на одном разбиении — кластеры Бутины, раскиданные по фолдам генератором с зерном ноль. Парный бутстрап покрывал случайность выборки соединений, но не случайность самого разбиения. Прогон на других зёрнах меняет только то, как кластеры распределяются по пяти фолдам; кластеризация, признаки, гиперпараметры и код те же.

Абсолютный уровень плавает: 0.7729, 0.7830, 0.7672, 0.7757 для набора без механистического блока. Стандартное отклонение 0.0066, размах 0.0158 — больше, чем весь эффект, ради измерения которого строилась абляция сетка. Любое число вида «макро 0.767» без указания разбиения имеет точность до первого знака после запятой, не до третьего.




Рис. 10. Слева — макро-ST-RAE на четырёх зёрнах разбиения. Справа — стандартное отклонение по этим четырём зёрнам, по ферментам. Механистический блок снижает зависимость от разбиения в 3.4 раза по макро, и падение сосредоточено на 2D6.

Направление держится: разность отрицательна на всех четырёх зёрнах (-0.0056 , -0.0140 , -0.0012 , -0.0112), Спирмен растёт тоже на всех четырёх, а на 2D6 от $+0.033$ до $+0.052$. Бутстрап на одном разбиении накрывал ноль; четыре разбиения показывают, что знак устойчив, хотя величина гуляет в десять раз.

Самое интересное здесь в разбросах, а не в средних. Набор без блока имеет по зёрнам разброс 0.0066, с блоком — 0.0019, в 3.4 раза меньше. По ферментам эффект сосредоточен там, где и должен: на 2D6 разброс падает с 0.0132 до 0.0052, а на 3A4 почти не меняется.

Похоже, тридцать механистических чисел дают модели опору, не зависящую от того, какие аналоги попали в обучающие фолды. Фингерпринт такой опоры не даёт: он узнаёт соединение по соседям, и когда соседи уезжают в отложенный фолд, узнавание рассыпается. Главная польза блока, видимо, в этом, а не в приросте среднего.

Протокол из-за этого меняется. Любое сравнение вариантов идёт на фиксированном наборе из нескольких разбиений и отчитывается разностью на каждом плюс разбросом. Одно разбиение годится для отладки и не годится для решения, что отправлять.

13.4. Устойчивость к версии библиотеки

Две оси случайности уже учтены: бутстрап покрывает выбор соединений, четыре зерна — выбор разбиения. Есть третья, и она не случайная: версия библиотеки, которой посчитаны числа.

Версии `scikit-learn` с 1.3.2 по 1.8.0 воспроизводят сохранённые предсказания *побитово* — максимум модуля разности ноль. Версия 1.9.0 не воспроизводит: каждое предсказание сдвигается в среднем на 0.135 pIC_{50} , максимум 0.59. На макро это выглядит безобидно — набор без блока 0.7729 против 0.7759, с блоком 0.7673 против 0.7646, — но измеряемый эффект блока при этом меняется с -0.0056 на -0.0113 , то есть удваивается.

Вывод не меняется: и 0.0113 тонет в размахе 0.0158 по зёрнам. Но величина, ради измерения которой строилась абляционная сетка, зависит от версии библиотеки вдвое — значит потолок версии в окружении не осторожность, а часть протокола, и снимать его можно только вместе с пересчётом всей таблицы.

numpy к этому отношения не имеет: 1.26.4 и 2.5.2 воспроизводят одинаково точно. Первое подозрение на numpy 2 не подтвердилось.

13.5. Парный бутстрап

Любое сравнение двух вариантов — только на одном и том же разбиении и с парным бутстрапом по соединениям: 2000–3000 пересборок, для каждой обе метрики пересчитываются на одной и той же пересобранной выборке, докладывается распределение разности и доля пересборок, где стало хуже. Разность без интервала не является результатом.

Для макро надо ресэмплить соединения общей таблицы, а потом для каждого фермента брать те из них, у кого есть метка — так сохраняется корреляция между ферментами. Считать четыре независимых бутстрапа и усреднять нельзя.

13.6. Сетка абляций

Каждая строка снимается с парным бутстрапом относительно предыдущей, на нескольких зёрнах.

1. Фингерпринт и дескрипторы, бустинг. Базовая линия.
2. Предобученный энкодер вместо ручных признаков, одна голова на эндпойнт.
3. Плюс коррегионализация (15).
4. Плюс механистический блок и канал артефактов пробы.
5. Плюс скрининг через (8): главная проверка всей идеи.
6. Плюс Emax и плечо с преинкубацией в общее правдоподобие.
7. Плюс ансамбль и конформная калибровка.
8. Плюс решающий слой: отдельно для регрессии, отдельно для МСС.
9. Плюс трансдуктивный слой.

Строка 5 — точка, на которой конструкция оправдывается или не оправдывается. Обязательный контроль к ней: сильная многозадачная базовая линия на тех же признаках и том же энкодере, обученная на одних метках кривых. Если совместное правдоподобие её не обыгрывает, это отрицательный результат, и он идёт в отчёт как есть.

14. Что уже измерено и не работает

Это тоже результат, и он объясняет, почему решение выглядит так, а не проще. Если скрининг настолько информативен, зачем городить совместное правдоподобие? Нельзя ли подключить его в лоб? Проверены три способа.

Почему базовые линии не совпадают. Три скрипта, давшие эту таблицу, строят разбиение по фингерпринту в 1024 бита, тогда как абляционная сетка и все остальные числа документа — по 2048. При 1024 битах кластеризация даёт 4694 кластера против 4703, и вектор фолдов другой: дайджест d7b7ca15 против 2d93c198. Поэтому ни одно число этой таблицы не сопоставимо с 0.767 из раздела 13: различаются не только модели, но и выборки, на которых они отложены.

Между собой фолды у трёх скриптов совпадают, и расхождение базовых линий объясняется целиком конфигурацией: шесть физико-химических признаков против

Подход	ST-RAE	Δ к своей базе	ρ	$\Delta\rho$
Скрининг как признак, в лоб	0.921	+0.138	0.566	+0.009
То же с честной вложенной схемой	0.788	0.000	0.559	+0.006
Два этапа: скрининг, затем пересчёт	1.006	+0.212	0.561	+0.010
Смесь двух маршрутов пополам	0.803	+0.009	0.587	+0.036

Таблица 5. Разности считаются от базовой линии *того же прогона*: 0.783, 0.788, 0.794, 0.794. Расходятся они не случайно — это три разных скрипта с тремя разными конфигурациями, см. ниже, — поэтому сравнивать строки между собой по абсолютной величине нельзя, только по разностям.

восьми даёт 0.783 против 0.788, а 250 итераций бустинга против 200 — 0.788 против 0.794. Оба различия детерминированы и воспроизводятся при повторном запуске точно. Разброс в 0.011 — это не шум прогона, а три разные модели на общих фолдах.

Скрининг как признак, в лоб. Обучаем вспомогательную модель предсказывать $\log_2 fc$, её выход подаём как признак в основную. Ошибка — вспомогательный признак посчитан моделью, для которой обучающие строки основной модели были внутренними. На них он точнее, чем окажется на отложенных, основная модель учится на него опираться, и опора рассыпается там, где её проверяют: 0.783 против 0.921. На честной вложенной схеме выигрыш ровно нулевой. Разница между 0.783 и 0.921 целиком артефакт процедуры.

Двухэтапная инверсия. Предсказать $\log_2 fc$, потом перевести в pIC_{50} монотонной калибровкой. Обязана выдать число там, где правдоподобие плоское: в зонах насыщения из раздела 5.3 калибровка не определена, и любое значение оттуда одинаково согласуется с показанием. Результат: ранговая информация сохраняется и даже растёт, а абсолютная шкала разваливается.

Смесь. Полусумма двух маршрутов. Стоит +0.009 ST-RAE и покупает +0.036 Спирмена, причём ранг растёт на всех четырёх ферментах. Это уже почти приемлемый обмен, но он не решает задачу, а балансирует между двумя плохими решениями.

Общий вывод: информация в скрининге есть, ранг улучшается всегда. Вся проблема в том, как перевести её в абсолютную шкалу pIC_{50} , и этим занимается совместное правдоподобие через общую латентную кривую.

Сюда же два отрицательных результата из предыдущих разделов: решающий слой под ST-RAE имеет потолок 0.015 макро и в реалистичной версии сейчас теряет 0.018; выигрыш механистического блока по ST-RAE неотличим от нуля и поштучно, и на макро.

15. Что сломается и по какому признаку это видно

Планшетный дрейф был в этом списке и снят измерением (раздел 5.2).

16. Что не проверено

Список на момент выпуска документа.

Сама совместная модель не запускалась ни разу. Проверен её теоретический фундамент (раздел 7) и все компоненты по отдельности; строка 5 абляции, где стоит она сама, пуста. Это главный незакрытый риск. Всё остальное объясняет, почему

Режим отказа	Признак	Реакция
Совместное правдоподобие не обыгрывает многозадачную базовую линию	строка 5 абляции внутри интервала парного бутстрапа на нескольких зёрнах	зафиксировать как отрицательный результат, отправлять многозадачную модель; решающий и трансдуктивный слои от неё не зависят
Голова E как свалка для остатка	разброс выхода E на соединениях только со скринингом заметно выше, чем на соединениях с кривой	заменить на константу на фермент, зафиксировать $h_e = 1$
Калибровка зависит от соединения, а не только от фермента	остатки (8) систематически изогнуты по π на подмножестве с полными кривыми	монотонная сплайн-поправка поверх хилловской формы либо смесь двух режимов
Серийный приор переобучается на якоря	на псевдотестовых фолдах модель с (22) хуже, чем без	увеличить τ или снять слой
Конформные интервалы калиброваны маргинально, но не условно	покрытие по зонам активности расходится с номинальным	мондриановский конформал с зонами как таксономией
Расхождение локальной оценки с промежуточной таблицей	разрыв больше, чем между случайным и кластерным разбиениями	чинить разделы 13 и трансдуктивный слой, а не архитектуру

Таблица 6. Каждому риску — наблюдаемый признак и заранее решённая реакция.

конструкция должна работать, а не показывает, что она работает.

Вероятностное правило TDI — интегрирование (21) по совместному предсказательному распределению — не запускалось; все измеренные варианты детерминированные.

Оценщик pK_a проверен на двадцати соединениях, выбранных вручную. Средняя ошибка 0.60 при медианной 0.2, то есть среднее делают четыре промаха, худший — кофеин, 4.5 единицы: правило относит его азот к имидазолам с базовым 7.0 и недоштрафовывает соседние карбонилы. На бинарный вопрос про заряд при 7.4 это не влияет, но мотив «ароматический азот через атом от карбонила» встречается у трёх процентов обучающей выборки — зона, где правило может систематически завышать.

Учит ли графовая сеть протонирование сама — не проверялось. Если учит, часть выводов про механистический блок придётся переписать.

Зависимость калибровки от соединения в этих данных непроверяема: у каждого соединения одно показание скрининга, разделить «соединение отклоняется от калибровки» и «прибор шумит» на одном измерении нельзя.

Контроль в проверке ограничения диапазона выравнивает количество примеров, но не форму распределения меток.

17. Сводка чисел

	1A2	2C9	2D6	3A4	Макро
Меток pIC_{50}	1412	1285	1493	2335	6525
Межквартильный размах меток	1.00	0.92	0.83	1.50	—
Надёжность меток (потолок R^2)	0.948	0.905	0.934	0.898	—
ST-RAE, фингерпринт и дескрипторы	0.880	0.702	0.993	0.518	0.773
ST-RAE, плюс механистический блок	0.879	0.691	0.980	0.519	0.767
Спирмен, фингерпринт и дескрипторы	0.497	0.583	0.351	0.764	0.549
Спирмен, плюс механистический блок	0.496	0.597	0.403	0.765	0.565
Калибровка: E	0.728	0.621	0.867	0.931	—
Калибровка: h	1.261	1.112	1.243	1.968	—
Ранговая связь скрининга с pIC_{50}	−0.86	−0.90	−0.83	−0.94	—
Ско ST-RAE по четырём зёрнам, без блока	0.0136	0.0098	0.0132	0.0063	0.0066
Ско ST-RAE по четырём зёрнам, с блоком	0.0109	0.0078	0.0052	0.0057	0.0019

Таблица 7. Всё — пятикратная кросс-валидация по кластерам Бутины при пороге 0.35. Макро в строках ST-RAE и Спирмена посчитано на зерне 0; в строках со стандартным отклонением — по четырём зёрнам.

Правило решения для TDI	MCC 3A4	MCC 2D6
Всегда «нет»	0.000	0.000
Классификатор, порог 0.5	0.302	0.103
Классификатор, порог подобран	0.356	0.127
Две независимые регрессии плеч, затем правило	0.255	0.094
Отдельная голова на сдвиг, затем правило	0.323	0.104
То же с подобранным порогом сдвига	0.324	0.149
Подстановочный порог по сырым вероятностям	0.325	0.115
Подстановочный порог после калибровки Платта	0.352	0.092

Таблица 8. Все числа получены на 2346 соединениях для 3A4 и 1495 для 2D6 — тех, у кого есть и признаки, и метка. Доля положительных в этих выборках 32.6 и 21.7 процента; по файлу TDI целиком — 21.3 и 21.6, и разница целиком объясняется тем, что 1238 соединений без кривой доза-эффект автоматически размечены как отрицательные.