

Модель предсказания ингибирования цитохромов P450

Устройство решения для OpenADMET CYP Blind Challenge: что в данных,
что мы измерили, как устроена модель и почему именно так

27 августа 2026

Аннотация

Документ описывает решение задачи предсказания ингибирования четырёх изоформ цитохрома P450 по структуре молекулы. Содержит разбор того, что лежит в данных и что мы из них измерили, устройство модели и обоснование каждого её элемента, протокол проверки и список того, что уже проверено и не работает. Все числа получены прогонами на открытых данных соревнования и воспроизводимы; графики построены по тем же прогонам. Рассчитан на две аудитории сразу: на химика, знакомого с основами машинного обучения, и на специалиста по машинному обучению, знакомого с основами биохимии.

Содержание

1	Задача	3
1.1	Метрика регрессии и что из неё следует	3
1.2	Метрика классификации	3
2	Биохимия задачи	4
2.1	Что такое цитохромы P450 и почему именно эти четыре	4
2.2	Почему ингибирование — проблема	5
2.3	Что такое IC_{50} и pIC_{50}	5
2.4	Как читают результат и откуда берутся артефакты	5
2.5	Что такое time-dependent ингибирование	5
2.6	Что такое E_{max} и положительный контроль	6
2.7	Чем четыре фермента различаются	7
3	Данные	8
3.1	Что меряют эти таблицы	8
3.2	Как собран тестовый набор	8
4	Что мы измерили до того, как что-то строить	9
4.1	Версия первая: метки шумные, учить нечего	10
4.2	Версия вторая: не хватает нужных признаков	11
4.3	Версия третья: дело в том, какие соединения попали в выборку	12
5	Порождающая модель	13
5.1	Правдоподобия по источникам	14
5.2	Калибровка прибора	15
5.3	Почему цензурирование получается само	16
6	Идентифицируемость	17
6.1	Крутизна — на уровень фермента	17
6.2	Глубина: амортизация вместо поштучной подгонки	17
6.3	А теперь измерения, и они меняют вывод	18

7	Механизм пропусков	19
7.1	Как раскладывается совместное распределение	19
7.2	Что даёт симуляция	20
8	Архитектура	20
8.1	Ствол	20
8.2	Связь между ферментами: коррегионализация	21
8.3	Механистический блок	23
8.4	Канал артефактов пробы	23
8.5	Головы	23
9	Функция потерь и обучение	23
9.1	Батчинг по молекулам, а не по строкам	24
9.2	Двухэтапная калибровка	24
9.3	Весы источников	24
10	Неопределённость	25
11	Решающий слой	25
11.1	Регрессия: вывод	25
11.2	Регрессия: то, что работает	27
11.3	Оценка сдвига зависит от модели, и это не мелочь	33
11.4	TDI: здесь слой окупается	34
12	Трансдуктивный слой	36
12.1	Сдвиг распределения	36
12.2	Серийный случайный эффект	36
13	Протокол оценки	36
13.1	Уровней строгости меньше, чем задумывалось	37
13.2	Насколько наша проверка похожа на тест	37
13.3	Устойчивость к разбиению	39
13.4	Устойчивость к версии библиотеки	40
13.5	Парный бутстрап	40
13.6	Сетка абляций	40
14	Что уже измерено	41
14.1	Совместное правдоподобие: первый запуск	42
14.2	Шумовая лестница: что она показала и что переписала	45
14.3	Виноват был не сид, а одно соединение	46
14.4	Сеть против бустинга: разница меньше, чем починка	48
14.5	Представление и данные: два эксперимента, которых не было	49
14.6	Все эти числа измерены не там, где считается результат	51
15	Что сломается и по какому признаку это видно	55
16	Что не проверено	55
17	Сводка чисел	57

1. Задача

Вход — SMILES молекулы. Оцениваемых треков два: регрессия и классификация. Третий, предсказание позы лиганда в кармане фермента, откроется в середине соревнования и здесь не разбирается.

В регрессионном треке нужно выдать матрицу $\hat{Y} \in \mathbb{R}^{750 \times 4}$: pIC_{50} прямого ингибирования для CYP1A2, CYP2C9, CYP2D6 и CYP3A4. В классификационном — $\hat{Y} \in \{0, 1\}^{750 \times 2}$: метку time-dependent ингибирования для 3A4 и 2D6. Тестовые 750 соединений выданы без меток, отправка закрывается 3 ноября.

1.1. Метрика регрессии и что из неё следует

Метрика — не средняя абсолютная ошибка. Организаторы публикуют вместе с каждым pIC_{50} границы доверительного интервала байесовской подгонки кривой, и ошибка считается до ближайшей границы, а не до точечной оценки:

$$\text{ST-RAE} = \frac{\sum_i [(\hat{y}_i - h_i)_+ + (l_i - \hat{y}_i)_+]}{\sum_i [(\bar{y} - h_i)_+ + (l_i - \bar{y})_+]}, \quad \bar{y} = \frac{1}{n} \sum_i y_i. \quad (1)$$

Здесь l_i и h_i — нижняя и верхняя границы интервала i -го соединения, а $(\cdot)_+ = \max(\cdot, 0)$. Числитель: предсказание, попавшее внутрь полосы, не штрафуетсся вовсе, а вышедшее наружу штрафуетсся только на расстояние до ближайшего края. Знаменатель: та же величина для константного предсказателя, выдающего среднее по оценочному набору. Отношение единица означает, что модель не лучше предсказания одного числа для всех соединений подряд; меньше единицы — лучше.

Из этого следует три вещи, и каждая влияет на архитектуру.

Первое. Задача интервально-цензурированная, и обучаться надо на той же клипованной L1, а не на квадратичной ошибке. Квадратичная будет тянуть предсказание к центру полосы там, где метрике всё равно, где именно внутри полосы оно стоит.

Второе. Это отношение сумм, а не среднее отношений. Соединения с широкой полосой почти невесомы в обеих частях: они дают мало и в числитель, и в знаменатель. Метрику определяют соединения с узкой полосой, то есть активные, у которых кривая хорошо определена.

Третье. Оптимальная точечная оценка под (1) не обязана совпадать с условным средним предсказательного распределения. Это разбирается в разделе 11.

Знаменатель считается по среднему *того набора*, на котором метрика вычисляется. У нас это среднее по обучающей подвыборке фермента, на лидерборде — по 750 тестовым соединениям. Значит наши числа и числа лидерборда напрямую несопоставимы, даже если модель одна и та же; сопоставимы только разности между вариантами, посчитанные на одном наборе.

1.2. Метрика классификации

Для TDI считается коэффициент корреляции Мэтьюса:

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}. \quad (2)$$

Это коэффициент корреляции Пирсона между двумя бинарными векторами, предсказанным и истинным. Меняется он от -1 до $+1$: ноль — уровень подбрасывания

монетки, единица — полное совпадение, минус единица — систематически наоборот. Величины порядка 0.3, которые встречаются дальше в документе, для такой задачи — уже осмысленный сигнал, а не шум.

При несбалансированных классах МСС ведёт себя куда честнее точности: предсказать всем «нет» даёт точность 78 процентов и МСС ровно ноль.

Ещё одно, без чего дальнейшее непонятно: модель выдаёт не метку, а *вероятность* того, что соединение — TDI. Метку из неё получают, сравнивая вероятность с порогом. По привычке берут 0.5, и вот почему здесь так делать нельзя. МСС не раскладывается по объектам: вклад одного соединения зависит от того, что предсказано остальным, потому что все четыре счётчика стоят под общим корнем. Значит и оптимальный порог зависит от всей выборки сразу, и 0.5 почти никогда им не оказывается — его надо выбирать явно, см. раздел 11.

Обе метрики агрегируются макро-усреднением по эндпойнтам — то есть по восьми задачам (четыре фермента на регрессию, два на классификацию, каждая считается отдельно), — и лидерборд сортируется по этому среднему.

У макро-усреднения есть следствие, которое объясняет композицию всего дальнейшего текста: худший фермент весит в итоговой оценке ровно столько же, сколько лучший. Улучшить CYP3A4, который и так предсказывается вдвое лучше бессмысленного уровня, стоит в общей сумме ровно столько же, сколько улучшить CYP2D6, который не предсказывается вовсе. Поэтому CYP2D6 занимает примерно половину этого документа: он не самый интересный химически, он самый дорогой арифметически.


2. Биохимия задачи

Раздел для тех, кто пришёл со стороны машинного обучения: что физически стоит за каждой колонкой в данных. Без этого половина решений в модели выглядит произволом.

2.1. Что такое цитохромы P450 и почему именно эти четыре

Цитохромы P450 — надсемейство гем-тиолатных монооксигеназ. Гем — порфириновое кольцо с железом в центре, то же самое, что в гемоглобине; «тиолатные» означает, что пятое координационное место железа занимает атом серы остатка цистеина. Название историческое: восстановленный комплекс фермента с угарным газом даёт полосу поглощения при 450 нм.

Каталитический цикл в общем виде: фермент связывает субстрат, железо восстанавливается, присоединяет кислород, кислород расщепляется с образованием высокореакционного оксоферрильного интермедиата (Compound I), который вырывает водород у субстрата и вставляет туда гидроксил. Суммарно



Электроны поставляют НАДФН через флавопротеин цитохром-P450-редуктазу. Для эксперимента отсюда следует вот что: без НАДФН фермент не работает, так что катализ можно включать и выключать в пробирке. На этом приёме построено измерение TDI.

Смысл реакции — сделать липофильную чужеродную молекулу более полярной, чтобы её можно было конъюгировать (вторая фаза метаболизма) и вывести. Печёночные P450 — главный барьер между проглоченным веществом и системным кровотоком.

Изоформ у человека около 57, но лекарственный метаболизм сосредоточен в немногих. CYP3A4 отвечает примерно за половину всех оборотов, CYP2D6, CYP2C9, CYP2C19 и CYP1A2 — за большую часть остального. Четвёрка в соревновании покрывает подавляющее большинство клинически значимых взаимодействий.

2.2. Почему ингибирование — проблема

Если препарат А ингибирует фермент, который выводит препарат В, концентрация В в крови растёт — иногда в разы. Для препарата с узким терапевтическим окном это прямая дорога к токсичности, вплоть до снятия с рынка уже зарегистрированного средства, безопасного само по себе.

Поэтому ингибирование P450 проверяют рано, ещё на стадии выбора соединения-кандидата. Предсказание по структуре экономит эти пробы, и цена ошибки здесь измеряется в снятых с разработки молекулах.

2.3. Что такое IC_{50} и pIC_{50}

В пробу вносят фермент, зонд-субстрат с известной скоростью превращения и испытуемое соединение в нескольких концентрациях. Измеряют, насколько упала скорость превращения зонда. IC_{50} — концентрация испытуемого соединения, при которой скорость падает вдвое. $pIC_{50} = -\log_{10} IC_{50}$ в молях на литр: $pIC_{50} = 6$ соответствует одному микромолю, $pIC_{50} = 4$ — ста микромолям. Больше pIC_{50} — сильнее ингибитор.

Важная оговорка: IC_{50} — не константа связывания. Она зависит от концентрации зонд-субстрата и от механизма (конкурентный ингибитор вытесняется субстратом, неконкурентный — нет); связь с константой ингибирования K_i даёт соотношение Ченга–Прусоффа. Сравнивать IC_{50} между лабораториями и пробами напрямую нельзя, внутри одного набора — можно, и именно это мы и делаем.

2.4. Как читают результат и откуда берутся артефакты

Зонд-субстрат подбирают так, чтобы его превращение было легко измерить. Способов два.

Флуоресцентный: зонд после окисления даёт флуоресцирующий продукт, и прибор просто меряет свечение. Дёшево и быстро, поэтому так сделаны 1A2, 2C9 и 3A4 в этом наборе.

Масс-спектрометрический: продукт детектируют по массе. Дороже, но специфичнее; так сделан 2D6.

Отсюда конкретный артефакт. Если испытуемое соединение само флуоресцирует в том же диапазоне или, наоборот, тушит флуоресценцию продукта, прибор покажет изменение сигнала, которого химически не было. Ложное «ингибирование» появится в трёх флуоресцентных эндпойнтах и не появится в масс-спектрометрическом. Поэтому в модели заведён отдельный канал артефактов пробы (раздел 8.4): это конфаундер с известной структурой, а не шум.

2.5. Что такое time-dependent ингибирование

Обычное ингибирование обратимо: молекула садится в карман, мешает субстрату, отпускает. Уберите ингибитор — активность вернётся.

Time-dependent ингибирование, оно же механизм-зависимая инактивация, устроено иначе. Фермент сам превращает соединение в реакционноспособный продукт, и этот продукт остаётся — ковалентно модифицирует гем или белок, либо образует прочный комплекс с железом (metabolite-intermediate complex). Фермент выведен из строя необратимо. Отличительные признаки: процесс требует катализа (без НАДФН не идёт), развивается во времени, насыщается по концентрации, и активность не восстанавливается отмывкой.

Клинически это гораздо хуже обратимого ингибирования. Обратимый ингибитор перестаёт мешать, как только выводится из организма. Инактивированный фермент восстанавливается только синтезом нового белка, а на это уходят сутки-двое. Поэтому эффект накапливается при повторных приёмах и держится долго после отмены.

Как это измеряют. Ставят два плеча одной пробы.

Прямое плечо: соединение и зонд-субстрат вносят одновременно, сразу меряют IC_{50} . Видно обратимое ингибирование.

Плечо с преинкубацией: соединение сначала выдерживают с ферментом и НАДФН, дав катализу поработать, и только потом вносят зонд и меряют IC_{50} . Если соединение — механизм-зависимый инактиватор, за время преинкубации часть фермента выведена из строя, и измеренная IC_{50} окажется ниже: соединение выглядит потентнее, чем было.

Разница между плечами и есть сигнал. В логарифмической шкале это сдвиг

$$\Delta = \pi_{\text{после преинкубации}} - \pi_{\text{прямое}} \geq 0,$$

и неотрицательность здесь не соглашение, а физика: преинкубация может только добавить инактивации, но не отменить обратимое связывание. Двукратный сдвиг IC_{50} — то есть $\Delta > \log_{10} 2 \approx 0.301$ — общепринятый порог, за которым соединение помечают как TDI.

Отсюда становится понятной вторая ветвь правила разметки из раздела 11. Соединение может быть настолько слабым обратимым ингибитором, что в прямом плече его IC_{50} вообще не определяется как значимая ($\pi \leq 4$, то есть слабее ста микромолей; буквой π здесь и дальше по всему документу обозначена сила ингибирования — та же pIC_{50} , просто короче, а Δ — насколько сильнее соединение выглядит после преинкубации, в тех же логарифмических единицах). Но если после преинкубации оно перешло порог активности с тем же двукратным запасом ($\pi + \Delta > 4 + \log_{10} 2$), это тоже TDI — просто инактивация оказалась единственным его механизмом. Правило и состоит из этих двух случаев.

2.6. Что такое $E_{\max}$ и положительный контроль

Кривая доза-эффект выходит на плато. Высота плато — $E_{\max}$, предельная доля подавленной активности. Полный ингибитор обнуляет активность, частичный оставляет какую-то долю сколь угодно высокой концентрации. Причины частичности бывают разные: соединение садится не в каталитический карман, а в аллостерический; или у фермента несколько сайтов связывания субстрата, как у CYP3A4.

Измеряют $E_{\max}$ не в абсолютных единицах, а относительно положительного контроля — известного полного ингибитора этого фермента, который ставят в ту же пробу. Отсюда шкала в данных: полный ингибитор даёт примерно -1 , потому что

подавил столько же, сколько контроль. Такая нормировка снимает разброс между планшетами и партиями фермента.

2.7. Чем четыре фермента различаются

Отсюда понятно, почему модель устроена как многозадачная с явной матрицей связей, а не как одна голова.

CYP3A4 — самый крупный и самый неразборчивый. Активный карман большой и податливый, вмещает молекулы вплоть до циклических пептидов; в нём помещается больше одного лиганда одновременно, откуда кооперативность и не всегда сигмоидные кривые. Узнавание в основном гидрофобное, поэтому предсказатель «крупная жирная молекула — вероятный ингибитор» работает удивительно хорошо. Отсюда и лучшая предсказуемость 3A4 в наших измерениях.

CYP2C9 — карман поменьше, на входе положительно заряженный остаток аргинина, притягивающий анионы. Субстраты преимущественно кислые, с карбоксильной или другой ионизуемой группой. С 3A4 частично перекрывается по липофильности, отсюда ранговая корреляция 0.69.

Раз это число появилось, стоит сказать, что оно значит, — дальше ранговая корреляция встречается почти в каждом разделе. Она сравнивает не сами значения, а *порядок*: если расставить соединения по силе ингибирования 3A4 и отдельно по силе ингибирования 2C9, насколько похоже получатся два списка. Меняется от -1 (порядки строго противоположны) через ноль (никакой связи) до $+1$ (порядки совпадают). Для нас это самая понятная из метрик: она отвечает на вопрос «назовёт ли модель самую опасную молекулу самой опасной», не требуя, чтобы она угадала само число.

CYP1A2 — узкая плоская щель. Субстраты — плоские ароматические системы, полициклика и азотистые гетероциклы. Они же его и индуцируют, из-за чего у курильщиков клиренс некоторых препаратов заметно выше.

CYP2D6 объясняет половину этого документа. В активном центре сидят остатки аспартата и глутамата, дающие солевой мостик с протонированным атомом азота лиганда. Практически все известные субстраты и ингибиторы 2D6 — основания, заряженные при физиологическом pH. Узнавание идёт не по общей липофильности, а по конкретному электростатическому взаимодействию на конкретном расстоянии от ароматического ядра.

Долю протонированной формы даёт уравнение Гендерсона–Хассельбальха:

$$f_{\text{прот}} = \frac{1}{1 + 10^{\text{pH} - \text{p}K_a}}. \quad (3)$$

При pH 7.4 третичный амин с $\text{p}K_a$ около 9.8 заряжен на 99.6 процента, пиридиновый азот с $\text{p}K_a$ 5.2 — на 0.6 процента, а амид не заряжен вовсе. Разница в сто с лишним раз по доле заряженных молекул. Фингерпринт, считающий фрагменты в радиусе двух связей, видит во всех трёх случаях просто «атом азота в таком-то окружении» и различить их не может — отсюда механистический блок признаков.

И ещё: 2D6 сильно полиморфен. Часть популяции несёт неработающие аллели, часть — дубликации гена; это делает предсказание ингибирования 2D6 клинически особенно ценным, но на наши данные не влияет, поскольку измерения делаются на рекомбинантном ферменте одного варианта.

3. Данные

Пять таблиц, около 35 тысяч строк. Устройство этих данных важнее их объёма: вся конструкция модели вырастает из одной асимметрии. Обучающая матрица разрежена и смещена отбором, тестовая плотная.

Источник	Форма	Заполнено	Что это
Кривые доза-эффект, прямое плечо	4905 × 4	26–48 %	pIC ₅₀ плюс границы интервала и стандартная ошибка
Кривые, плечо с преинкубацией	6145 × 4	21–58 %	то же для условия TDI
E _{max} , оба плеча	6146 × 8	частично	предельная глубина подавления и её интервал
Одноточечный скрининг	4376 × 4	100 %	log ₂ fc при 49.5 мкМ и стандартная ошибка
Тест	750 × 4	—	слепой, плотный

Таблица 1. Пять источников. Пересечения между ферментами внутри таблицы кривых маленькие: одновременно для 1A2 и 2C9 измерено 295 соединений, для 2C9 и 2D6 — 230. Скрининг — единственный плотный источник, и он покрывает весь диапазон активностей, включая неактивные соединения, которых в кривых почти нет.

3.1. Что меряют эти таблицы

Кривая доза-эффект: соединение разводят по концентрациям, для каждой измеряют, насколько подавлена активность фермента, и через полученные точки проводят сигмоиду. Из подгонки получают pIC₅₀ — отрицательный десятичный логарифм концентрации, при которой активность падает вдвое. Байесовская подгонка даёт не только точку, но и интервал, отражающий, насколько уверенно эта точка определена. У соединений, чья кривая не дошла до плато, интервал широкий.

Одноточечный скрининг: то же измерение, но при одной концентрации 49.5 мкМ. На выходе log₂fc — логарифм отношения сигнала с соединением к сигналу без него. Ноль означает, что ничего не произошло, отрицательные значения — что активность подавлена.

Полные кривые снимали не для всех подряд. Соединение поднимали на подробное измерение, если оно показало эффект на скрининге. Это отбор по зависимой переменной, и он деформирует обучающую выборку способом, который разобран в разделе 4.3.

Правило это не универсальное. Скрининг есть у 4375 из 4905 соединений с кривыми; у оставшихся 530 его нет, и все 530 несут метку *только* по 3A4 — на 1A2, 2C9 и 2D6 у них меток ноль. То есть для трёх ферментов отбор по скринингу описывает выборку целиком, а на 3A4 почти четверть кривых (530 из 2335) пришла каким-то другим путём, и для них аргумент про отбор просто не про них.

3.2. Как собран тестовый набор

Организаторы описали процедуру: взяли по 25 лучших ингибиторов каждого из 1A2, 2C9 и 3A4, к каждому добавили по 10 ближайших соседей по фингерпринту, итого 3 × 25 × 10 = 750.

Это проверяется, и проверка сходится частично. Здесь важно, что порог кластеризации выбирается, а не выводится, и картина от него зависит сильно. При рабочем пороге 0.35 из 750 тестовых соединений выходит 477 групп с медианным размером один, групп по пять и более членов 21, и в них лежат 155 соединений. При 0.48 — 203 группы с медианным размером два, 56 групп по пять и более, в них 496 соединений. То есть серийная структура в наборе есть, но её видимый охват меняется от пятой части до двух третей в зависимости от того, что считать серией. Ровно 75 серий ровно по 10 не восстанавливается ни при каком пороге — число 75 получается делением 750 на 10.

Что восстанавливается уверенно, так это положение якорей: оно от порога почти не зависит. Для каждой группы найдено ближайшее обучающее соединение, и его активность стоит на 92–94 перцентиле обучающего распределения по 1A2 и на 97.5–99 по 2C9 при любом пороге от 0.35 до 0.50, тогда как по 2D6, который в отборе не участвовал, — на 58–66. По 3A4 оценка гуляет заметно шире, от 82 до 95, и опираться на неё точное число нельзя. Оговорка, без которой эти проценты читаются неверно: якорей с меткой всего от девяти до тридцати семи на фермент, так что медиана здесь имеет широкий интервал. Медианное сходство Танимото тестового соединения с ближайшим обучающим равно 0.587.

Значит распределение меток на тесте не совпадает с обучающим: тест обогащён активными по трём ферментам и близок к фону по четвёртому. И устроен он как набор серий аналогов вокруг известных хитов, а не как случайная выборка из химического пространства. Проверять модель надо соответственно.

4. Что мы измерили до того, как что-то строить

Первое, что было сделано — простая базовая линия и разбор, почему она ведёт себя так, как ведёт. Без этого нет способа отличить работающую конструкцию от красивой.

Базовая линия: счётчики фрагментов Моргана радиуса 2 (2048 бит), 217 дескрипторов RDKit, градиентный бустинг, пятикратная кросс-валидация по кластерам Бутины при пороге сходства 0.35.

Три вещи из этого перечисления стоит расшифровать сразу, потому что дальше они встречаются на каждой странице.

Счётчики фрагментов Моргана — способ описать молекулу числами: перебираются все её фрагменты до заданного радиуса вокруг каждого атома, и каждый попадает в свою ячейку из двух тысяч. Получается длинный вектор, по которому похожие молекулы похожи. *Дескрипторы* — две сотни обычных вычислимых характеристик: молекулярная масса, липофильность, число доноров водородной связи и так далее.

Кросс-валидация — способ честно измерить качество, не имея тестовых меток. Выборка режется на пять частей; модель учат на четырёх и предсказывают пятую, потом меняют, какая часть отложена, и так пять раз. В итоге у каждого соединения есть предсказание от модели, которая его *не видела*. Такие предсказания называют предсказаниями вне фолда, и только они годятся для оценки: числа, посчитанные на тех же молекулах, на которых учились, показывают способность запоминать, а не предсказывать.

По кластерам Бутины — уточнение, зачем нужно отдельное объяснение. Если резать выборку случайно, близкий структурный аналог соединения легко останется в обучении, и модель «угадает» его по родственнику. Поэтому соединения сначала группируют по сходству, и в отложенную часть уходит целая группа целиком. Насколько это на самом деле меняет дело — отдельный вопрос, к нему мы вернёмся в

разделе 13, и ответ там неожиданный.




Рис. 1. Базовая линия регрессионного трека. Красная линия — уровень предсказания одного числа для всех соединений. CYP3A4 предсказывается вдвое лучше этого уровня, CYP2D6 — на семь тысячных.

Прежде чем читать числа, стоит договориться о шкале. Метрика конкурса, ST-RAE, устроена так, что **меньше — лучше**, а единица — это уровень бессмысленного предсказания: столько получится, если всем соединениям подряд выдать одно и то же число. Всё, что заметно ниже единицы, — работа модели; всё, что около единицы, — её отсутствие.

По этой шкале CYP3A4 предсказывается примерно вдвое лучше бессмысленного уровня, а CYP2D6 — на семь тысячных лучше него, то есть не предсказывается вовсе. Три остальных фермента располагаются между этими крайностями. Ранговое согласие (насколько верно модель расставляет соединения по порядку активности, безотносительно самих чисел) даёт ту же картину: на 3A4 оно высокое, на 2D6 — вдвое ниже.

CYP2D6 и стал главным предметом разбирательства, потому что от объяснения зависит, что вообще строить дальше. Ниже три версии, по очереди.

4.1. Версия первая: метки шумные, учить нечего

Если почти весь разброс опубликованных активностей — погрешность измерения, то потолок для любой модели низкий и делать нечего. Обычно разделить настоящий разброс и шум трудно, но здесь вместе с каждым значением опубликована его собственная стандартная ошибка.

Дисперсии независимых источников разброса складываются, поэтому

$$\text{Var}(\text{наблюдаемое}) = \text{Var}(\text{настоящее}) + \text{Var}(\text{шум}), \quad \text{надёжность} = 1 - \frac{\text{Var}(\text{шум})}{\text{Var}(\text{набл.})}. \quad (4)$$

Надёжность — доля разброса меток, которая приходится на настоящие химические различия. Она же задаёт потолок R^2 для любой модели на этих метках: предсказать шум нельзя.

Для CYP2D6 надёжность выходит **0.93**: девяносто три процента разброса опубликованных активностей — это настоящие химические различия, и только семь процентов —

погрешность прибора. У остальных трёх ферментов примерно столько же. Версия не подтвердилась: учить есть чему.

Более того, сравнение с этим потолком показывает, насколько велик недобор. На CYP2D6 модель осваивает лишь восьмую часть того, что метки в принципе позволяют освоить, а на CYP3A4 — две трети. Дело, стало быть, не в том, что данные плохи, а в том, что модель их не берёт.

Оговорка, которую надо держать в голове. Надёжность посчитана через *средний квадрат* погрешности, и это существенно, потому что погрешность распределена крайне неравномерно: у типичного соединения она в несколько раз меньше средней, а почти шестьдесят процентов всего шума дают верхние пять процентов соединений, у которых подгонка кривой развалилась. Число в (4) от этого не портится — туда и должен идти средний квадрат, — но следствие важное: взвешивать соединения по их индивидуальной погрешности имеет гораздо больше смысла, чем кажется, если смотреть только на среднее.

4.2. Версия вторая: не хватает нужных признаков

Как разобрано в разделе 2.7, CYP2D6 узнаёт субстраты через солевой мостик с протонированным азотом, а не через общую липофильность. Фингерпринт про заряд не знает: третичный амин и амид для него — два похожих азота в похожем окружении, хотя доля заряженной формы у них различается в сотни раз.

Собрали блок из 30 химически осмысленных чисел: оценка pK_a самого основного центра, доля протонированной формы при pH 7.4, полный заряд молекулы, счётчики классов азота и кислотных групп, топологическое расстояние от заряженного азота до ближайшего ароматического кольца. Оценщик pK_a — правило: базовое значение класса минус индуктивный штраф от электроноакцепторных заместителей с затуханием по числу связей. На двадцати соединениях с литературными значениями средняя ошибка 0.60 единицы, медианная 0.2, и на бинарный вопрос «заряжено ли при 7.4» правило ответило верно во всех двадцати случаях.

Результат двойственный, и это тот случай, когда полезно смотреть на две метрики сразу.

Чтобы понять, что было дальше, нужна одна процедура. Сравнивая две модели, мало посмотреть, у какой число лучше: разница может целиком объясняться тем, какие соединения случайно попали в выборку. Поэтому выборку многократно пересобирают с возвращением и всякий раз считают разность — это называют парным бутстрапом. Получается интервал, в котором разность лежит правдоподобно. Если интервал накрывает ноль, различить две модели этими данными нельзя.

По метрике конкурса выигрыша нет. Интервал накрывает ноль и на CYP2D6, и на макро. Механистический блок, придуманный ровно под механизм CYP2D6, по ST-RAE не даёт ничего.

По ранжированию выигрыш есть, и он избирателен именно так, как предсказывает химия. На CYP2D6 ранговая корреляция растёт с 0.35 до 0.40, и здесь интервал ноль уже не накрывает. На CYP2C9 прирост на грани различимости, а на CYP1A2 и CYP3A4 — нули. То есть блок помогает там и только там, где по химическим соображениям и должен.

Ещё показательнее вот что. Модель, построенная на одних только тридцати механистических числах — без фингерпринта и без дескрипторов вообще, — воспроизводит на CYP2D6 почти всю ранжирующую способность полной модели. На трёх остальных

ферментах те же тридцать чисел дают примерно половину. Сигнал CYP2D6, стало быть, низкоразмерный и химически специфичный: его несут несколько осмысленных величин, а не две тысячи структурных битов.

Итог: механизм назван верно, но выигрыш по метрике соревнования неотличим от нуля. Признаки — часть ответа, не главная его часть.

4.3. Версия третья: дело в том, какие соединения попали в выборку




Рис. 2. Распределения измеренных активностей. Цветом выделены средние 50 процентов соединений. У CYP3A4 задача во многом сводится к тому, чтобы отделить левую часть от правой. У CYP2D6 левой части почти нет, и модели приходится различать соединения внутри узкой полосы.

У CYP2D6 отбор оставил узкую полосу: средняя половина соединений уместилась в интервал шириной 0.83 логарифмической единицы против 1.50 у CYP3A4. Это ограничение диапазона, оно же *selection on the dependent variable*: если отобрать объекты по интересующему признаку и потом мерить связь только среди отобранных, связь ослабевает, хотя в полной популяции она никуда не делась.

Проверка требует второго показателя активности того же фермента, измеренного без отбора. Он есть: $\log_2 fc$ скрининга, снятый для 4375 соединений подряд, включая неактивные. Учим ту же модель на тех же признаках и тех же фолдах предсказывать его вместо pIC_{50} .

Чтобы это не превратилось в сравнение «больше примеров против меньше», сделан контроль: из соединений со скринингом случайно выбирается ровно столько же, сколько у этого фермента меток кривых.

Результат ложится ровно так, как предсказывает объяснение через ограничение диапазона: чем уже полоса меток у фермента, тем больше выигрыш от перехода на показатель с полным диапазоном. Порядок ферментов по величине выигрыша в точности обратен порядку по ширине полосы, а на CYP3A4 — у которого полоса самая широкая — выигрыш вообще меняет знак.




Рис. 3. Выигрыш от перехода на показатель с полным диапазоном против ширины полосы меток. Пустой кружок — качество на метках кривых, закрашенный — на скрининге при равном числе обучающих примеров. Стрелка тем длиннее, чем уже полоса меток, и на CYP3A4 разворачивается.

Этот отрицательный знак важнее самой монотонности: он работает внутренним контролем. Если бы дело было просто в том, что скрининг легче предсказуем сам по себе, выигрыш был бы положительным везде. Он не положительный везде. На CYP2D6 же доля объяснённой дисперсии при равном числе обучающих примеров вырастает более чем вдвое.

Модель прекрасно умеет учить химию CYP2D6, но не может показать это на выданных метках. Основная причина провала — геометрия меток, и чинится она не признаками, а тем, что в правдоподобие входит источник с полным диапазоном. На этом и построено всё остальное.

Честная оговорка про контроль: выровнено количество примеров, но не форма распределения меток. Совсем чистый эксперимент требует подобрать подвыборку так, чтобы совпадало и то и другое.

5. Порождающая модель

Все пять таблиц — наблюдения над одним объектом: кривой доза-эффект для тройки «молекула m , фермент e , плечо a » (плечо — прямое измерение или измерение после преинкубации). Модель описывает эту кривую, а не отдельные таблицы, и каждая таблица подключается своим правдоподобием.

Слово «правдоподобие» здесь ключевое и дальше встречается постоянно, поэтому стоит сказать, что за ним стоит. Настоящей кривой мы не видим никогда — видим только результаты измерений, каждое со своим шумом. Правдоподобие отвечает на вопрос: если предположить, что настоящая кривая вот такая, насколько ожидаемым было бы то, что мы на самом деле намерили? Обучение состоит в переборе возможных кривых в пользу тех, при которых наблюдения выглядят наименее удивительно. Записывают это обычно через $-\log p$ — логарифм берут, чтобы вероятности разных измерений складывались, а не перемножались, а минус — чтобы задача стала задачей минимизации. Ценность такой записи в том, что каждый источник данных добавляет

в общую сумму своё слагаемое, и разные по природе измерения оказываются на одном языке.

Латентные параметры тройки:

$$\theta_{m,e,a} = (\pi_{m,e,a}, E_{m,e,a}, h_e), \quad \pi_{m,e,tdi} = \pi_{m,e,dir} + \Delta_{m,e}, \quad \Delta \geq 0. \quad (5)$$

Здесь π — потенция, та самая pIC_{50} ; E — предельная глубина подавления, то есть какая доля активности фермента подавляется при бесконечной концентрации; h — крутизна перехода, вынесенная на уровень фермента (почему — в разделе 6). Сдвиг Δ неотрицателен, потому что преинкубация может только усилить ингибирование, а не ослабить.

Прямая модель прибора — доля подавленной активности при концентрации C :

$$I(C; \theta) = \frac{E}{1 + 10^{h(pC - \pi)}}, \quad pC = -\log_{10} C. \quad (6)$$

Уравнение Хилла. При $pC = \pi$, то есть когда концентрация равна IC_{50} , показатель обнуляется и подавлена ровно половина от предельной глубины. Выше концентрация — меньше pC — отрицательнее показатель — ближе I к E . Ниже — наоборот. Крутизна h задаёт, за сколько декад концентрации происходит переход: при $h = 1$ путь от десяти до девяноста процентов эффекта занимает примерно две декады.

5.1. Правдоподобия по источникам

Кривая из двенадцати точек даёт несимметричную оценку: интервал вокруг pIC_{50} обычно длиннее с одной стороны. Усреднять границы — терять эту информацию, поэтому берём расщеплённую нормаль с двумя масштабами:

$$-\log p(y_{\text{крив}} | \pi) = \text{split-}\mathcal{N}(\pi; \hat{\pi}, \sigma^-, \sigma^+), \quad \sigma^- = \frac{\hat{\pi} - l}{1.96}, \quad \sigma^+ = \frac{h - \hat{\pi}}{1.96}. \quad (7)$$

Две половинки нормального распределения с разными ширинами, сшитые в моде и отнормированные общим множителем $2/[\sqrt{2\pi}(\sigma^- + \sigma^+)]$. Правило деления на 1.96 точно только при симметричной полосе: у расщеплённой нормали слева лежит масса $\sigma^-/(\sigma^- + \sigma^+)$, а не половина, поэтому квантиль стоит не в 1.96 сигмы. На наших данных полосы почти симметричны — максимум медианной асимметрии 0.13 логарифмической единицы — и расхождение составляет 0.0004 единицы pIC_{50} . Правило годится, но по этой причине, а не по общей верности.

Скрининг входит через (6) с аффинной калибровкой на фермент:

$$\hat{y}_{\text{скр}} = s_e \cdot \log_2(1 - I(C_0; \theta_{\text{dir}})) + b_e, \quad -\log p(y_{\text{скр}} | \theta, \psi_e) = \frac{(y_{\text{скр}} - \hat{y}_{\text{скр}})^2}{2(\sigma_i^2 + \sigma_e^2)} + \log \sqrt{\sigma_i^2 + \sigma_e^2}. \quad (8)$$

Прибор показывает логарифм оставшейся активности, отсюда $\log_2(1 - I)$. Пара (s_e, b_e) поглощает динамический диапазон пробы и нормировку; σ_i — опубликованная стандартная ошибка конкретного измерения, σ_e — обучаемая добавка, отвечающая за неучтённый разброс. Набор $\psi_e = (s_e, b_e, \sigma_e)$ и есть калибровка прибора.

Етах — прямое наблюдение второго параметра тройки; плечо с преинкубацией — наблюдение $\pi + \Delta$ с тем же расщеплённым нормальным правдоподобием.

5.2. Калибровка прибора

Калибровка — это функция, переводящая скрытую кривую в показание прибора. Не свойство соединения, а свойство установки: та же молекула на другом приборе даст другое показание, а pIC_{50} у неё останется прежней. Связь нелинейная и насыщающаяся: очень сильный ингибитор и ингибитор вдесятеро сильнее дадут при 49.5 мкМ практически одинаковое показание, потому что оба подавили всё, что можно.

Подгоняем E и h на фермент по соединениям, у которых есть и то и другое измерение.




Рис. 4. Калибровка. Точки — соединения, у которых есть и pIC_{50} , и показание скрининга. Сплошная линия — подгонка формой (6) с двумя параметрами на фермент, пунктир — свободная монотонная кривая, задающая предел для любой монотонной калибровки.

Из этой картинки следует три вещи.

Связь очень сильная: ранговая корреляция от -0.83 до -0.94 . Поэтому скрининг — почти достаточная статистика. Свободная монотонная калибровка по измеренному показанию даёт макро-ST-RAE 0.359 против 0.767 у полной модели по структуре. Знай мы показание скрининга для тестовых соединений, задача была бы вдвое легче; но на тесте его нет, пересечение теста с первичной библиотекой ровно нулевое.

Хилловская форма теряет немного, но теряет. Стандартное отклонение остатка против свободной монотонной кривой: 0.231 против 0.208 на 1A2, 0.185 против 0.167 на 2C9, 0.497 против 0.390 на 2D6, 0.612 против 0.499 на 3A4. То есть двухпараметрическая форма жёстче, чем нужно, особенно на 2D6, где свободная кривая выходит на плато у неактивных, а хилловская тянется к нулю. Это аргумент за монотонную сплайн-поправку поверх параметрической формы, но не за отказ от неё: форма даёт

правильную экстраполяцию там, где данных мало.

Крутизна разная: на 3A4 подобралось $h = 1.97$, на остальных около 1.2. Это свойство постановки на конкретном ферменте, поэтому калибровка не может быть общей на все четыре.

Отдельно проверен планшетный дрейф. Планшетов девять на фермент, и сырой разброс медиан по планшетах выглядит тревожно: до 0.293 при размахе 0.922. Но планшеты не рандомизированы, активные соединения сидят кучно, поэтому надо вычесть то, что объясняется составом планшета. После вычитания предсказанного по pIC_{50} разброс падает до 0.039–0.087 при стандартном отклонении остатка 0.19–0.61.

Планшет объясняет от 0.9 до 8 процентов остаточной дисперсии, и разброс по ферментам здесь важнее диапазона: 3A4 0.9 %, 2D6 2.3 %, 1A2 3.2 %, а 2C9 8.1 % — почти в девять раз больше, чем 3A4. Вычитание свободной монотонной калибровкой вместо хилловской даёт 0.9, 2.7, 3.8 и 6.7 процента, то есть та же картина: число — свойство данных, а не выбора калибровки. Отдельного слагаемого в модели всё же не требуется, но по другой причине, чем малость доли: даже на 2C9 планшетная компонента даёт стандартное отклонение около 0.05 в единицах $\log_2 fc$, что заметно меньше собственной погрешности одного показания.

Про обозначение: E в калибровке — не тот E , что в (5). Там предельная глубина подавления самого соединения, здесь — параметр установки, вбирающий её динамический диапазон. Совпадение буквы неудачное и в коде их надо развести.

5.3. Почему цензурирование получается само

Это главный технический аргумент за такую конструкцию. Продифференцируем (6) по потенци, обозначив $x = 10^{h(pC_0 - \pi)}$:

$$\frac{\partial I}{\partial \pi} = +E h \ln 10 \cdot \frac{x}{(1+x)^2}. \quad (9)$$

Множитель $x/(1+x)^2$ максимален при $x = 1$, то есть ровно когда $\pi = pC_0$, и равен там одной четвёртой; при $x \rightarrow 0$ и $x \rightarrow \infty$ он затухает экспоненциально. Фишеровская информация о π , которую несёт одна точка скрининга, пропорциональна квадрату этого множителя.




Рис. 5. Сколько информации о потенци несёт одно измерение при концентрации C_0 . Колокол сосредоточен вокруг pC_0 с шириной порядка $1/h$ декад и обнуляется в обеих зонах насыщения.

На практике это значит, что в зонах насыщения градиент по π исчезает сам.

Для соединения, которое при 49.5 мкМ не подавило ничего, модель извлекает из скрининга мягкое неравенство «активность ниже примерно такой-то», а не число. Для соединения, подавившего всё, — неравенство с другой стороны. Никакого специального кода цензурирования писать не надо, оно следует из формы кривой.

Форма (9) видна в данных напрямую: перегиб зависимости показания от pIC_{50} на CYP3A4 приходится на 4.3 (рис. 4), то есть на $pC_0 = 4.305$ для 49.5 мкМ.

6. Идентифицируемость

Первое, что спросит любой, кто это читает: из однотоочечного измерения наблюдается ровно скаляр $I(C_0)$, а параметров в (5) три. Тройка (π, E, h) точно не идентифицируется — любая кривая, проходящая через ту же ординату при C_0 , объясняет данные одинаково хорошо.

Риск конкретный: сеть сбросит остаток в E , чтобы подогнать показание скрининга, и испортит π — единственную величину, которую с неё спрашивают на лидерборде.

Что с этим делаем, по возрастанию силы ограничения.

6.1. Крутизна — на уровень фермента

h_e , один скаляр на фермент вместо десятков тысяч. Первую версию делаем вообще с $h_e \equiv 1$. Оправдание не только техническое: крутизна кривой в такой пробе определяется в основном механизмом и стехиометрией связывания, а не индивидуальными особенностями лиганда, и подгонка калибровки (раздел 5.2) даёт по ферментам устойчивые 1.11–1.97.

6.2. Глубина: амортизация вместо поштучной подгонки

Есть два способа получить E для каждого соединения.

Поштучная подгонка: у каждого соединения свой свободный параметр E_m . Для 4905 соединений и четырёх ферментов это 19 620 свободных чисел, каждое подбирается только по данным своего соединения, и никакой связи между похожими молекулами нет.

Амортизация: свободных E_m нет вовсе, есть одна общая функция — голова сети, получающая представление молекулы и выдающая ответ:

$$E_{m,e} = \sigma(u_e^\top z_m + c_e). \quad (10)$$

Здесь z_m — вектор-представление молекулы из общего ствола, u_e и c_e — веса и сдвиг головы фермента, сигмоида зажимает ответ в интервал от нуля до единицы. Параметров $4(d+1)$, то есть при $d = 256$ чуть больше тысячи, и они обслуживают все соединения сразу, включая те, у которых своей кривой нет. Отсюда слово: дорогая процедура вывода амортизуется по всем объектам.

Как это работает регуляризатором. Чтобы выдать одному соединению нестандартное E , сети надо сдвинуть его представление, а представление производится общим стволом из структуры, и тот же ствол обслуживает все похожие молекулы. Подогнать E индивидуально можно только там, где есть структурная закономерность — класс молекул, систематически ведущий себя как частичный ингибитор. Если такого класса нет, а есть только шум подгонки кривой, сети выгоднее выдать всем примерно одинаковое E . Формально это сужение множества гипотез: достижимые наборы

$\{E_m\}$ — уже не произвольный вектор длины N , а образ структурного пространства под гладким отображением. Регуляризация здесь не слагаемое в функции потерь, а свойство параметризации.

6.3. А теперь измерения, и они меняют вывод

Всё сказанное объясняет, почему амортизация безопасна. Но у организаторов опубликованы измеренные E : колонки EmaxVsPosCtrl_direct_inhibition с доверительными полосами. Смотреть на них надо было до всяких рассуждений.




Рис. 6. Слева: цветной отрезок — где лежат 90 процентов соединений, серый — средняя ширина доверительной полосы одного измерения. Серый шире цветного на всех четырёх ферментах. Справа: надёжность по (4), отрицательная везде.

Шкала здесь относительно положительного контроля, поэтому полный ингибитор даёт примерно -1 . И вот что оказалось. Весь разброс E между соединениями уже, чем заявленная погрешность одного измерения, — на CYP3A4 втрое, на CYP2D6 вдвое. Иначе говоря, если взять два случайных соединения, разница их измеренных E в среднем меньше, чем неопределённость каждого из этих двух чисел по отдельности. Различать соединения по E в такой ситуации нельзя.

Отсюда отрицательная надёжность: от -0.73 до -1.43 . У честной величины она лежит между нулём и единицей; отрицательная означает, что заявленная дисперсия шума больше всего наблюдаемого разброса. Буквально это может означать, что полосы посчитаны консервативно, но верхняя оценка сигнала уровня соединения от этого не меняется — он не превышает нуля.

Значит амортизация была правильным решением по неправильной причине. Дело не в том, что сеть не сможет переобучиться на индивидуальные E , а в том, что переобучаться там не на чем: сигнала уровня соединения в этих колонках нет. Вместо головы достаточно одной константы на фермент, примерно -1 у всех четырёх, — и, если хочется страховки, поштучной поправки с жёстким штрафом, которую данные обязаны прижать к нулю.

Что наблюдаемая вариация E — артефакт подгонки кривой, а не химия, видно ещё и по такому признаку. Связь между измеренным E и активностью почти отсутствует у неактивных и у активных соединений, но резко усиливается в средней зоне — ровно там, где кривая доза-эффект обрывается, не дойдя до плато, и подгонщику приходится выбирать глубину наугад, по гребню. Само по себе это подозрительно. Но решает

дело знак: у трёх ферментов в средней зоне более потентные соединения выглядят давящими *глубже*, а у CYP2D6 — наоборот, *мельче*. Химического механизма, который переворачивал бы этот знак от фермента к ферменту, не существует. Это подпись процедуры подгонки, а не свойство молекул.

Диагностика на будущее остаётся прежней: смотреть разброс выхода головы E отдельно на соединениях с полной кривой и на соединениях только со скринингом. Если на вторых разброс заметно выше, голова используется как свалка для остатка.

7. Механизм пропусков

Полные кривые снимали не для всех: отбор шёл по результату первичного скрининга. Это отбор по зависимой переменной, то есть *missing not at random* по построению, и он же — причина провала на CYP2D6, измеренная в разделе 4.3.

Спасает вот что: *переменная отбора наблюдаема*. Скрининг есть для 4375 из 4905 соединений обучающей выборки, и именно он определял, кого поднимут на подробное измерение.

7.1. Как раскладывается совместное распределение

Пишем совместную плотность через скрытую активность a , честно:

$$p(y_{\text{крив}}, y_{\text{скр}}, R \mid x, \theta) = p(R \mid y_{\text{скр}}) \int p(a \mid x, \theta) p(y_{\text{скр}} \mid a) p(y_{\text{крив}} \mid a)^R da. \quad (11)$$

Здесь R — индикатор попадания в подробное измерение, $p(a \mid x, \theta)$ — что модель думает об активности до измерений (центр — предсказание сети, ширина — признание того, что структура определяет активность не полностью), два следующих множителя — шум каждого прибора, зависящий только от истинной активности. Множитель $p(y_{\text{крив}} \mid a)$ входит в степени R , то есть только для отобранных.

Главный шаг — вынос $p(R \mid y_{\text{скр}})$ за интеграл. Он законен потому, что решение об отборе принималось глядя на показание скрининга, а не на скрытую активность: под интегралом по a этот множитель величины a не содержит.

Применяя цепное правило, получаем рабочую форму:

$$p(y_{\text{крив}}, y_{\text{скр}}, R \mid \theta) = \underbrace{p(R \mid y_{\text{скр}})}_{\text{без } \theta} \cdot \underbrace{p(y_{\text{крив}} \mid y_{\text{скр}}, \theta)}_{\text{условно}} \cdot p(y_{\text{скр}} \mid \theta). \quad (12)$$

Первый множитель не зависит от θ , при дифференцировании логарифма даёт ноль и полностью выпадает из градиента. Значит можно обучаться на полном правдоподобии, вообще не моделируя процедуру отбора, и оценки останутся состоятельными. Условие ровно одно: скрининг должен входить в модель как наблюдение. Если его выбросить, первый множитель перестанет быть отделимым и смещение вернётся. По сути это поправка хекмановского типа, у которой первая ступень не моделируется, а наблюдается.

Средний множитель обязан быть *условным* по $y_{\text{скр}}$, и это место, где легко ошибиться. Заменить его на маргинальный $p(y_{\text{крив}} \mid \theta)$ можно только при нулевом собственном латентном разбросе соединения: два показания меряют одну скрытую активность, они коррелированы, а отбор идёт по одному из них — значит среди отобранных распределение второго сдвинуто. Маргинальный множитель про этот сдвиг не знает.

7.2. Что даёт симуляция

Проверено на данных, где истина известна по построению: $a = x^T \beta + \varepsilon$, скрининг у всех, кривая — у верхних двадцати восьми процентов по скринингу (порог квантиля 0.72).

Способ подгонки	Смещение, норма	Наклон калибровки
Только отобранные метки кривых	0.433	0.731
Совместное правдоподобие, отбор по скринингу	0.019	1.012
Только скрининг, все строки (контроль сверху)	0.002	1.000
Отбор по скрытой истине, скрининг у неотобранных не виден	0.512	0.681

Таблица 2. Сорок повторов, шесть тысяч соединений, в подробное измерение попадает 28 процентов. Наклон единица означает, что коэффициенты восстановлены без систематического сжатия.

Подгонка по одним отобранным меткам сжимает коэффициенты до 0.73 от истины — ровно то ограничение диапазона, которое видно на CYP2D6. Совместное правдоподобие возвращает 1.01.

Четвёртая строка важнее первых трёх. Сломайте условие, то есть сделайте отбор зависящим от скрытой величины и уберите скрининг у неотобранных, и совместная схема ломается так же, как наивная. Значит аргумент держится не на общей идее «использовать больше данных», а на наблюдаемости первой ступени отбора. В наших данных она наблюдаема.

Отдельно измерена цена замены условного множителя на маргинальный. Смещения нет при нулевом латентном остатке, при $\sigma_{\text{лат}} = 0.35$ оно примерно втрое меньше стандартной ошибки оценки, при $\sigma_{\text{лат}} = 0.70$ уже сравнимо с ней. И независимо от смещения такая схема занижает собственную погрешность в 1.18–1.21 раза, потому что считает два коррелированных наблюдения одного соединения за два независимых свидетельства. Значит голова, предсказывающая pIC_{50} , должна получать на вход показание скрининга того же соединения. Или, что то же самое, обе величины должны выводиться из общего латентного слоя с явной ковариацией, а не из двух независимых голов.

На инференсе скрининга нет, но это не мешает. Условный множитель нужен на обучении, чтобы оценка не была смещена отбором; на предсказании мы маргинализуем по $y_{\text{скр}}$, что при общем латентном слое сводится к одному прогону сети.

Оговорка: 530 соединений с кривыми не имеют скрининга, и для них аргумент не работает. По выборке целиком доля небольшая, но лежит она не равномерно: все 530 — это метки 3A4, почти четверть всех кривых этого фермента. Так что на трёх ферментах оговорка пустая, а на 3A4 её надо закрывать — взвесить или выкинуть в абляции.

8. Архитектура

8.1. Ствол

Предобученный химический энкодер $f_{\varphi} : \text{SMILES} \rightarrow z \in \mathbb{R}^d$. Организаторы выложили свои веса (CheMeleon, предобученный D-MPNN, и chemprop-foundation), плюс доступны MinimoI и графовые трансформеры. Ансамблируем по семействам

претрейна, а не по сидам одного семейства: ошибки разных семейств коррелируют слабее, и ансамбль из четырёх разных архитектур даёт больше, чем из восьми запусков одной. Дообучение через LoRA-адаптеры, чтобы 6.5 тысяч меток кривых не переписали претрейн, обученный на миллионах молекул.

8.2. Связь между ферментами: коррелионализация

Ферментов четыре, и надо решить, как их связать. Очевидные способы не годятся. Четыре независимые модели: 2C9 не пользуется 2335 метками 3A4, хотя они меряют почти одно и то же. Одна общая голова: 2D6 тянет в сторону остальных трёх, а он с ними не коррелирует. Общий ствол и четыре независимые головы уже лучше, но связь между задачами остаётся неявной.

Коррелионализация — термин из геостатистики: совместное моделирование нескольких величин, измеренных в одних точках, через общую структуру плюс отдельную матрицу связей между величинами. Простейший вариант, *intrinsic coregionalization model*, выносит эту матрицу в явный параметр.

Голова линейная поверх общего представления:

$$\pi_{m,e} = w_e^\top g(z_m) + b_e, \quad W = [w_1 \ w_2 \ w_3 \ w_4] \in \mathbb{R}^{d \times 4}. \quad (13)$$

Вся связь между ферментами сидит в углах между столбцами W : если w_2 и w_4 смотрят почти в одну сторону, модели 2C9 и 3A4 читают представление одинаково. Матрица этих углов

$$B = W^\top W \in \mathbb{R}^{4 \times 4}, \quad B_{ee'} = w_e^\top w_{e'}, \quad (14)$$

и на неё навязывается структура «несколько общих осей плюс своё у каждого»:

$$B \approx LL^\top + \text{diag}(\kappa), \quad L \in \mathbb{R}^{4 \times r}, \quad r = 2. \quad (15)$$

Строка e матрицы L говорит, насколько фермент участвует в каждой из r общих осей; $LL^\top$ — общая часть ковариации ранга r ; κ_e — специфичная часть фермента, то, что есть только у него. Это обычная факторная модель: r общих механизмов узнавания плюс идиосинкразия.

Данные говорят то же, что раздел 2.7: 2C9 и 3A4 идут в паре ($\rho = 0.688$), а 2D6 ортогонален всем троим (0.059, -0.120, 0.056). Матрица положительно определена, минимальное собственное число 0.287, так что раскладывать её можно. Нагрузки: ось 1 — 2C9 -0.907, 3A4 -0.773, 1A2 -0.480, 2D6 +0.033; ось 2 — 2D6 -0.726, остальные около нуля. Специфичные части κ : 0.759, 0.161, 0.472, 0.390.

Первая ось — липофильная промискуитетность: крупные жирные молекулы садятся в широкие карманы 2C9 и 3A4. Вторая — 2D6 с его солевым мостиком. Общая голова тянула бы 2D6 по первой оси и портила бы его.

Про ранг надо помнить вот что. При четырёх задачах внедиагональ содержит шесть чисел, а нагрузки ранга 2 дают $4 \times 2 = 8$ параметров минус одна степень свободы на вращение, то есть семь. Модель насыщена: ранг 2 воспроизводит внедиагональ точно не потому, что угадал структуру, а потому что параметров хватает. По-настоящему ограничивает только ранг 1, и он промахивается максимум на 0.10, причём весь промах приходится на 2D6. Так что структура ранга 2 — не сжатие, а способ задать приор и инициализацию. Польза проявится, когда B будет тянуть головы во время обучения, а не в самой аппроксимации матрицы четыре на четыре.




Рис. 7. Слева — ранговая корреляция rC_{50} между ферментами, посчитанная по общим соединениям (от 230 пар у 2C9–2D6 до 473 у 2C9–3A4). Справа — нагрузки факторной модели ранга 2 на те же данные: каждая стрелка показывает, насколько фермент участвует в каждой из двух общих осей. Первая ось нагружает 2C9, 3A4 и слабее 1A2, на 2D6 стоит на нуле; вторая ось — почти исключительно 2D6.

Регуляризационный член. Задача — не дать столбцам W разъехаться в произвольные углы, когда у фермента мало меток, и притянуть матрицу связей к тому, что видно в данных:

$$\Omega(W) = \frac{\lambda_1}{2} \|\rho(W^\top W) - \hat{\rho}\|_F^2 + \frac{\lambda_2}{2} \|W\|_F^2, \quad \rho(B) = D^{-1/2} B D^{-1/2}, \quad D = \text{diag}(B). \quad (16)$$

Первое слагаемое: строим B , нормируем в корреляционную матрицу, вычитаем эмпирическую $\hat{\rho}$, складываем квадраты разностей. Нормировка нужна потому, что притягивать надо углы, а не длины столбцов — длина отвечает за масштаб предсказания и настраивается данными. Второе — обычная усадка весов. Норма Фробениуса $\|A\|_F = \sqrt{\sum_{ij} A_{ij}^2}$ — евклидова длина матрицы, вытянутой в строку.

Почему именно так, а не поэлементный штраф на W . Матрица W определена не однозначно: умножение справа на любую ортогональную Q не меняет ни $W^\top W$, ни предсказания. Регуляризатор обязан обладать той же симметрией, иначе он штрафует за выбор системы координат, а не за содержание. Обе величины в (16) проходят через W только в виде $W^\top W$, поэтому симметрию сохраняют; поэлементный штраф — нет.

Низкий ранг входит не штрафом, а параметризацией. Практически проще держать не W со сложным штрафом, а сразу L и κ и строить головы из них:

$$\pi_{m,e} = L_e \cdot U^\top g(z_m) + \sqrt{\kappa_e} s_e^\top g(z_m) + b_e, \quad (17)$$

где $U \in \mathbb{R}^{d \times 2}$ — проекция на общие оси, общая для всех ферментов, а s_e — вектор специфического направления фермента. Тогда $B = LL^\top + \text{diag}(\kappa)$ выполняется по построению, штраф за ранг не нужен, а от (16) остаётся притяжение к $\hat{\rho}$ плюс усадка. Инициализация L и κ — из факторного разложения эмпирической матрицы, причём именно факторным анализом с итеративной оценкой общностей: наивное собственное разложение полной матрицы с единицами на диагонали искажает внедиагональные элементы до 0.23, потому что факторы начинают гнаться за диагональю.

Проверять надо две вещи. Положить $\lambda_1 = 0$ и посмотреть, куда уедет выученная матрица связей от эмпирической: если далеко, значит либо в представлении есть структура, которой нет в сырых корреляциях, либо голова переобучается. И сравнить с четырьмя независимыми головами на тех же разбиениях.

8.3. Механистический блок

30 признаков, описанных в разделе 4.3, конкатенируются с z_m либо подаются через FiLM — то есть модулируют активации ствола, а не просто дописываются в конец вектора.

Зачем блок нужен, если по метрике он почти ничего не даёт. По ранжированию он избирателен так, как предсказывает химия, и это подтверждено бутстрапом; модель на одних этих 30 числах воспроизводит большую часть ранжирующей способности на 2D6 и меньше половины на остальных. Вдобавок он заметно стабилизирует модель (раздел 13). Считается блок за секунду.

8.4. Канал артефактов пробы

Как описано в разделе 2, 1A2, 2C9 и 3A4 читаются по флуоресценции, а 2D6 — масс-спектрометрией, и собственная флуоресценция соединения или тушение сигнала дают ложное «ингибирование» только в первых трёх. Это конфаундер, общий для трёх эндпойнтов и отсутствующий у четвёртого, и он частично объясняет, почему 1A2, 2C9 и 3A4 коррелируют между собой.

Добавляем скалярный признак-помеху (протяжённость сопряжения, известные хромофорные каркасы) с обучаемым коэффициентом, входящий только в три флуоресцентных эндпойнта. Это поправка на конфаундер с известной структурой, а не ещё один признак в общую кучу: модель получает возможность объяснить часть общей вариации артефактом, а не химией.

8.5. Головы

- π -голова — линейная поверх (17), выход в $\mathbb{R}$.
- (σ^-, σ^+) -голова — гетероскедастичные, через softplus; обучаются через (7). Границы интервалов лежат в данных и обычно никем не используются, а решающему слою они нужны.
- E — константа на фермент, по итогам раздела 6, плюс опциональная штрафуемая поправка.
- Δ -голова — softplus, отдельная. Не разность двух независимых регрессий: шум двух плеч коррелирован и частично сокращается в разности, поэтому предсказывать сдвиг напрямую точнее. Измерено: 0.255 против 0.323 по МСС на 3A4 в пользу отдельной головы.

9. Функция потерь и обучение

Статус раздела. Здесь и в разделе 10 описан замысел, а не работающий код. Оба раздела написаны до того, как начались измерения, и с тех пор не менялись, тогда как всё, что измерено, живёт в разделах 13 и 14. Читать их надо как проектную

документацию: так задумано, и ни одно число документа на этой конструкции не получено.

Прежде чем смотреть на формулу, стоит сказать, что она делает. Обучение — это подбор весов модели, при котором её предсказания меньше всего расходятся с измерениями. Мера расхождения и называется функцией потерь: она берёт все имеющиеся наблюдения, считает, насколько плохо модель с ними согласуется, и складывает в одно число, которое затем минимизируют. Ценность записи ниже в том, что каждый источник данных вносит своё слагаемое: одна общая сумма позволяет учить модель на пяти разнородных таблицах сразу, а коэффициенты λ говорят, кого слушать внимательнее.

$$\mathcal{L} = \sum_{m,e} \left[\lambda_{\text{крив}} \ell_{\text{крив}} + \lambda_{\text{tdi}} \ell_{\text{tdi}} + \lambda_{\text{max}} \ell_{\text{max}} + \lambda_{\text{скр}} \ell_{\text{скр}} \right] + \lambda_{\text{полоса}} \ell_{\text{полоса}} + \lambda_{\text{st}} \ell_{\text{st}} + \Omega(W). \quad (18)$$

Первые четыре слагаемых — правдоподобия четырёх источников из раздела 5. Пятое обучает головы полос (σ^- , σ^+). Шестое — клипованная L1 из (1), посчитанная на обучающих полосах; она выравнивает функцию потерь с метрикой соревнования, потому что правдоподобие оптимизирует не совсем то, по чему считается лидерборд. Последнее — регуляризатор (16).

9.1. Батчинг по молекулам, а не по строкам

Единица батча — молекула со всеми её наблюдениями по всем источникам и ферментам. Иначе теряется смысл конструкции: латентная $\theta_{m,e}$ общая для кривой, Етах и скрининга, и градиенты от них должны сходиться на одном узле в пределах одного шага. Батч по строкам превращает конструкцию обратно в обычную многозадачную модель с общим стволом.

9.2. Двухэтапная калибровка

Если учить $\psi_e = (s_e, b_e, \sigma_e)$ совместно с сетью с самого начала, есть вырожденное решение: сеть подстраивает π под удобную калибровку вместо обратного. Порядок такой.

1. На подмножестве, где есть и кривая, и скрининг, фиксируем π равным опубликованному и подгоняем 12 скаляров ψ напрямую. Задача низкоразмерная, решается за секунды; результат — в разделе 5.2.
2. Обучаем сеть с замороженной ψ .
3. Размораживаем ψ с маленьким шагом обучения на последних эпохах.

9.3. Веса источников

Стартуем с $\lambda \propto 1/n_{\text{источника}}$, чтобы 17.5 тысяч точек скрининга не задавили 6.5 тысяч меток кривых. Потом пробуем гомоскедастичное взвешивание по неопределённости: каждому источнику свой обучаемый $\log \sigma^2$, веса выводятся из него, и модель сама решает, какому источнику доверять. Проверяем это абляцией, а не берём на веру: приём известен, но на маленьких выборках его собственный шум иногда съедает пользу.

10. Неопределённость

Статус раздела. Как и предыдущий, это замысел, а не работающий код: раздел написан до измерений и с тех пор правился один раз. Ни одно число документа на описанной здесь конструкции не получено.

На выходе нужно распределение, а не число, и не ради красоты: решающий слой (раздел 11) без него не работает вообще — ему нужно знать не только, какую активность модель считает наиболее вероятной, но и насколько она в этом уверена.

Неопределённость принято делить надвое, и деление это не педантизм, а рабочий инструмент. *Эпистемическая* часть — та, что происходит от нашего незнания: похожих молекул в обучении было мало, и модель просто не знает, что тут бывает. Она уменьшается, если добавить данных. *Алеаторная* часть — собственный шум измерения: сколько ни добавляй молекул, прибор точнее не станет. Различать их нужно потому, что реагировать на них надо по-разному, и потому что трансдуктивный слой опирается ровно на первую.

Собирается распределение из трёх частей.

Ансамбль по сидам и семействам энкодеров даёт эпистемическую часть — ту неопределённость, которая происходит от незнания правильной модели и падает с ростом данных. Дешёвые альтернативы, если бюджет не позволяет держать ансамбль: SWAG или лапласовское приближение на последнем слое.

Гетероскедастичные головы (σ^- , σ^+) дают алеаторную часть — шум прибора, который не уменьшить никаким количеством данных.

Конформная калибровка на разбиении, воспроизводящем дизайн теста. Обычная конформная калибровка даёт маргинальное покрытие: в среднем по всей выборке 90 процентов заявленных интервалов накрывают истину. Нам нужно условное: у неактивных соединений полосы широкие по построению, и если модель систематически промахивается на активных, среднее покрытие это замаскирует. Проверяем покрытие по зонам активности отдельно, при необходимости берём мондриановский вариант с зонами в качестве таксономии.

Разделять алеаторную и эпистемическую части нужно не для отчёта, а для трансдуктивного слоя: эпистемическая компонента велика там, где мало похожих обучающих примеров, а тест как раз состоит из серий аналогов вокруг известных хитов.

11. Решающий слой

Предсказательное распределение получено. Осталось превратить его в то, что просят отправить: одно число для регрессии и один бит для классификации. Это отдельный шаг, и правильный ответ зависит от метрики.

11.1. Регрессия: вывод

Модель выдаёт не одно число, а распределение возможных значений активности. Отправить же надо ровно одно число. Какое?

Ответ зависит от метрики, и здесь он нетривиален. Если бы штраф был квадратичным, надо было бы брать среднее; если бы линейным — медиану. Но ST-RAE не штрафует за ошибку, попавшую внутрь доверительной полосы измерения, и это меняет ответ.

Важная тонкость, без которой дальнейшее повисает: для новой молекулы никто не

сообщает ни активности, ни ширины полосы. И то и другое приходится предсказывать, поэтому границы полосы L и H — тоже случайные величины, а не известные числа. Риск точечной оценки $\hat{y}$ — это средний штраф по всему, что может оказаться правдой:

$$R(\hat{y}) = \mathbb{E}[(\hat{y} - H)_+] + \mathbb{E}[(L - \hat{y})_+], \quad R'(\hat{y}) = F_H(\hat{y}) - (1 - F_L(\hat{y})). \quad (19)$$

Здесь $\mathbb{E}$ — среднее по распределению, запись $(x)_+$ означает « x , если положительно, иначе ноль» (то есть штраф только за выход за границу), а F_L и F_H — вероятности того, что соответствующая граница окажется левее $\hat{y}$. Производная считается без выкладок, на пальцах: сдвигая ответ чуть вправо, мы добавляем штраф там, где верхняя граница уже осталась позади, и снимаем штраф там, где нижняя граница ещё впереди.

Оба слагаемых выпуклы, значит найденная точка — глобальный минимум, а условие оптимума получается на удивление простым:

$$F_L(\hat{y}^*) + F_H(\hat{y}^*) = 1. \quad (20)$$

В переводе на процедуру это означает следующее. Возьмём несколько сотен выборок из предсказательного распределения, для каждой посчитаем пару границ, сложим все получившиеся числа — и нижние, и верхние — в один общий массив и возьмём медиану. Всё. В вырожденном случае, когда полоса схлопывается в точку, рецепт даёт обычную медиану, чего и следовало ожидать от метрики на основе абсолютной ошибки.

Вывод верный и проверен численно. А вот следствие, которое из него раньше выводилось — что для неактивных соединений оптимум смещается вверх, — оказалось неверным. Оно опиралось на предположение, что полосы у неактивных соединений сильно асимметричны: длинный хвост вниз, короткий вверх. Измерение показало, что полосы почти симметричны везде, и у трёх ферментов из четырёх у неактивных асимметрия вообще смотрит в другую сторону.

Вариант решающего слоя	1A2	2C9	2D6	3A4	Макро
Сырое предсказание модели	0.879	0.691	0.980	0.519	0.767
Пул границ, полосы предсказаны моделью	0.889	0.710	1.002	0.540	0.785
Пул границ с истинными полосами (оракул)	0.864	0.670	0.971	0.505	0.752

Таблица 3. Один и тот же предиктор, разные решающие слои, те же фолды. Оракул недостижим — он знает истинные границы, — и задаёт потолок всей затеи.

Красивый вывод, однако, не окупается. Даже оракульная версия — та, которой кто-то заранее сообщил истинные границы полос, чего на тесте не будет никогда, — выигрывает около двух процентов. А наша реальная версия, где полосы предсказывает та же модель, не выигрывает вовсе: она *проигрывает* сырому предсказанию, и проигрывает больше, чем оракул выигрывает.

Число «два процента» стоит читать как порядок, а не как измерение. Оно получено вычитанием двух строк таблицы, посчитанных с разными настройками сэмплирования, и одна только разница настроек двигает результат на величину порядка самого эффекта. Поэтому «около двух процентов» — честная формулировка, а три знака после запятой — нет.

Кто на самом деле двигает метрику. Раньше здесь стояло объяснение: метрику целиком определяют активные соединения с узкими симметричными полосами, а у неактивных полосы широкие, поэтому вклада они не дают. Первая половина верна, вторая нет.

Доля числителя / знаменателя, %	1A2	2C9	2D6	3A4
Неактивные, $y < 4$	22 / 34	16 / 30	12 / 20	19 / 25
Средние, $4 \leq y < 5$	14 / 5	30 / 5	35 / 17	43 / 25
Активные, $y \geq 5$	64 / 62	54 / 65	53 / 63	38 / 50

Таблица 4. Числитель — это ошибка модели, знаменатель — ошибка бессмысленного предсказателя, и метрика есть их отношение. Строка показывает, какую долю каждого из них даёт зона активности. На CYP3A4 средняя зона даёт числителя больше, чем активные соединения.

Неактивные соединения несут от восьмой до пятой части всей ошибки, и полосы у них действительно широкие и заметно несимметричные. А активные доминируют только на CYP1A2; на CYP3A4 больше всего ошибки приходится на среднюю зону — ту самую, где кривая доза-эффект обрывается, не дойдя до плато. Так что прежнее объяснение было не просто неточным, а указывало не на тех.

Почему при этом слой не работает — вопрос к измерению, а не к рассуждению, и измерение уже есть: и оракульный потолок, и реальная потеря стоят в таблице выше. Объяснения, которое связывало бы одно с другим, у нас пока нет. Прежнее было неверным, и лучше это признать, чем оставить красивое.

Слой понижается в приоритете: делать после того, как заработает всё остальное, и только если головы, предсказывающие ширину полосы, дадут заметно лучшую её оценку, чем нынешний бустинг.

11.2. Регрессия: то, что работает

Пул границ оказался тупиком. Второй рычаг постобработки, найденный позже, оказался самым сильным из всего, что мы пробовали, — и одновременно самым коварным. Начать стоит с явления, которое за ним стоит, потому что понять его можно без всякого машинного обучения.

Предсказания разложены по шкале слишком широко. Возьмём молекулы, которым модель дала самые высокие оценки активности, и посмотрим на их истинные значения. В среднем они окажутся *ниже* предсказанных. Возьмём те, которым модель дала самые низкие, — их истинные значения окажутся выше. При этом модель не смещена: по выборке целиком её среднее совпадает с истинным. Преувеличены именно края.

Причина не в нашей модели, а в устройстве любого предсказания. Оценка — это сумма сигнала и ошибки. Отбирая молекулы по высокой оценке, мы отбираем и те, у которых сигнал действительно велик, и те, у которых он умеренный, а вверх их вынесла ошибка. Вторых всегда какая-то доля есть, и при проверке они возвращаются к своей настоящей, более скромной величине. Химику это знакомо как регрессия к среднему: чемпионы первичного скрининга на повторе почти всегда выглядят скромнее, и не потому, что что-то испортилось в постановке.

Отсюда лечение. Если края преувеличены, их надо поджать к середине:

$$\hat{y} \rightarrow \mu + \lambda(\hat{y} - \mu), \quad (21)$$

где μ — центр, к которому жмём, а λ — насколько сильно: при $\lambda = 1$ не жмём вовсе, при $\lambda = 0$ схлопываем все предсказания в одну точку. Коэффициент подбирается только на обучающих фолдах и применяется к отложенным. Иными словами, процедура,

выбирающая λ , никогда не видит тех молекул, на которых её потом проверяют; без этой предосторожности любое улучшение было бы подгонкой под ответ, а не результатом.

Выигрыш крупный: макро ST-RAE идёт с **0.767** до **0.733** (напомним, метрика такая, что меньше — лучше). Для сравнения, весь механистический блок — тридцать признаков, придуманных специально под химию цитохромов, — стоит примерно в шесть раз меньше. Знак держится на всех четырёх разбиениях и на всех шести наборах признаков, а доверительный интервал не подходит к нулю. Порядок молекул по активности при этом не меняется вовсе: преобразование монотонное, мы не переставляем молекулы местами, а только сжимаем шкалу.

Что это не подгонка, видно и с другой стороны. Если вместо (21) просто перекалибровать предсказания методом наименьших квадратов — провести прямую через облако «предсказание против истины», — наклон выходит меньше единицы на всех четырёх ферментах, а свободный член совпадает с тем, что даёт формула сжатия, до третьего знака. Два независимых способа находят одну и ту же поправку, и у неё есть классическое имя: регрессионное затухание.

Но качество предсказаний при этом не улучшается. Средняя абсолютная ошибка почти не двигается, а на CYP3A4 сжатие её даже ухудшает; доля объяснённой дисперсии не двигается вовсе. То есть мы не стали лучше угадывать активность — мы стали лучше попадать в то, что считает метрика.

Здесь легко себя обмануть, и мы обманули. ST-RAE не штрафует за ошибку, которая укладывается в полосу погрешности самого измерения. Естественнo предположить, что сжатие загоняет предсказания внутрь этих полос, — и такое объяснение в этом разделе стояло, пока его не проверили. Оно неверно: доля предсказаний, попадающих внутрь полосы, после сжатия не растёт, а падает.

Что происходит на самом деле, видно из разложения выигрыша по зонам активности. Неактивные соединения от сжатия всегда *проигрывают* — их предсказания уезжают вверх, дальше от истины. Выигрыш приходит из средней зоны шкалы, и он больше проигрыша. Значит сжатие — это поправка к систематическому смещению предсказаний в середине, а не эксплуатация ширины полос. Формулировка скучнее прежней, зато выдерживает проверку.

Где стоит центр, важнее, чем кажется. В самой записи (21) спрятана ловушка. Формула выглядит как два независимых рычага: куда жать и насколько сильно. На деле это одна прямая. Сжатие к центру c с коэффициентом λ — это в точности прямая $a + b\hat{y}$ с наклоном $b = \lambda$ и свободным членом $a = c(1 - \lambda)$. Закрепить центр и подбирать только λ — всё равно что искать наилучшую прямую, заранее запретив ей часть направлений.

Отсюда два следствия, оба неочевидные. Первое: сдвиг центра двигает сами предсказания не на эту величину, а на неё же, умноженную на $(1 - \lambda)$, — при типичном λ около 0.8 это впятеро меньше. Раньше здесь стояло «оптимальный сдвиг центра +0.40», и читалось это как сдвиг всех предсказаний на 0.4 логарифмической единицы; на самом деле предсказания двигались примерно на 0.1. Второе: чем ближе λ к единице, тем хуже определён центр, а при $\lambda = 1$ он не определён вовсе — жать не на что, и любой центр даёт один и тот же ответ.

Поэтому подбирать надо оба параметра сразу. Это даёт **0.715** вместо 0.733, то есть ещё примерно столько же, сколько стоил весь механистический блок, — просто за счёт того, что семейству разрешили полную свободу.

Пользоваться этим в полную силу мешает одно обстоятельство. Всё посчитанное

выше молча предполагает, что тестовый набор устроен как обучающий. Он устроен иначе. Организаторы собрали его вокруг «якорей» — соединений из верхних процентов нашего же распределения активности, — и добавили к каждому по десятку структурных соседей (раздел 3). Значит активных соединений на тесте в среднем больше, чем у нас, и середина шкалы там сдвинута вверх.

Для сжатия это существенно, потому что мы жмём к *среднему*. Если настоящее среднее теста выше нашего, мы тянем активные предсказания вниз, то есть в неправильную сторону. Первая проверка это и показала: на верхней четверти нашей собственной выборки по активности — грубой имитации обогащённого набора — сжатие к обучающему среднему ухудшает результат на всех четырёх ферментах.

Вывод, однако, оказался слишком сильным, и поправило его прямое измерение, а не рассуждение о том, как набор собран. Вместо того чтобы гадать, можно прогнать одну и ту же модель по обоим выборкам и сравнить распределения её собственных выходов. Отображение «признаки → предсказание» при этом одно и то же, поэтому разница на выходе — это разница на входе, а не разница качества. Измеренный сдвиг оказался мягким. И, что важнее любого числа, на CYP2D6 он *отрицателен* — а именно этот фермент в отборе якорей не участвовал. Метод, стало быть, отличает обогащённый набор от необогащённого, то есть меряет то, что должен.

Стресс-тест на верхней четверти двигал среднюю активность втрое сильнее, чем сдвиг, который на тесте есть на самом деле. Он опровергал не ту гипотезу.

А при мягком сдвиге оптимум почти не двигается. Если перевесить обучающую выборку так, чтобы распределение её предсказаний стало похоже на тестовое, наилучшая пара параметров остаётся практически той же, и сжатие под таким распределением не меняет знак, а по-прежнему выигрывает — заметно.

Чего это не доказывает, и это важнее всего остального в подразделе. Перевешивание правит распределение предсказаний и молча предполагает, что связь «предсказание — истина» на тесте та же, что у нас. Проверить это можно только на тесте, а перекалибровка ровно для того и существует, так что бесплатного обеда здесь нет. Есть и вторая ось, которой перевешивание не касается вовсе: тестовые молекулы структурно ближе друг к другу и к якорям, чем что-либо, что можно выкроить из нашей выборки. Насколько сдвинут тест, мы знаем лишь с точностью до вилки, и обе её границы получены косвенно — снизу из измеренного сдвига предсказаний, сверху из перцентилей якорей.

«Не требует угадывать» — это тоже угадывание, просто молчаливое. Подгонять пару при нулевом сдвиге выглядит как отказ от предположения, но это предположение: что тест распределён как обучающая выборка. Мы же сами показали, что это не так. Вопрос поэтому не в том, гадать или не гадать, а в том, какая ставка меньше проигрывает, если гадание неверно.

Ответ считается прямо: подгонять пару при одном сдвиге, а проверять при другом. Диагональ такой таблицы — оракул, который сдвиг знает; верхняя строка — то, что делается сейчас.

Подгонка при нуле проигрывает по обоим разумным критериям: её худший случай на 0.087 хуже, средний по вилке на 0.040 хуже. Знак этой разности держится на всех четырёх сидах при любом тесте от $\delta = 0.2$ и выше. Единственное, в чём она выигрывает, — нижний край вилки, где она лучше на 0.013.

Величины стоит сравнить. Ошибка в выборе δ стоит от 0.04 до 0.09; весь выбор между бустингом и нейросетью, как показано в разделе 14, стоит 0.005. *Мы спорили об архитектуре, а решает то, при каком предположении о тесте подогнана постобработка*

Макро ST-RAE по вилке δ от +0.1 до +0.6	худший	средний	при 0.1	при 0.6
Подгонка при нуле (сейчас)	0.913	0.816	0.734	0.913
Подгонка под середину вилки	0.826	0.776	0.747	0.826
Минимакс по вилке	0.800	0.786	0.800	0.796
Оракул, знающий сдвиг	0.792	0.764	0.731	0.792

Таблица 5. Подгонка при нуле хороша ровно в одной точке вилки — на её нижнем краю — и худшая из трёх везде остальное.

— и разница между этими двумя вопросами почти в двадцать раз. Подраздел 14.6 показывает, что это верно не только для архитектуры: монотонная усадка, подобранная под метрику, ставит потолок всему, что не двигает ранг предсказаний, — и смене функции потерь, и поправке на источник внешних данных. Работа со сдвигом δ лежит вне этого класса, потому что меняет не предсказания, а маргиналь, под которую усадка подгоняется.

Но сдвиг не один на все ферменты, и на CYP2D6 он отрицательный. Здесь стояло, что два измерения сдвига противоречат друг другу на 2D6: рассуждение о конструкции набора давало +0.19, а прямое измерение −0.19. Противоречия нет, потому что эти числа измеряют разное. Перцентили якорей в `src/reweight.py` защиты как 93 / 98 / 62 / 90, и 62 у 2D6 стоит не случайно: *этот фермент в отборе якорей не участвовал.* Его число — внутренний контроль, показывающий, что у неотобранного фермента обогащения нет. Оценкой сдвига оно никогда не было, а вилка от +0.1 до +0.6 выведена из трёх остальных ферментов. Перенести её на 2D6 — ошибка, и её сделали мы.

Прямое измерение при этом прочно: сдвиг предсказаний −0.190 при бутстрап-интервале от −0.234 до −0.145 по 750 тестовым соединениям. И у него есть механизм, который проверяется без единой тестовой метки. CYP2D6 узнаёт лиганда солевым мостиком от аспартата и глутамата к протонированному основному азоту (раздел 2.7), а три остальных — по липофильности, плоскостности или аниону. Тестовый набор обеднён именно этой химией примерно вдвое: фармакофор 2D6 с 0.148 до 0.083, доля оснований при pH 7.4 с 0.175 до 0.104, третичные амины и пиперидины — вдвое, и все различия при $|z| > 4.8$.

Что это значит для активности, проверяется на нашей же выборке. CYP2D6 — *единственный фермент, у которого основания активнее прочих соединений*, на +0.55; у трёх остальных наоборот, от −0.24 до −0.45. Один и тот же сдвиг состава поэтому опускает активность на 2D6 и слегка поднимает на остальных — ровно то, что и измерено, знак сходится на всех четырёх.

На 2D6 сходится и величина, и это стоило отдельной ошибки. Здесь стояло «около пятой части»; верно — *около трёх четвертей*. Доля оснований бралась по всем 4905 строкам, тогда как контраст активности измерен внутри маски фермента, а маски различаются по составу сильно: в размеченной части 2D6 оснований 0.355 против 0.114–0.122 у трёх остальных. Причина в том, что кривые доза-эффект снимали по результатам скрининга, поэтому у 2D6 размечено преимущественно то, что он и узнаёт. Тест же размечен целиком, и оснований в нём 0.104. Отсюда разность долей в четверть, а не в семь сотых, и ожидаемый сдвиг −0.138 против измеренного −0.190.

Практическое следствие. Подгонять постобработку под *общий* сдвиг — значит подгонять её для CYP2D6 в заведомо неверную сторону, потому что там сдвиг другого знака. Проверка — `verify/k7_2d6shift.py`.

Поферментная подгонка, и сколько она стоит. Здесь пришлось отозвать два числа

подряд, и второе — наше собственное, найденное внешней проверкой. Прежде сдвиг предсказаний делили на затухание $b = 0.789 / 0.898 / 0.743 / 0.999$, называя результат нижней границей. Это неверно ни при каком прочтении: b — доля *выходного* отклонения, которая реальна, то есть само регрессионное затухание, а доля *входного* сдвига, доходящая до выхода, — другой наклон той же диаграммы, равный R^2/b и составляющий $0.29 / 0.41 / 0.22 / 0.59$. Деление на b не даёт ни того ни другого, и числа $+0.018 / +0.164 / -0.256 / +0.437$ отзываются.

Второе отозванное — наше. Диапазоны строились из кластерного бутстрапа сдвига *предсказаний* и использовались как диапазоны сдвига *меток*. Это разные величины, и связывает их множитель b/R^2 , равный $3.40 / 2.43 / 4.48 / 1.69$. Все четыре диапазона были не в той шкале, а выбранные по ним сдвиги недействительны.

И оказалось, что коэффициент передачи вообще не нужен. Вместо того чтобы делить сдвиг предсказаний на неизвестный множитель, можно наклонять маргиналь метки, пока среднее предсказание не сойдётся с наблюждённым на тесте:

$$\mathbb{E}_{\text{тест}}[\hat{y}] = \int \mathbb{E}[\hat{y} | y] p_{\text{тест}}(y) dy. \quad (22)$$

Ядро $\mathbb{E}[\hat{y} | y]$ — это обратная регрессия, и она оценивается изотоникой прямо на вневыборочных предсказаниях. Инструмент не нужен, а вопрос «чему равна передача» не ставится вовсе: направление задаётся самим наклоном маргинали. Заодно снимается спор о том, скаляр она или нет, — она и не должна была им быть.

Оценки по ядру: $+0.045 / +0.362 / -0.917 / +0.740$. Последнюю, впрочем, пришлось поправить сразу же, и поправка поучительна.

На CYP2D6 у ядра есть слабое место, и оно ровно там, где ответ важнее всего. Ядро предполагается одним и тем же на тесте и у нас, а раздел выше показал, что состав теста сдвинут по оси протонирования: оснований там 0.104 против 0.355 в размеченной части 2D6. Объединённое ядро списывает всё падение среднего предсказания на падение меток — но часть его есть просто смена состава, потому что модель предсказывает основаниям высокую активность почти независимо от истинной. Проверяется это прямо: ядра, оценённые внутри страт по отдельности, на 2D6 расходятся на 0.35–0.58 по всей шкале, тогда как на трёх остальных ферментах практически совпадают.

Починка заменяет допущение измерением: оценить ядро отдельно в каждой страте и смешать их по *тестовой* доле, а не по нашей. После этого δ на 2D6 равна -0.508 вместо -0.917 , и она распадается на -0.138 чистого состава и -0.371 настоящего сдвига меток. Контроль конструкции сработал: на трёх ферментах, где доли различаются на один пункт, стратификация двигает оценку на 0.003–0.007, то есть ни на что. Разбор — `verify/k10_strat2d6.py`. Инвариантность ядра внутри страт по-прежнему предполагается; заменено широкое допущение на узкое. Линейный предел этой же связи, $\Delta\hat{y} \cdot b/R^2$, даёт $+0.046 / +0.359 / -0.850 / +0.737$ — совпадает всюду, кроме 2D6, у которого R^2 наименьший и нелинейность ядра заметна. Основа диапазонов — кластерный бутстрап этой оценки: тест состоит из якорей с аналогами, при кластеризации порогом 0.50 в нём 172 группы на 750 молекул, и вклад группировки в дисперсию составляет от 4.4 до 6.7.

Правило выбирается по худшему случаю *внутри диапазона*, а не в одной точке: иначе выбор под оценку и проверка по ней же были бы одним действием.

Поферментная подгонка выигрывает 0.091 у лучшего единого правила и 0.107 у того, что делается сейчас.

Интервалы здесь шире, чем стояло раньше, и это тоже исправление. Кластерный

Худший случай внутри своего диапазона	1A2	2C9	2D6	3A4	Макро
Диапазон истины	-0.3 ... 0.4	0.1 ... 0.7	-1.1 ... 0.1	0.5 ... 1.0	—
Подгонка при нуле (сейчас)	0.948	0.996	0.944	0.876	0.941
Единое $\delta = 0.3$	0.894	0.877	1.124	0.807	0.925
Поферментная подгонка	0.889	0.827	0.911	0.710	0.834
Какой сдвиг выбран	+0.4	+0.5	-0.1	+1.0	—

Таблица 6. Единое положительное δ на CYP2D6 хуже, чем не делать ничего: 1.035 против 0.913.

бутстрап ресэмплил только обучающую сторону, держа наблюденное тестовое среднее фиксированным: он ловил неопределённость ядра и выбрасывал неопределённость цели. А цель входит в обращение с множителем, обратным наклону ядра, и наклоны эти равны 0.29 / 0.41 / 0.22 / 0.59, то есть выброшенная часть была больше оставленной. После ресэмплинга обеих сторон интервалы шире в 2.3–4.7 раза.

Расширение неопределённости, вопреки ожиданию, поферментную подгонку не обесценило, а усилило: чем шире диапазоны, тем дороже обходится одно общее число и тем больше места хеджировать каждый фермент отдельно. Перевернулось при этом другое — *какой* фермент требует подгонки. Диапазон 2D6 теперь оседлал ноль, и правило худшего случая выбирает там почти ничего (-0.1), тогда как существенные сдвиги уходят на 1A2 и 2C9.

Но главную работу делает не оценка, а критерий, и его мы унаследовали, а не выбрали. Правило до сих пор выбиралось по худшему случаю внутри диапазона — это страховка от плохого лидерборда. Если цель другая, лучший ожидаемый балл, то выбирать надо по среднему по апостериорному распределению сдвига, а оно у нас есть: полторы тысячи розыгрышей на фермент. Два критерия расходятся не в деталях, а по знаку: при усреднении широкий разброс тянет к общему правилу, при худшем случае — прочь от него.

Разница оказалась больше, чем между любыми двумя оценками δ за весь этот раздел. Выигрыш поферментной подгонки равен 0.107 по худшему случаю и 0.045 по среднему: больше половины того, что мы записывали как результат измерения, держалось на выборе критерия.

И тем же стандартом надо мерить собственное правило. Единое $\delta = 0.3$ забраковано тем, что на 2D6 оно хуже бездействия. Поферментное правило по худшему случаю выбирает на 1A2 сдвиг +0.4 — и он хуже бездействия в 81 проценте розыгрышей. Это ровно тот же дефект, просто переехавший в другую ячейку, и заметить его мешало то, что он в нашу пользу.

Доля розыгрышей, где правило хуже бездействия	1A2	2C9	2D6	3A4
$P(\delta \geq 0)$ — определён ли вообще знак	0.59	0.99	0.05	1.00
Выбор по худшему случаю	+0.4	+0.5	-0.1	+1.0
хуже бездействия	0.81	0.28	0.07	0.13
Выбор по среднему	+0.1	+0.3	-0.5	+0.7
хуже бездействия	0.51	0.09	0.20	0.01

Таблица 7. На CYP1A2 знак сдвига не определён, и любой ненулевой выбор там — подбрасывание монеты против бездействия.

Отсюда правило, которое выдерживает обе проверки: *подгонять поферментно на 2C9, 2D6 и 3A4 и не трогать 1A2*. На 1A2 средний критерий выбирает +0.1, выигрывает этим 0.0001 и проигрывает бездействию в половине случаев — то есть добавляет разброс без ожидаемой выгоды. Ноль там не осторожность, а лучший ход.

11.3. Оценка сдвига зависит от модели, и это не мелочь

Всё выше молчаливо считает, что δ — свойство теста. Так она и определена: сдвиг маргинали *меток*, которые от нашей модели не зависят. Но оценивается она обращением ядра $\mathbb{E}[\hat{y} \mid y]$, а ядро строится по предсказаниям, и состоятельность обращения держится на предположении, что связь предсказания с истиной на тесте та же, что на обучении. Раздел 12 это предположение называет и честно помечает как непроверяемое. Оно проверяемо наполовину: две разные модели нарушают его по-разному, и расхождение их оценок — нижняя граница систематической ошибки.

	1A2	2C9	2D6	3A4
δ на поферментной модели	+0.045	+0.362	−0.917	+0.740
δ на пулированной модели	+0.344	+0.801	−0.405	+0.847
расхождение	0.30	0.44	0.51	0.11
полуширина бутстрапа	0.40	0.30	0.53	0.25

Таблица 8. Смена модели двигает оценку сдвига не меньше, чем вся выборочная неопределённость, а на CYP2C9 — больше.

Механизм виден прямо: разрыв между средним предсказанием на тесте и средним вне фолда на обучении растёт при пулировании на всех четырёх ферментах, с +0.014 / +0.147 / −0.190 / +0.437 до +0.101 / +0.300 / −0.078 / +0.477. Пулированная модель поднимает то, что говорит о тесте, сильнее того, что говорит об обучении, и обращение читает это как больший сдвиг меток.

Правило от этого меняется существенно: под пулированным апостериором средний критерий выбирает +0.3 / +0.8 / −0.4 / +0.8 вместо +0.0 / +0.3 / −0.5 / +0.7, и проверку «не хуже бездействия» проходят все четыре фермента, а не три.

Что принято. Ни одна из двух оценок. Выбрать между ними без тестовых меток нельзя, а больший сдвиг, опирающийся на возможно смещённую, — более дорогая ошибка, чем меньший. Розыгрыши обеих сложены с равным весом — это решение, а не вывод, — и правило подобрано под расширенным распределением: 0 / +0.5 / −0.4 / +0.8, с пропуском CYP1A2 по прежнему основанию. Выигрыш поферментной подгонки под ним 0.066: между 0.047 и 0.101, которые дают два одномодельных апостериора по отдельности.

Смысл этого шире одной строки в submit.py. До сих пор в неопределённость δ входила только выборочная часть; систематическая не входила никуда, и интервалы этого раздела её не содержат. Теперь она посчитана хотя бы на двух моделях одного семейства, и она того же порядка, что и всё остальное.

И на 2D6 знак сдвига держится теперь еле-еле. При стратифицированном ядре и честном интервале вероятность того, что сдвиг там неотрицателен, равна 0.039: девяностопроцентный интервал ноль исключает, девяностопятипроцентный уже нет. Утверждение «на 2D6 сдвиг отрицателен» остаётся самым прочным из четырёх, но «уверенно отличается от нуля» — уже неверная его формулировка. Но интереснее не макро, а столбец 2D6, и на честных диапазонах он говорит резче прежнего: *единое*

$\delta = 0.3$ теперь хуже полного бездействия и по макро — 0.817 против 0.808, — потому что вред на 2D6 (1.035 против 0.913) перевешивает выигрыш на трёх остальных. Единое положительное δ не просто недобирает на 2D6, оно активно вредит, и ровно потому, что настоящий сдвиг там отрицательный.

И честный итог по сужению. Диапазоны от этой работы в основном не сузились, а сдвинулись. По-настоящему сузился один — 2C9. У 1A2 диапазон расширился и ноль теперь внутри него. У 3A4 сдвинулся вниз примерно на 0.1. А у 2D6 — единственное приобретение, которое стоит запомнить: ноль из него вышел. Кластерный интервал там $[-0.281, -0.093]$, и это единственный фермент, у которого ноль не накрывается ни наивным интервалом, ни кластерным.

Оговорка, которая остаётся. Выбранные сдвиги — решение при заданных диапазонах, а диапазоны построены из измерений, у которых есть своя неопределённость. Минимумы при этом внутренние, а не упирающиеся в край сетки: проверено расширением сетки вдвое. `src/submit.py` принимает поферментные значения (`--delta 0.3, 0.4, -0.1, 0.8`), по умолчанию ноль — менять умолчание значит менять то, что отправляется, и это решение команды.

Практический итог. Сжатие в `src/submit.py` по умолчанию по-прежнему выключено; изменилось то, что при включении теперь можно назвать предполагаемый сдвиг явно (`--delta`), а не получить нулевой молча. Значение по умолчанию оставлено нулевым, чтобы поведение не поменялось само собой: выбор ставки — решение команды, а не побочный эффект правки. Цена ошибки здесь несимметрична, и тестовый набор открывается один раз.

11.4. TDI: здесь слой окупается

Метка TDI не измеряется напрямую. Она вычисляется из двух измеренных pIC_{50} — прямого плеча и плеча с преинкубацией (раздел 2.5) — по составному правилу, и правило воспроизводит опубликованные метки без единого исключения: 2334 из 2334 для 3A4 и 1493 из 1493 для 2D6. Оговорка: это те строки, где измерены оба плеча. Меток TDI по 3A4 в файле 3584, и у 1250 из них прямого плеча нет, так что правило проверено на двух третях. Проверять на остальных нечем и незачем: все 1250 размечены отрицательно.

Проверено и покомпонентно, но точнее, чем здесь стояло раньше. Убрать любое из двух слагаемых — и правило начинает пропускать положительные: 84 пропуска на 3A4 и 51 на 2D6 без второго, 680 и 273 без первого. Ложных срабатываний при этом ноль: каждое слагаемое со своим условием даёт только подмножество истинных. Сотни ложных появляются, если снять условие и взять неравенство само по себе, — 420 и 642 на 3A4, 1083 на 2D6 для второго. Единственное исключение: $\Delta > \log_{10} 2$ без условия даёт на 2D6 всего 56 ложных, десятки, а не сотни.

Значит вероятность «да» надо считать интегрированием правила по совместному предсказательному распределению, а не отдельной сигмоидой:

$$p_i = \Pr(\pi > 4, \Delta > \log_{10} 2) + \Pr(\pi \leq 4, \pi + \Delta > 4 + \log_{10} 2). \quad (23)$$

Два слагаемых — два случая правила разметки, разобранных в разделе 2.5. Считать это надо совместно: π и Δ коррелированы, перемножать вероятности по отдельности нельзя. На практике — Монте-Карло по сэмплам из ансамбля.

Дальше порог. Как отмечено в разделе 1, МСС не раскладывается по объектам, поэтому 0.5 почти всегда неоптимален. При калиброванных p_i берём порог, максимизирующий

ожидаемый MCC на всём наборе из 750. Два способа, оба дешёвые: подстановка ожидаемых счётчиков $\mathbb{E}[TP] = \sum_{i: p_i > t} p_i$ со свипом по t , либо Монте-Карло по пуассон-биномиальному распределению меток.




Рис. 8. MCC как функция порога. Слова «при калиброванных p_i » оказались не формальностью: на сырых вероятностях подстановочный порог промахивается мимо максимума. На CYP3A4 он даёт 0.325 при достижимых 0.358, на CYP2D6 — 0.115 при 0.127. На 3A4 промах стоит больше половины всего выигрыша от подбора порога. (Раньше в подписи стояло 0.356 против 0.358 в тексте — одна и та же величина, разошедшаяся из-за шага сетки порогов: рисунок перебирает 180 значений, `f9_mccthr` — 200. Точный максимум по всем различным вероятностям 0.3574.)

На сохранённых вероятностях бустинга средняя предсказанная вероятность равна 0.256 против настоящей доли положительных 0.326 на 3A4 и 0.079 против 0.217 на 2D6. Подстановочный метод берёт на 3A4 порог 0.375 и даёт MCC 0.325, тогда как оптимум при 0.258 даёт 0.358 — потеря 0.033. Вложенная калибровка Платта возвращает почти всё: потеря падает до 0.003, показатель Брайера с 0.2075 до 0.1853, чистый выигрыш +0.028 MCC.

Два уточнения к этому числу. Оно получено при зашитом сиде разбиения калибратора; по десяти сидам выигрыш идёт от +0.018 до +0.029 при среднем +0.025, так что 0.028 — верх диапазона, а не типичное значение. И сравнивать его с перестановками признаков в абляциях, как здесь стояло раньше, нельзя: те меряются в ST-RAE на регрессионном треке, а этот — в MCC на классификационном, и никакой абляции признаков для классификатора мы не гоняли.

На 2D6 не окупается. Калибровка чинит калибровку (средняя предсказанная с 0.079 до 0.217, Брайер с 0.199 до 0.169), а MCC не растёт: изотоническая сжимает достижимый максимум с 0.127 до 0.108, Платт уводит порог не туда. При MCC порядка 0.12 и 260 положительных на обучение калибратора его собственный шум съедает пользу.

В архитектуру идёт связка «вложенная калибровка, затем подстановочный порог», с абляцией на каждом эндпойнте отдельно.

Незакрытая дыра: вероятностная версия (23) с интегрированием по ансамблю не запускалась ни разу. Все измеренные варианты правила — детерминированные

подстановочные.

12. Трансдуктивный слой

Про тест известно больше, чем обычно, и этим можно пользоваться. Аккуратно.

12.1. Сдвиг распределения

Тест обогащён активными по трём ферментам и близок к фону по четвёртому (раздел 3). Это ковариатный сдвиг с индуцированным сдвигом меток: $p_{\text{тест}}(y) \neq p_{\text{обуч}}(y)$. Модель, откалиброванная на обучающей маргинали, будет систематически занижать активность тестовых соединений. Лечится перекалибровкой под ожидаемую тестовую маргиналь, оценённую из известной конструкции набора, и проверяется на разбиении, воспроизводящем дизайн теста.

12.2. Серийный случайный эффект

Тест — серии аналогов вокруг якорей, но охват этой структуры зависит от того, что считать серийей: при рабочем пороге 0.35 в группы по пять и более членов попадает 155 соединений из 750, при 0.48 — 496 (раздел 3). Естественно предположить, что соединения одной серии имеют общий сдвиг:

$$\hat{y}_i = f(x_i) + b_{s(i)}, \quad b_s \sim \mathcal{N}(\mu(\text{якорь}_s), \tau^2). \quad (24)$$

Здесь $s(i)$ — серия, к которой относится соединение i , b_s — её общий сдвиг, $\mu(\text{якорь}_s)$ — центр приора, привязанный к активности якоря, τ — насколько сильно мы разрешаем серии отклоняться от него.

Соблазн стянуть предсказание к активности якоря надо давить. Медианная разница pIC_{50} в обучающих парах со сходством Танимото 0.6–0.85 составляет от 0.33 до 0.68 логарифмической единицы. Обрывы активности реальны: похожие молекулы регулярно различаются в разы. Значит τ должно быть порядка 0.5, а не 0.1, и оценивать его надо по обучающим парам при том же уровне сходства, а не подбирать.

Оговорка, которая тут важнее самого числа: пар в этой полосе всего 601 на всю обучающую выборку, и обе метки есть лишь у 30 из них на 1A2, 15 на 2C9, 23 на 2D6 и 510 на 3A4. То есть три из четырёх медиан стоят на полутора-трёх десятках пар, и приводить их с двумя знаками — преувеличение точности. Вывод про порядок τ от этого не страдает: он одинаков при любом прочтении этих чисел. А вот оценивать τ по обучающим парам пофермент, как здесь предлагается, на 2C9 не выйдет — пятнадцати пар для этого мало, и придётся либо пулить ферменты, либо расширять полосу сходства.

Проверять эффект от (24) можно только на псевдотестовых сериях: на случайном разбиении он покажет ложный выигрыш, потому что там соседи по серии лежат в обучении.

13. Протокол оценки

Что считать выигрышем, решается до эксперимента. Иначе за два месяца можно уехать сколь угодно далеко.

13.1. Уровней строгости меньше, чем задумывалось

Задумывалось три уровня. Измерение оставило один и небольшую страту.

Случайное пятикратное — задумывалось верхней границей, годной только для отладки. Здесь стояло, что оно вдвое оптимистичнее кластерного, и это неверно. Если поменять только вектор фолдов, оставив те же признаки и те же настройки, разница оказывается в третьем знаке, а на трёх ферментах из четырёх случайное разбиение даже *строже* кластерного. Два режима, которые задумывались как разные уровни строгости, по факту меряют одно и то же.

Кластерное по Бутине при пороге 0.35 — рабочий режим, все числа этого документа получены на нём. Соединения группируются по сходству, и целый кластер целиком уходит в отложенный фолд, так что модель не может узнать соединение по его близкому родственнику в обучении. Причина, по которой это почти не отличается от случайного, видна сразу: при пороге 0.35 из 4905 соединений получается 4703 кластера, то есть подавляющее большинство — синглтоны, и группировать почти нечего.

Отсюда не следует, что кластеризация бесполезна. Следует, что её действие не в медиане, а в хвосте: она защищает ровно те несколько процентов выборки, у которых вообще есть близкие аналоги, — а на типичном соединении, у которого аналогов нет, она неотличима от случайного разбиения. Числа — ниже, вместе с тем, что из них следует для теста.

Разбиение под дизайн теста — задумывалось третьим уровнем: псевдотестовый фолд строится тем же алгоритмом, что и настоящий тест — берём хит из обучающей выборки, забираем его ближайших соседей, держим всю серию снаружи. Уровнем протокола оно быть не может: как *разбиение*, то есть нарезка всей выборки, тестовой геометрии оно не достигает ни при каком пороге. Как *страта* — достигает, но маленькая. Оба утверждения измерены, подробности в следующем подразделе.

13.2. Насколько наша проверка похожа на тест

Прежде чем отбирать модели, надо спросить: наша кросс-валидация вообще такой же трудности, как тест? Мера простая — сходство соединения с ближайшим к нему обучающим.

У отложенного кластерного фолда медиана 0.435 и доля соединений со сходством выше 0.7 равна половине процента. У настоящего теста медиана 0.587, и таких соединений каждое десятое.

Режим	Медиана	Доля > 0.7
Потолок: соединение против всей остальной выборки	0.450	0.038
Случайное пятикратное	0.437	0.033
Кластерное 0.35	0.435	0.005
Тест против всего обучения	0.587	0.101

Таблица 9. Сходство проверяемого соединения с ближайшим обучающим. Первая строка — leave-one-out: соединение сравнивается со всей остальной выборкой сразу. Более щедрого разбиения не существует, поэтому это потолок.

Первая строка — потолок для любой перенарезки обучающей выборки, и тест стоит *выше* него. Разрыв 0.137 неустраним: дело не в неудачно подобранном пороге




Рис. 9. Насколько далеко проверяемое соединение от того, что модель видела. Разрыв медиан 0.153, и он идёт в неожиданную сторону: наша проверка труднее теста.

кластеризации, а в том, что в обучающей выборке в среднем нет соединений, настолько похожих друг на друга. Тест устроен как серии аналогов вокруг якорей, и близость к обучению заложена в него конструкцией.

Из этого не следует, что псевдотестовую проверку построить нельзя — следует, что она не может быть *разбиением*. Разбиение делит всю выборку и потому упирается в среднее. Страта не делит: соединение уходит наружу только вместе с обязательством, что его аналог остаётся внутри. Так геометрия теста воспроизводится точно — медиана сходства отложенных с обучением 0.643 при тестовых 0.587, — но набирается таких соединений 328, то есть 6.7 процента выборки, и распределены они крайне неровно: 267 размеченных на 3A4 против 38, 36 и 32 на 1A2, 2C9 и 2D6.

Практический вывод жёсткий. Псевдотестовая проверка существует и осмысленна на CYP3A4. На остальных трёх ферментах при трёх десятках соединений доверительный интервал шире любого эффекта, который мы собираемся измерять, и называть это проверкой нельзя. Всё, что в разделах 10 и 12 обещано «на разбиении, воспроизводящем дизайн теста», проверяемо в этом объёме и не более.

Из той же таблицы видно менее очевидное. По медиане кластерное и случайное разбиения неразличимы, 0.435 против 0.437: при пороге 0.35 из 4905 соединений выходит 4703 кластера, почти все синглтоны, и кластеризация почти ничего не группирует. Расходятся они только в хвосте — доля соединений со сходством выше 0.7 отличается в семь раз, 0.005 против 0.033. Кластерное разбиение работает ровно на тех трёх процентах, у которых есть близкие аналоги, и весь его смысл там. Тест этим хвостом переобогачён втрое против случайного и в двадцать раз против кластерного.

Значит нужный инструмент — не новое разбиение, а расслоение уже имеющейся оценки по сходству: смотреть отдельно на ту четверть выборки, где проверяемое соединение ближе всего к обучающему, потому что она ближе всего к условиям теста. На этой четверти результат заметно лучше, чем на всей выборке, и особенно заметно на CYP2D6.

Читать это надо как вторую, диагностическую полосу, а не как способ отбора моделей. Она смотрит ровно на тот хвост, где кластерное и случайное разбиения вообще расходятся; а если поднять отсечку до настоящей тестовой медианы, соединений останется семь процентов — выше собственного потолка выборки отбирать уже

нечего.

Приятная половина прежнего вывода остаётся: 0.767 — оценка снизу, на лидерборде должно быть лучше. Неприятная тоже: мы отбираем модели по способности экстраполировать на чужую химию, а тест награждает за интерполяцию внутри серии аналогов. Это разные умения, и лучшая по нашей сетке модель не обязана быть лучшей там. Разбиением эту дыру не закрыть — её закрывает только промежуточный лидерборд.

13.3. Устойчивость к разбиению

Все числа регрессионного трека изначально стояли на одном разбиении — кластеры Бутины, раскиданные по фолдам генератором с сидом ноль. Парный бутстрап покрывал случайность выборки соединений, но не случайность самого разбиения. Прогон на других сидах меняет только то, как кластеры распределяются по пяти фолдам; кластеризация, признаки, гиперпараметры и код те же.




Рис. 10. Слева — макро-ST-RAE на четырёх сидах разбиения. Справа — стандартное отклонение по этим четырём сидам, по ферментам. Механистический блок снижает зависимость от разбиения в 3.4 раза по макро, и падение сосредоточено на 2D6.

Первое, что отсюда следует, — предостережение о точности. Абсолютный уровень гуляет от сида к сиду на величину *большую*, чем весь эффект, ради измерения которого строилась абляционная сетка. Практический вывод: число вида «макро 0.767», названное без указания разбиения, имеет точность до первого знака после запятой, а не до третьего, и сравнивать два таких числа из разных прогонов бессмысленно.

Второе: направление при этом держится. Разность в пользу механистического блока отрицательна на всех четырёх сидах, ранговая корреляция растёт тоже на всех четырёх. Бутстрап на одном разбиении накрывал ноль и потому не позволял ничего утверждать; четыре разбиения показывают, что знак устойчив, — хотя величина эффекта гуляет примерно в десять раз, и это тоже надо сказать вслух.

Третье, и самое интересное, — в разбросах, а не в средних. С механистическим блоком результат становится втрое менее чувствителен к тому, как именно нарезана выборка, и падение разброса сосредоточено ровно на CYP2D6, тогда как на CYP3A4 не меняется почти ничего. То есть блок делает не столько лучше, сколько *устойчивее*, и именно там, где по химическим соображениям и должен. Устойчивость — не то, ради чего его строили, но для отбора моделей она стоит не меньше среднего уровня: модель, чей результат зависит от нарезки сильнее, чем от собственного устройства,

ничего не говорит о том, что будет на тесте.

Похоже, тридцать механистических чисел дают модели опору, не зависящую от того, какие аналоги попали в обучающие фолды. Фингерпринт такой опоры не даёт: он узнаёт соединение по соседям, и когда соседи уезжают в отложенный фолд, узнавание рассыпается. Главная польза блока, видимо, в этом, а не в приросте среднего.

Протокол из-за этого меняется. Любое сравнение вариантов идёт на фиксированном наборе из нескольких разбиений и отчитывается разностью на каждом плюс разбросом. Одно разбиение годится для отладки и не годится для решения, что отправлять.

13.4. Устойчивость к версии библиотеки

Две оси случайности уже учтены: бутстрап покрывает выбор соединений, четыре сида — выбор разбиения. Есть третья, и она не случайная: версия библиотеки, которой посчитаны числа.

Версии `scikit-learn` с 1.3.2 по 1.8.0 воспроизводят сохранённые предсказания *побитово* — максимум модуля разности ноль. Версия 1.9.0 не воспроизводит: каждое предсказание сдвигается в среднем на 0.135 pIC_{50} , максимум 0.59. На макро это выглядит безобидно — набор без блока 0.7729 против 0.7759, с блоком 0.7673 против 0.7646, — но измеряемый эффект блока при этом меняется с -0.0056 на -0.0113 , то есть удваивается.

Вывод не меняется: и 0.0113 тонет в размахе 0.0158 по сидам. Но величина, ради измерения которой строилась абляционная сетка, зависит от версии библиотеки вдвое — значит потолок версии в окружении не осторожность, а часть протокола, и снимать его можно только вместе с пересчётом всей таблицы.

`numpy` к этому отношения не имеет: 1.26.4 и 2.5.2 воспроизводят одинаково точно. Первое подозрение на `numpy` 2 не подтвердилось.

13.5. Парный бутстрап

Любое сравнение двух вариантов — только на одном и том же разбиении и с парным бутстрапом по соединениям: 2000–3000 пересборок, для каждой обе метрики пересчитываются на одной и той же пересобранной выборке, докладывается распределение разности и доля пересборок, где стало хуже. Разность без интервала не является результатом.

Для макро надо ресэмплить соединения общей таблицы, а потом для каждого фермента брать те из них, у кого есть метка — так сохраняется корреляция между ферментами. Считать четыре независимых бутстрапа и усреднять нельзя.

13.6. Сетка абляций

Каждая строка снимается с парным бутстрапом относительно предыдущей, на нескольких сидах.

1. Фингерпринт и дескрипторы, бустинг. Базовая линия.
2. Предобученный энкодер вместо ручных признаков, одна голова на эндпойнт.
3. Плюс коррегионализация (15).
4. Плюс механистический блок и канал артефактов пробы.
5. Плюс скрининг через (8): главная проверка всей идеи.
6. Плюс Emax и плечо с преинкубацией в общее правдоподобие.

7. Плюс ансамбль и конформная калибровка.
8. Плюс решающий слой: отдельно для регрессии, отдельно для МСС.
9. Плюс трансдуктивный слой.

Строка 5 — точка, на которой конструкция оправдывается или не оправдывается. Обязательный контроль к ней: сильная многозадачная базовая линия на тех же признаках и том же энкодере, обученная на одних метках кривых. Если совместное правдоподобие её не обыгрывает, это отрицательный результат, и он идёт в отчёт как есть.

14. Что уже измерено

Это тоже результат, и он объясняет, почему решение выглядит так, а не проще. Раздел начинался как перечень того, что не работает; последний подраздел добавлен позже и описывает единственную попытку, которая частично удалась, поэтому заголовок пришлось поправить.

Если скрининг настолько информативен, зачем городить совместное правдоподобие? Нельзя ли подключить его в лоб? Проверены три способа.

Подход	ST-RAE	Δ к своей базе	ρ	$\Delta\rho$
Скрининг как признак, в лоб	0.921	+0.138	0.566	+0.009
То же с честной вложенной схемой	0.788	0.000	0.559	+0.006
Два этапа: скрининг, затем пересчёт	1.006	+0.212	0.561	+0.010
Смесь двух маршрутов пополам	0.803	+0.009	0.587	+0.036

Таблица 10. Разности считаются от базовой линии *того же прогона*: 0.783, 0.788, 0.794, 0.794. Расходятся они не случайно — это три разных скрипта с тремя разными конфигурациями, см. ниже, — поэтому сравнивать строки между собой по абсолютной величине нельзя, только по разностям.

Почему базовые линии не совпадают. Три скрипта, давшие эту таблицу, строят разбиение по фингерпринту в 1024 бита, тогда как абляционная сетка и все остальные числа документа — по 2048. При 1024 битах кластеризация даёт 4694 кластера против 4703, и вектор фолдов другой: дайджест d7b7ca15 против 2d93c198. Поэтому ни одно число этой таблицы не сопоставимо с 0.767 из раздела 13: различаются не только модели, но и выборки, на которых они отложены.

Между собой фолды у трёх скриптов совпадают, и расхождение базовых линий объясняется целиком конфигурацией: шесть физико-химических признаков против восьми даёт 0.783 против 0.788, а 250 итераций бустинга против 200 — 0.788 против 0.794. Оба различия детерминированы и воспроизводятся при повторном запуске точно. Разброс в 0.011 — это не шум прогона, а три разные модели на общих фолдах.

Скрининг как признак, в лоб. Обучаем вспомогательную модель предсказывать $\log_2 fc$, её выход подаём как признак в основную. Ошибка — вспомогательный признак посчитан моделью, для которой обучающие строки основной модели были внутренними. На них он точнее, чем окажется на отложенных, основная модель учится на него опираться, и опора рассыпается там, где её проверяют: 0.783 против 0.921. На честной вложенной схеме выигрыш ровно нулевой. Разница между 0.783 и 0.921 целиком артефакт процедуры.

Двухэтапная инверсия. Предсказать $\log_2 fc$, потом перевести в pIC_{50} монотонной

калибровкой. Обязана выдать число там, где правдоподобие плоское: в зонах насыщения из раздела 5.3 калибровка не определена, и любое значение оттуда одинаково согласуется с показанием. Результат: абсолютная шкала разваливается, а ранговая информация в среднем сохраняется — но только в среднем, см. ниже.

Смесь. Полусумма двух маршрутов. Стоит +0.009 ST-RAE и покупает +0.036 Спирмена, причём ранг растёт на всех четырёх ферментах. Это уже почти приемлемый обмен, но он не решает задачу, а балансирует между двумя плохими решениями.

Общий вывод: информация в скрининге есть, но «ранг улучшается всегда» — верно только для макро. Поферментно двухэтапная инверсия ранг роняет, причём на том ферменте, вокруг которого построен весь документ: на 2D6 Спирмен идёт с 0.398 до 0.362, на 3A4 с 0.749 до 0.747, и держится макро только за счёт 1A2 (+0.048) и 2C9 (+0.028). Смесь двух маршрутов — единственный из трёх вариантов, который поднимает ранг на всех четырёх. Информация в скрининге, таким образом, есть, и вся проблема в том, как перевести её в абсолютную шкалу pIC_{50} , не потеряв ранг там, где он нужнее всего. Этим, по замыслу, занимается совместное правдоподобие через общую латентную кривую.

14.1. Совместное правдоподобие: первый запуск

Написанное выше — это то, что можно было сказать до того, как строка 5 аблационной сетки была запущена. Теперь она запущена, и предыдущий вывод требует существенного уточнения. Подраздел длинный, поэтому сначала о том, что в нём вообще происходит.

Задача. У нас есть два сорта измерений. Полная кривая доза-эффект дорога, её сняли не для всех соединений, и именно она даёт pIC_{50} — то, что просят предсказать. Скрининг в одной концентрации дешёв, его сняли гораздо шире, и он даёт одно число $\log_2 fc$, косвенно связанное с активностью. Вопрос: можно ли дешёвыми измерениями помочь предсказанию дорогой величины?

Почему не подать скрининг просто как признак. В тестовом наборе его нет вовсе — только имя и SMILES. Модель, которой на входе нужно показание скрининга, неотправляема в принципе. Значит скрининг может влиять только на *обучение*, а к моменту предсказания исчезать.

Конструкция. Общий ствол — слой, который строит внутреннее представление молекулы, — и две головы поверх него: одна предсказывает pIC_{50} , другая $\log_2 fc$. Обучаются они вместе, поэтому градиент от скрининговой головы формирует общее представление, а на выводе эта голова просто не вызывается. Ручка λ_{scr} задаёт, насколько сильно слагаемое скрининга участвует в обучении: при нуле оно не участвует вовсе.

Контрольная рука — та же самая сеть при $\lambda_{scr} = 0$. Обе головы есть и там, и там, число параметров одинаково, а начальные веса засеяны по паре (сид разбиения, номер фолда) и не по λ . То есть две руки стартуют из буквально одинаковых весов, и единственное, чем они отличаются, — присутствие скрининга в функции потерь. Это и делает сравнение сравнением канала, а не двух разных сетей.

Как эти варианты называются дальше. Вариант модели в эксперименте здесь и ниже называется *рукой* — не путать с *плечом* пробы (прямым или после преинкубации, раздел 3): два соседних анатомических слова обозначают совершенно разные вещи. Рук в этом подразделе две. *Двухголовая* — та, где у скрининга своя двухголовая рука. *Одноголовая* — та, где отдельной головы нет и предсказание скрининга вычисляется

из активности через заранее подогнанную кривую прибора (в коде она называется *calibrated*, и это название неудачно: оно читается как «после перекалибровки», а означает ровно обратное — калибровка в неё зашита заранее и никакой перекалибровки там нет).

Что канал даёт, тоже стоит назвать точно. Он даёт не лишние *строки* — все 4905 молекул и так имеют хотя бы одну метку pIC_{50} , — а лишние *колонки*: для конкретного фермента появляется сигнал с тех соединений, где его кривую не мерили, а скрин снимали. По ферментам объём *supervision* вырастает в два-три раза.

По макро знак не держится. «Сид» здесь — это способ нарезать выборку на пять частей для перекрёстной проверки; сидов четыре, то есть четыре независимые нарезки. Так вот, при $\lambda_{scr} = 3$ канал на одном сиде заметно ухудшает результат, на двух улучшает, на одном не меняет. Ответ на вопрос «помогает ли канал» зависит от того, какую нарезку взять, и одно разбиение дало бы уверенный ответ — любой из двух. Это ровно тот случай, ради которого в этом репозитории и заведено правило четырёх сидов.

(В предыдущей версии этого абзаца стояли три числа, взятые из двух разных строк дозовой кривой — часть при $\lambda = 3$, часть при $\lambda = 1$. Каждая строка сама по себе была верна, фраза, составленная из обеих, — нет.)

Поферментно, однако, эффект упорядочен. Усреднив по четырём сидам, получаем: на CYP3A4 и CYP2C9 канал помогает, на CYP1A2 вредит, на CYP2D6 вредит сильнее всего. Этот порядок в точности повторяет то, насколько скрининг вообще связан с pIC_{50} у данного фермента: сильнее всего у 3A4, слабее всего у 2D6. Читается это так — канал помогает ровно настолько, насколько дешёвое измерение вообще что-то говорит о дорогом, и вредит там, где не говорит почти ничего. Худшим оказывается CYP2D6, тот самый фермент, вокруг трудности которого построен весь документ.

Насколько этому верить — и ответ оказался «гораздо меньше, чем хотелось». Ферментов четыре, и совпадение порядка из четырёх элементов случайно происходит в одном случае из двенадцати. Это один бит свидетельства, а не закон. Хуже того, у двухголовой руки этот идеальный порядок держится на *одном прогоне*: по сидам эффект на 2D6 равен +0.609, −0.040, −0.121, +0.034, то есть первый сид даёт почти всё, а без него порядок разваливается (+0.400 вместо −1.000). И пара 2C9/3A4 не различима вовсе — разность между ними 0.002 при ошибке среднего вчетверо большей. Из четырёхточечного порядка в этой руке измерено ровно одно сравнение: 1A2 против пары {2C9, 3A4}.

У одноголовой руки порядок, наоборот, устойчив: он держится и по медиане, и без первого сида. Дальше в подразделе речь идёт в основном о ней.

Развилка «ранг вверх, шкала вниз» оказалась не настоящей, но прежде чем показывать почему, нужно различить две вещи, которые дальше встречаются постоянно. Модель может правильно расставить молекулы *по порядку* активности и при этом систематически ошибаться в самих *числах* — например, сжимать или растягивать шкалу. Первое называют ранговой информацией, второе — шкалой. Метрика конкурса смотрит на числа, поэтому испорченная шкала бьёт по результату, даже если порядок безупречен.

Измерение показало, что канал портит именно шкалу, и портит *монотонно*: порядок молекул при включении канала почти не меняется. А монотонная порча снимается монотонным же преобразованием. Изотоническая калибровка — это как раз оно: по обучающим фолдам строится неубывающая ступенчатая кривая, переводящая предсказание в лучшую оценку истины, и применяется к отложенному фолду. Она не

может переставить молекулы местами, она только перерисовывает шкалу.

Макро ST-RAE, среднее по четырём сидам	$\lambda = 0$	$\lambda = 3$	$\lambda = 3 + \text{изо}$	$\lambda = 0 + \text{изо}$
	0.781	0.810	0.747	0.773

Таблица 11. Четвёртый столбец — контроль, без которого третий ничего не значил бы: перекалибровка помогает обеим рукам, но рука с каналом после неё лучше руки без него, и знак держится на всех четырёх сидах.

Читать таблицу так. Сам по себе канал ($\lambda = 3$) хуже базовой линии. Сама по себе перекалибровка ($\lambda = 0 + \text{изо}$) помогает, но умеренно. А вместе они дают лучший результат из четырёх. Значит совместное правдоподобие переносит *ранг*, а шкалу переносит перекалибровка *после* него; порознь не работает ни то, ни другое.

Возражение, которое пришлось проверить. Две свободные головы над общим стволом ничем друг с другом не связаны: голова скрининга вольна представлять $\log_2 \text{fc}$ как угодно, и ничто не заставляет её выражать его через активность. Строго говоря, выше измерена многозадачность, а не совместное правдоподобие в том виде, в каком его задаёт раздел 5, — там скрининг связан с активностью *фиксированной* кривой прибора $g(\pi)$, подогнанной заранее (раздел 5.2).

Одноголовый вариант это исправляет буквально: один латент, предсказание канала считается как g от предсказанной активности, ноль новых параметров, та же ручка. Результат обратен ожиданию — он хуже двухголовой руки, и на этот раз знак держится на всех четырёх сидах: до перекалибровки макро 1.000 против 0.810.

Первое объяснение напрашивалось само и не подтвердилось. Кривая прибора g насыщается: у очень активных соединений сигнал упирается в потолок, у совсем неактивных — в пол, и в обеих зонах её производная почти нулевая. Там, где производная нулевая, показание скрининга не может сказать про активность ничего: любое значение активности одинаково с ним согласуется. Естественно предположить, что одноголовая рука страдает тем сильнее, чем больше у фермента таких «слепых» соединений. У CYP3A4 их больше всех — около сорока процентов выборки.

Объяснение через насыщение при этом не проходит. Оно предсказывает, что хуже всех будет там, где слепая доля больше, то есть на 3A4. Разложение потери по ферментам говорит обратное:

Потеря при $\lambda = 3$ против $\lambda = 0$, среднее по четырём сидам	1A2	2C9	2D6	3A4
Доля «слепых» соединений (что предсказывает насыщение)	0.22	0.07	0.14	0.40
Двухголовая рука	+0.05	−0.03	+0.12	−0.03
Одноголовая рука	+0.24	+0.01	+0.63	+0.01
Она же при разрушенном канале	+0.38	+0.25	+0.39	+0.21

Таблица 12. Самый слепой фермент оказался наименее пострадавшим. А последняя строка ломает и всё информационное объяснение разом: канал там практически мёртв, а потеря выросла.

CYP3A4 несёт сорок процентов слепых соединений и теряет меньше всех; CYP2D6 несёт четырнадцать и теряет на порядок больше всех. Предсказанного насыщением порядка не наблюдается. То же и со вторым объяснением — поглощением промаха фиксированной кривой: величина, которая его меряет, упорядочивает ферменты не в ту сторону.

Сказать «обе гипотезы исключены» при четырёх точках было бы слишком сильно, и раньше здесь именно так и было сказано. Правильнее: предсказанного ими порядка не видно. Исключает их другое измерение.

14.2. Шумовая лестница: что она показала и что переписала

Порядок из четырёх ферментов конфаундирован со всем сразу, и никакое количество сидов этого не чинит. Чинит вмешательство: если испортить скрининговый канал управляемой дозой шума, то внутри одного фермента не меняется ничего — ни соединения, ни метки, ни полосы, ни разбиение, ни начальные веса, — кроме того, сколько канал знает. Четыре точки превращаются в четыре кривые.

Шум добавляется к стандартизованной цели канала, и сумма делится на $\sqrt{1 + \eta^2}$, так что разброс цели остаётся прежним, а падает ровно её связь с активностью — в известное число раз. Контроль: при $\lambda = 0$ канал в потери не входит, и предсказания при $\eta = 2$ обязаны совпасть с предсказаниями при $\eta = 0$ побитово. Совпали, на всех четырёх сидах.

Внутриферментный отклик есть, и он воспроизводится. У двухголовой руки знак сдвига держится на всех четырёх сидах для трёх ферментов из четырёх, при ошибке среднего в несколько тысячных; у одноголовой — для всех четырёх. Это единственная часть подраздела, где вывод не опирается на сравнение ферментов между собой, и ради неё лестница и строилась.

Дальше начинается неожиданное. Порча одноголовой руки оказалась не информационной, и прежнее объяснение — «своей болезни у жёсткой калибровки нет, она впятеро умножает уже имеющуюся» — измерением снято. Если разрушить 95–97 процентов информации канала, потеря не исчезает, а *растёт*: на 1A2, 2C9 и 3A4 она увеличивается на +0.15, +0.25 и +0.20. Уцелевшие проценты информации не могут делать больше работы, чем делали все сто. Значит то, что портит жёсткую руку, живёт не в содержании канала.

У двухголовой руки поферментной структуры не обнаружено вовсе, и это отрицательный результат, который стоит записать наравне с положительными. Средние отклонения от единой кривой не превышают 0.009 при собственном разбросе 0.033, и остаток неотличим от того, что даёт случайная перестановка меток. У одноголовой та же структура огромна. То есть всё поферментное локализовано в жёсткой связи, а не в канале.

Складывается из этого одномеханизменное чтение, и данные его держат. Канал тянет предсказанную активность к псевдо-метке, полученной из скрининга. *Качество* этой метки задаёт шум — отсюда монотонный отклик внутри фермента. А *масштаб* тяги в единицах pIC_{50} задаёт прибор: у жёсткой связи он фиксирован калибровкой и от шума не зависит, у свободной головы его нет вовсе, потому что голова вольна поглотить расхождение в себя. Отсюда и поферментная структура там, где связь жёсткая, и её отсутствие там, где голова свободна.

Двухмеханизменное объяснение — «канал несёт информацию, которую шум разрушает, плюс многозадачное давление, которого шум не трогает» — напрашивалось и не подтвердилось ни одной своей половиной. Давления нет в той руке, где нет жёсткой связи, а в той, где оно есть, шум его не сохраняет, а усиливает.

Всё сказанное ограничено одним обстоятельством, и снять его добавлением сидов нельзя. Чем именно упорядочены ферменты, этот эксперимент не различает. По четырём ферментам совпадают, с попарным Спирменом ровно ± 1 , три разные

величины: связь скрининга с активностью; средняя ширина доверительной полосы, из которой метрика и считает ошибку; и усиление калибровочной кривой — сколько единиц pIC_{50} ложной тяги производит одно стандартное отклонение остатка скрининга. Ни один тест этого подраздела их не разделяет, и шумом разделить нельзя в принципе: шум двигает информативность, а полосу и карту прибора не двигает.

Одну из трёх удалось вычеркнуть, и дёшево. Если пересчитать метрику по тем же сохранённым предсказаниям, выровняв полосу на всех ферментах или убрав её вовсе, поферментная структура почти не меняется: 2D6 остаётся худшим с огромным отрывом, 1A2 вторым, а 2C9 и 3A4 — около нуля. Значит эффект живёт в самих предсказаниях, а не в том, как метрика их читает, и ширина полосы объяснением быть не может. Остаются две неразличимые: информативность скрининга и усиление прибора. Первая привлекательнее, но не доказана.

Разделить их может ровно одно вмешательство, и оно дешёвое: поменять местами калибровочные константы (E, h) между CYP2D6 и CYP3A4 и прогнать одноголовую руку заново. Данные, метки, полосы, разбиение, инициализация и связь скрининга с активностью при этом остаются буквально теми же, двигается только карта прибора. Оно запущено, и ответ отрицательный: карта порядок не задаёт.

Прогон снабжён двумя контролями, и оба сработали. При $\lambda = 0$ карта не вызывается вовсе, и предсказания совпали с необменянными побитово на всех четырёх сидах, то есть обмен не достаёт туда, куда не должен. А два необменянных фермента, 1A2 и 2C9, сохранили свои карты и показывают, сколько шума даёт сам перезапуск: 0.019 и 0.009. Сдвиг у обменянных надо читать против этой величины, а не против нуля.

Сдвиг порчи после обмена карт, по сидам	1A2	2C9	2D6	3A4
Чья теперь карта	своя	своя	3A4	2D6
Сид 0	-0.02	+0.00	+0.61	+0.00
Сиды 1–3, среднее	+0.02	-0.01	+0.00	+0.02

Таблица 13. Обменянные ферменты сдвинулись меньше, чем нетронутые контрольные.

Предсказание было такое: 2D6, получив более крутую карту 3A4, должен пострадать заметно меньше своих +0.63, а 3A4 с пологой картой 2D6 — уехать с почти нуля в десятые. Не произошло ни того ни другого. Без первого сида 2D6 сдвинулся на +0.003, а 3A4 на +0.016, то есть *меньше*, чем сдвинулся контрольный 1A2, которому вообще ничего не меняли. Порча осталась при своём ферменте: 2D6 по-прежнему худший с огромным отрывом, 3A4 по-прежнему около нуля.

Значит из двух неразличимых величин карта прибора выбывает, и выбывает по вмешательству, а не по корреляции. Остаётся информативность скрининга — или что-то ещё в данных самого фермента, чего мы не назвали. Второе честнее: эксперимент показал, где механизма *нет*, и не показал, где он есть.

14.3. Виноват был не сид, а одно соединение

Первый сид к этому моменту трижды создал вывод, которого на трёх остальных нет: сдвиг порчи 2D6 в таблице выше, идеальный порядок из четырёх точек и расхождение в NaN. Правило четырёх сидов каждый раз это ловило, но диагноз ставило неверный — «разбиение неудачное». Разбиение тут ни при чём.

Само оно ничем не выделяется: размеры фолдов, средняя активность, разброс, доля активных и знаменатель метрики у первого сида такие же, как у остальных трёх,

вплоть до второго знака. А вот предсказания выделяются, и резко. У двухголовой руки при $\lambda = 3$ на CYP2D6 находится *одно* соединение, OCNT-2328942 с истинной активностью 2.53, которому модель предсказывает -360 на первом сиде и -22 на третьем; на двух других сидах оно ведёт себя нормально. Показание скрининга у него при этом заурядное (отклонение полтора десятых стандартных), так что это не выброс в данных, а срыв оптимизации, который приходится на него.

ST-RAE — сумма модулей отклонений, поэтому одно предсказание в -360 добавляет к числителю около 362 при знаменателе порядка 120. Одна молекула из 1493 утраивает метрику фермента.

Обрежем предсказания диапазоном меток фермента плюс-минус две единицы. Порог отсекает невозможное и не трогает низкое: на трёх ферментах из четырёх он не задевает ни одного соединения, на 2D6 — в среднем полсоединения. Результат:

Порча 2D6 при $\lambda = 3$, по сидам	сид 0	сид 1	сид 2	сид 3	знак
Двухголовая, как есть	+0.609	-0.040	-0.121	+0.034	2 из 4
Двухголовая, обрезано	+0.035	+0.027	+0.027	+0.034	4 из 4
Одноголовая, как есть	+0.941	+0.536	+0.425	+0.613	4 из 4
Одноголовая, обрезано	+0.575	+0.574	+0.587	+0.596	4 из 4

Таблица 14. Обрезка невозможных значений превращает самое неустойчивое число раздела в одно из самых устойчивых.

Отсюда следуют две вещи, и они противоположны по знаку.

Утверждение про двухголовую руку не выживает. Её порча на 2D6 равна не $+0.120$, а $+0.031$, и после этого 2D6 перестаёт быть худшим ферментом — худшим становится 1A2 с $+0.047$. Идеальный порядок, на котором стоит весь предыдущий подраздел, был создан одним соединением, попавшим на два сида из четырёх; без него ранговое согласие с информативностью скрининга равно -0.800 , а не -1.000 . Фразу «сильнее всего канал вредит на 2D6, том самом ферменте, вокруг которого построен документ» надо снять: на двухголовой руке она держалась на одной молекуле.

Утверждение про одноголовую руку выживает, и становится крепче. Её порча на 2D6 равна $+0.583$ против $+0.235$ у 1A2 — разрыв в два с половиной раза остаётся, порядок ферментов не меняется, ранговое согласие как было -1.000 , так и осталось. Больше того, обрезка её *стабилизирует*: разброс по сидам падает с 0.516 до 0.022, то есть в двадцать три раза. Всё, что раздел говорит про жёсткую связь, посчитано теперь на числах, которые не зависят от того, какой сид взять.

И то, чего это не касается. Отправляемая модель — бустинг, а не сеть, и он за пределы диапазона меток не экстраполирует: все 750 предсказаний в `results/submission/` лежат внутри. Обрезка там не нужна. Но `src/submit.py` её и не делает, так что если отправлять когда-нибудь станет сеть, защиты от -360 в конвейере нет.

Помельче, но записать стоит. Две ячейки одноголовой руки получены после численного спасения: без ограничения на показатель экспоненты в калибровочной кривой она разошлась в NaN на первом сиде. Ограничение нейтрально — все конечные ячейки воспроизвелись до последнего знака, — но сам факт стоит записать: жёсткая рука не просто хуже, она способна не обучиться там, где свободная работает нормально, на том же сиде и с теми же начальными весами.”””

Стоит спросить и о чистоте самого измерительного прибора. Изотоника монотонна, поэтому внутри одного фолда порядок она сохраняет точно — проверено, ни одной перестановки на двадцати применениях. Но у неё есть свойство, которое легко

проглядеть: она склеивает соседние предсказания в одно значение. Сотни соединений фолда отображаются в несколько десятков различных чисел, и в склеенном значении оказывается больше девяноста пяти процентов соединений. А поскольку каждый фолд получает свою карту, на склеенном из пяти фолдов векторе порядок уже не сохраняется строго: несколько процентов пар меняются местами, и худшее соединение уезжает на сотню с лишним позиций списка. Хуже того, ранговая корреляция с самими метками — то, что прибор обязан не трогать, — слегка падает на всех четырёх ферментах.

Сравнение двух рук это всё же не отменяет, и по конкретной причине: искажение почти синфазно. Оно примерно одинаково бьёт по обеим рукам, поэтому *разность* между ними смещается на порядок меньше, чем каждая из них по отдельности. Пользоваться прибором можно; говорить, что он сохраняет ранг, нельзя.

Остаётся вопрос, шум ли разрыв между руками после перекалибровки. После изотоники руки почти сходятся — 0.747 у двухголовой руки против 0.752 у жёсткой. Разница 0.006 сначала была названа «вдвое меньшей, чем разброс по сидам», и это была ошибка выбора линейки: разброс по сидам брался *до* перекалибровки. Но обе руки к этому моменту уже перекалиброваны, а перекалибровка разброс схлопывает почти в десять раз. Против правильной линейки разрыв — это два стандартных отклонения, и знак его держится на всех четырёх сидах.

Формулировка поэтому такая: форма связи между каналами стоит 0.006 ранговой информации — мало, но измеримо. Не «в пределах шума». Разница принципиальна: второе закрывает вопрос, первое — это то же самое утверждение, что и до перекалибровки, только ослабленное в десятки раз.

Отсюда следует, во что обходится интерпретируемость. Прежний вывод, что спорить о форме связи между каналами было бы спором не о том, верен про количество информации и неверен как итог: потому что читается как оправдание раздела 5. Наоборот: рука, которая буквально реализует его порождающую конструкцию, — это та самая рука, которой нужна самая сильная починка. Честная рамка другая. Фиксированная связь есть моделирующее допущение, которое *стоит* производительности и *покупает* интерпретируемость, и у этого есть ценник: до перекалибровки 1.000 против 0.810, после — 0.752 против 0.747.

Происхождение этих чисел. Первая версия обеих рук в репозитории не сохранилась: скрипт писал оба режима в один файл под ключом, в котором режима не было, и второй прогон затирает первый. Ключ исправлен, обе руки пересчитаны заново на четырёх сидах, и всё, на что опирается подраздел, воспроизвелось. Тожество при $\lambda = 0$ проверено буквально: максимум модуля разности предсказаний двух рук равен нулю на всех четырёх сидах, как и должно быть по построению.

14.4. Сеть против бустинга: разница меньше, чем починка

Остаётся сравнение нейросетевой модели с бустингом — единственное место раздела, которое влияет на то, что мы отправляем. Раньше оно было посчитано на одном сиде разбиения, и притом на том самом, куда попадает срывающееся соединение из предыдущего подраздела. То есть число, на которое опирается решение об отправке, было получено на единственном заведомо испорченном прогоне. Пересчитано на четырёх сидах, с обрезкой предсказаний сети и с одинаковой постобработкой на обеих сторонах.

Прежний вывод был «бустинг впереди, но разрыв сужается вдвое». Он не выживает

Макро ST-RAE, среднее по четырём сидам	$\delta = 0$	$\delta = 0.2$	$\delta = 0.4$	$\delta = 0.6$
Бустинг, без постобработки	0.767	0.828	0.897	0.972
Бустинг, аффинная пара	0.716	0.761	0.828	0.913
Сеть, аффинная пара	0.715	0.763	0.832	0.918

Таблица 15. Разница между моделями — в четвёртом знаке. Разница между «постобработкой» и «без» — в втором.

целиком. Разрыв оказался не 0.089, а от 0.000 до 0.005 — на два порядка меньше, — и он не сужается, а растёт: при $\delta = 0$ модели неразличимы, а к $\delta = 0.6$ бустинг уходит вперёд на 0.005. Направление противоположно ожидавшемуся.

Измеренным при этом можно назвать не всё. При δ ниже 0.3 знак разности не держится на четырёх сидах, то есть там модели попросту неразличимы. Знак держится от 0.3 до 0.6, и там бустинг впереди, но на величину, которую стоит сравнить с чем-нибудь: сама постобработка стоит 0.051, то есть *вдесятеро больше всей разницы между моделями*. Отношение уточнено в подразделе 14.6, и уточнение оказалось сильнее: постобработка не добавляется к прочим улучшениям, она их замещает.

Отсюда практический вывод, и он не про архитектуру. Выбор между бустингом и сетью в этом диапазоне почти ничего не решает; решает то, как обработаны предсказания после модели, и при каком δ эта обработка подогнана. Строить дальше стоит второе, а не первое.

Сюда же результаты из предыдущих разделов. Отрицательный: решающий слой на пуле границ имеет потолок 0.015 макро и в реалистичной версии теряет 0.018. Положительный, найденный позже и описанный в разделе 11: усадка предсказаний к подогнанной аффинной паре даёт -0.052 макро (0.7673 до 0.7150).

Здесь же стояло, что выигрыш механистического блока по ST-RAE неотличим от нуля и поштучно, и на макро. Это снято подразделом 14.6, и снято в нашу пользу: утверждение было получено сырым измерением, а у блока сигнал ранговый, который сырая мера как раз занижает. После аффинной пары блок стоит -0.009 макро ($p = 0.006$) и -0.022 на CYP2D6 ($p = 0.0004$), а прирост ранговой связи там $+0.045$ — больше, чем даёт любое другое вмешательство в этом документе. Выигрыш живёт в геометрии метрики, а не в качестве предсказания, и это ограничение остаётся. А вот опасение, что на тестовой маргинали он сменит знак, измерением снято: сдвиг там втрое слабее того, на котором знак менялся.

14.5. Представление и данные: два эксперимента, которых не было

Весь этот раздел, как и вывод «выбор модели стоит 0.005, а постобработка 0.051», получен внутри одного представления. Абляционная сетка — это шесть наборов из счётчиков Моргана, дескрипторов RDKit и механистического блока; ни предобученного энкодера из раздела 8, ни внешних данных в ней нет ни в одной строке. Утверждение было локальным, а прочитано как общее, и это стоило проверить.

Энкодер: сначала отрицательный, потом наоборот. Организаторы выложили шестнадцать чекпойнтов chemprgr, каждый предобучен предсказывать своё семейство дескрипторов. Взял rdkit2d: он предобучен ровно на тех дескрипторах, что лежат в нашем блоке. Эмбединг подан тому же ученику, на тех же фолдах, с той же метрикой.

Первые три строки были посчитаны сразу, четвёртая — через сутки, и без неё вывод был сформулирован неверно. Мы написали «предобученное представление

Представление	Макро ST-RAE
FP+DESC+MECH, пересчитано здесь	0.7673
Эмбединг один	0.7784
Эмбединг + механистический блок	0.7765
FP+DESC+MECH + эмбединг	0.7589

Таблица 16. Как замена представление проигрывает 0.009 — третья строка против первой, оба набора с механистическим блоком; как добавка — выигрывает 0.008. Контроль воспроизведён точно: 0.7673 против 0.7673 в сводке.

проигрывает рукодельному, значит представление не было узким местом». Первая половина верна, вторая из неё не следует, и rdkit2d — ровно тот чекпойнт, на котором эта подмена особенно соблазнительна. Он предобучен воспроизводить наши же дескрипторы, поэтому он самый честный выбор для вопроса «бьёт ли выученное представление рукодельное» и самый *невыгодный* для вопроса «добавляет ли оно хоть что-нибудь»: энкодер, обученный повторять то, что у нас уже есть, меньше всех способен что-то к этому добавить. Проигрыш замены не закрывает вопрос о дополнении — его закрывает только строка с конкатенацией, и она даёт −0.008.

Поферментно добавка помогает 1A2 (−0.022) и 2D6 (−0.039) и вредит 2C9 (+0.009) и 3A4 (+0.019) — тот же рисунок, что и у внешних данных ниже.

Внешние данные: положительный, и не там, где ожидалось. Вместе с базовой моделью организаторы выложили её обучающий набор — 8068 соединений с pIC_{50} по нашим же четырём ферментам, curated из ChEMBL. Две проверки сделаны до всего остального: пересечение с *тестом* равно нулю из 750, пересечение с обучением — 64 соединения, они отброшены.

Нулевое пересечение с тестом стоит прочитать осторожнее, чем оно выглядит. Доля пересечения с обучением — 1.3%, что на 750 тестовых соединениях предсказывало бы около десяти совпадений; вероятность ровно нуля при биномиальной модели $5 \cdot 10^{-5}$. Ноль поставлен намеренно, и объяснений два. Либо тест собирали в обход публичных данных — тогда он обеднён публичной химией и модель «тест = якоря плюс их аналоги из того же пула», на которой стоит раздел 12, слабеет. Либо внешний файл почистили против теста перед публикацией — тогда про состав теста это не говорит ничего. Первая гипотеза требует, чтобы тест лежал *дальше* от публичной химии, чем наше обучение; измерено обратное, тест ближе на +0.014 медианы, интервал [+0.010, +0.021] с ресемплингом обеих сторон. Гипотеза отвергнута. Заодно закрыта утечка по близости, а не только по совпадению: ни одно тестовое соединение не имеет во внешнем наборе аналога с Танимото выше 0.7.

Шкалы у двух наборов не совпадают. На общих соединениях внешние метки выше на +0.22 / +0.35 / +0.60 / +0.56, а по маргиналиям разрыв доходит до +1.36 на 3A4. Естественно было счесть это ошибкой калибровки и поправить вычитанием. Измерение говорит обратное.

Верхние три строки читаются так. Видимый разрыв шкал — по большей части не ошибка калибровки, а настоящее обогащение активными: в ChEMBL публикуют то, что сработало. Сдвигая внешние метки вниз, мы портим верные значения, и чем грубее оценка сдвига, тем сильнее. Поправка по маргиналиям, самая грубая, стоит +0.037 вместо выигрыша.

Нижние две показывают, что инструмент был не тот. Разрыв — это эффект *отбора*, а отбор не действует одинаково по всему химическому пространству, поэтому одно

Изменение к контролю (отрицательное лучше)	1A2	2C9	2D6	3A4	Макро
Внешние как есть	−0.026	+0.022	−0.036	−0.011	−0.013
Сдвиг по парным	−0.019	+0.028	−0.041	+0.003	−0.007
Сдвиг по маргинали	−0.009	+0.082	−0.043	+0.116	+0.037
Столбец-индикатор источника	−0.024	− 0.000	−0.042	−0.002	−0.017
Наклон к парному сдвигу	−0.029	−0.007	− 0.071	−0.017	− 0.031

Таблица 17. Вычитание константы делает хуже; поправка, допускающая неоднородность, — лучше.

число на фермент не может его выразить. Это та же ошибка, которую раздел 12 уже разбирал для теста: сдвиг — не вся форма. Столбец-индикатор источника (единица у внешних строк, ноль у наших; предсказываем при нуле) даёт модели выразить поправку самой, по областям. Наклон — экспоненциальное перевзвешивание внешних меток к парному сдвигу — не трогает ни одной метки вовсе, только гасит перепредставленных активных.

Индикатор был предрегистрирован как строгое обобщение обеих крайностей: расщепившись по нему в корне, дерево воспроизводит «без внешних», ни разу не расщепившись — «как есть». Единственный информативный исход — лечь ниже обеих, и он выпал.

Про CYP2C9 первое объяснение было неверным. Мы написали, что ему вредит поправка, потому что у него меньше всего парных соединений, шесть, и сдвиг известен хуже прочих. Но 2C9 портится и в руке «как есть», где никакой поправки не применяется по построению, и внешних меток у него 2506 — вторые по количеству. Ни тонкость оценки, ни дефицит данных не годятся. Обучение на одних внешних метках с предсказанием наших соединений отделяет их данные от нашего объединения: по рангу 2C9 оказывается вторым из четырёх, то есть его внешние метки не хуже прочих. Причина осталась не установленной; индикатор источника её чинит (+0.022 → −0.000), но какой именно механизм он при этом снимает, из четырёх точек не выводится.

14.6. Все эти числа измерены не там, где считается результат

У предыдущего подраздела есть оговорка, которая при проверке оказалась не оговоркой, а поправкой ко всему разделу. Каждое число абляционной сетки — это ST-RAE *сырых* предсказаний вне фолда. А отправляем мы не их: перед отправкой к предсказаниям каждого фолда подгоняется аффинная пара (раздел 11), и она стоит 0.051 макро. Вопрос, который следовало задать два месяца назад: что от измеренных выигрышей остаётся, если сравнивать не сырые предсказания, а те, которые уходят в файл.

Ни один не выживает. Все пять уходят под шумовой пол 0.007, а три из пяти меняют знак на вредный. Крупнейшая находка — смена квадратичной ошибки на абсолютную, −0.046 сырым, — после пары стоит 0.002.

Механизм виден, как только сказан. Аффинная пара — это усадка, подобранная *прямо под метрику*, пофолдово. Всё, что снижает разброс предсказаний или снимает систематическое смещение, она уже делает, и делает адаптивно. Отсюда и величина самой пары: на базе L2 она стоит 0.052, на предсказаниях L1 — всего 0.009, потому что L1 забрал почти всё, что там было.

Квадрат 2×2 показывает то же самое с другой стороны, и заодно отвечает на

Сид 0	Сырой	После пары	Выигрыш сырой	Выигрыш после
База (L2, FP+DESC+MECH)	0.7673	0.7150	—	—
L1 вместо L2	0.7218	0.7131	−0.046	−0.002
Столбец-индикатор источника	0.7504	0.7117	−0.017	−0.003
Наклон к парному сдвигу	0.7363	0.7156	−0.031	+0.001
Внешние строки как есть	0.7545	0.7218	−0.013	+0.007
Эмбединг конкатенацией	0.7589	0.7263	−0.008	+0.011

Таблица 18. Аффинная пара подгоняется вне фолда, отдельно для каждой руки. Ни один из пяти выигрышей её не переживает.

естественный вопрос, складываются ли поправки.

Сид 0	Сырой	После пары
L2	0.7673	0.7150
L2 + наклон к парному	0.7363	0.7156
L1	0.7218	0.7131
L1 + наклон к парному	0.7225	0.7238

Таблица 19. Наклон стоит −0.031 поверх L2 и +0.001 поверх L1. Сложение предсказывало 0.691.

Не складываются. Три вмешательства — согласованные с метрикой потери, перевзвешивание внешних меток и аффинная усадка — оказываются *взаимозаменяемыми*, а не дополняющими: любое одно доводит примерно до 0.713, а два вместе дают 0.724, то есть хуже любого поодиночке. Сырая колонка растянута на 0.046, обработанная — на 0.011.

Единственная рука проверена на четырёх сидах, и правило репозитория отвечает на вопрос само. Сырой выигрыш L1 держит знак на всех четырёх и лежит между 0.041 и 0.046 — это результат. После пары он равен 0.002, и на третьем сиде знак переворачивается — это не результат.

Два исключения, и оба нашлись потому, что таблица выше неполна. В неё не попал ствол из подраздела про совместное правдоподобие — он измерен в другом файле и записан сырым, −0.018. Прогнанный через тот же конвейер, с той же обрезкой предсказаний сети, что и в таблице 15, и с одинаковой аффинной парой на всех трёх руках:

Сид	Ствол $\lambda = 0$	Ствол $\lambda = 3$	Бустинг	Канал	Ствол минус бустинг
0	0.7397	0.7182	0.7150	−0.021	+0.003
1	0.7446	0.7142	0.7183	−0.031	−0.004
2	0.7376	0.7145	0.7164	−0.023	−0.002
3	0.7435	0.7128	0.7124	−0.031	+0.000
Среднее	0.7414	0.7149	0.7155	−0.026	−0.001

Таблица 20. Канал скрининга — единственное вмешательство в этом репозитории, которое переживает постобработку.

Канал стоит −0.026 *после* пары, знак держится на всех четырёх сидах, $t = -10.87$, $p = 0.002$. Обрезка здесь не косметика: без неё сид 0 даёт 0.9192 — это то самое соединение с предсказанием −360, и таблица 15 обрезает по той же причине.

Вторая половина, однако, не следует. Ствол с включённым каналом бустинг *не бьёт*: 0.7149 против 0.7155, знак разности скачет по сидам, $t = -0.39$, $p = 0.72$. Паритет, а не превосходство. Решение отложить ствол остаётся верным; неверным было списать канал как пустой.

Второе исключение — наш собственный механистический блок, и его сырое измерение не завышало, а *занижало*. Сырым он даёт -0.015 на CYP2D6 при $p = 0.088$, то есть неотличим от нуля; после аффинной пары -0.022 при $p = 0.0004$, а прирост ранга $+0.045$ — больше, чем у канала ствола. Это ровно то, что критерий ниже и предсказывает: у блока вклад ранговый, и сырая мера смешивает его с подгонкой масштаба, которую пара всё равно уберёт. Отсюда и знак ошибки: у рук, чей вклад — масштаб и положение, сырое завышает; у рук, чей вклад — ранг, занижает.

И одна деталь, ради которой стоило разбирать блок на части. Загадка была в том, что `frac_prot_74` — доля протонированных, на которой стоит весь разбор CYP2D6 в разделе 4.3, — не участвует на этом ферменте ни в одном расщеплении. Блок разбит на три группы: 16 счётчиков азотистой и кислотной функциональности, 8 признаков состояния протонирования при 7.4 и 6 топологических — расстояние от основного азота до ароматики плюс явные флаги фармакофора 2D6.

Прирост ранга к «без блока», 4 сида	CYP2D6	p	CYP2C9	p
Весь блок (30)	+0.0454	0.002	+0.0148	0.017
Только состояние протонирования (8)	+0.0454	0.008	+0.0097	0.001
Только счётчики групп (16)	+0.0437	0.013	+0.0111	0.004
Только геометрия и фармакофор (6)	+0.0580	0.001	+0.0030	0.545

Таблица 21. На CYP2D6 работает геометрия, на CYP2C9 — состав. Разделение предсказано механизмом и записано до прогона.

На CYP2D6 шесть геометрических признаков несут эффект целиком и несут его лучше всех тридцати: $+0.0127$ ранга сверх целого блока, $p = 0.009$; остальные двадцать четыре разбавляют. На CYP2C9 те же шесть не дают *ничего* ($p = 0.55$), а вклад приходит от счётчиков и состояния.

Это ровно то разделение, которого требует механизм. Солевой мостик 2D6 к Asp301 и Glu216 — ограничение *геометрическое*: протонированный азот на определённом расстоянии от ароматического кольца. Arg108 у CYP2C9 связывает анионы, и это вопрос того, *что* в молекуле есть, а не где оно расположено.

Заодно снимается и загадка. `frac_prot_74` не расщепляется не потому, что протонирование неважно, — группа состояния сама по себе даёт те же $+0.0454$, — а потому, что геометрические признаки несут ту же химию резче, и дерево выбирает их. Оговорка: превосходство геометрии над целым блоком твёрдо в ранге и остаётся тенденцией в метрике после аффинной пары (-0.0038 , $p = 0.090$). Это два разных утверждения, и установлено первое.

Почему одни вмешательства постобработка съедает, а другие нет. Ответ в одну строку, и он же превращает весь этот подраздел из наблюдения в критерий. Аффинная пара монотонна; изотоника, которой мы калибровали ствол, тоже. Монотонное отображение двигает масштаб и положение и *не может изменить порядок*. Значит вмешательство переживает постобработку тогда и только тогда, когда добавляет *ранговой* информации — а это измеряется прямо, а не выводится.

Это закрывает три вопроса сразу. Смена потерь схлопывается, потому что ранга не добавляет — причём не оттого, что L1 «просто иначе усадил»: ранговая связь между

Прирост ранговой связи с истиной, 4 сйда	$\Delta\rho$	t	p	Знаки
Канал в стволе ($\lambda = 3$ против $\lambda = 0$)	+ 0.0350	13.83	0.001	++ ++
L1 вместо L2	+0.0016	0.97	0.405	++ ++
Ствол $\lambda = 3$ против бустинга	+0.0016	0.53	0.632	++ ++

Таблица 22. Сам ранг: ствол $\lambda = 0 - 0.5297$, ствол $\lambda = 3 - 0.5646$, бустинг $- 0.5630$, L1 $- 0.5646$.

предсказаниями L1 и L2 равна 0.82–0.96, то есть порядок переставлен изрядно, и ни одна из перестановок не оказалась информацией. Канал выживает, потому что даёт 0.035 ранга. А паритет ствола с бустингом объясняется тем же: канал поднимает ствол ровно до ранга, который у бустинга уже есть, 0.5646 против 0.5630, и не дальше.

Отсюда правило для всякой будущей абляции, и оно бесплатно: **печатать прирост ранговой связи рядом с сырой метрикой**. Сырая колонка отвечает на вопрос «сдвинуло ли вмешательство предсказания», а это не тот вопрос; ранговая — на вопрос «сдвинуло ли туда, куда постобработка не дотягивается». Оценка после изотоники — тот же критерий в единицах самой метрики и консервативная граница: изотоника охватывает более широкий класс монотонных отображений, чем аффинная пара, поэтому что переживёт её, переживёт и пару.

Что здесь на самом деле сломалось. Не пять экспериментов, а конвенция измерения. Причём документ содержал обе сразу и этого не заметил: таблица 15 сравнивает бустинг с сетью *после* аффинной пары и потому честно показывает разницу в четвёртом знаке, а вся абляционная сетка и оба эксперимента предыдущего подраздела — до неё. Числа «выбор модели стоит 0.005» и «внешние данные стоят 0.013» несравнимы между собой: первое измерено после постобработки, второе до. Сравнить их, как это делает подзаголовок предыдущего подраздела, было ошибкой, и она наша.

Отсюда тезис раздела формулируется сильнее, чем раньше, и точнее, чем в первой редакции этого подраздела. Было: постобработка стоит вдесятеро больше выбора модели. Написали сначала: постобработка *замещает* прочие улучшения. Верное: **согласованная с метрикой монотонная постобработка ставит потолок всему, что не двигает ранг** — и это не про то, что улучшать больше нечего, а про то, где искать. Из шести измеренных вмешательств потолка избежало два, ровно те, у которых прирост ранга отличен от нуля: канал скрининга в стволе и механистический блок. Второе особенно поучительно, потому что оно наше собственное и лежало в списке отрицательных результатов два месяца.

Три оговорки, и ни одна не спасает руки. Аффинная пара здесь подогнана при $\delta = 0$; под апостериорным распределением δ разворот тот же — L1 со своим δ даёт 0.7764 против 0.7647 у базы. Избыточность на *нашей* маргинали не доказывает избыточности на сдвинутой тестовой — но проверить это без тестовых меток нельзя, а принять в свою пользу означало бы сделать ровно то, против чего написан весь этот раздел. И наконец: работа со сдвигом δ постобработкой тоже не поглощается, но по третьей причине — не потому, что двигает ранг, а потому, что двигает *цель*. Пересчёт правила на L1-предсказаниях смещает только 2С9, с +0.3 до +0.4, а выигрыш поферментной подгонки остаётся тем же, 0.047 против 0.049. Монотонная пара подгоняется под нашу маргиналь; сдвиг меняет, под какую маргиналь её подгонять, и потому лежит вне того класса, для которого доказан потолок.

Практическое следствие: submit.ru по итогам всей этой работы не меняется ни в одной строке.

15. Что сломается и по какому признаку это видно

Режим отказа	Признак	Реакция
Совместное правдоподобие не обыгрывает многозадачную базовую линию	строка 5 абляции внутри интервала парного бутстрапа на нескольких сидах	зафиксировать как отрицательный результат, отправлять многозадачную модель; решающий и трансдуктивный слои от неё не зависят
Голова E как свалка для остатка	разброс выхода E на соединениях только со скринингом заметно выше, чем на соединениях с кривой	заменить на константу на фермент, зафиксировать $h_e = 1$
Калибровка зависит от соединения, а не только от фермента	остатки (8) систематически изогнуты по π на подмножестве с полными кривыми	монотонная сплайн-поправка поверх хилловской формы либо смесь двух режимов
Серийный приор переобучается на якоря	на псевдотестовой <i>страте</i> (328 соединений, из них 267 с меткой 3A4; раздел 13) модель с (24) хуже, чем без. На остальных трёх ферментах страта слишком мала, и триггер там не срабатывает вовсе	увеличить τ или снять слой
Конформные интервалы калиброваны маргинально, но не условно	покрытие по зонам активности расходится с номинальным	мондриановский конформал с зонами как таксономией
Расхождение локальной оценки с промежуточной таблицей	макро отличается больше чем на 0.03 — столько даёт переход к тестовой геометрии на нашей же выборке (0.767 против 0.739 на верхней четверти по сходству)	чинить разделы 13 и трансдуктивный слой, а не архитектуру

Таблица 23. Каждому риску — наблюдаемый признак и заранее решённая реакция.

Планшетный дрейф был в этом списке и снят измерением (раздел 5.2).

16. Что не проверено

Список на момент выпуска документа.

Совместная модель запущена в минимальной форме, полная — нет. Строка 5 абляции больше не пуста: общий ствол с двумя головами и переключателем при слагаемом скрининга измерен на четырёх сидах, результат в разделе 14. Коротко: канал несёт извлекаемую информацию, но получить её в единицах метрики удаётся только вместе с перекалибровкой после модели, а поферментно эффект меняет знак и на 2D6 отрицателен.

Незакрытым остаётся следующее. Измерены две свободные головы над общим стволом, то есть многозадачность; конструкция раздела 5, где скрининг ограничивает π через фиксированную калибровку, — отдельный объект, и он тоже измерен:

результат в разделе 14, и он хуже, а не лучше.

Механизм порчи одноголовой руки не установлен, и объясняющая переменная не идентифицирована. Шумовая лестница запущена и описана в разделе 14. Она дала внутриферментную причинность, которой не было, и сняла информационное объяснение: при почти мёртвом канале потеря не падает, а растёт. Но чем именно упорядочены ферменты, она различить не может и не могла: связь скрининга с активностью, ширина доверительной полосы и усиление калибровочной кривой упорядочивают четыре фермента одинаково, с попарным Спирменом ± 1 . Ширину полосы удалось вычеркнуть пересчётом метрики по тем же предсказаниям с выровненной и с нулевой полосой; две оставшиеся неразличимы, и шумом их не разделить — шум двигает информативность и не двигает ни полосу, ни карту прибора.

Разделяющее вмешательство запущено: калибровочные константы (E, h) обменны между CYP2D6 и CYP3A4, всё остальное оставлено прежним. Карта прибора порядок не задаёт — обменные ферменты сдвинулись меньше, чем необменные контрольные. Остаётся информативность скрининга либо что-то ещё в данных самого фермента; эксперимент показал, где механизма нет, и не показал, где он есть. Что могло бы показать, мы пока не придумали.

Сравнение нейросетевой модели с бустингом пересчитано на четырёх сидах и больше не опирается на один испорченный прогон (раздел 14). Итог: в правдоподобном диапазоне сдвига разница между моделями не превышает 0.005 и ниже $\delta = 0.3$ вообще не измерена, тогда как постобработка стоит 0.051. Выбор архитектуры здесь почти ничего не решает.

Само это сравнение оказалось единственным в разделе, сделанным правильно. Оно считано после аффинной пары, а абляция сетка — до неё, и подраздел 14.6 показал, чего это стоило: из выигрышей, измеренных сырыми предсказаниями, после пары выживают два — канал скрининга в стволе и механистический блок, ровно те, у которых прирост ранговой связи с истиной отличен от нуля. Причём блок сырое измерение не завышало, а занижало, и он два месяца числился отрицательным результатом. Проверять новые руки теперь надо в той же точке, где считается результат, и печатать рядом прирост ранга: он и говорит заранее, переживёт ли рука постобработку.

Предобученный энкодер запущен, и в двух видах: как замена нашему представлению и как добавка к нему (раздел 14). Не запускались коррегионализация и совместное правдоподобие поверх неё, то есть строка 2 и полная версия 5. Это по-прежнему объясняет, почему конструкция должна работать, а не показывает, что она работает в полном виде.

Вероятностное правило TDI — интегрирование (23) по совместному предсказательному распределению — не запускалось; все измеренные варианты детерминированные.

Оценщик rK_a проверен на двадцати соединениях, выбранных вручную. Средняя ошибка 0.60 при медианной 0.2, то есть среднее делают четыре промаха, худший — кофеин, 4.5 единицы: правило относит его азот к имидазолам с базовым 7.0 и недоштрафовывает соседние карбонилы. На бинарный вопрос про заряд при 7.4 это не влияет, но мотив «ароматический азот через атом от карбонила» встречается у трёх процентов обучающей выборки — зона, где правило может систематически завышать.

Проверка, которая это меряет, до сих пор не запускалась: у неё было сломано две подстановки путей и не хватало каталога в `sys.path`, а внутри она читала не то поле возврата — индекс атома вместо имени класса, из-за чего два её числа печатались нулями. После починки картина шире заявленной. Самый основной центр относится

к имидазолу или пиридину у 55.8 процента обучающей выборки, то есть больше чем у половины молекул ответ правила опирается на ароматический азот. Пересечение с карбонилом по соседству — ровно конфигурация кофеина — даёт 109 молекул, 2.2 процента. Три процента из предыдущего абзаца остаются верными, но относятся к мотиву, а не к тем молекулам, у которых на этом мотиве стоит итоговый ответ.

Учит ли графовая сеть протонирование сама — не проверялось. Если учит, часть выводов про механистический блок придётся переписать.

Зависимость калибровки от соединения в этих данных непроверяема: у каждого соединения одно показание скрининга, разделить «соединение отклоняется от калибровки» и «прибор шумит» на одном измерении нельзя.

Контроль в проверке ограничения диапазона выравнивает количество примеров, но не форму распределения меток.

17. Сводка чисел

	1A2	2C9	2D6	3A4	Макро
Меток pIC_{50}	1412	1285	1493	2335	6525
Межквартильный размах меток	1.00	0.92	0.83	1.50	—
Надёжность меток (потолок R^2)	0.948	0.905	0.934	0.898	—
ST-RAE, фингерпринт и дескрипторы	0.880	0.702	0.993	0.518	0.773
ST-RAE, плюс механистический блок	0.879	0.691	0.980	0.519	0.767
Спирмен, фингерпринт и дескрипторы	0.497	0.583	0.351	0.764	0.549
Спирмен, плюс механистический блок	0.496	0.597	0.403	0.765	0.565
Калибровка: E	0.728	0.621	0.867	0.931	—
Калибровка: h	1.261	1.112	1.243	1.968	—
Ранговая связь скрининга с pIC_{50}	−0.86	−0.90	−0.83	−0.94	—
Ско ST-RAE по четырём сидам, без блока	0.0136	0.0098	0.0132	0.0063	0.0066
Ско ST-RAE по четырём сидам, с блоком	0.0109	0.0078	0.0052	0.0057	0.0019

Таблица 24. Кросс-валидированы шесть строк из двенадцати. Четыре строки ST-RAE и Спирмена — пятикратная кросс-валидация по кластерам Бутины при пороге 0.35, макро на сиде 0; две строки со стандартным отклонением — по четырём сидам того же разбиения. Остальные шесть кросс-валидацией не являются и сравнивать их с первыми по строгости нельзя: число меток и межквартильный размах — статистики колонки, надёжность — разложение дисперсии по заявленной погрешности измерения, а калибровка E , h и ранговая связь скрининга — подгонки на всей выборке сразу, без отложенной части.

Правило решения для TDI	MCC 3A4	MCC 2D6
Всегда «нет»	0.000	0.000
Классификатор, порог 0.5	0.302	0.103
Классификатор, порог подобран	0.356	0.127
Две независимые регрессии плеч, затем правило	0.255	0.094
Отдельная голова на сдвиг, затем правило	0.323	0.104
То же с подобранным порогом сдвига	0.324	0.149
Подстановочный порог по сырым вероятностям	0.325	0.115
Подстановочный порог после калибровки Платта	0.352	0.092

Таблица 25. Все числа получены на 2346 соединениях для 3A4 и 1495 для 2D6 — тех, у кого есть и признаки, и метка. Доля положительных в этих выборках 32.6 и 21.7 процента; по файлу TDI целиком — 21.3 и 21.6, и разница целиком объясняется тем, что 1238 соединений без кривой доза-эффект автоматически размечены как отрицательные.